Einführung in die Numerische Mathematik[1]

Modul 61521 der FernUniversität in Hagen

Wintersemester 2026/27

Prof. Dr. Torsten Linß

[1]© 2016–2026, T. Linß, Lehrgebiet Numerische Mathematik, FernUniversität in Hagen

Inhaltsverzeichnis

1 Fehleranalyse und Computerzahlen **1**
- 1.1 Absoluter und relativer Fehler . . . 4
- 1.2 Maschinenarithmetik . . . 6
  - 1.2.1 Gleitkommazahlen . . . 6
  - 1.2.2 Rundung . . . 7
  - 1.2.3 Grundoperationen und elementare Funktionen . . . 10
- 1.3 Rundungsfehlereinfluss und Fehlerfortpflanzung . . . 12
  - 1.3.1 Numerische Differentiation . . . 12
  - 1.3.2 Kondition von Aufgaben . . . 16
  - 1.3.3 Kondition von Algorithmen . . . 20
- 1.4 Lösungen der Aufgaben . . . 25

2 Nichtlineare Gleichungen **29**
- 2.1 Intermezzo: Etwas Analysis . . . 31
  - 2.1.1 Normierte und vollständige Vektorräume . . . 31
  - 2.1.2 Matrizen und Matrixnormen . . . 33
  - 2.1.3 Das Störungslemma . . . 35
  - 2.1.4 Integrale vektorwertiger Funktionen . . . 37
  - 2.1.5 Fehler vektorwertiger Größen . . . 40
- 2.2 Banachscher Fixpunktsatz und Fixpunktiteration . . . 41
  - 2.2.1 Praktische Umsetzung der Fixpunktiteration . . . 44
  - 2.2.2 Die Fixpunktiteration für differenzierbare Funktionen . . . 45
- 2.3 Das Newton-Verfahren . . . 47
  - 2.3.1 Grundidee des Verfahrens . . . 47
  - 2.3.2 Illustrierende Beispiele und geometrische Interpretation . . . 48
  - 2.3.3 Konvergenz des Newton-Verfahrens . . . 51
  - 2.3.4 Gedämpfte Newton-Verfahren . . . 53
  - 2.3.5 Praktische Aspekte des Newton-Verfahrens . . . 55
- 2.4 Lösungen der Aufgaben . . . 57
- 2.5 Programmlistings . . . 61

3 Polynome **63**
- 3.1 Intermezzo: Euklidische Vektorräume . . . 64
- 3.2 Vektorraum und Ring der Polynome . . . 67
  - 3.2.1 Der Ring der Polynome . . . 68
  - 3.2.2 Der Vektorraum der Polynome . . . 69

3.2.3 Das Horner-Verfahren . . . 69
3.3 Tschebyscheff-Polynome . . . 73
3.4 Orthogonale Polynome . . . 76
3.4.1 Der Orthogonalitätsbegriff für Polynome . . . 76
3.5 Dreigliedrige Rekursionen für orthogonale Polynome . . . 80
3.6 Der Clenshaw-Algorithmus zur Polynomauswertung . . . 86
3.7 Nullstellen orthogonaler Polynome . . . 88
3.8 Lösungen der Aufgaben . . . 91

4 Polynominterpolation **97**
4.1 Lineare Interpolation . . . 98
4.2 Die Lagrangesche Form des Interpolationspolynoms . . . 101
4.3 Die Newtonsche Form des Interpolationspolynoms . . . 104
4.4 Auswertung des Interpolationspolynoms . . . 109
4.4.1 Das Verfahren von Aitken und Neville . . . 109
4.4.2 Das modifizierte Horner-Schema . . . 111
4.5 Der Interpolationsfehler . . . 113
4.6 Hermite-Interpolation . . . 116
4.7 Rundungsfehlereinfluss . . . 119
4.8 Das Runge-Phänomen . . . 121
4.9 Optimierung der Stützstellen . . . 123
4.10 Lösungen der Aufgaben . . . 127

5 Quadratur **129**
5.1 Riemann-Summen . . . 130
5.2 Elementare Quadraturformeln . . . 133
5.2.1 Konstruktion mittels Interpolation . . . 133
5.2.2 Der Quadraturfehler . . . 136
5.3 Summierte Quadraturformeln . . . 139
5.3.1 Konstruktion . . . 139
5.3.2 Numerische Illustration . . . 141
5.3.3 Der Quadraturfehler . . . 142
5.4 Ordnung und Exaktheit von Quadraturformeln . . . 144
5.5 Gauss-Legendre-Formeln . . . 146
5.5.1 Maximaler Exaktheitsgrad und optimale Wahl der Stützstellen . . . 147
5.5.2 Gewichte der Gauss-Legendre-Formeln . . . 148
5.5.3 Fehler der Gauss-Legendre-Formeln . . . 150
5.6 Extrapolation und Romberg-Verfahren . . . 152
5.6.1 Richardson-Extrapolation . . . 152
5.6.2 Das Romberg-Verfahren . . . 159
5.7 Lösungen der Aufgaben . . . 161

6 Spline-Interpolation **163**
6.1 Polynomiale Splines . . . 164
6.2 Lineare C^0-Splines . . . 165
6.3 Kubische C^2-Splines . . . 167

6.3.1 Konstruktion und Berechnung 168
6.3.2 Lösung tridiagonaler Gleichungssysteme 171
6.3.3 Interpolationsfehler 172
6.3.4 Minimaleigenschaft von $\mathcal{S}_3^2$-Splines 175
6.4 Lösungen der Aufgaben 177

Kapitel 1

Fehleranalyse und Computerzahlen

Sich zu Beginn eines Mathematikkurses lang und breit über Fehler auszulassen, mag etwas absurd erscheinen, wo doch gerade in der Mathematik auf logische Strenge und Exaktheit größter Wert gelegt wird. Es geht vielmehr darum, im Grunde außermathematische Einflüsse in ihrer Wirkung auf Resultate mathematischer Rechnungen zu analysieren und zu bewerten. Um ein konkretes Problem aus der Praxis zu lösen, beschreibt man es mit dem Formalismus der Mathematik, formt es so um, dass es algorithmisch zugänglich ist und bestimmt schließlich eine genäherte Lösung mit Hilfe verfügbarer Rechentechnik. In allen drei Stufen können Fehler auftreten, die einzugrenzen sind, um entscheiden zu können, ob das erhaltene Resultat einen akzeptablen Ersatz für das eigentlich gesuchte Ergebnis darstellt. Eine kleine Geschichte, die von Prof. Franz Locher überliefert wurde, mag die Problematik erläutern.

Der berühmte Gallier Obelix wollte in der Nähe seines Dorfes eine Hinkelstein-Allee errichten. Die Steinreihe sollte 60 Steine umfassen und genau geradlinig verlaufen. Je zwei Steine sollten einen Abstand von 30 Obelix-Längen haben. Obelix hatte sich einen Stock geschnitten, der genau so lang war wie er selbst und den er als Maßstab benutzte. Zum Peilen, ob die Steine in einer Geraden stehen, verließ er sich auf sein scharfes Auge.

Alles war gut gegangen, aber beim 57. Stein gab es Probleme. Denn gleich nach dem 56. Stein war das Ufer eines kleinen, ungefähr 15 Obelix-Längen breiten Teiches. Wo genau sollte der 57. Stein aufgestellt werden?

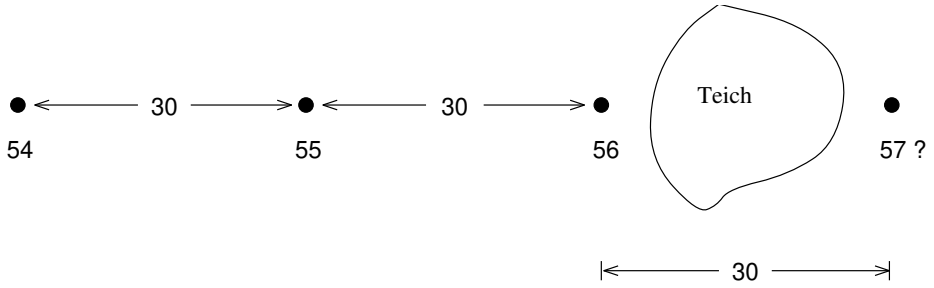


Abbildung 1.1: Lage des 57. Steines

Obelix überlegte hin und her. Auch ein leckerer Wildschweinbraten half ihm nicht auf die richtige Spur. Schließlich holte er sich Rat bei dem Druiden Numerix aus dem Nachbardorf Agen, einem



Abbildung 1.2: Obelix und Numerix

etwas introvertierten Vetter seines Freundes Asterix, der bei so kniffligen Problemen oft ganz gute Ideen hatte.

Kein Problem für Numerix! Er malte eine Skizze in den Sand und erklärte Obelix, dass er zwei Hilfshinkelsteine *A* und *B* genau mit den angegebenen Abständen platzieren solle. Dann könne er von *A* und *B* aus auch den 57. Stein genau positionieren. Wichtig seien die Abstände von 30 und 42 Obelix-Längen, was immer die Zahl 42 bedeuten mochte.

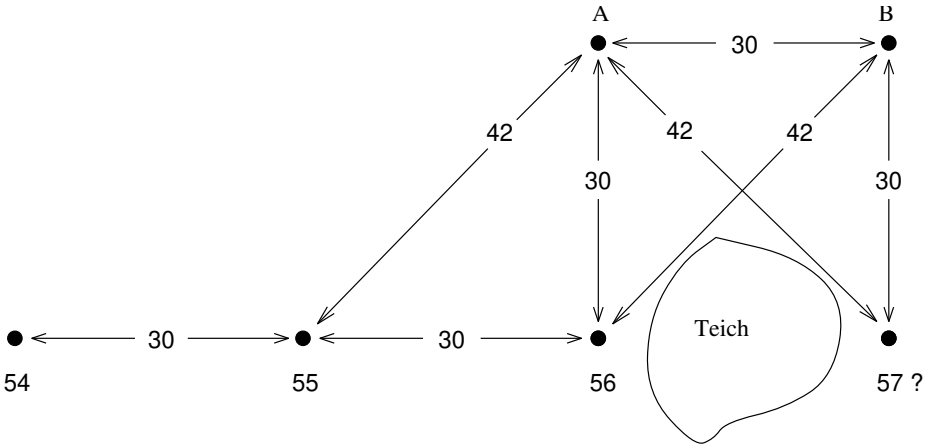


Abbildung 1.3: Konstruktion mit Hilfe von Hilfshinkelsteinen

Obelix ging ans Werk und plagte sich einen ganzen Tag (Numerix hatte vergessen, ihm zu raten, ein langes Seil zu verwenden!), bis er schließlich den 57. Stein aufgestellt hatte, der aber leider nicht in einer Fluchtlinie mit den anderen stand. Am nächsten Morgen zog er nochmals Numerix zu Rate. Der meinte zwar, ein bisschen mogeln müsse man am Schluss vielleicht schon, aber nicht so viel, wie es hier anscheinend nötig sei. Irgend etwas war faul im Staate Gallien. Numerix maß alles nach und stellte dann auch fest, daß der Abstand von *A* nach *B* nur 28 Obelixlängen betrug. (Obelix waren beim Abstecken zwei Wildschweine über den Weg gelaufen; er hatte seine Arbeit kurz unterbrochen und in der Aufregung die Wildschweine mitgezählt.) Als Numerix dies berichtigt hatte, stand auch der 57. Stein ganz ordentlich in der Reihe. Obelix freute sich; aber Numerix dachte, man hätte halt doch 42 und eine halbe Länge statt nur 42 nehmen sollen!

Ihnen ist sicher schnell klar, warum auch beim zweiten Mal der 57. Stein nicht genau in der Fluchtlinie stand – offensichtlich eine Folge von Fehlern und von Fehlerakkumulation. Bei den Fehlern, mit denen Obelix zu kämpfen hatte, können wir verschiedene Typen unterscheiden:

- menschlicher Irrtum,
- Modellfehler (der geometrischen Konstruktion liegt der Satz von Pythagoras[1] zu Grunde, der natürlich nur in vollkommen ebenem Gelände anwendbar ist),
- Messfehler (z. B. bei der Peilung auf Geradlinigkeit),
- Rundungsfehler (1.4 statt $\sqrt{2}$).

[1] Pythagoras von Samos, *≈569 v. Chr., †≈ 475 v. Chr.

1.1 Absoluter und relativer Fehler

Diese beiden Begriffe sind wesentlich in der Fehlerrechnung und Ihnen ihrem Wesen nach bereits bekannt. Trotzdem möchten wir sie hier nochmals formal definieren.

Definition 1.1.1

Seien $\alpha, \tilde{\alpha} \in \mathbb{C}$, wobei wir $\tilde{\alpha}$ als Näherung der Größe α interpretieren. Wir nennen

$$\Delta_\alpha := \tilde{\alpha} - \alpha$$

den **absoluten Fehler** von α und

$$\varepsilon_\alpha := \frac{\Delta_\alpha}{\alpha} = \frac{\tilde{\alpha} - \alpha}{\alpha}, \quad \alpha \neq 0,$$

den **relativen Fehler** von α.

Bemerkung 1.1.2. Beachten Sie, dass die Fehler vorzeichenbehaftet sind. Oft wird man sich lediglich für eine Abschätzung des Betrags der Fehler interessieren.

Bemerkung 1.1.3. Absolute Fehler sind von geringer Aussagekraft. Wird, z. B., für einen Marathonlauf die Strecke um 1mm falsch vermessen, hat dies keinen Einfluss auf den Rennausgang. Bei einer 4mm-Schraube sieht dies anders aus. Abweichungen von 1mm machen sie unbrauchbar. Von größerer Bedeutung sind daher relative Fehler, da sie die Abweichung in Relation zur Größe setzen.

Bei Rechnung mit fehlerbehafteten Größen ist ein Ergebnis zu erwarten, das ebenfalls mit einem Fehler behaftet ist. Wir wollen uns dies an einem einfachen Beispiel veranschaulichen, der Berechnung des Volumens einer Pyramide mit Grundfläche $F > 0$ und Höhe $h > 0$.

Da sowohl F als auch h fehlerbehaftet sein können, ist auch für das Volumen

$$V = \frac{1}{3} F \cdot h$$

ein Fehler zu erwarten. Seien also $\tilde{F} = F + \Delta_F$ und $\tilde{h} = \Delta_h + h$ die fehlerbehaftete Grundfläche bzw. Höhe. Das mit diesen Näherungen ermittelte Volumen der Pyramide sei

$$\tilde{V} = \frac{1}{3} \tilde{F} \cdot \tilde{h}.$$

Für den absoluten Fehler des Volumens gilt (Übungsaufgabe!)

$$\Delta_V = \tilde{V} - V = \frac{1}{3}\Big(F\Delta_h + h\Delta_F + \Delta_F\Delta_h\Big). \tag{1.1}$$

Sind die Fehler Δ_F und Δ_h klein, dann ist ihr Produkt $\Delta_F\Delta_h$ sehr klein und kann vernachlässigt werden:

$$\Delta_V \doteq \frac{1}{3}\Big(F\Delta_h + h\Delta_F\Big). \tag{1.2}$$

Im Rahmen der Fehlerrechnung sprechen wir von **Gleichheit in linearer Näherung** (oder **erster Näherung**), wenn Produkte und höhere Potenzen (größer als 1) der Fehler vernachlässigt werden. Statt des Gleichheitszeichens verwenden wir dann das Symbol „$\doteq$“.

Zur Bestimmung des relativen Fehlers des Volumens dividieren wir (1.2) durch $V = \frac{1}{3}F \cdot h > 0$ und erhalten für den relativen Fehler des Volumens in linearer Näherung

$$\varepsilon_V = \frac{\Delta_V}{V} \doteq \frac{\frac{1}{3}(F\Delta_h + h\Delta_F)}{\frac{1}{3}F \cdot h} = \frac{\Delta_h}{h} + \frac{\Delta_F}{F} = \varepsilon_h + \varepsilon_F.$$

Wir stellen fest, dass sich bei der Berechnung des Volumens der Pyramide die relativen Fehler (in linearer Näherung) addieren.

Aufgabe 1.1.4. Verifizieren Sie (1.1). ◊

1.2 Maschinenarithmetik

Die Beschränktheit der Ressourcen eines Computers, insbesondere des Speicherplatzes, bedingt, dass nicht alle reellen Zahlen auf einem Computer zur Verfügung stehen, sondern lediglich eine endliche Teilmenge. Dieser Abschnitt führt ein in das Rechnen mit Computerzahlen.

1.2.1 Gleitkommazahlen

Für technisch-wissenschaftliche Anwendungen – so auch in der numerischen Mathematik – haben sich **Gleitkommazahlen** (engl.: floating-point numbers) durchgesetzt. Sie werden durch

- *Vorzeichen*, *Mantisse*, *Basis* und *Exponent*

beschrieben. Zum Beispiel entspricht dem Dezimalbruch -5432.1 die Gleitkomma-Darstellung

$$\begin{array}{ccccccc} - & & 0.54321 & \times & 10^4 & & \\ \uparrow & & \uparrow & & \uparrow & \nwarrow & \text{Exponent} \\ \text{Vorzeichen} & & \text{Mantisse} & & \text{Basis} & & e = 4 \\ \sigma = -1 & & & & b = 10 & & \end{array}$$

Die Eingabe und Ausgabe von Zahlen erfolgt in der Regel im Dezimalsystem, da es uns am geläufigsten ist. Zur eigentlichen Rechnung müssen diese Zahlen jedoch in das interne Zahlensystem des Computers umgewandelt werden, das i. Allg. auf dem Dualsystem basiert.

Im Dualsystem mit Basis $b = 2$ wird dabei jede Zahl $x \in \mathbb{R}$ nach Zweierpotenzen entwickelt:

$$x = \pm\left(\alpha_k 2^k + \alpha_{k-1} 2^{k-1} + \cdots\right), \quad \alpha_k \neq 0, \quad \alpha_j \in \{0, 1\}, \quad j = k, k-1, \ldots$$

Dem entspricht die Darstellung als Dualbruch

$$\begin{array}{c} x = \pm[\alpha_k \alpha_{k-1} \alpha_{k-2} \cdots \alpha_0 \ . \ \alpha_{-1} \alpha_{-2} \cdots]_2, \\ \qquad\qquad\qquad\qquad\quad \uparrow \\ \qquad\qquad\qquad\qquad \text{Komma, Dualpunkt} \end{array}$$

wobei ein tiefgestelltes b in der Darstellung $[\ldots]_b$ die zugrundeliegende Basis angibt.

Definition 1.2.1: Gleitkommazahlen

Seien $b \in \mathbb{N} \setminus \{1\}$, $m \in \mathbb{N}$, $e_*, e^* \in \mathbb{Z}$, $e_* < e^*$. Die Elemente der Menge

$$\mathbb{M}_b(m, [e_*, e^*]) := \{0\} \cup \left\{ x \in \mathbb{R} : x = \sigma b^e \sum_{i=1}^{m} z_i b^{-i}, \quad \sigma \in \{-1, 1\}, \right.$$
$$\left. z_i \in \{0, 1, \ldots, b-1\}, \quad z_1 \neq 0, \quad e \in \mathbb{Z}, \quad e_* \leq e \leq e^* \right\}$$

heißen die **(normalisierten) Gleitkommazahlen** mit **Mantissenlänge** $m \in \mathbb{N}$, **Basis** $b \in \mathbb{N} \setminus \{1\}$ und **Exponentenbereich** $[e_*, e^*]$. In dieser Darstellung wird das **Vorzeichen** der Gleitkommazahl durch σ repräsentiert, die z_i sind die **Ziffern** und e der **Exponent**.

Die endliche Menge $\mathbb{M}_b(m,[e_*,e^*])$ normalisierter Gleitkommazahlen ist durch die Parameter b, m sowie das Intervall $[e_*,e^*]$ festgelegt. Man kann sich überlegen, dass $\mathbb{M}_b(m,[e_*,e^*])$ exakt

$$2(b-1)b^{m-1}(e^*-e_*+1)+1$$

Zahlen umfasst, die auf der reellen Zahlenachse aber nicht gleichmäßig verteilt sind, was Abbildung 1.4 an einem einfachen Beispiel verdeutlicht.

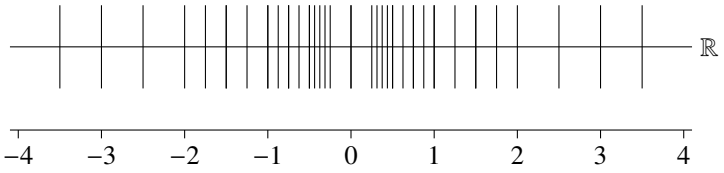


Abbildung 1.4: Normalisierte Gleitkommazahlen; vertikale Linien repräsentieren die Elemente von $\mathbb{M}_2(3,[-1,2])$.

Die kleinste positive Zahl in $\mathbb{M}_b(m,[e_*,e^*])$ ist

$$z_{\min} := \min\Big\{y : y\in\mathbb{M}_b(m,[e_*,e^*]),\ \ y>0\Big\} = [0.10\cdots0]_b\cdot b^{e_*} = b^{e_*-1},$$

die größte ist

$$z_{\max} := \max\Big\{y : y\in\mathbb{M}_b(m,[e_*,e^*])\Big\} = [0.\underbrace{(b-1)(b-1)\cdots(b-1)}_{m-\text{mal Ziffer } b-1}]_b\cdot b^{e^*} \approx b^{e^*}.$$

Bei Betrachtung von Abbildung 1.4 fallen die Lücken zwischen Null und $\pm z_{\min}$ auf – die sog. „Lücken um die Null“. Diese können durch Übergang zu den **denormalisierten Gleitkommazahlen** $\mathring{\mathbb{M}}_b(m,[e_*,e^*])$ aufgefüllt werden, bei denen als erste Ziffer der Mantisse auch die Null zugelassen wird, siehe Abbildung 1.5.

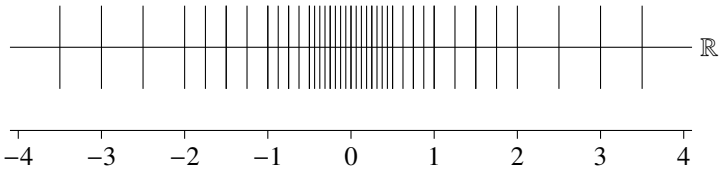


Abbildung 1.5: Denormalisierte Gleitkommazahlen $\mathring{\mathbb{M}}_2(3,[-1,2])$.

Aufgabe 1.2.2. Bestimmen Sie alle Elemente von $\mathbb{M}_2\,(3,[-1,2])$! ◊

1.2.2 Rundung

Eine gegebene reelle Zahl z lässt sich i. Allg. nicht durch eine Gleitkommazahl darstellen. Zahlen, die betragsmäßig größer als $z_{\max}$ sind, lassen sich nicht sinnvoll durch eine Gleitkommazahl repräsentieren und werden computerintern als „NaN“ (engl.: not-a-number) gekennzeichnet. Man spricht auch davon, dass ein **Gleitkommaüberlauf** (engl.: overflow) stattgefunden hat.

Ist $|z| \leq z_{\max}$, so muss $z \in \mathbb{R} \setminus \mathring{\mathbb{M}}_b(m, [e_*, e^*])$ auf eine Maschinenzahl **gerundet** werden. Formal wird z durch eine nächstgelegene Gleitkommazahl $\mathrm{rd}(z)$ approximiert. Die Abbildung

$$\mathrm{rd}\colon [-z_{\max}, z_{\max}] \to \mathring{\mathbb{M}}_b(m, [e_*, e^*])\colon z \mapsto \mathrm{rd}(z)$$

mit

$$|\mathrm{rd}(z) - z| = \min_{y \in \mathring{\mathbb{M}}_b(m,[e_*,e^*])} |y - z|\,. \tag{1.3}$$

wird als **Rundung** bezeichnet. In der Regel ist $\mathrm{rd}(z)$ eindeutig bestimmt. Liegt allerdings z exakt in der Mitte zweier benachbarter Gleitkommazahlen, dann gibt es zwei potentielle Kandidaten für $\mathrm{rd}(z)$. Für diesen Fall sind in den entsprechenden Standards Festlegungen getroffen, die Eindeutigkeit schaffen. Ist $\mathrm{rd}(z) = 0$ für ein $z \neq 0$, so spricht man von **Gleitkommaunterlauf**.

Realisiert wird die Rundung auf zwei Wegen:

- prozessorintern, falls z das Ergebnis einer Rechenoperation mit Maschinenzahlen ist,
- durch Programmbibliotheken, falls z eine Programmeingabe ist, z. B. durch Eingabe als Zeichenkette.

Für ein gegebenes $z \in \mathbb{R}$ ist eine obere Schranke für den Betrag des **absoluten Rundungsfehlers** durch (1.3) gegeben:

$$|\mathrm{rd}(z) - z| = \min_{y \in \mathring{\mathbb{M}}_b(m,[e_*,e^*])} |y - z|\,.$$

Wie eingangs diskutiert (Bem. 1.1.3) sind absolute Fehler von geringer Aussagekraft. Von größerer Bedeutung sind relative Fehler. Für eine reelle Zahl $z \neq 0$ ist der Betrag des **relative Rundungsfehler** bei Repräsentation durch Maschinenzahlen gegeben durch

$$\left|\frac{\mathrm{rd}(z) - z}{z}\right|,$$

vgl. Def. 1.1.1. Ihn wollen wir im Folgenden genauer untersuchen.

Sei $z \in \mathbb{R}$ mit $|z| \in [z_{\min}, z_{\max}]$. Dann existiert ein eindeutig bestimmtes $e \in [e_*, e^*]$ mit $|z| \in [b^{e-1}, b^e)$. Die normalisierten Gleitkommazahlen im Intervall $[b^{e-1}, b^e]$ sind

$$[0.10\cdots00]_b \cdot b^e, [0.10\cdots01]_b \cdot b^e, \ldots, [0.(b-1)\cdots(b-1)]_b \cdot b^e, [1.0\cdots0]_b \cdot b^e.$$

Man überlegt sich, dass auf dem Intervall $[b^{e-1}, b^e]$ der Abstand zwischen zwei benachbarten Gleitkommazahlen b^{e-m} ist. Für den Betrag des **absoluten Rundungsfehler** folgt somit zunächst

$$|\mathrm{rd}(z) - z| \leq \frac{1}{2} b^{e-m}$$

und für den **relativen Rundungsfehler**

$$\frac{|\mathrm{rd}(z) - z|}{|z|} \leq \frac{1}{2}\frac{b^{e-m}}{b^{e-1}} = \frac{1}{2} b^{1-m} =: \mathtt{eps}, \tag{1.4}$$

da $|z| \geq b^{e-1}$.

Die Größe `eps`, welche bei gewählter Basis nur von der Länge m der Mantisse abhängt, wird als **Maschinengenauigkeit** bezeichnet. Sie ist die wichtigste Größe, die Gleitkommaarithmetiken charakterisiert.

Wir formalisieren dieses letzte Ergebnis und schaffen uns zugleich ein Modell zur mathematischen Fassung der Gleitkommazahlen.

Satz 1.2.3

Die Abbildung $\mathrm{rd} : [-z_{\max}, z_{\max}] \to \mathring{\mathbb{M}}_b(m, [e_*, e^*])$ erfülle (1.3). Dann existiert für jedes $z \in \mathbb{R}$, $z_{\min} \leq |z| \leq z_{\max}$, ein $\varepsilon \in \mathbb{R}$ mit

$$\mathrm{rd}(z) = (1+\varepsilon)\, z \quad \text{und} \quad |\varepsilon| \leq \texttt{eps} = \frac{1}{2} b^{1-m}.$$

Bemerkung 1.2.4. Ist $z \in (-z_{\min}, z_{\min})$ – also wenn denormalisierte Gleitkommazahlen zum Einsatz kommen – dann gilt die Abschätzung (1.4) i. Allg. nicht. Für $z \to 0$ konvergiert der relative Rundungsfehler betragsmäßig gegen Eins.

In der Praxis haben sich die IEEE[2]-Standards mit unterschiedlichen Genauigkeiten durchgesetzt:

- einfache Genauigkeit: $\mathring{\mathbb{M}}_2(24, [-126, 127])$,
- doppelte Genauigkeit: $\mathring{\mathbb{M}}_2(53, [-1022, 1023])$ und
- erweiterte doppelte Genauigkeit: $\mathring{\mathbb{M}}_2(64, [-16382, 16383])$.

Die für sie charakteristischen Parameter sind in der folgenden Tabelle aufgelistet. Sie enthält außerdem die Namen der entsprechenden C-Datentypen sowie die Anzahl der zur Speicherung einer Gleitkommazahl des jeweiligen Typs benötigten Bytes. Die Wahl der Exponentenbereiche bedingt, dass $z_{\max} \approx 1/z_{\min}$, weshalb $z_{\max}$ nicht angegeben ist.

b	m	e_*	e^*	`eps`	$z_{\min}$	C, C++	Bytes
2	24	−126	127	$5.960 \cdot 10^{-8}$	$5.878 \cdot 10^{-39}$	`float`	4
2	53	−1022	1023	$1.110 \cdot 10^{-16}$	$1.112 \cdot 10^{-308}$	`double`	8
2	64	−16382	16383	$5.421 \cdot 10^{-20}$	$1.681 \cdot 10^{-4932}$	`long double`	12

Tabelle 1.1: Parameter der Maschinenzahlen des IEEE-Standards

Bemerkung 1.2.5. Für höhere Genauigkeiten sind Programmbibliotheken entwickelt worden, z. B. die *GNU Multiple Precision Arithmetic Library*[3]. Allerdings hat höhere Genauigkeit ihren Preis, nämlich längere Rechenzeiten und höheren Speicherbedarf.

[2] Institute of Electrical and Electronics Engineers, `https://www.ieee.org/`

[3] `http://gmplib.org/`

Bemerkung 1.2.6. Für die Kodierung des Vorzeichens wird ein Bit benötigt. Bei Verwendung der Basis 2 genügen für die Mantisse normalisierter Gleitkommazahlen $m - 1$ Bits, da die erste Mantissenstelle stets Eins ist. Für den Exponenten werden 8, 11 bzw. 16 Bits (bei einfacher, doppelter bzw. erweiterter doppelter Genauigkeit) benötigt. Bei genauerer Betrachtung fällt auf, dass statt der möglichen 256, 2048 bzw. 32768 Exponenten lediglich 254, 2046 bzw. 32766 verwendet werden. Die verbleibenden zwei möglichen Exponenten werden genutzt, um anzuzeigen, dass

- ein Überlauf stattgefunden hat, also keine sinnvolle Gleitkommazahl vorliegt, oder
- die kodierte Zahl eine denormalisierte Gleitkommazahl ist. In diesem Fall ist der Exponent $e = e_*$ und die erste Mantissenstelle ist Null.

Bemerkung 1.2.7. Die vier Grundrechenarten mit IEEE-konformen *normalisierten* Gleitkommazahlen werden hardwareseitig durch alle aktuellen Prozessortypen unterstützt. Rechenoperationen mit *denormalisierten* Zahlen werden mittels Programmbibliotheken bewerkstelligt und sind i. Allg. wesentlich langsamer. Die Nutzung denormalisierter Zahlen kann durch Compileroptionen beeinflusst werden.

1.2.3 Grundoperationen und elementare Funktionen

Wir wenden uns jetzt den **arithmetischen Grundoperationen** zu. Diese liefern als Resultate i. Allg. selbst dann keine Gleitkommazahlen, wenn die Operanden Gleitkommazahlen sind. Daher sind maschinen-interne Rundungen erforderlich. Als Resultat erhält man Näherungen

$$x \oplus y, \quad x \ominus y, \quad x \otimes y \quad \text{und} \quad x \oslash y$$

für die arithmetischen Grundoperationen

$$x + y, \quad x - y, \quad x \times y \quad \text{und} \quad x/y.$$

Die Näherungen werden in zwei Schritten berechnet:

S1. Aus den zwei Operanden wird zunächst prozessorintern ein Zwischenresultat mit höherer Genauigkeit durch Rechnung mit längerer Mantisse gebildet.

S2. Anschließend wird dieses Ergebnis auf die normale Stellenzahl gerundet und auf den entsprechenden Speicherplatz geschrieben.

Oder kurz

$$x \odot y := \mathrm{rd}(x \cdot y),$$

wobei „$\cdot$“ und „$\odot$“ für eine beliebige der vier Grundoperationen bzw. ihre maschinenseitige Realisierung stehen.

Die so implementierten arithmetischen Grundoperationen besitzen folgende Eigenschaft.

Axiom 1.2.8: Axiom der Gleitkommaarithmetik für die Grundoperationen

Für alle $x, y \in \mathbb{M}_b(m, [e_*, e^*])$ mit $|x \cdot y| \in [z_{\min}, z_{\max}]$ existiert ein $\varepsilon \in \mathbb{R}$ derart, dass

$$x \odot y = (1 + \varepsilon)(x \cdot y) \quad \text{mit} \quad |\varepsilon| \leq \texttt{eps}. \tag{1.5}$$

Elementare Funktionen

$$f \in \left\{\sin, \cos, \tan, \sqrt{\ }, \exp, \ln, \ldots\right\}$$

werden mittels Programmbibliotheken oder prozessorintern ausgewertet.

Axiom 1.2.9: Axiom der Gleitkommaarithmetik für elementare Funktionen

Ist $f_\circ$ die programmtechnische Implementierung von f, dann gilt

$$f_\circ(x) = (1 + \varepsilon) f(x) \quad \text{für alle} \quad x \in \Omega \subset D_f, \quad \text{mit} \quad |\varepsilon| \leq K_f \texttt{eps}, \tag{1.6}$$

mit einer moderaten Konstante K_f, z. B. $K_f \in [1, 10]$.

Für welchen Teilbereich Ω der Gleitkommazahlen Abschätzungen dieses Typs tatsächlich gelten, und wie groß K_f ist, sollte dem Compiler-Handbuch zu entnehmen sein.

Aufgabe 1.2.10. Betrachtet werde die Menge der Gleitkommazahlen $\mathbb{M}_2(4, [-7, 7])$. Bestimmen Sie für jede der folgenden Operationen mit den Computerzahlen $x = [0.1011]_2 \cdot 2^0$ und $y = [0.1100]_2 \cdot 2^0$, ob sie exakt ausgeführt werden oder ob es zu Rundungen, Überlauf oder Unterlauf kommt:

$$z = x \ominus y, \quad z = (y \ominus x)^{10}, \quad z = x \oplus y, \quad z = y \oplus (x \oslash 4) \quad \text{und} \quad z = x \oplus (y \oslash 4).$$

Bemerkung: Zur Vereinfachung erfolge die Rundung nach jedem Rechenschritt durch einfaches Abschneiden nach der 4. Mantissenstelle. ♢

Beispiel 1.2.11. Das Distributivgesetz

$$(a + b)c = ac + bc$$

gilt in der Menge der Gleitkommazahlen i. Allg. nicht. Wir betrachten dazu eine Gleitkommaarithmetik mit Maschinengenauigkeit eps sowie Gleitkommazahlen a, b und c. Die beiden Berechnungsvorschriften sind

$$y_1 = (a \oplus b) \otimes c \quad \text{und} \quad y_2 = (a \otimes c) \oplus (b \otimes c).$$

Für die erste Berechnungsvorschrift gilt nach (1.5)

$$a \oplus b = (a + b)(1 + e_1) \quad \text{bzw.} \quad (a \oplus b) \otimes c = (a \oplus b)c(1 + e_2) \quad \text{mit} \quad |e_1|, |e_2| \leq \texttt{eps}.$$

und damit in linearer Näherung

$$y_1 = (a \oplus b) \otimes c = (a + b)c(1 + e_1)(1 + e_2) \doteq (a + b)c(1 + e_1 + e_2).$$

Der relative Fehler ε_1, der Berechnungsvorschrift ist durch $y_1 = (a + b)c(1 + \varepsilon_1)$, gegeben. Wir erhalten $\varepsilon_1 = e_1 + e_2$, also $|\varepsilon_1| \leq 2\texttt{eps}$. ♠

Aufgabe 1.2.12. Untersuchen Sie den relativen Fehler ε_2, der zweiten Berechnungsvorschrift. Wann ist welche Berechnungsvorschrift wesentlich genauer als die andere? ♢

1.3 Rundungsfehlereinfluss und Fehlerfortpflanzung

Wir beginnen diesen Abschnitt mit einem Beispiel.

1.3.1 Numerische Differentiation

Eine der grundlegenden Aufgaben der numerischen Mathematik ist die näherungweise Berechnung der Ableitung einer Funktion, die zwar nicht explizit bekannt, aber z. B. mittels eines Algorithmus auswertbar ist. Eine ähnliche Aufgabenstellung ist die Bestimmung der Beschleunigung eines Körpers aus einer gegebenen Messreihe seiner Geschwindigkeit.

Definitionsgemäß gilt für eine Funktion[4] $f \in C^1(a,b)$

$$f'(x) = \lim_{h\to 0} \frac{f(x+h)-f(x)}{h}, \quad x \in (a,b).$$

Eine naheliegende Idee ist nun, für ein hinreichend kleines $h > 0$ den Quotienten

$$(\delta_h f)(x) := \frac{f(x+h)-f(x)}{h} \tag{1.7}$$

als eine Approximation für $f'(x)$ zu verwenden. Die Sinnhaftigkeit dieses Zugangs wird durch folgende Aussage über den auftretenden **Approximationsfehler** gewährleistet.

Aussage 1.3.1

Seien $f \in C^2[a,b]$, $a < b$, und $M := \|f''\|_{[a,b]}$. Dann gilt

$$\left|(\delta_h f)(x) - f'(x)\right| \le \frac{M}{2}\,|h|$$

für alle $x \in [a,b]$ und $h \neq 0$ mit $x + h \in [a,b]$.

Beweis. Seien x und $x+h$ wie in den Voraussetzungen des Satzes. Dem Satz von Taylor[5] zufolge, vgl. *Lehrtext Analysis*, Satz 4.3.9, existiert ein ξ zwischen x und $x+h$ mit

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2} f''(\xi).$$

Wir dividieren durch $h \neq 0$ und bilden die Beträge:

$$\left|(\delta_h f)(x) - f'(x)\right| = \frac{|h|}{2}\,|f''(\xi)|\,.$$

Es folgt die Behauptung des Satzes, da $|f''(\xi)| \le M$. □

[4] Wir bezeichnen mit $C^k(a,b)$ und $C^k[a,b]$, $k \in \mathbb{N}_0$, die linearen Räume der k-mal stetig differenzierbaren Funktionen auf den Intervallen (a,b) bzw. $[a,b]$. Den Raum $C[a,b] = C^0[a,b]$ versehen wir mit der Maximumnorm

$$\|v\|_{[a,b]} := \max_{\xi\in[a,b]} |v(\xi)|\,, \quad v \in C[a,b].$$

Er wird so zu einem normierten Raum.

[5] Brook Taylor *18.8.1685 (Edmonton, Middlesex, England), †29.12.1731 (Somerset House, London, England)

Der Fehler bei der näherungsweisen Berechnung der ersten Ableitung (einer zweimal stetig differenzierbaren Funktion) gemäß (1.7) ist (im schlechtesten Fall) proportional zu h. Wir wollen dies an einem konkreten Beispiel illustrieren. Unser Vorgehen dabei ist typisch für die numerische Mathematik: ein Verfahren/Algorithmus wird an einer Testaufgabe erprobt, dessen Lösung bekannt ist.

Zu berechnen sei die Ableitung der Exponentialfunktion $\exp : x \mapsto \mathrm{e}^x$ an der Stelle $x = 1$. Die Ableitung der Exponentialfunction ist natürlich bekannt:

$$\exp'(1) = \exp(1) \approx 2.718281828459045.$$

Wir approximieren $\exp'(1)$ durch $(\delta_h \exp)(1)$ mit $h = 10^{-1}, 10^{-2}, \ldots, 10^{-15}$. Zu diesem Zweck haben wir ein kleines Programm geschrieben, das uns auf einem handelsüblichen Rechner ausgeführt Tabelle 1.2 liefert.

Programm 1: Differenzenquotient zur Approximation der ersten Ableitung

```
% Matlab/Octave
for i= 1:15
  h= 10^(-i);                          % Schrittweite h
  delta= (exp(1+h)-exp(1))/h;          % Differenzenquotient
  fehler= abs(delta-exp(1));           % Fehler
  printf('10^{-%d} & %.15f & %.3e \n', i, delta, fehler);
endfor
```

h	$(\delta_h \exp)(1)$	Fehler
10^{-1}	2.858841954873883	$1.406 \cdot 10^{-1}$
10^{-2}	2.731918655787124	$1.364 \cdot 10^{-2}$
10^{-3}	2.719641422533225	$1.360 \cdot 10^{-3}$
10^{-4}	2.718417747082924	$1.359 \cdot 10^{-4}$
10^{-5}	2.718295419956717	$1.359 \cdot 10^{-5}$
10^{-6}	2.718283187430615	$1.359 \cdot 10^{-6}$
10^{-7}	2.718281968405734	$1.399 \cdot 10^{-7}$
10^{-8}	2.718281821856294	$6.603 \cdot 10^{-9}$
10^{-9}	2.718282043900899	$2.154 \cdot 10^{-7}$
10^{-10}	2.718283376168529	$1.548 \cdot 10^{-6}$
10^{-11}	2.718314462413218	$3.263 \cdot 10^{-5}$
10^{-12}	2.718714142702083	$4.323 \cdot 10^{-4}$
10^{-13}	2.717825964282383	$4.559 \cdot 10^{-4}$
10^{-14}	2.708944180085382	$9.338 \cdot 10^{-3}$
10^{-15}	3.108624468950438	$3.903 \cdot 10^{-1}$

Tabelle 1.2: Approximation der Ableitung von exp durch δ_h; korrekte Stellen unterstrichen

Zunächst beobachten wir, dass im Einklang mit Auss. 1.3.1 für $h = 10^{-1}, \ldots, 10^{-8}$ der Fehler proportional zu h ist, und die Güte der Approximation mit kleiner werdendem h zunimmt. Bei

weiterer Verkleinerung von h ist jedoch eine signifikante Verschlechterung zu beobachten. Auf den ersten Blick widerspricht dies Auss. 1.3.1.

Dieser Widerspruch ist aber nur ein scheinbarer, denn der Beweis von Auss. 1.3.1 geht davon aus, dass mit reellen Zahlen gerechnet wird. Unser Programm arbeitet aber mit Gleitkommazahlen! Dadurch ist die Berechnung von $(\delta_h f)(x)$ mit Rundungsfehlern behaftet:

$$f'(x) \approx (\delta_h f)(x) \approx \Big(f_\circ(\mathrm{rd}(x) \oplus \mathrm{rd}(h)) \ominus f_\circ(\mathrm{rd}(x))\Big) \oslash \mathrm{rd}(h).$$

Rundungsfehler treten auf

- bei der Repräsentation von x und h durch Gleitkommazahlen,
- bei der Addition von x und h,
- bei der Auswertung von f
- bei der Subtraktion im Zähler sowie
- bei der Division durch h.

Exemplarisch wollen wir lediglich den Einfluss der fehlerbehafteten Auswertung von f analysieren. Vereinfachend nehmen wir daher an, dass x, h und $x + h$ exakt durch Gleitkommazahlen repräsentiert werden, und auch die Division durch h exakt ausgeführt wird. (Die hierbei auftretenden Fehler können in der Tat vernachlässigt werden.) Mit diesen vereinbarten Annahmen gilt

$$f'(x) - \frac{f_\circ(x+h) - f_\circ(x)}{h} = f'(x) - \frac{(1+\varepsilon_1)f(x+h) - (1+\varepsilon_2)f(x)}{h}$$

mit relativen Fehlern bei der Auswertung von f entsprechend (1.6):

$$|\varepsilon_1|, |\varepsilon_2| \le K_f \,\mathtt{eps}\,. \tag{1.8}$$

Den Zähler des zweiten Bruches auf der rechten Seite multiplizieren wir aus und erhalten für den **Gesamtfehler**:

$$f'(x) - \frac{f_\circ(x+h) - f_\circ(x)}{h} = \underbrace{f'(x) - (\delta_h f)(x)}_{\text{Approximationsfehler}} - \underbrace{\frac{\varepsilon_1 f(x+h) - \varepsilon_2 f(x)}{h}}_{\textbf{Rundungsfehler}},$$

Den Approximationsfehler schätzen wir mit Hilfe von Auss. 1.3.1 ab, für den Rundungsfehler verwenden wir (1.8):

$$\left| f'(x) - \frac{f_\circ(x+h) - f_\circ(x)}{h} \right| \le \frac{M|h|}{2} + \frac{2\mathtt{eps}}{|h|} K_f \|f\|_{[a,b]}\,. \tag{1.9}$$

Diese detailliertere Untersuchung zeigt den Einfluss der Rundungsfehler. Für kleiner werdendes h wird zwar der Approximationsfehler kleiner, aber die Rundungsfehler aus der Arbeit mit Gleitkommazahlen werden verstärkt. Abbildung 1.6 illustriert die Situation.

Mit Mitteln der Differentialrechnung können wir untersuchen, für welche Werte von h die rechte Seite von (1.9), unsere garantierte Schranke für den Gesamtfehler, minimal wird. Wir beschränken uns dabei auf positive Werte von h und definieren

$$\psi\colon h \mapsto \psi(h) := \frac{Mh}{2} + \frac{2\mathtt{eps}}{h} K_f \|f\|_{[a,b]}\,.$$

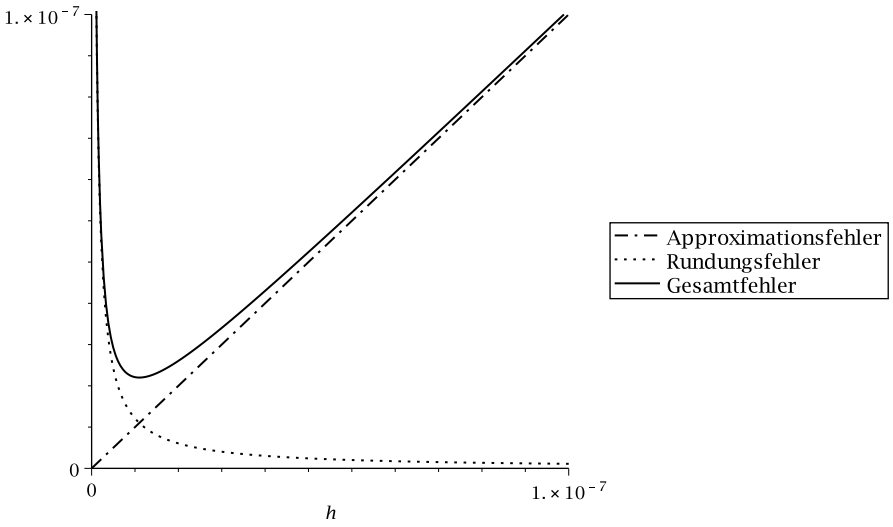


Abbildung 1.6: Fehlerkomponenten bei der numerischen Differentiation

Wir bestimmen die Nullstelle der ersten Ableitung

$$\psi'(h) := \frac{M}{2} - \frac{2\mathtt{eps}}{h^2} K_f \, \|f\|_{[a,b]} \ ,$$

und erhalten als **optimale Schrittweite**

$$h^* = 2\sqrt{\frac{\mathtt{eps} K_f \, \|f\|_{[a,b]}}{M}}$$

und das zugehörige **optimale Fehlerniveau**

$$\left| f'(x) - \frac{f_\circ(x+h^*) - f_\circ(x)}{h^*} \right| \le \psi(h^*) = M_f \sqrt{\mathtt{eps}} \, , \qquad M_f := 2\sqrt{M K_f \, \|f\|_{[a,b]}} \, .$$

Bemerkung 1.3.2. In der Praxis ist die Konstante M_f unbekannt, da sie von f, f'' und möglicherweise auch von verwendeten Programmbibliotheken abhängt. Ebenso ist h^* von diesen Größen abhängig, und ist nicht präzise angebbar, sondern lediglich von der Größenordnung her:

$$h^* \approx \sqrt{\mathtt{eps}} \quad \text{und damit} \quad \left| f'(x) - \frac{f_\circ(x+h^*) - f_\circ(x)}{h^*} \right| \approx \sqrt{\mathtt{eps}} \, .$$

Im unserem Beispiel (Berechnung der Ableitung der Exponentialfunktion) hat der Computer mit doppelter Genauigkeit gerechnet. Für diese ist $\mathtt{eps} \approx 1.110 \cdot 10^{-16}$. Eine gute Wahl ist dementsprechend $h^* \approx 10^{-8}$. Für diesen Wert von h haben wir in Tabelle 1.2 auch die genaueste Approximation der Ableitung erhalten. Der Gesamtfehler liegt bei $\sqrt{\mathtt{eps}} \approx 10^{-8}$.

Das Ergebnis ist etwas ernüchternd. Bei der näherungsweisen Berechnung der Ableitung mittels (1.7) sind lediglich die ersten 8 Dezimalstellen korrekt, obwohl unser Computer mit 16 Dezimalstellen arbeitet.

Aufgabe 1.3.3. Untersuchen Sie den symmetrischen Differenzenquotienten

$$f'(x) \approx (\delta_h^* f)(x) := \frac{f(x+h) - f(x-h)}{2h}, \quad h > 0.$$

Zeigen Sie: Ist $f \in C^3[a,b]$, $a < b$, und $x \pm h \in (a,b)$, dann gilt für den Approximationsfehler

$$\left|(\delta_h^* f)(x) - f'(x)\right| \leq Mh^2$$

mit einer Konstante $M \geq 0$. Bestimmen Sie M.

Analysieren Sie den Rundungsfehlereinfluss bei Arbeit mit Maschinengenauigkeit `eps`. Für welches h ist eine hohe Approximationsgüte zu erwarten? Wie groß ist der zu erwartende Fehler? Schreiben Sie ein kleines Programm und verifizieren Sie Ihr Ergebnis für die Approximation von $\exp'(1)$ durch δ_h^*. ◊

1.3.2 Kondition von Aufgaben

Gegeben sei die **Aufgabe**, aus einem Satz von **Eingangsdaten** $x_1, \ldots, x_n \in \mathbb{R}$ ein **Resultat** $z \in \mathbb{R}$ entsprechend der Vorschrift

$$z = f(x_1, \ldots, x_n)$$

zu berechnen. Wir interessieren uns dafür, den Einfluss von Fehlern in den Eingangsdaten auf das Resultat abzuschätzen. Störungen der Eingangsdaten resultieren z. B. aus der Verwendung von Gleitkommazahlen oder von mit Messfehlern behafteten Daten.

Mit dieser Fragestellung hatten wir uns an einem einfachen Beispiel bereits im Abschnitt 1.1 beschäftigt, wo das Volumen einer Pyramide zu berechnen war. Wir wollen das Vorgehen jetzt verallgemeinern und formalisieren.

Bemerkung 1.3.4. An dieser Stellen müssen wir klar trennen zwischen der *Aufgabe* und einer konkreten *Berechnungsvorschrift* zu ihrer Lösung auf einem Computer. Durch die Arbeit mit Gleitkommazahlen werden im Laufe der Rechnung Rundungsfehler eingeführt, die bei einer schlechten Berechnungsvorschrift das Resultat ungünstig verfälschen können, wie wir es z. B. schon in Aufg. 1.2.12 beobachtet haben.

Dem Einfluss von Rundungsfehlern bei der Berechnung von f und der Analyse von Berechnungsvorschriften/Algorithmen werden wir uns im Abschnitt 1.3.3 widmen.

Um uns das Studium der Fehlerfortpflanzung zu erleichtern, nehmen wir an, dass die Funktion $f : \mathbb{R}^n \to \mathbb{R}$ in einer hinreichend großen Umgebung von $(x_1, \ldots, x_n)$ zweimal stetig differenzierbar ist. Dies gestattet uns eine Taylorentwicklung bis zum quadratischen Glied.

Die betrachteten Daten fassen wir zu dem Datenvektor

$$\boldsymbol{x} := (x_1, \ldots, x_n)^T,$$

zusammen. Die mit Fehlern behafteten Daten seien

$$\tilde{\boldsymbol{x}} := (\tilde{x}_1, \ldots, \tilde{x}_n)^T.$$

Definitionsgemäß ist der absolute Fehler

$$\boldsymbol{\Delta_x} := (\Delta_{x_1}, \ldots, \Delta_{x_n})^T = \tilde{\boldsymbol{x}} - \boldsymbol{x}.$$

Die relativen Fehler der einzelnen Komponenten sind

$$\varepsilon_{x_i} := \frac{\Delta_{x_i}}{x_i}, \quad i = 1, \ldots, n.$$

Uns interessiert der Einfluss von $\boldsymbol{\Delta_x}$ auf den Fehler $\Delta_z := \tilde{z} - z$ im Resultat. Dabei ist $z = f(\boldsymbol{x})$ der exakte Funktionswert, während sich $\tilde{z} = f(\tilde{\boldsymbol{x}})$ aus der Berechnung mit dem gestörten Argument ergibt.

Dem Satz von Taylor zufolge gilt, vgl. *Lehrtext Analysis*, Satz 4.4.8,

$$f(\tilde{\boldsymbol{x}}) = f(\boldsymbol{x}) + \sum_{i=1}^{n} D_i f(\boldsymbol{x}) \Delta_{x_i} + \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} D_{ij} f(\boldsymbol{\xi}) \Delta_{x_i} \Delta_{x_j},$$

mit einem $\boldsymbol{\xi}$ auf der Verbindungsstrecke von $\boldsymbol{x}$ und $\tilde{\boldsymbol{x}}$, oder kurz

$$f(\tilde{\boldsymbol{x}}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^T \boldsymbol{\Delta_x} + \frac{1}{2} \boldsymbol{\Delta_x}^T \boldsymbol{H}_f(\boldsymbol{\xi}) \boldsymbol{\Delta_x}$$

mit dem Gradienten ∇f und der Hesse[6]-Matrix $\boldsymbol{H}_f$ der Funktion f:

$$\boldsymbol{H}_f := \begin{pmatrix} D_{11} f & D_{12} f & \cdots & D_{1n} f \\ D_{21} f & D_{22} f & \cdots & D_{2n} f \\ \vdots & \vdots & \ddots & \vdots \\ D_{n1} f & D_{n2} f & \cdots & D_{nn} f \end{pmatrix}.$$

(Wegen des Satzes von Schwarz ist $\boldsymbol{H}_f$ symmetrisch.) Unter Vernachlässigung der quadratisch kleinen Terme $\Delta_{x_i} \Delta_{x_j}$ erhalten wir in linearer Näherung für den Fehler in z

$$\Delta_z = \tilde{z} - z = f(\tilde{\boldsymbol{x}}) - f(\boldsymbol{x}) \doteq \sum_{i=1}^{n} D_i f(\boldsymbol{x}) \Delta_{x_i} \tag{1.10}$$

Die partielle Ableitung $D_i f(\boldsymbol{x})$ gibt also in erster Näherung an, um welchen Faktor verstärkt (oder gedämpft) der *absolute* Fehler Δ_{x_i} der i-ten Komponente des Datenvektors in den *absoluten* Fehler Δ_z des Resultates eingeht. Von größerer Bedeutung ist aber der Zusammenhang zwischen den *relativen* Fehlern in den Eingangsdaten und im Ergebnis.

Wir dividieren (1.10) durch $z = f(\boldsymbol{x})$:

$$\varepsilon_z = \frac{\Delta_z}{z} \doteq \sum_{i=1}^{n} \frac{x_i}{f(\boldsymbol{x})} D_i f(\boldsymbol{x}) \frac{\Delta_{x_i}}{x_i} = \sum_{i=1}^{n} \frac{x_i}{f(\boldsymbol{x})} D_i f(\boldsymbol{x}) \, \varepsilon_{x_i}.$$

Der *relative* Fehler in x_i geht also um den Faktor

$$\frac{x_i}{f(\boldsymbol{x})} D_i f(\boldsymbol{x})$$

verstärkt (oder gedämpft) in den *relativen* Fehler des Ergebnisses ein. Ist der Faktor betragsmäßig groß, so wirkt sich der relative Fehler ε_{x_i} in der i-ten Komponente des Datenvektors sehr ungünstig auf den relativen Fehler des Resultats aus.

[6] Ludwig Otto Hesse, *22.4.1811 (Königsberg, Preussen) †4.8.1874 (München, Deutschland)

Definition 1.3.5: Kondition von Aufgaben

Gegeben sei die Aufgabe, $z = f(\boldsymbol{x})$ für ein $\boldsymbol{x} \in \mathbb{R}^n$ zu berechnen. Die Größe

$$\kappa_i := \frac{x_i}{f(\boldsymbol{x})} D_i f(\boldsymbol{x}), \quad i = 1, \ldots, n,$$

wird als **Konditionszahl der Aufgabe bezüglich der *i*-ten Komponente des Datenvektors** (oder **bezüglich des *i*-ten Argumentes**) bezeichnet.

Eine Aufgabe mit (mindestens) einer betragsmäßig großen Konditionszahl wird als **schlecht konditioniert** bezeichnet. Man spricht auch von der **natürlicher Instabilität** der Aufgabe. Sind alle Konditionszahlen moderat, so spricht man hingegen von einer **gut konditionierten** Aufgabe.

Beachten Sie, dass bei der Definition der Konditionszahlen neben den partiellen Ableitungen von f auch die Faktoren $x_i/f(\boldsymbol{x})$ auftreten. Diese sind besonders ungünstig, wenn ein betragsmäßig *kleines Resultat* aus betragsmäßig *großen Daten* zu berechnen ist.

Bemerkung 1.3.6. Der Übergang von „gut konditioniert“ zu „schlecht konditioniert“ ist fließend. Entscheidend ist, ob in einer bestimmten Anwendung die Verstärkung der relativen Fehler um einen gewissen Faktor akzeptiert werden kann oder nicht.

Wir analysieren exemplarisch die Grundrechenarten.

Beispiel 1.3.7. Multiplikation: Gegeben ist die Aufgabe, das Produkt z zweier reeller Zahlen x_1 und x_2 zu berechnen. Der Zusammenhang zwischen Ergebnis und Eingangsdaten ist gegeben durch

$$z = f(x_1, x_2) = x_1 x_2.$$

Die Konditionszahl κ_1 bezüglich des ersten Argumentes ist

$$\kappa_1 = \frac{x_1}{f(x_1, x_2)} D_1 f(x_1, x_2) = \frac{x_1}{x_1 x_2} x_2 = 1.$$

Völlig analog erhalten wir $\kappa_2 = 1$. Die Multiplikation zweier Zahlen ist gut konditioniert. ♠

Beispiel 1.3.8. Division: Zu berechnen ist

$$z = f(x_1, x_2) = \frac{x_1}{x_2}, \quad x_2 \neq 0.$$

Für die Konditionszahlen erhalten wir

$$\kappa_1 = \frac{x_1}{f(x_1, x_2)} D_1 f(x_1, x_2) = \frac{x_1}{\frac{x_1}{x_2}} \frac{1}{x_2} = 1$$

sowie

$$\kappa_2 = \frac{x_2}{f(x_1, x_2)} D_2 f(x_1, x_2) = \frac{x_2}{\frac{x_1}{x_2}} \frac{-x_1}{x_2^2} = -1.$$

Die Division zweier Zahlen ist ebenfalls gut konditioniert. ♠

Beispiel 1.3.9. Addition, Subtraktion: Zu berechnen ist

$$z = f(x_1, x_2) = x_1 + x_2.$$

Die Konditionszahlen sind

$$\kappa_1 = \frac{x_1}{f(x_1, x_2)} D_1 f(x_1, x_2) = \frac{x_1}{x_1 + x_2} \quad \text{und} \quad \kappa_2 = \frac{x_2}{f(x_1, x_2)} D_2 f(x_1, x_2) = \frac{x_2}{x_1 + x_2}.$$

Diese werden groß, wenn $(x_1 + x_2)$ betragsmäßig wesentlich kleiner als x_1 bzw. x_2 ist. Mit anderen Worten, wird die Differenz zweier etwa gleichgroßer Zahlen berechnet (also $x_1 \approx -x_2$), ist eine signifikante Verstärkung von Rundungsfehlern zu erwarten. ♠

Der u. U. schlechten Kondition der Subtraktion sind wir bereits bei der numerischen Differentiation im Abschnitt 1.3.1 begegnet. Dort wurde gemäß

$$\exp'(1) \approx \frac{\mathrm{e}^{1+h} - \mathrm{e}^1}{h}$$

eine Approximation der ersten Ableitung berechnet. Wir wollen bei 16-stelliger Genauigkeit die Berechnung der Differenz im Zähler für $h = 10^{-8}$ detailliert nachvollziehen.

$\mathrm{e}^{1+h} = x_1$	2.718 281 855 641 863
$\mathrm{e}^1 = x_2$	2.718 281 828 459 045
$\mathrm{e}^{1+h} - \mathrm{e}^1 = z$	$0.000\,000\,027\,182\,818 = 2.718\,281\,800\,000\,000 \cdot 10^{-8}$

Wir beobachten bei der Berechnung der Differenz einen „Verlust“ der letzten 8 Mantissenstellen. Dieser Effekt, der bei der Subtraktion zweier annähernd gleicher Zahlen auftritt, wird als **Stellenauslöschung** bezeichnet. Er muss – falls möglich – vermieden werden.

Beispiel 1.3.10. Wurzelfunktion. Zu berechnen sei $z = f(a) = \sqrt{a}$, $a \geq 0$. Die Konditionszahl dieser Aufgabe ist

$$\kappa = \frac{a}{f(a)} f'(a) = \frac{a}{\sqrt{a}} \frac{1}{2\sqrt{a}} = \frac{1}{2}.$$

Die Aufgabe ist gut konditioniert. ♠

Beispiel 1.3.11. Lösung quadratischer Gleichungen. Vorgelegt sei die Aufgabe, bei gegebenen $p, q > 0$, $q \ll p^2$,

$$\lambda = \varphi(p, q) = p - \sqrt{p^2 - q}$$

zu berechnen. Es handelt sich dabei um eine der Lösungen von $\lambda^2 - 2p\lambda + q = 0$. Auf den ersten Blick scheint hier eine kritische Subtraktion aufzutreten, da $\sqrt{p^2 - q} \approx p$, weshalb man Stellenauslöschung erwarten könnte. Allerdings stehen Minuend und Subtrahend in einem Zusammenhang. Sie sind also nicht unabhängig voneinander mit Rundungsfehlern behaftet. Es bedarf daher einer genaueren Untersuchung.

Wir bestimmen zunächst die Konditionszahl der Aufgabe bezüglich p:

$$\kappa_1 = \frac{p}{\varphi(p, q)} D_1 \varphi(p, q) = \frac{p}{p - \sqrt{p^2 - q}} \left(1 - \frac{p}{\sqrt{p^2 - q}}\right) = \frac{-p}{\sqrt{p^2 - q}} \approx -1,$$

da $\sqrt{p^2-q} \approx p$ für $q \ll p^2$.

Für die Konditionszahl bezüglich q gilt

$$\kappa_2 = \frac{q}{\varphi(p,q)} D_2\varphi(p,q) = \frac{q}{p-\sqrt{p^2-q}} \frac{1}{2\sqrt{p^2-q}} = \frac{p+\sqrt{p^2-q}}{2\sqrt{p^2-q}},$$

wobei wir bei der letzten Umformung

$$\lambda = \varphi(p,q) = p - \sqrt{p^2-q} = \frac{q}{p+\sqrt{p^2-q}} \tag{1.11}$$

verwendet haben (VIETA[7]scher Wurzelsatz). Es folgt

$$\kappa_2 = \frac{p+\sqrt{p^2-q}}{2\sqrt{p^2-q}} \approx 1, \quad \text{für } q \ll p^2.$$

Beide Konditionszahlen sind in etwa 1. Die Aufgabe ist somit gut konditioniert. ♠

1.3.3 Kondition von Algorithmen

Die natürliche Stabilität (oder Instabilität) ist eine Eigenschaft der gegebenen Aufgabe. Sie hängt nur von der vorgelegten Aufgabe ab, aber nicht von dem für die Berechnung gewählten Algorithmus.

In diesem Abschnitt werden wir sehen, dass das Ergebnis einer gut konditionierten Aufgabe durch einen ungeschickt gewählten **Algorithmus** (Berechnungsmethode) stark verfälscht werden kann, also ein Verlust an Genauigkeit eintritt. In diesem Fall sprechen wir von **numerischer Instabilität**. Sie ist eine Eigenschaft des **Algorithmus** und hängt vom gewählten Rechnungsverlauf ab, bei dem **Rundungsfehler** in einzelnen Berechnungsschritten unter Umständen erheblich verstärkt werden können.

Um unser weiteres Vorgehen zu motivieren kommen wir zurück auf Bsp. 1.3.11, in dem für gegebene $p, q > 0$, $q \ll p^2$,

$$\lambda = p - \sqrt{p^2-q} \tag{1.12}$$

zu berechnen war. Wir setzen (1.12) direkt in einen Algorithmus um und berechnen nacheinander die Zwischenergebnisse

$$y_1 := p \cdot p\,, \quad y_2 := y_1 - q \quad \text{und} \quad y_3 := \sqrt{y_2}$$

sowie das Endergebnis

$$\lambda := p - y_3.$$

[7]François Viète (latinisiert Vieta), *1540 (Fontenay-le-Comte, Poitou (jetzt Vendée), Frankreich), †13.12.1603 (Paris, Frankreich)

Wird hierbei mit Gleitkommazahlen gerechnet, werden alle drei Zwischenergebnisse y_i mit Fehlern behaftet sein. Wir müssen uns der Frage stellen, welchen Einfluss diese Fehler auf das Endergebnis haben. Dazu stellen wir λ in Abhängigkeit von den y_i dar und analysieren anschließend mit unseren Ergebnissen aus Abschnitt 1.3.2 die Fehlerfortpflanzung.

Wir rollen den Algorithmus von hinten auf. Der letzte Berechnungsschritt gibt uns unmittelbar die Abhängigkeit von y_3:

$$\lambda = p - y_3 \,. \tag{1.13a}$$

Wir gehen einen Schritt zurück und ersetzen $y_3 = \sqrt{y_2}$:

$$\lambda = p - \sqrt{y_2} \,, \tag{1.13b}$$

was uns die Abhängigkeit von y_2 liefert. Als nächstes substituieren wir $y_2 = y_1 - q$:

$$\lambda = p - \sqrt{y_1 - q} \,. \tag{1.13c}$$

Wir haben jetzt explizite Darstellungen von λ in Abhängigkeit von den Zwischenergebnissen y_i und können nun mit Hilfe unserer Überlegungen aus Abschnitt 1.3.2 die Frage beantworten, wie sich relative Fehler in den Zwischenergebnissen y_i auf das Resultat λ auswirken. Oder mit anderen Worten:

- Wie ist die Aufgabe, λ gemäß (1.13c) zu berechnen, bezüglich y_1 konditioniert?
- Wie ist die Aufgabe, λ gemäß (1.13b) zu berechnen, bezüglich y_2 konditioniert?
- Wie ist die Aufgabe, λ gemäß (1.13a) zu berechnen, bezüglich y_3 konditioniert?

Wir bestimmen die entsprechenden Konditionszahlen K_i gemäß Def. 1.3.5:

$$\begin{aligned} K_1 &:= \frac{y_1}{\lambda}\frac{\partial \lambda}{\partial y_1} = \frac{y_1}{\lambda}\frac{-1}{2\sqrt{y_1 - q}} \,, \\ K_2 &:= \frac{y_2}{\lambda}\frac{\partial \lambda}{\partial y_2} = \frac{y_2}{\lambda}\frac{-1}{2\sqrt{y_2}} \,, \\ K_3 &:= \frac{y_3}{\lambda}\frac{\partial \lambda}{\partial y_3} = \frac{y_3}{\lambda}(-1) \,. \end{aligned}$$

Man überlegt sich, dass $\lambda, y_1, y_2, y_3 > 0$. Ferner folgt aus $q \ll p^2$,

$$\lambda = p - \sqrt{p^2 - q} = \frac{q}{p + \sqrt{p^2 - q}} \approx \frac{q}{2p} \quad \text{sowie} \quad \sqrt{y_1 - q} \approx p.$$

Somit ist

$$K_1 \approx -\frac{p^2}{q}, \quad \text{also} \quad |K_1| \approx \frac{p^2}{q} \gg 1.$$

Kleine Fehler in y_1 werden also signifikant verstärkt, was alles andere als wünschenswert ist!

Aber woran liegt das? Gehen wir die Schritte des Algorithmus im Einzelnen durch. Bei der Berechnung von y_1 werden zwei Zahlen multipliziert. Hier geht nichts schief, vgl. Bsp. 1.3.7.

Im nächsten Schritt wird eine kleine Zahl von einer großen subtrahiert. Auch dies kann nicht die Ursache sein, siehe Bsp. 1.3.9. Zur Berechnung von y_3 wird eine Wurzel gezogen. Auch dies ist problemlos, wie wir in Bsp. 1.3.10 festgestellt hatten. Es ist der letzte Schritt, bei dem λ als Differenz von p und y_3 berechnet wird. Da $y_3 \approx p$ tritt hier Stellenauslöschung auf.

Formal können wir dies bestätigen, indem wir die Aufgabe, λ gemäß (1.13a) zu berechnen, betrachten und ihre Konditionszahl bzgl. y_3 untersuchen:

$$K_3 \approx -\frac{2p^2}{q}\,.$$

Sie ist betragsmäßig sehr groß. Im letzten Schritt werden also alle unsere Bemühungen, ein genaues Ergebnis zu berechnen, zunichte gemacht.

Die Aufgabe ist gut konditioniert, unser erster Algorithmus, den wir uns ausgedacht haben, aber unbrauchbar. Wir müssen also noch an einer Alternative arbeiten. Bevor wir uns dieser Aufgabe zuwenden, wollen wir unser bisheriges Vorgehen verallgemeinern und formalisieren.

Ein Algorithmus zur Berechnung von $z = f(\boldsymbol{x})$ aus dem Datenvektor $\boldsymbol{x}$ bestehe aus folgenden **Berechnungsschritten**, bei denen Zwischenergebnisse y_i, $i = 1, \ldots, N-1$, berechnet werden.

$$\begin{aligned}
y_1 &= r_1(\boldsymbol{x}) \\
y_2 &= r_2(y_1, \boldsymbol{x}) \\
y_3 &= r_3(y_1, y_2, \boldsymbol{x}) \\
&\vdots \\
y_{N-1} &= r_{N-1}(y_1, y_2, \ldots, y_{N-2}, \boldsymbol{x}) \\
z &= r_N(y_1, y_2, \ldots, y_{N-1}, \boldsymbol{x})
\end{aligned}$$

Uns interessiert die Frage, wie sich Rundungsfehler im Zwischenergebnis y_i auf das Resultat z auswirken.

Zu diesem Zweck betrachten wir y_i als Eingabe und stellen uns die Frage, wie die Aufgabe, z aus $\boldsymbol{x}$ sowie $y_1, \ldots, y_i$ zu bestimmen, bezüglich y_i konditioniert ist. Diese Aufgabe wird durch die sog. **Restabbildung**

$$R_i \colon (y_1, \ldots, y_i, \boldsymbol{x}) \mapsto z$$

beschrieben. Die Restabbildungen werden sukzessive, durch Elimination der Zwischenergebnisse $y_{N-1}, y_{N-2}, \ldots, y_{i+1}$, aus den Berechnungsvorschriften des Algorithmus bestimmt:

$$\begin{aligned}
z &= R_{N-1}(y_1, \ldots, y_{N-1}, \boldsymbol{x}) \coloneqq r_N(y_1, \ldots, y_{N-1}, \boldsymbol{x}) \\
&= R_{N-2}(y_1, \ldots, y_{N-2}, \boldsymbol{x}) \coloneqq R_{N-1}(y_1, \ldots, y_{N-2}, r_{N-1}(y_1, \ldots, y_{N-2}, \boldsymbol{x}), \boldsymbol{x}) \\
&\vdots \\
&= R_{N-k}(y_1, \ldots, y_{N-k}, \boldsymbol{x}) \coloneqq R_{N-k+1}(y_1, \ldots, y_{N-k}, r_{N-k+1}(y_1, \ldots, y_{N-k}, \boldsymbol{x}), \boldsymbol{x}), \quad k < N.
\end{aligned}$$

Die Verstärkung oder Abschwächung der relativen Fehler im Zwischenergebnis y_i berechnen sich, unseren Ergebnissen aus Abschnitt 1.3.2 folgend, gemäß

$$\frac{y_i}{R_i(y_1, \ldots, y_i, \boldsymbol{x})}\, D_i R_i(y_1, \ldots, y_i, \boldsymbol{x}) = \frac{y_i}{z}\, D_i R_i(y_1, \ldots, y_i, \boldsymbol{x}), \quad i = 1, \ldots, N-1.$$

Definition 1.3.12: Kondition von Algorithmen

Die Größen

$$K_i := \frac{y_i}{z} D_i R_i(y_1, \ldots, y_i, \boldsymbol{x}), \quad i = 1, \ldots, N-1,$$

heißen die **Konditionszahlen des Algorithmus** (bzgl. des Zwischenergebnisses y_i).
Ein Algorithmus wird als **numerisch stabil** bezeichnet, wenn alle seine Konditionszahlen betragsmäßig nicht wesentlich größer sind als die Konditionszahlen der Aufgabe. Andernfalls heißt er **numerisch instabil**.

Bemerkung 1.3.13. Wie bei der Kondition von Aufgaben ist der Übergang von „stabil“ zu „instabil“, fließend. Entscheidend ist wiederum, in welchem Ausmaß Verstärkungen der relativen Fehler akzeptiert werden können.

Beispiel 1.3.14. Wir kommen zurück auf unser einführendes Beispiel und analysieren es mit dem soeben hergeleiteten Formalismus. Für gegebene $p, q > 0$, $q \ll p^2$, ist also $\lambda = p - \sqrt{p^2 - q}$ zu berechnen.

Der Algorithmus ist:

$$\begin{aligned} y_1 &:= r_1(p,q) &&= p \cdot p, \\ y_2 &:= r_2(y_1,p,q) &&= y_1 - q, \\ y_3 &:= r_3(y_1,y_2,p,q) &&= \sqrt{y_2}, \\ \lambda &:= r_4(y_1,y_2,y_3,p,q) &&= p - y_3. \end{aligned}$$

Offenbar sind $\lambda, y_1, y_2, y_3 > 0$.

Zur Untersuchung der Stabilität bestimmen wir zunächst die Restabbildungen:

$$\begin{aligned} \lambda = R_3(y_1,y_2,y_3,p,q) &= r_4(y_1,y_2,y_3,p,q) && = p - y_3, \\ = R_2(y_1,y_2,p,q) &= R_3(y_1,y_2,r_3(y_1,y_2,p,q),p,q) && = p - \sqrt{y_2}, \\ = R_1(y_1,p,q) &= R_2(y_1,r_2(y_1,p,q),p,q) && = p - \sqrt{y_1 - q} \end{aligned}$$

und berechnen anschließend die Konditionszahlen des Algorithmus

$$\begin{aligned} K_1 &= \frac{y_1}{\lambda} D_1 R_1(y_1,p,q) &&= \frac{y_1}{\lambda} \frac{-1}{2\sqrt{y_1 - q}}, \\ K_2 &= \frac{y_2}{\lambda} D_2 R_2(y_1,y_2,p,q) &&= \frac{y_2}{\lambda} \frac{-1}{2\sqrt{y_2}}, \\ K_3 &= \frac{y_3}{\lambda} D_3 R_3(y_1,y_2,y_3,p,q) &&= \frac{y_3}{\lambda} (-1). \end{aligned}$$

In der uns interessierenden Situation, also $q \ll p^2$, gilt

$$y_2 \approx p^2, \quad y_3 \approx p \quad \text{und} \quad \lambda = p - \sqrt{p^2 - q} = \frac{q}{p + \sqrt{p^2 - q}} \approx \frac{q}{2p}$$

Woraus dann für die Beträge der Konditionszahlen des Algorithmus folgt

$$|K_1|, |K_2| \approx \frac{p^2}{q} \gg 1 \quad \text{und} \quad |K_3| \approx \frac{2p^2}{q} \gg 1.$$

Der Algorithmus ist numerisch instabil und somit unbrauchbar, da eine (hier sogar alle) Konditionszahlen des Algorithmus wesentlich größer als die Konditionszahlen der Aufgabe sind, vgl. Bsp. 1.3.11. Die Ursache liegt – wie bereits diskutiert – in der Subtraktion im letzten Schritt des Verfahrens, bei der Stellenauslöschung auftritt. ♠

Durch Anwendung des Vietaschen Wurzelsatzes kann eine alternative Berechungsvorschrift angegeben werden, die numerisch stabil ist. Wir lösen dazu die folgende Übungsaufgabe.

Aufgabe 1.3.15. Ausgehend von (1.11) kann zum Berechnen von

$$\lambda = p - \sqrt{p^2 - q} = \frac{q}{p + \sqrt{p^2 - q}}, \quad p, q > 0, \;\; p^2 \gg q,$$

der folgende Algorithmus verwendet werden:

$$y_1 := p \cdot p, \quad y_2 := y_1 - q, \quad y_3 := \sqrt{y_2}, \quad y_4 := p + y_3, \quad \lambda := q/y_4.$$

Bestimmen Sie die Restabbildungen R_i, $i = 1, \ldots, 4$, und berechnen Sie die zugehörigen Konditionszahlen K_i, $i = 1, \ldots, 4$, des Algorithmus! Entscheiden Sie, ob der Algorithmus numerisch stabil ist! ◊

1.4 Lösungen der Aufgaben

Lösung 1.1.4.

$$\Delta_V = \tilde{V} - V = \frac{1}{3}\tilde{F}\cdot\tilde{h} - \frac{1}{3}F\cdot h = \frac{1}{3}\Big\{(F+\Delta_F)(h+\Delta_h) - F\cdot h\Big\}$$
$$= \frac{1}{3}\Big\{Fh + F\Delta_h + h\Delta_F + \Delta_F\Delta_h - Fh\Big\} = \frac{1}{3}\Big\{F\Delta_h + h\Delta_F + \Delta_F\Delta_h\Big\}.$$

♣

Lösung 1.2.2. Wegen $b = 2$ sind die in der Darstellung möglichen Ziffern gerade 0 und 1. Bei den normalisierte Gleitkommazahlen muss die erste Nachkommastelle der Mantisse von 0 verschieden sein. Zudem hat die Mantisse jeweils 3 Nachkommastellen. In untenstehender Tabelle erhalten wir also die erste Spalte aller vorkommenden Mantissen (1. Spalte). Die erste Nachkommastelle hat dabei den Wert $\frac{1}{2}$, die zweite den Wert $\frac{1}{4}$ und die dritte den Wert $\frac{1}{8}$. Für eine Mantisse $[0.\alpha_1\alpha_2\alpha_3]_3$ errechnet sich so ein Wert von $\frac{\alpha_1}{2} + \frac{\alpha_2}{4} + \frac{\alpha_3}{8}$ (siehe 2. Spalte).

Für die vorkommenden Exponenten $e \in \{-1, 0, 1, 2\}$ müssen alle Mantissen noch mit 2^e multipliziert werden. Diese Ergebnisse stehen in der dritten bis sechsten Spalte.

m	$x = \frac{\alpha_1}{2} + \frac{\alpha_2}{4} + \frac{\alpha_3}{8}$	$x\cdot 2^{-1}$	$x\cdot 2^{0}$	$x\cdot 2^{1}$	$x\cdot 2^{2}$
0.100	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{2}$	1	2
0.101	$\frac{1}{2}+\frac{1}{8}=\frac{5}{8}$	$\frac{5}{16}$	$\frac{5}{8}$	$\frac{5}{4}$	$\frac{5}{2}$
0.110	$\frac{1}{2}+\frac{1}{4}=\frac{3}{4}$	$\frac{3}{8}$	$\frac{3}{4}$	$\frac{3}{2}$	3
0.111	$\frac{1}{2}+\frac{1}{4}+\frac{1}{8}=\frac{7}{8}$	$\frac{7}{16}$	$\frac{7}{8}$	$\frac{7}{4}$	$\frac{7}{2}$

Sämtliche in der Tabelle aufgeführten Zahlen kommen zudem mit negativem Vorzeichen vor. Zusätzlich gehört noch die 0 zu $\mathbb{M}_2(3,[-1,2])$. ♣

Lösung 1.2.10. Wir arbeiten in $\mathbb{M}_2(4,[-7,7])$, d. h. mit Basis 2, der Mantissenlänge 4 und dem Exponentenbereich $-7,\ldots,7$. Die beiden Operanden sind

$$x = [0.1011]_2\cdot 2^0 = 1\cdot 2^{-1} + 0\cdot 2^{-2} + 1\cdot 2^{-3} + 1\cdot 2^{-4}$$

und

$$y = [0.1100]_2\cdot 2^0 = 1\cdot 2^{-1} + 1\cdot 2^{-2} + 0\cdot 2^{-3} + 0\cdot 2^{-4}$$

$\underline{z = x\ominus y:}$

$$x - y = -[0.1000]_2\cdot 2^{-3} \in \mathbb{M}_2(4,[-7,7]), \quad\Longrightarrow\quad x\ominus y = x - y = -[0.1000]_2\cdot 2^{-3}.$$

Die Rechnung wird also *exakt* ausgeführt.

$\underline{z = (y\ominus x)^{10}:}$

$$y\ominus x = [0.1000]_2\cdot 2^{-3} \quad\Longrightarrow\quad (y\ominus x)^{10} = [0.1000]_2\cdot 2^{-39}.$$

Exponent (-39) ist kleiner als -7, unterschreitet also den Exponentenbereich. Das Ergebnis wird auf 0 gerundet: $(y \ominus x)^{10} = 0$. Es findet ein *Unterlauf* statt

$\underline{z = x \oplus y :}$

$$x + y = [1.0111]_2 \cdot 2^0 \notin \mathbb{M}_2(4, [-7, 7]), \quad \Longrightarrow \quad x \oplus y = [0.1011]_2 \cdot 2^1.$$

Das Ergebnis ist durch Abschneiden der 5. Mantissenstelle *gerundet*.

$\underline{z = y \oplus (x \oslash 4) :}$ Zunächst ist $x \oslash 4 = [.1011]_2 \cdot 2^{-2} = x/4$, also

$$y + x \oslash 4 = [.111011]_2 \cdot 2^0 \notin \mathbb{M}_2(4, [-7, 7]), \quad \Longrightarrow \quad y \oplus (x \oslash 4) = [0.1110]_2 \cdot 2^0.$$

Das Ergebnis ist durch Abschneiden der 5. und 6. Mantissenstelle *gerundet*.

$\underline{z = x \oplus (y \oslash 4) :}$ Es ist $(y \oslash 4) = [0.1100]_2 \cdot 2^{-2} = y/4$, also

$$x + y \oslash 4 = [0.1110]_2 \cdot 2^0 \in \mathbb{M}_2(4, [-7, 7]), \quad \Longrightarrow \quad x \oplus (y \oslash 4) = y + x/4 = [0.1110]_2 \cdot 2^0.$$

Das Ergebnis ist *exakt*. ♣

Lösung 1.2.12. Sowohl die Multiplikation als auch die Addition von Maschinenzahlen werden mit relativen Fehlern kleiner als eps ausgeführt. Für die zweite Berechnungsvorschrift gilt somit

$$\begin{aligned} y_2 &= (a \otimes c) \oplus (b \otimes c) = (1 + e_3)(a \otimes c + b \otimes c) = (1 + e_3)((1 + e_4)ac + (1 + e_5)bc) \\ &= (1 + e_3)\left((1 + e_4)\frac{a}{a + b} + (1 + e_5)\frac{b}{a + b}\right)(a + b)c \end{aligned}$$

mit $|e_i| \leq \texttt{eps}$, $i = 3, 4, 5$.

Für den relativen Fehler ε_2 erhalten wir

$$\varepsilon_2 = e_3 + e_4\frac{a}{a + b} + e_5\frac{b}{a + b} + e_3\left(e_4\frac{a}{a + b} + e_5\frac{b}{a + b}\right) \doteq e_3 + e_4\frac{a}{a + b} + e_5\frac{b}{a + b}.$$

Bei Verwendung der ersten Berechnungsvorschrift addieren sich die Rundungsfehler, wie wir bereits gesehen haben. Die zweite Berechnungsvorschrift ist wesentlich ungünstiger falls $a \approx -b$, da $|a + b|$ sehr klein ist. Dann sind $|a/(a + b)|$ und $|b/(a + b)|$ sehr groß und die Fehler e_4 und e_5 werden signifikant verstärkt.

Ein Beispiel bei Rechnung auf dem Computer mit doppelter Genauigkeit ($\texttt{eps} = 2^{-52} \approx 1.1 \cdot 10^{-16}$) möge dieses Ergebnis verdeutlichen. Wir wählen die drei Gleitkommazahlen $a = 1 - 2^{-52}$, $b = -1$ und $c = 3/2$. Die relativen Fehler sind $\varepsilon_1 = 0$ bzw. $\varepsilon_2 = 1/3 \gg \texttt{eps}$.

Bei der zweiten Berechnungsvorschrift ist der relative Fehler ca. 10^{15} mal größer als die Maschinengenauigkeit. Das Ergebnis wäre also völlig unbrauchbar. ♣

Lösung 1.3.3. Seien $x \in (a, b)$ beliebig und $h > 0$ hinreichend klein, so dass $x \pm h \in [a, b]$. Nach Taylor existieren ein $\xi^- \in [x - h, x]$ und ein $\xi^+ \in [x, x + h]$ mit

$$f(x - h) = f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{6}f'''(\xi^-)$$

und

$$f(x + h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{6}f'''(\xi^+).$$

Es folgt

$$(\delta_h^* f)(x) - f'(x) = \frac{h^2}{12}\Big(f'''(\xi^+) + f'''(\xi^-)\Big)$$

Setze $M := \frac{1}{6}\,\|f'''\|_{[a,b]}$. Wir erhalten für den Approximationsfehler

$$\Big|(\delta_h^* f)(x) - f'(x)\Big| \le Mh^2.$$

Zur Analyse des Rundungsfehlereinflusses verfahren wir wie bei der Herleitung von (1.9):

$$f'(x) - \frac{f_\circ(x+h) - f_\circ(x-h)}{2h} = f'(x) - (\delta_h^* f)(x) + \frac{\varepsilon_1 f(x+h) - \varepsilon_2 f(x-h)}{2h},$$

woraus die Abschätzung

$$\left|f'(x) - \frac{f_\circ(x+h) - f_\circ(x-h)}{2h}\right| \le Mh^2 + \frac{\mathtt{eps}}{h} K_f\,\|f\|_{[a,b]}$$

folgt.

Minimierung der rechten Seite liefert die optimale Schrittweite $h^* \approx \mathtt{eps}^{1/3}$. Das zugehörige Fehlerniveau bei der Approximation der ersten Ableitung ist $\mathtt{eps}^{2/3}$.

Bei Rechnung mit doppelter Genauigkeit, also $\mathtt{eps} \approx 1.1 \cdot 10^{-16}$, ist $h^* \approx 4.8 \cdot 10^{-6}$ mit Fehlerniveau von ungefähr $2.3 \cdot 10^{-11}$. Insgesamt eine signifikante Verbesserung im Vergleich zur Verwendung der einseitigen Differenz δ_h im Abschnitt 1.3.1. Zu beachten ist aber, dass eine höhere Regularität (Differenzierbarkeit) der Funktion f erforderlich ist! ♣

Lösung 1.3.15. Algorithmus:

$$\begin{aligned}
y_1 &= r_1(p,q) = p \cdot p,\\
y_2 &= r_2(y_1,p,q) = y_1 - q,\\
y_3 &= r_3(y_1,y_2,p,q) = \sqrt{y_2},\\
y_4 &= r_4(y_1,y_2,y_3,p,q) = p + y_3,\\
\lambda &= r_5(y_1,y_2,y_3,y_4,p,q) = q/y_4.
\end{aligned}$$

Offenbar sind $\lambda, y_1, y_2, y_3 > 0$.

Die Restabbildungen sind:

$$\begin{aligned}
\lambda &= R_4(y_1,y_2,y_3,y_4,p,q) = r_5(p,q,y_1,y_2,y_3,y_4,p,q) = q/y_4,\\
&= R_3(y_1,y_2,y_3,p,q) = R_4(y_1,y_2,y_3,r_4(y_1,y_2,y_3,p,q),p,q) = q/(p+y_3),\\
&= R_2(y_1,y_2,p,q) = R_3(y_1,y_2,r_3(y_1,y_2,p,q),p,q) = q/(p+\sqrt{y_2}),\\
&= R_1(y_1,p,q) = R_2(y_1,r_2(y_1,p,q),p,q) = q/(p+\sqrt{y_1-q})
\end{aligned}$$

Die Konditionszahlen des Algorithmus sind

$$\begin{aligned}
K_1 &= \frac{y_1}{\lambda} D_1 R_1(y_1,p,q) = \frac{y_1}{\lambda}\,\frac{-q}{(p+\sqrt{y_1-q})^2}\,\frac{1}{2\sqrt{y_1-q}} = -\frac{y_1 q}{2\lambda y_3 y_4^2},\\
K_2 &= \frac{y_2}{\lambda} D_2 R_2(y_1,y_2,p,q) = \frac{y_2}{\lambda}\,\frac{-q}{(p+\sqrt{y_2})^2}\,\frac{1}{2\sqrt{y_2}} = -\frac{y_3 q}{2\lambda y_4^2},\\
K_3 &= \frac{y_3}{\lambda} D_3 R_3(y_1,y_2,y_3,p,q) = \frac{y_3}{\lambda}\,\frac{-q}{(p+y_3)^2} = -\frac{y_3 q}{\lambda y_4^2},\\
K_4 &= \frac{y_4}{\lambda} D_4 R_4(y_1,y_2,y_3,y_4,p,q) = \frac{y_4}{\lambda}\,\frac{-q}{y_4^2} = -\frac{q}{\lambda y_4}
\end{aligned}$$

In der gegebenen Situation, also $q \ll p^2$, gilt

$$y_2 \approx p^2, \quad y_3 \approx p, \quad y_4 \approx 2p \quad \text{und} \quad \lambda \approx \frac{q}{2p}$$

Woraus für die Konditionszahlen des Algorithmus

$$|K_1|, |K_2| \approx \frac{1}{4}, \quad |K_3| \approx \frac{1}{2} \quad \text{sowie} \quad |K_4| \approx 1$$

folgt. Die Konditionszahlen des Algorithmus besitzen die gleiche Größenordnung wie die der Aufgabe. Der Algorithmus ist damit numerisch stabil. ♣

Kapitel 2

Nichtlineare Gleichungen

Ein Aufgabengebiet der Numerischen Mathematik ist das Lösen nichtlinearer Gleichungen, z. B. $x = \mathrm{e}^{-x}$, um mit einem einfachen Beispiel zu beginnen. Aber auch die Bestimmung der lokalen Extrema einer differenzierbaren Funktion $g\colon \mathbb{R}^n \to \mathbb{R}$ führt auf ein i. Allg. nichtlineares Gleichungssystem. Potentielle Extremstellen $\boldsymbol{x}$ sind durch $\nabla g(\boldsymbol{x}) = \mathbf{0}$ charakterisiert.

Nichtlineare Gleichungen (und Gleichungssysteme) können i. Allg. nicht geschlossen gelöst werden, d. h. ihre Lösung(en) sind nicht in endlich vielen Schritten berechenbar. Oftmals ist es schon schwierig zu entscheiden, ob eine nichtlineare Gleichung überhaupt Lösungen besitzt und ggf. wie viele.

Wir werden zwei Klassen von Problemen betrachten.

Aufgabenstellung: Fixpunktaufgabe

Gegeben ist eine Funktion $\varphi : \mathbb{R}^n \to \mathbb{R}^n$, $n \in \mathbb{N}$. Gesucht ist ein **Fixpunkt** $\boldsymbol{x}^* \in \mathbb{R}^n$ von φ. Das ist ein Vektor $\boldsymbol{x}^* \in \mathbb{R}^n$ mit $\boldsymbol{x}^* = \varphi(\boldsymbol{x}^*)$.

Aufgabenstellung: Nullstellenaufgabe

Gegeben ist eine Funktion $f : \mathbb{R}^n \to \mathbb{R}^n$. Gesucht ist eine **Nullstelle** $\boldsymbol{x}^* \in \mathbb{R}^n$ von f, d. h. ein Vektor $\boldsymbol{x}^* \in \mathbb{R}^n$ mit $f(\boldsymbol{x}^*) = \mathbf{0}$.

Beide Aufgabenstellungen können ineinander überführt werden. Aus der Fixpunktaufgabe $\boldsymbol{x}^* = \varphi(\boldsymbol{x}^*)$ erhalten wir durch einfaches Umstellen die Nullstellenaufgabe $\boldsymbol{x}^* - \varphi(\boldsymbol{x}^*) = \mathbf{0}$. Umgekehrt lässt sich aus der Nullstellenaufgabe $f(\boldsymbol{x}^*) = \mathbf{0}$ eine Fixpunktaufgabe machen: $\boldsymbol{x}^* = \boldsymbol{x}^* - g(\boldsymbol{x}^*)f(\boldsymbol{x}^*)$, wobei $g\colon \mathbb{R}^n \to \mathbb{R}^{n,n}$ eine beliebige Funktion mit $g(\boldsymbol{x}^*) \neq 0$ sein kann.

Numerische Verfahren für nichtlineare Gleichungen generieren ausgehend von einem Startvektor $\boldsymbol{x}^0$ eine Folge von Iterierten[1] $\boldsymbol{x}^1, \boldsymbol{x}^2, \ldots$, die unter gewissen Voraussetzungen gegen die Lösung $\boldsymbol{x}^*$ des Problems konvergiert. Dabei wird einer Verfahrensvorschrift folgend, die Iterierte $\boldsymbol{x}^{k+1}$ aus den bereits bekannten Näherungen $\boldsymbol{x}^0, \ldots, \boldsymbol{x}^k$ (oder aus einer Teilmenge von ihnen) berechnet.

Wichtige Kriterien bei der Beurteilung iterativer Verfahren hinsichtlich ihrer Effizienz sind

[1] Für Folgen und indizierte Mengen im $\mathbb{R}^n$ verwenden wir die Notation $\boldsymbol{x}^n$ mit hochgestelltem Iterationsindex, ein tiefgestellter Index wie i in x_i^n bezeichnet die i-te Komponente der n-ten Iterierten. Im Eindimensionalen werden wir hiervon abweichen und den Iterationsindex tiefstellen.

Konvergenzgeschwindigkeit: Wie schnell konvergiert die Folge $(\boldsymbol{x}^k)_{k\in\mathbb{N}_0}$ für $k \to \infty$ gegen $\boldsymbol{x}^*$? Wie kann die Konvergenzgeschwindigkeit charakterisiert werden?

Aufwand: Wie teuer ist die Berechnung einer Iterierten $\boldsymbol{x}^k$ mit Blick auf Rechenzeit und Speicherbedarf?

2.1 Intermezzo: Etwas Analysis

Bevor wir uns den numerischen Aspekten nichtlinearer Gleichungen zuwenden, wollen wir zwei grundlegende Begriffe aus der Analysis rekapitulieren: normierte und vollständige Räume. Ergänzend werden wir Normen für Matrizen einführen.

2.1.1 Normierte und vollständige Vektorräume

Definition 2.1.1: Norm

Sei $\mathbb{V}$ ein Vektorraum über $\mathbb{R}$. Eine Abbildung $\|\cdot\| : \mathbb{V} \to \mathbb{R}$ heißt **Norm** auf $\mathbb{V}$, falls sie die folgenden drei Eigenschaften besitzt.

N_1: $\|\cdot\|$ ist **positiv definit**, d. h.,

$$\|\boldsymbol{x}\| > 0 \quad \forall\, \boldsymbol{x} \in \mathbb{V} \setminus \{\mathbf{0}\}.$$

N_2: $\|\cdot\|$ ist **absolut homogen**, d. h.,

$$\|\alpha \boldsymbol{x}\| = |\alpha|\, \|\boldsymbol{x}\| \quad \forall\, \boldsymbol{x} \in \mathbb{V},\ \alpha \in \mathbb{R}.$$

N_3: Es gilt die **Dreiecksungleichung**

$$\|\boldsymbol{x} + \boldsymbol{y}\| \leq \|\boldsymbol{x}\| + \|\boldsymbol{y}\| \quad \forall\, \boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}.$$

Das Paar $(\mathbb{V}, \|\cdot\|)$ wird als **normierter Vektorraum** bezeichnet, vgl. *Lehrtext Analysis*, Definition 1.4.1.

Sofern klar ist, welche Norm betrachtet wird, schreiben wir auch kurz $\mathbb{V}$ statt $(\mathbb{V}, \|\cdot\|)$.

Für den Nullvektor $\mathbf{0} \in \mathbb{V}$ folgt aus Eigenschaft N_2

$$\|\mathbf{0}\| = \|0 \cdot \mathbf{0}\| = 0\, \|\mathbf{0}\| = 0.$$

Zusammen mit N_1 können wir weiterhin schlussfolgern, dass $\|\boldsymbol{x}\| = 0$ genau dann, wenn $\boldsymbol{x} = \mathbf{0}$.

Bekanntestes Beispiel einer Norm für Vektoren $\boldsymbol{x} = (x_1, \ldots, x_n)^T \in \mathbb{R}^n$ ist die **Euklid**[2]**ische Norm** $\|\cdot\|_2$. Sie ist definiert durch

$$\|\boldsymbol{x}\|_2 := \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}.$$

Für die Numerik sind zwei weitere Normen von Bedeutung, nämlich die **Summen-** und die **Maximumnorm**

$$\|\boldsymbol{x}\|_1 := \sum_{i=1}^{n} |x_i| \quad \text{und} \quad \|\boldsymbol{x}\|_\infty := \max_{i=1,\ldots,n} |x_i|\,,$$

[2]Euklid von Alexandria, *ca. 365 BC (Alexandria?), †ca. 265 (Alexandria, heute Ägypten)

vgl. auch *Lehrtext Analysis*, Satz/Definition 1.4.4.

Dass $\|\cdot\|_\infty$ eine Norm auf $\mathbb{R}^n$ ist, überlegen wir uns schnell. Eigenschaften N_1 und N_2 sind evident. Die Dreiecksungleichung (N_3) folgt aus der für $\mathbb{R}$ bekannten Dreiecksungleichung. Sind $\boldsymbol{x}$ und $\boldsymbol{y}$ zwei beliebige Vektoren in $\mathbb{R}^n$, dann gilt

$$|x_i + y_i| \leq |x_i| + |y_i| \leq \|\boldsymbol{x}\|_\infty + \|\boldsymbol{y}\|_\infty , \quad i = 1, \ldots, n.$$

Nach Übergang zum Maximum auf der linken Seite erhalten wir

$$\|\boldsymbol{x} + \boldsymbol{y}\|_\infty \leq \|\boldsymbol{x}\|_\infty + \|\boldsymbol{y}\|_\infty ,$$

also die Dreiecksungleichung für die Maximumnorm.

Aufgabe 2.1.2. Zeigen Sie, dass die Summennorm $\|\cdot\|_1$ eine Norm auf $\mathbb{R}^n$ ist! Verifizieren Sie dazu die drei Norm-Axiome. ◊

Die verschiedenen Normen auf $\mathbb{R}^n$ können gegeneinander abgeschätzt werden. Wir lösen dazu exemplarisch die folgende Übungsaufgabe.

Aufgabe 2.1.3. Zeigen Sie, dass für beliebige Vektoren $\boldsymbol{x} \in \mathbb{R}^n$ die Abschätzungen

$$\|\boldsymbol{x}\|_\infty \leq \|\boldsymbol{x}\|_1 \leq n \, \|\boldsymbol{x}\|_\infty ,$$

gelten und diese nicht verbessert werden können, d. h. dass es Vektoren $\boldsymbol{x} \neq \boldsymbol{0}$ gibt, für die Gleichheit in den einzelnen Ungleichungen gilt. ◊

Definition 2.1.4: Äquivalenz von Normen

Zwei Normen $\|\cdot\|$ und $\|\cdot\|_*$ auf einem Vektorraum $\mathbb{V}$ werden als **äquivalent** bezeichnet, falls Konstanten $A, B > 0$ existieren, so dass

$$A \, \|\boldsymbol{x}\| \leq \|\boldsymbol{x}\|_* \leq B \, \|\boldsymbol{x}\| \quad \forall \, \boldsymbol{x} \in \mathbb{V}.$$

Einem Beispiel für die Äquivalenz von Normen sind wir bereits in Aufg. 2.1.3 begegnet. Allgemeiner gilt folgender Satz. Er ist eine Folgerung aus Hilfssatz 1.5.10 im *Lehrtext Analysis*.

Satz 2.1.5: Normäquivalenzsatz

Auf $\mathbb{R}^n$ sind alle Normen äquivalent.

Abschließend möchten wir uns mit dem Begriff der **Vollständigkeit** beschäftigen. Er ist zentral, um die Existenz von Lösungen sowohl der Fixpunktaufgabe als auch der Nullstellenaufgabe zu sichern.

Definition 2.1.6: Cauchy-Folgen, Banach-Raum

Eine Folge $(x_n)_{n\in\mathbb{N}}$ von Elementen eines normierten Raumes $(\mathbb{V}, \|\cdot\|)$ heißt

(i) konvergent gegen ein Element $x \in \mathbb{V}$, falls für alle $\varepsilon > 0$ ein $n_0 \in \mathbb{N}$ existiert, so dass $\|x_n - x\| < \varepsilon$ für alle $n \geq n_0$, vgl. *Lehrtext Analysis*, Definition 1.5.4.

(ii) **Cauchy[3]-Folge**, falls für alle $\varepsilon > 0$ ein $n_0 \in \mathbb{N}$ existiert, so dass $\|x_n - x_m\| < \varepsilon$ für alle $n, m \geq n_0$, vgl. *Lehrtext Analysis*, Definition 1.5.14.

Ein normierter Raum heißt **vollständig** oder auch **Banach[4]-Raum**, wenn in ihm jede Cauchy-Folge konvergiert, vgl. *Lehrtext Analysis*, Definition 1.5.17.

Satz 2.1.7

Versehen mit einer beliebigen Norm ist der $\mathbb{R}^n$ ein Banach-Raum.

Beweis. Dies ist Satz 1.5.18 im *Lehrtext Analysis*. □

2.1.2 Matrizen und Matrixnormen

Normen auf Vektorräumen gestatten es uns, in diesen Räumen zu messen, z. B. die Länge eines Vektors oder die Differenz zweier Vektoren – in einem gewissen, durch die Norm festgelegtem, Sinn. Aus der Linearen Algebra ist bekannt, dass die Vektorraumhomomorphismen — zu denen auch die Matrizen gehören — ebenfalls Vektorräume bilden. Diese Räume möchten wir ebenfalls mit Normen ausstatten. Um sinnvoll mit ihnen arbeiten zu können, müssen sie zu den Vektornormen passen. Was dies konkret bedeutet, werden wir gleich sehen.

Diese Konzepte sind wichtig bei der Konvergenzanalysis für iterative Verfahren in den späteren Abschnitten dieses Kapitels.

Aus der Linearen Algebra ist bekannt, dass der Raum der **Vektorraumhomomorphismen** (oder linearen Abbildungen) $\mathrm{Hom}(\mathbb{R}^m, \mathbb{R}^n)$, $m, n \in \mathbb{N}$, isomorph zum Raum der $m \times n$-Matrizen $\mathbb{R}^{m,n}$ ist. Ist $\boldsymbol{A} \in \mathbb{R}^{m,n}$, dann beschreibt

$$L_A : \mathbb{R}^n \to \mathbb{R}^m : \boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$$

eine **lineare Abbildung** von $\mathbb{R}^n$ nach $\mathbb{R}^m$, also $L_A \in \mathrm{Hom}(\mathbb{R}^n, \mathbb{R}^m)$. Umgekehrt sind die Spalten von $\boldsymbol{A}$ die Bilder der kanonischen Basisvektoren $\boldsymbol{e}^i$ unter L_A. Die Zuordnung von linearen Abbildungen in $\mathrm{Hom}(\mathbb{R}^n, \mathbb{R}^m)$ zu Matrizen in $\mathbb{R}^{m,n}$ ist somit eineindeutig. Die Menge $\mathrm{Hom}(\mathbb{R}^n, \mathbb{R}^m)$ der Vektorraumhomomorphismen ist ihrerseits ein Vektorraum über $\mathbb{R}$.

Ein Spezialfall ist jener der quadratischen Matrizen $\mathbb{R}^{n,n}$, $n \in \mathbb{N}$. Für diese wollen wir jetzt Normen einführen, mit denen in Verbindung mit einer auf $\mathbb{R}^n$ gegebenen Norm sinnvoll gearbeitet werden kann. Dabei muss darauf geachtet werden, dass die jeweils verwendeten Normen zueinander passen, miteinander verträglich sind. Insbesondere muss auch die Matrixmultiplikation berücksichtigt werden.

[3] Augustin Louis Cauchy, *21.08.1789 (Paris), †23.05.1857 (Sceaux, bei Paris)

[4] Stefan Banach, 30.3.1892 (Kraków, Österreich-Ungarn), †31.8.1945 (Lwiw, Ukraine)

Definition 2.1.8: Matrixnorm, Verträglichkeit

(i) Eine Norm $\|\cdot\|_*$ auf $\mathbb{R}^{n,n}$, $n \in \mathbb{N}$, heißt **submultiplikativ** falls

$$\|\boldsymbol{A}\boldsymbol{B}\|_* \leq \|\boldsymbol{A}\|_* \|\boldsymbol{B}\|_* \quad \forall\, \boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n,n}.$$

Eine submultiplikative Norm $\|\cdot\|_*$ auf dem Raum $\mathbb{R}^{n,n}$ heißt **Matrixnorm**.

(ii) Eine Norm $\|\cdot\|_*$ auf $\mathbb{R}^{n,n}$ heißt **verträglich** mit der Norm $\|\cdot\|$ auf $\mathbb{R}^n$, falls

$$\|\boldsymbol{A}\boldsymbol{x}\| \leq \|\boldsymbol{A}\|_* \|\boldsymbol{x}\|, \quad \forall\, \boldsymbol{A} \in \mathbb{R}^{n,n},\ \boldsymbol{x} \in \mathbb{R}^n.$$

Satz 2.1.9

Sei $(\mathbb{R}^n, \|\cdot\|)$ ein normierter Vektorraum. Die Abbildung

$$|||\cdot||| : \mathbb{R}^{n,n} \to \mathbb{R} : \boldsymbol{A} \mapsto |||\boldsymbol{A}||| := \max_{\boldsymbol{x} \in \mathbb{R}^n \setminus \{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \tag{2.1}$$

ist eine submultiplikative Norm und mit der Vektornorm $\|\cdot\|$ verträglich. Sie wird als die der Vektornorm $\|\cdot\|$ **zugeordnete Matrixnorm** bezeichnet.

Die Verträglichkeit der Matrixnorm $|||\cdot|||$ mit der Vektornorm folgt unmittelbar aus (2.1) durch Multiplikation mit $\|\boldsymbol{x}\|$:

$$\|\boldsymbol{A}\boldsymbol{x}\| \leq |||\boldsymbol{A}||| \, \|\boldsymbol{x}\|, \quad \forall \boldsymbol{A} \in \mathbb{R}^{n,n}, \boldsymbol{x} \in \mathbb{R},$$

zu zeigen bleibt, dass $|||\cdot|||$ eine Norm auf $\mathbb{R}^{n,n}$ ist, und dass diese submultiplikativ ist.

Aufgabe 2.1.10. Zeigen Sie, dass $|||\cdot|||$ eine Norm und submultiplikativ ist! ◊

Bemerkung 2.1.11. Für alle $\boldsymbol{x} \in \mathbb{R}^n \setminus \{\boldsymbol{0}\}$ ist $\boldsymbol{v} := \boldsymbol{x}/\|\boldsymbol{x}\|$ ein Vektor mit $\|\boldsymbol{v}\| = 1$. Wegen der absoluten Homogenität der Norm und der Linearität von L ist

$$\frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \left\| \frac{1}{\|\boldsymbol{x}\|} \boldsymbol{A}\boldsymbol{x} \right\| = \left\| \boldsymbol{A} \left(\frac{\boldsymbol{x}}{\|\boldsymbol{x}\|} \right) \right\| = \|\boldsymbol{A}\boldsymbol{v}\|.$$

Daher lässt sich $|||\cdot|||$ äquivalent durch

$$|||\boldsymbol{A}||| := \max_{\boldsymbol{v} \in \mathbb{R}^n :\, \|\boldsymbol{v}\| = 1} \|\boldsymbol{A}\boldsymbol{v}\|$$

definieren.

Aufgabe 2.1.12. Nicht jede Norm auf $\mathbb{R}^{n,n}$ ist eine Matrixnorm. Konstruieren Sie eine Norm auf $\mathbb{R}^{2,2}$, die nicht submultiplikativ und somit keine Matrixnorm ist! ◊

In formaler Analogie zur Euklidischen Vektornorm wird durch

$$\|\boldsymbol{A}\|_F := \left\{ \sum_{i,j=1}^{n} |a_{ij}|^2 \right\}^{1/2} = \sqrt{\mathrm{Spur}(\boldsymbol{A}^H \boldsymbol{A})}$$

eine Norm auf $\mathbb{R}^{n,n}$ definiert, die sog. **Frobenius[5]-Norm**.

[5] Ferdinand Georg Frobenius, *26.10.1849 (Charlottenburg, Preußen), †3.8.1917 (Berlin, Deutschland)

Aufgabe 2.1.13. Beweisen Sie: (a) Die Frobenius-Norm $\|\cdot\|_F$ ist submultiplikativ und somit eine Matrixnorm. (b) Sie ist mit der Euklidischen Norm $\|\cdot\|_2$ verträglich. ◊

Aufgabe 2.1.14. Es bezeichne $\|\cdot\|$ eine Vektornorm auf $\mathbb{R}^n$ und $|||\cdot|||$ die zugeordnete Matrixnorm. Beweisen Sie: Ist $\|\cdot\|_*$ eine mit $\|\cdot\|$ verträgliche Matrixnorm, dann gilt $|||\boldsymbol{A}||| \leq \|\boldsymbol{A}\|_*$ für alle $\boldsymbol{A} \in \mathbb{R}^{n,n}$. ◊

Einige wichtige zugeordnete Matrixnormen sind die folgenden.

- **Zeilensummennorm** (der Maximumnorm zugeordnet)

$$\|\boldsymbol{A}\|_\infty := \max_{i=1,\dots,n} \sum_{j=1}^{n} \left|a_{ij}\right|$$

- **Spaltensummennorm** (der Summennorm zugeordnet)

$$\|\boldsymbol{A}\|_1 := \max_{j=1,\dots,n} \sum_{i=1}^{n} \left|a_{ij}\right| = \left\|\boldsymbol{A}^H\right\|_\infty$$

- **Spektralnorm** (der Euklidischen Norm zugeordnet)

$$\|\boldsymbol{A}\|_2 := \varrho(\boldsymbol{A}^H\boldsymbol{A})^{1/2},$$

  wobei $\varrho(\boldsymbol{B})$ den **Spektralradius** der Matrix $\boldsymbol{B}$, also den Betrag des betragsgrößten Eigenwertes von $\boldsymbol{B}$ bezeichnet:

$$\varrho(\boldsymbol{B}) := \max\Big\{|\lambda| : \lambda \in \sigma(\boldsymbol{B})\Big\}.$$

  Die Menge $\sigma(\boldsymbol{B}) := \{\lambda \in \mathbb{C} : \lambda \text{ ist Eigenwert von } \boldsymbol{B}\}$ wird als das **Spektrum** der Matrix $\boldsymbol{B}$ bezeichnet.

Aufgabe 2.1.15. Beweisen Sie, dass die Zeilensummennorm der Maximumnorm zugeordnet ist! ◊

Aufgabe 2.1.16. Beweisen Sie: Für jede beliebige Matrix $\boldsymbol{A} \in \mathbb{R}^{n,n}$ sind alle Eigenwerte von $\boldsymbol{A}^T\boldsymbol{A}$ reell und nicht negativ! (Daraus können wir dann schließen, dass $\|\boldsymbol{A}\|_2 = \max\{\sqrt{\lambda} : \lambda \in \sigma(\boldsymbol{A}^T\boldsymbol{A})\}$.) ◊

Wir haben im Satz 2.1.9 gesehen, dass zu jeder Vektornorm eine Matrixnorm existiert, die mit ihr verträglich ist, nämlich die der Vektornorm zugeordnete Matrixnorm. Natürlich kann man auch die umgekehrte Frage stellen: Gibt es zu einer gegebenen Matrixnorm eine Vektornorm derart, dass sie miteinander verträglich sind? Dazu lösen wir folgende Übungsaufgabe.

Aufgabe 2.1.17. (a) Weisen Sie nach: Zu jeder Matrixnorm $\|\cdot\|_*$ auf $\mathbb{R}^{n,n}$ existiert eine Vektornorm $\|\cdot\|$ auf $\mathbb{R}^n$ mit der $\|\cdot\|_*$ verträglich ist.

(b) Gibt es zu einer gegebenen Matrixnorm $\|\cdot\|_*$ stets eine Vektornorm auf $\mathbb{R}^n$, der $\|\cdot\|_*$ zugeordnet ist? ◊

2.1.3 Das Störungslemma

In diesem Abschnitt stellen wir ein Hilfsmittel zur Verfügung, das es uns später gestattet, die Fehlerfortpflanzung beim Lösen linearer Gleichungssysteme, aber auch die Konvergenz bestimmter iterativer Verfahren für nichtlineare Gleichungssysteme zu analysieren.

Satz 2.1.18

Sei $\|\cdot\|$ eine Matrixnorm auf $\mathbb{R}^{n,n}$. Sei $\boldsymbol{C} \in \mathbb{R}^{n,n}$ eine Matrix mit $\|\boldsymbol{C}\| < 1$. Dann ist $\boldsymbol{I}_n - \boldsymbol{C}$ invertierbar, und es gilt

$$(\boldsymbol{I}_n - \boldsymbol{C})^{-1} = \sum_{i=0}^{\infty} \boldsymbol{C}^i = \boldsymbol{I}_n + \boldsymbol{C} + \boldsymbol{C}^2 + \boldsymbol{C}^3 + \cdots \tag{2.2}$$

Bemerkung 2.1.19. Die Reihe in (2.2) wird als NEUMANN[6]sche Reihe bezeichnet.

Beweis. (i) Wir beweisen zunächst indirekt die Invertierbarkeit der Matrix $\boldsymbol{I}_n - \boldsymbol{C}$. Angenommen, $\boldsymbol{I}_n - \boldsymbol{C}$ ist singulär. Dann existiert ein Vektor $\boldsymbol{x} \neq \boldsymbol{0}$ mit $(\boldsymbol{I}_n - \boldsymbol{C})\,\boldsymbol{x} = \boldsymbol{0}$, also $\boldsymbol{x} = \boldsymbol{C}\boldsymbol{x}$. Nach Aufg. 2.1.17 existiert eine Vektornorm $\|\cdot\|_*$, mit der die Matrixnorm $\|\cdot\|$ verträglich ist. Es folgt

$$\|\boldsymbol{x}\|_* = \|\boldsymbol{C}\boldsymbol{x}\|_* \leq \|\boldsymbol{C}\|\,\|\boldsymbol{x}\|_* .$$

Division durch $\|\boldsymbol{x}\|_*$ impliziert $\|\boldsymbol{C}\| \geq 1$, was im Widerspruch zur Voraussetzung $\|\boldsymbol{C}\| < 1$ steht.

(ii) Wir widmen uns jetzt (2.2) und weisen dazu nach, dass die Folge der Partialsummen der NEUMANNschen Reihe gegen $(\boldsymbol{I}_n - \boldsymbol{C})^{-1}$ konvergiert, also

$$\lim_{k\to\infty} \sum_{i=0}^{k} \boldsymbol{C}^i = (\boldsymbol{I}_n - \boldsymbol{C})^{-1} \quad \text{bzw.} \quad \lim_{k\to\infty} (\boldsymbol{I}_n - \boldsymbol{C}) \sum_{i=0}^{k} \boldsymbol{C}^i = \boldsymbol{I}_n.$$

Es gilt (Teleskopsumme)

$$(\boldsymbol{I}_n - \boldsymbol{C}) \sum_{i=0}^{k} \boldsymbol{C}^i = \sum_{i=0}^{k} \left(\boldsymbol{C}^i - \boldsymbol{C}^{i+1}\right) = \boldsymbol{I}_n - \boldsymbol{C}^{k+1}. \tag{2.3}$$

Die Submultiplikativität der Matrixnorm impliziert $\|\boldsymbol{C}^i\| \leq \|\boldsymbol{C}\|^i$, $i = 1, 2, \ldots$ Wegen $\|\boldsymbol{C}\| < 1$ folgt somit, dass $(\|\boldsymbol{C}\|^i)_{i=0,1,\ldots}$ eine geometrische Folge mit Grenzwert 0 ist. Es folgt $\lim\limits_{k\to\infty} \boldsymbol{C}^{k+1} = \boldsymbol{0}$.

Mittels Grenzübergang für $k \to \infty$ in (2.3) erhalten wir (2.2). □

Satz 2.1.20: Störungslemma

Sei $\|\cdot\|$ eine zugeordnete Matrixnorm. Ist $\boldsymbol{A} \in \mathbb{R}^{n,n}$ eine invertierbare Matrix und $\Delta_{\boldsymbol{A}} \in \mathbb{R}^{n,n}$ eine Störung von $\boldsymbol{A}$ mit $\left\|\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right\| < 1$, dann ist die Matrix $\boldsymbol{A} + \Delta_{\boldsymbol{A}}$ ebenfalls invertierbar und es gilt

$$\left\|(\boldsymbol{A} + \Delta_{\boldsymbol{A}})^{-1}\right\| \leq \frac{\left\|\boldsymbol{A}^{-1}\right\|}{1 - \left\|\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right\|}.$$

[6]Carl Gottfried Neumann, *7.5.1832 (Königsberg, Preußen), †27.3.1925 (Leipzig)

Beweis. *(i)* Zunächst folgt aus Satz 2.1.18 mit $\boldsymbol{C} := -\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}$ die Invertierbarkeit von $\boldsymbol{I}_n + \boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}$ und jene von $\boldsymbol{A} + \Delta_{\boldsymbol{A}} = \boldsymbol{A}\left(\boldsymbol{I}_n + \boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right)$.

(ii) Unter Verwendung der Neumannschen Reihe haben wir die Darstellung

$$(\boldsymbol{A} + \Delta_{\boldsymbol{A}})^{-1} = \left(\boldsymbol{I}_n + \boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right)^{-1}\boldsymbol{A}^{-1} = \left\{\boldsymbol{I}_n + \sum_{k=1}^{\infty}\left(-\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right)^k\right\}\boldsymbol{A}^{-1},$$

aus der wir mit Hilfe der Dreiecksungleichung und der Submultiplikativität der Matrixnorm $\|\cdot\|$ die folgende Abschätzung herleiten

$$\left\|(\boldsymbol{A} + \Delta_{\boldsymbol{A}})^{-1}\right\| \leq \left\{1 + \sum_{k=1}^{\infty}\left\|\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right\|^k\right\}\left\|\boldsymbol{A}^{-1}\right\|.$$

Es folgt (geometrische Reihe!)

$$\left\|(\boldsymbol{A} + \Delta_{\boldsymbol{A}})^{-1}\right\| \leq \frac{1}{1 - \left\|\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right\|}\left\|\boldsymbol{A}^{-1}\right\|,$$

da $\left\|\boldsymbol{A}^{-1}\Delta_{\boldsymbol{A}}\right\| < 1$. □

Anschaulich formuliert bedeutet das Störungslemma, dass eine kleine Störung einer invertierbaren Matrix nichts an der Invertierbarkeit der Matrix ändert.

Anders stellt sich die Situation bei nicht invertierbaren Matrizen dar: In jeder beliebig kleinen Umgebung (im Sinne einer Matrixnorm) einer solchen Matrix befindet sich eine invertierbare Matrix.

Nicht invertierbare Matrizen sind durch linear abhängige Spaltenvektoren (bzw. Zeilenvektoren) gekennzeichnet. Bereits eine minimale Modifikation – z. B. durch Rundung bei Repräsentation durch Maschinenzahlen – einzelner Komponenten dieser Vektoren kann dazu führen, dass diese Vektoren linear unabhängig werden. Die Arbeit mit singulären Matrizen stellt daher eine gewisse Herausforderung für die numerische Mathematik dar.

2.1.4 Integrale vektorwertiger Funktionen

Ableitungen multivariater und vektorwertiger Funktionen $\boldsymbol{f}\colon \mathbb{R}^m \to \mathbb{R}^n$ haben Sie in der Lektion 3 der Lehrveranstaltung *Analysis* (Modul 61211) kennengelernt. U. a. sind Sie dem Begriff der **Jacobi-Matrix** von Funktionen $\boldsymbol{f} = (f_1, \ldots, f_n)^T : \mathbb{R}^n \to \mathbb{R}^n$ begegnet:

$$\boldsymbol{f}' := \begin{pmatrix} D_1 f_1 & D_2 f_1 & \cdots & D_n f_1 \\ D_1 f_2 & D_2 f_2 & \cdots & D_n f_2 \\ \vdots & \vdots & \ddots & \vdots \\ D_1 f_n & D_2 f_n & \cdots & D_n f_n \end{pmatrix},$$

Für Funktionen $\boldsymbol{f} = (f_1, \ldots, f_n)^T : \mathbb{R} \to \mathbb{R}^n$ nutzen wir die Bezeichnung

$$\boldsymbol{f}' := (f_1', f_2', \ldots, f_n')^T.$$

Definition 2.1.21: RIEMANN-Integral vektorwertiger Funktionen

Sei $\boldsymbol{f} = (f_1, \ldots, f_n)^T : [a,b] \to \mathbb{R}^n$ eine vektorwertige Funktion mit RIEMANN-integrierbaren Koordinatenfunktionen f_i, $i = 1, \ldots, n$.

Dann nennen wir den Vektor

$$\int_a^b \boldsymbol{f}(x)\,\mathrm{d}x := \left(\int_a^b f_1(x)\,\mathrm{d}x, \ldots, \int_a^b f_n(x)\,\mathrm{d}x \right)^T \in \mathbb{R}^n,$$

das **RIEMANN-Integral** der Funktion $\boldsymbol{f}$ und die Funktion **RIEMANN-integrierbar**.

Durch Anwendung des Hauptsatzes der Differential- und Integralrechnung auf die einzelnen Komponenten ergeben sich die folgenden Zusammenhänge.

Satz 2.1.22

(i) Sei $\boldsymbol{f} : [a,b] \to \mathbb{R}^n$ stetig differenzierbar.

Dann gilt

$$\boldsymbol{f}(x) - \boldsymbol{f}(\xi) = \int_\xi^x \boldsymbol{f}'(t)\,\mathrm{d}t \quad \forall\, x, \xi \in [a,b].$$

(ii) Sei $\boldsymbol{g} : [a,b] \to \mathbb{R}^n$ stetig.

Dann ist für alle $\xi \in [a,b]$ die Funktion

$$\boldsymbol{f} : [a,b] \to \mathbb{R}^n : x \mapsto \boldsymbol{f}(x) = \int_\xi^x \boldsymbol{g}(t)\,\mathrm{d}t,$$

auf $[a,b]$ differenzierbar und es gilt $\boldsymbol{f}' = \boldsymbol{g}$

Mit Hilfe der ersten Aussage lässt sich der nächste Satz beweisen.

Satz 2.1.23

Sei $\boldsymbol{f} : M \subset \mathbb{R}^n \to \mathbb{R}^n$ stetig differenzierbar.

Dann gilt für alle Punkte $\boldsymbol{x}, \boldsymbol{\xi} \in M$, deren Verbindungsstrecke ganz im Inneren von M liegt

$$\boldsymbol{f}(\boldsymbol{x}) - \boldsymbol{f}(\boldsymbol{\xi}) = \int_0^1 \boldsymbol{f}'(\boldsymbol{\xi} + t(\boldsymbol{x} - \boldsymbol{\xi}))\,(\boldsymbol{x} - \boldsymbol{\xi})\;\mathrm{d}t.$$

Beweis. Wir führen die Hilfsfunktion

$$\boldsymbol{\varphi} : [0,1] \to \mathbb{R}^n : t \mapsto \boldsymbol{f}(\boldsymbol{\xi} + t\,(\boldsymbol{x} - \boldsymbol{\xi})).$$

ein. Diese ist so konstruiert, dass

$$\boldsymbol{f}(\boldsymbol{x}) - \boldsymbol{f}(\boldsymbol{\xi}) = \boldsymbol{\varphi}(1) - \boldsymbol{\varphi}(0).$$

Aus Satz 2.1.22.(i) folgern wir nun:

$$\boldsymbol{f}(\boldsymbol{x}) - \boldsymbol{f}(\boldsymbol{\xi}) = \int_0^1 \boldsymbol{\varphi}'(t)\,\mathrm{d}t. \tag{2.4}$$

Für die Bestimmung von $\boldsymbol{\varphi}'$ schreiben wir die i-te Komponente von $\boldsymbol{\varphi}$ ausführlich als

$$\varphi_i(t) = f_i\Big(\xi_1 + t(x_1 - \xi_1), \xi_2 + t(x_2 - \xi_2), \ldots, \xi_n + t(x_n - \xi_n)\Big).$$

Wir differenzieren nach t und wenden die Kettenregel an:

$$\begin{aligned}
\varphi_i'(t) &= D_1 f_i\Big(\xi_1 + t(x_1 - \xi_1), \xi_2 + t(x_2 - \xi_2), \ldots, \xi_n + t(x_n - \xi_n)\Big)(x_1 - \xi_1) \\
&\quad + D_2 f_i\Big(\xi_1 + t(x_1 - \xi_1), \xi_2 + t(x_2 - \xi_2), \ldots, \xi_n + t(x_n - \xi_n)\Big)(x_2 - \xi_2) \\
&\quad + \cdots \\
&\quad + D_n f_i\Big(\xi_1 + t(x_1 - \xi_1), \xi_2 + t(x_2 - \xi_2), \ldots, \xi_n + t(x_n - \xi_n)\Big)(x_n - \xi_n) \\
&= \Big(D_1 f_i\left(\boldsymbol{\xi} + t(\boldsymbol{x} - \boldsymbol{\xi}\right), D_2 f_i\left(\boldsymbol{\xi} + t(\boldsymbol{x} - \boldsymbol{\xi}\right), \ldots, D_n f_i\left(\boldsymbol{\xi} + t(\boldsymbol{x} - \boldsymbol{\xi}\right)\Big)\,(\boldsymbol{x} - \boldsymbol{\xi}).
\end{aligned}$$

Die $D_1 f_i, D_2 f_i, \ldots, D_n f_i$ bilden die i-te Zeile der Jacobi-Matrix von $\boldsymbol{f}$, und wir können den Vektor $\boldsymbol{\varphi}'$ kompakt als

$$\boldsymbol{\varphi}'(t) = \boldsymbol{f}'(\boldsymbol{\xi} + t(\boldsymbol{x} - \boldsymbol{\xi}))\,(\boldsymbol{x} - \boldsymbol{\xi})$$

schreiben. Diese Darstellung setzen wir in (2.4) ein und erhalten die Behauptung des Satzes. □

Aus der Lehrveranstaltung *Analysis* (Modul 61211, Satz 5.1.7.(v) ist Ihnen bekannt, dass für (skalare) Riemann-integrierbare Funktionen $f\colon [a,b] \to \mathbb{R}$, $a < b$, gilt

$$\left|\int_a^b f(t)\,\mathrm{d}t\right| \le \int_a^b |f(t)|\,\mathrm{d}t\,.$$

Eine analoge Aussage gib es für vektorwertige Funktionen, allerdings für die Norm statt des Betrags. Der Nachweis der Aussage erfolgt durch Betrachtung der Riemann-Summen für die Integrale auf den beiden Seiten der Ungleichung.

Satz 2.1.24

Sei $\boldsymbol{f}\colon [a,b] \to \mathbb{R}^n$ Riemann-integrierbar, $a < b$.

Dann gilt für jede Norm $\|\cdot\|$ auf $\mathbb{R}^n$

$$\left\|\int_a^b \boldsymbol{f}(t)\,\mathrm{d}t\right\| \le \int_a^b \|\boldsymbol{f}(t)\|\,\mathrm{d}t\,.$$

2.1.5 Fehler vektorwertiger Größen

Für vektorwertige Größen bedarf insbesondere der Begriff des **relativen Fehlers** einer gewissen Anpassung, da die Division durch einen Vektor nicht definiert ist.

Definition 2.1.25

Seien $(\mathbb{R}^n, \|\cdot\|)$ ein normierter Vektorraum und $\boldsymbol{x}, \tilde{\boldsymbol{x}} \in \mathbb{R}^n$, wobei wir $\tilde{\boldsymbol{x}}$ als Näherung der Größe $\boldsymbol{x}$ interpretieren. Wir nennen

$$\Delta_{\boldsymbol{x}} := \tilde{\boldsymbol{x}} - \boldsymbol{x}$$

den **absoluten Fehler** von $\boldsymbol{x}$ und

$$\varepsilon_{\boldsymbol{x}} := \frac{\|\Delta_{\boldsymbol{x}}\|}{\|\boldsymbol{x}\|} = \frac{\|\tilde{\boldsymbol{x}} - \boldsymbol{x}\|}{\|\boldsymbol{x}\|}, \quad \boldsymbol{x} \neq \boldsymbol{0},$$

den **relativen Fehler von $\boldsymbol{x}$ gemessen in der Norm** $\|\cdot\|$.

Bemerkung 2.1.26. Vom relativen Fehler in der Norm kann nicht auf die relativen Fehler

$$\varepsilon_{x_i} = \frac{\tilde{x}_i - x_i}{x_i}, \quad i = 1, \ldots, n,$$

der einzelnen Komponenten des Vektors geschlossen werden, da $\boldsymbol{x} \neq \boldsymbol{0}$ nicht impliziert, dass die betrachtete Komponente x_i von Null verschieden ist.

2.2 Banachscher Fixpunktsatz und Fixpunktiteration

Wir widmen uns zunächst der Fixpunktaufgabe $\boldsymbol{x}^* = \boldsymbol{\varphi}(\boldsymbol{x}^*)$, bzw. in komponentenweiser Form

$$\begin{aligned} x_1^* &= \varphi_1(x_1^*, x_2^*, \ldots, x_n^*)\,, \\ x_2^* &= \varphi_2(x_1^*, x_2^*, \ldots, x_n^*)\,, \\ &\vdots \\ x_n^* &= \varphi_n(x_1^*, x_2^*, \ldots, x_n^*)\,. \end{aligned}$$

Aussagen über die Existenz einer Lösung und ihre Eindeutigkeit trifft der **Banachsche Fixpunktsatz**, vgl. Satz 4.1.6 im *Lehrtext Analysis*.

Satz 2.2.1: Fixpunktsatz von Banach

Seien $D \subset \mathbb{R}^n$, $n \in \mathbb{N}$, eine abgeschlossene Menge, $\|\cdot\|$ eine Norm auf $\mathbb{R}^n$ und $\boldsymbol{\varphi}\colon D \to D$ eine kontrahierende Abbildung, d. h. es existiert eine Konstante $\kappa \in (0,1)$, die sog. **Kontraktionskonstante**, derart, dass gilt

$$\|\boldsymbol{\varphi}(\boldsymbol{x}) - \boldsymbol{\varphi}(\boldsymbol{y})\| \leq \kappa \|\boldsymbol{x} - \boldsymbol{y}\| \qquad \forall x, y \in D.$$

Dann existiert genau ein Punkt $\boldsymbol{x}^* \in D$ mit $\boldsymbol{x}^* = \boldsymbol{\varphi}(\boldsymbol{x}^*)$, der als **Fixpunkt** von $\boldsymbol{\varphi}$ bezeichnet wird.

Die Fixpunktgleichung $\boldsymbol{x}^* = \boldsymbol{\varphi}(\boldsymbol{x}^*)$ kann näherungsweise gelöst werden, indem wir von einem Startvektor $\boldsymbol{x}^0 \in D$ ausgehend eine Folge von Approximationen gemäß

$$\boldsymbol{x}^{k+1} = \boldsymbol{\varphi}(\boldsymbol{x}^k)\,, \quad k = 0, 1, 2, \ldots \tag{2.5}$$

berechnen. Das Verfahren (2.5) wird als **Fixpunktiteration** bezeichnet.

Satz 2.2.2

Unter den Voraussetzungen von Satz 2.2.1 ist die Folge $(\boldsymbol{x}^k)_{k\in\mathbb{N}_0}$ für jeden Startvektor $\boldsymbol{x}^0 \in D$ wohldefiniert und konvergiert gegen den Fixpunkt $\boldsymbol{x}^*$. Ferner gelten die Abschätzungen

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \leq \kappa \left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\right\|, \quad k \in \mathbb{N}, \tag{2.6}$$

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \leq \frac{\kappa^k}{1-\kappa} \left\|\boldsymbol{x}^1 - \boldsymbol{x}^0\right\|, \quad k \in \mathbb{N}, \tag{2.7}$$

sowie

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \leq \frac{\kappa}{1-\kappa} \left\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\right\|, \quad k \in \mathbb{N}. \tag{2.8}$$

Aufgabe 2.2.3. Beweisen Sie die Gültigkeit der Ungleichungen (2.6), (2.7) und (2.8)! ◊

Bemerkung 2.2.4. Die erste Abschätzung (2.6) besagt, dass bei jeder Iteration der Fehler reduziert wird, und die Folge der absoluten Fehler (gemessen in der Norm $\|\cdot\|$) monoton mindestens

wie eine geometrische Folge fällt. Die Fixpunktiteration konvergiert Q-linear im Sinne der folgenden Definition.

(ii) Ist die Kontraktionskonstante κ bekannt, so kann (2.7) genutzt werden, um **a priori** eine obere Schranke für die Anzahl der nötigen Iterationen anzugeben.

(iii) Mit (2.8) kann der Fehler der gerade berechneten Näherung $\boldsymbol{x}^k$ **a posteriori** abgeschätzt werden – ebenfalls unter der Prämisse, dass κ bekannt ist.

(iv) I. Allg. ist die Kontraktionskonstante κ nicht bekannt. In diesem Fall können wir während des Iterationsprozesses versuchen, selbige zu schätzen:

$$\kappa \approx \kappa_{k+1} := \frac{\left\|\boldsymbol{x}^{k+1} - \boldsymbol{x}^k\right\|}{\left\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\right\|}. \tag{2.9}$$

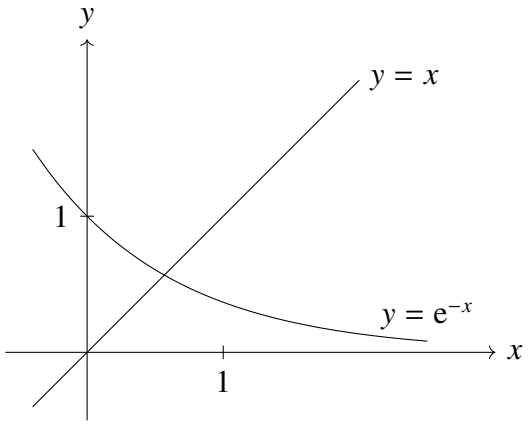
Dies ist durch die Ungleichung $\left\|\boldsymbol{x}^{k+1} - \boldsymbol{x}^k\right\| = \left\|\boldsymbol{\varphi}(\boldsymbol{x}^k) - \boldsymbol{\varphi}(\boldsymbol{x}^{k-1})\right\| \leq \kappa \left\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\right\|$ motiviert. Natürlich impliziert $\kappa_k < 1$ nicht $\kappa < 1$. Ist hingegen $\kappa_k > 1$, so können wir sofort folgern, dass die Funktion $\boldsymbol{\varphi}$ die Voraussetzungen des Banachschen Fixpunktsatzes nicht erfüllt — zumindest nicht in der verwendeten Norm. Es muss befürchtet werden, dass das Verfahren nicht konvergieren wird.

Definition 2.2.5: Konvergenzgeschwindigkeiten

Ein Verfahren erzeuge eine Folge $(\boldsymbol{x}_k)_{k\in\mathbb{N}_0}$, die gegen ein $\boldsymbol{x}^*$ konvergiert. Wir sagen, das Verfahren konvergiert

- (mindestens) ***Q*-linear** (oder mit der ***Q*-Ordnung** $p = 1$) mit Kontraktionskonstante κ, falls
$$\limsup_{k\to\infty} \frac{\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|}{\left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\right\|} =: \kappa < 1,$$
- ***Q*-überlinear**, falls
$$\limsup_{k\to\infty} \frac{\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|}{\left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\right\|} = 0,$$
- (mindestens) mit der ***Q*-Ordnung** $p > 1$, falls
$$\limsup_{k\to\infty} \frac{\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|}{\left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\right\|^p} \in \mathbb{R}.$$

Beispiel 2.2.6. Wir wollen eine Lösung der Gleichung $x - \mathrm{e}^{-x} = 0$ berechnen, die wir zunächst auf Fixpunktform bringen: $x = \mathrm{e}^{-x}$. Die folgende Skizze illustriert die Situation.



Gesucht ist der Schnittpunkt der durch $y = x$ beschriebenen Gerade mit der durch $y = \mathrm{e}^{-x}$ gegebenen Kurve. Die Gleichung besitzt die eindeutige Lösung $x^* = 0.5671432904097838\ldots$

Die Funktion $\varphi : \varphi(x) = \mathrm{e}^{-x}$ ist konvex. Ihre Ableitung ist negativ. Auf jedem Intervall $[a, 1]$, $a \in (0, x^*]$, gilt $|\varphi'(\xi)| \le \mathrm{e}^{-a} < 1, \xi \in [a, 1]$. Für beliebige $x, y \in [a, 1]$ existiert dem Mittelwertsatz zufolge ein ξ zwischen x und y mit

$$\varphi(x) - \varphi(y) = \int_y^x \varphi'(s)\,\mathrm{d}s = (x - y)\varphi'(\xi).$$

Somit existiert ein $\kappa = \mathrm{e}^{-a} < 1$ mit

$$|\varphi(x) - \varphi(y)| \le \kappa\,|x - y| \qquad \forall\ x, y \in [a, 1].$$

Die Fixpunktiteration ist also für jeden beliebigen Startwert $x_0 \in [a, 1]$ konvergent.

Für unsere Iteration wählen wir den Startwert $x_0 = 1$. Die folgende Tabelle enthält in den einzelnen Spalten den Index der berechneten Iterierten, ihren Wert sowie den absoluten Fehler der Iterierten als Näherung für den Fixpunkt x^*. Die letzte Spalte zeigt die Näherungen κ_k für die Kontraktionskonstante κ. (Das Listing eines Matlab/Octave-Programms findet sich auf S. 61.)

k	x_k	$\lvert x_k - x^*\rvert$	κ_k	k	x_k	$\lvert x_k - x^*\rvert$	κ_k
1	0.367879	$1.993 \cdot 10^{-1}$		11	0.566415	$7.286 \cdot 10^{-4}$	0.567
2	0.692201	$1.251 \cdot 10^{-1}$	0.513	12	0.567557	$4.133 \cdot 10^{-4}$	0.567
3	0.500474	$6.667 \cdot 10^{-2}$	0.591	13	0.566909	$2.344 \cdot 10^{-4}$	0.567
4	0.606244	$3.910 \cdot 10^{-2}$	0.552	14	0.567276	$1.329 \cdot 10^{-4}$	0.567
5	0.545396	$2.175 \cdot 10^{-2}$	0.575	15	0.567068	$7.539 \cdot 10^{-5}$	0.567
6	0.579612	$1.247 \cdot 10^{-2}$	0.562	16	0.567186	$4.276 \cdot 10^{-5}$	0.567
7	0.560115	$7.028 \cdot 10^{-3}$	0.570	17	0.567119	$2.425 \cdot 10^{-5}$	0.567
8	0.571143	$4.000 \cdot 10^{-3}$	0.566	18	0.567157	$1.375 \cdot 10^{-5}$	0.567
9	0.564879	$2.264 \cdot 10^{-3}$	0.568	19	0.567135	$7.800 \cdot 10^{-6}$	0.567
10	0.568429	$1.285 \cdot 10^{-3}$	0.567	20	0.567148	$4.424 \cdot 10^{-6}$	0.567

Die Gleichung $x - \mathrm{e}^{-x} = 0$ kann alternativ auch auf die Fixpunktform $x = -\ln x$ gebracht werden. Die resultierende Fixpunktiteration ist $x_{k+1} = -\ln x_k$, $k \in \mathbb{N}_0$. Wir starten mit $x_0 = 0.567$ und erhalten die Ergebnisse in der folgenden Tabelle.

k	x_k	$\lvert x_k - x^*\rvert$	κ_k
1	0.567396	$2.527 \cdot 10^{-4}$	
2	0.566698	$4.454 \cdot 10^{-4}$	1.763
3	0.567929	$7.857 \cdot 10^{-4}$	1.764
4	0.565759	$1.384 \cdot 10^{-3}$	1.763
5	0.569587	$2.444 \cdot 10^{-3}$	1.764
6	0.562843	$4.300 \cdot 10^{-3}$	1.762
7	0.574754	$7.611 \cdot 10^{-3}$	1.766
8	0.553813	$1.333 \cdot 10^{-2}$	1.758

k	x_k	$\lvert x_k - x^*\rvert$	κ_k
9	0.590929	$2.379 \cdot 10^{-2}$	1.772
10	0.526060	$4.108 \cdot 10^{-2}$	1.748
11	0.642341	$7.520 \cdot 10^{-2}$	1.793
12	0.442636	$1.245 \cdot 10^{-1}$	1.717
13	0.815007	$2.479 \cdot 10^{-1}$	1.865
14	0.204558	$3.626 \cdot 10^{-1}$	1.639
15	1.586903	1.020	2.264
16	-0.461784	1.029	1.482

Diesmal beobachten wir trotz eines sehr guten Startwertes in der Nähe des Fixpunktes x^*, dass die Folge der Iterierten nicht konvergiert, sondern gewissermaßen von x^* abgestoßen wird. Die Iteration bricht für $k = 16$ ab, da der Logarithmus einer negativen Zahl zu berechnen wäre. Die während des Iterationsprozesses berechneten κ_k sind größer als 1, was darauf hindeutet, dass etwas schief geht. ♠

2.2.1 Praktische Umsetzung der Fixpunktiteration

Bei der Implementierung auf einem Rechner muss der Iterationsprozess irgendwann beendet werden. Dazu ist ein geeignetes Abbruchkriterium zu formulieren. Einerseits wollen wir möglichst wenige Iterationen berechnen, um den Rechenaufwand und damit die benötigte Zeit minimal zu halten, andererseits ist eine gewisse Mindestgenauigkeit zu gewährleisten. Letztere hängt vom Gesamtkontext ab, in dem das Fixpunktproblem auftritt.

Wir können uns bspw. zum Ziel setzen, eine Näherung $\boldsymbol{x}^k$ des Fixpunktes zu berechnen, deren relativer Fehler — gemessen in einer gegebenen Norm — kleiner als eine vorgegebene Toleranz `TOL` ist, d. h. wenn

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \leq \texttt{TOL} \left\|\boldsymbol{x}^*\right\|. \tag{2.10}$$

Da $\boldsymbol{x}^*$ zu berechnen ist, sind natürlich weder $\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|$ noch $\left\|\boldsymbol{x}^*\right\|$ bekannt. Da (hoffentlich) $\boldsymbol{x}^k$ gegen $\boldsymbol{x}^*$ konvergiert, ersetzen wir auf der rechten Seite der Ungleichung $\|\boldsymbol{x}^*\|$ durch $\left\|\boldsymbol{x}^k\right\|$, während wir auf die linke Seite die a posteriori Abschätzung (2.8) anwenden. Wir erhalten als neues Abbruchkriterium

$$\frac{\kappa}{1-\kappa} \left\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\right\| \leq \texttt{TOL} \left\|\boldsymbol{x}^k\right\|.$$

Auch dieses ist noch nicht praktikabel, da die Kontraktionskonstante κ in der Regel nicht bekannt ist. Wir schätzen sie mittels (2.9) und formulieren als unser Abbruchkriterium die Ungleichung

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^{k-1}\right\| \leq \frac{1-\kappa_k}{\kappa_k} \texttt{TOL} \left\|\boldsymbol{x}^k\right\|. \tag{2.11}$$

Algorithmus 2.2.7: Fixpunktiteration mit Abbruchkriterium (2.11)

Gegeben: Eine Funktion $\varphi\colon D \subset \mathbb{R}^n \to D$, welche die Voraussetzungen des BANACHschen Fixpunktsatzes erfüllt, ein Startvektor $x^0 \in D$ und eine relative Fehlertoleranz TOL.

$x^{new} = \varphi(x^0), \quad n_{new} = \left\|x^{new} - x^0\right\|$

DO

$x^{old} = x^{new}, \quad n_{old} = n_{new}$

$x^{new} = \varphi(x^{old}), \quad n_{new} = \left\|x^{new} - x^{old}\right\|$

$\kappa = n_{new}/n_{old}$

WHILE $n_{new} > (1-\kappa)\,\mathtt{TOL}\,\|x^{new}\|/\kappa$

Ergebnis: eine Approximation x^{new} von x^* mit relativem Fehler der Größenordnung TOL.

Bemerkung 2.2.8. Angesichts der Annahmen bei der Herleitung des Abbruchkriteriums (2.11) ist nicht garantiert, dass die berechnete Approximation tatsächlich (2.10) erfüllt — daher die recht vage Formulierung „mit relativem Fehler der Größenordnung TOL“. In der Praxis ist es daher empfehlenswert, im Algorithmus TOL kleiner zu wählen als die angestrebte relative Genauigkeit.

2.2.2 Die Fixpunktiteration für differenzierbare Funktionen

Ist die Funktion $\varphi\colon \mathbb{R}^n \to \mathbb{R}^n$ stetig differenzierbar und besitzt sie einen Fixpunkt $x^* \in \mathbb{R}^n$, so kann die Konvergenz des Iterationsverfahrens lokal, d. h. in einer Umgebung des Fixpunktes, mit Hilfe der Ableitung (also der JACOBI-Matrix)

$$\varphi' = \begin{pmatrix} D_1\varphi_1 & D_2\varphi_1 & \cdots & D_n\varphi_1 \\ D_1\varphi_2 & D_2\varphi_2 & \cdots & D_n\varphi_2 \\ \vdots & \vdots & \ddots & \vdots \\ D_1\varphi_n & D_2\varphi_n & \cdots & D_n\varphi_n \end{pmatrix},$$

im Fixpunkt charakterisiert werden.

Bei gegebener Norm $\|\cdot\|$ sei für $x \in \mathbb{R}^n$ und $\delta > 0$ durch $U_\delta(x) := \left\{\xi \in \mathbb{R}^n\colon \|\xi - x\| < \delta\right\}$die δ-Umgebung von x definiert.

Satz 2.2.9

Es bezeichne $\|\cdot\|$ eine Vektornorm auf $\mathbb{R}^n$ und $\|\cdot\|_*$ eine mit ihr verträgliche Matrixnorm auf $\mathbb{R}^{n,n}$. Seien $\varphi : D \to \mathbb{R}^n$ eine auf der offenen Menge $D \subset \mathbb{R}^n$ stetig differenzierbare Funktion und $x^* \in D$ ein Fixpunkt von φ mit $\left\|\varphi'(x^*)\right\|_* < 1$.

Dann existiert für jedes κ, $\left\|\varphi'(x^*)\right\|_* < \kappa < 1$, ein $\varepsilon > 0$ derart, dass φ eine kontrahierende Abbildung von $U_\varepsilon(x^*)$ in $U_\varepsilon(x^*)$ mit Kontraktionskonstante κ ist.

Beweis. Wegen der Stetigkeit von φ' existiert für beliebiges κ, $\left\|\varphi'(x^*)\right\|_* < \kappa < 1$, eine Umgebung $U_\varepsilon(x^*) \subset D$, $\varepsilon = \varepsilon(\kappa) > 0$, mit

$$\|\varphi'(x)\|_* \le \kappa \quad \text{für alle } x \in U_\varepsilon(x^*). \tag{2.12}$$

Auf $U_\varepsilon(\boldsymbol{x}^*) \subset D$ ist die Funktion $\boldsymbol{\varphi}$ differenzierbar. Somit ergibt sich aus der Taylor-Entwicklung für Funktionen mehrerer Veränderlicher, Satz 4.4.8 im *Lehrtext Analysis*,

$$\boldsymbol{\varphi}(\boldsymbol{y}) - \boldsymbol{\varphi}(\boldsymbol{x}) = \boldsymbol{\varphi}'(\boldsymbol{\xi})\,(\boldsymbol{y} - \boldsymbol{x})$$

mit einem $\boldsymbol{\xi}$ auf der Geraden zwischen $\boldsymbol{x}$ und $\boldsymbol{y}$. Hieraus folgt

$$\|\boldsymbol{\varphi}(\boldsymbol{y}) - \boldsymbol{\varphi}(\boldsymbol{x})\| \le \|\boldsymbol{\varphi}'(\boldsymbol{\xi})\|_* \, \|\boldsymbol{y} - \boldsymbol{x}\| \le \kappa \, \|\boldsymbol{y} - \boldsymbol{x}\|$$

Für alle $\boldsymbol{x} \in U_\varepsilon(\boldsymbol{x}^*)$ folgt hieraus unmittelbar $\boldsymbol{\varphi}(\boldsymbol{x}) \in U_{\kappa\varepsilon}(\boldsymbol{x}^*) \subset U_\varepsilon(\boldsymbol{x}^*)$ da

$$\|\boldsymbol{\varphi}(\boldsymbol{x}) - \boldsymbol{x}^*\| = \|\boldsymbol{\varphi}(\boldsymbol{x}) - \boldsymbol{\varphi}(\boldsymbol{x}^*)\| \le \kappa \|\boldsymbol{x} - \boldsymbol{x}^*\| \quad \forall\, \boldsymbol{x} \in U_\varepsilon(\boldsymbol{x}^*). \tag{2.13}$$

Somit ist gezeigt, dass $\boldsymbol{\varphi}$ eine kontrahierende Abbildung von $U_\varepsilon(\boldsymbol{x}^*)$ in $U_\varepsilon(\boldsymbol{x}^*)$ mit Kontraktionskonstante $\kappa < 1$ ist. □

Aus Satz 2.2.9 folgt für stetig differenzierbare Funktionen φ, dass in unmittelbarer Umgebung des Fixpunktes die Kontraktion durch die Ableitung von φ im Fixpunkt bestimmt wird.

Bemerkung 2.2.10. Kann die Konvergenz eines numerischen Verfahrens nur für eine (möglicherweise sehr kleine) Umgebung der gesuchten Größe garantiert werden, so sprechen wir davon, dass das Verfahren **lokal konvergent** ist.

Wir werfen nochmals einen Blick zurück auf die erste Tabelle in Bsp. 2.2.6. Die letzte Spalte enthält die κ_k, welche die Fehlerreduktion in jedem Iterationsschritt beschreiben. Wir beobachten – im Einklang mit Satz 2.2.9 – dass die κ_k gegen $|\varphi'(x^*)| \approx 0.567\ldots$ konvergieren.

Etwas komplizierter stellt sich die Situation im $\mathbb{R}^n$, $n \ge 2$, dar, da hier die Bedingung $\left\|\varphi'(\boldsymbol{x}^*)\right\|_* < 1$ zunächst von der Wahl der Matrixnorm abhängt. Es kann gezeigt werden, dass der Spektralradius der Jacobi-Matrix ausschlaggebend ist für die Konvergenz der Fixpunktiteration. Sie ist nämlich genau dann konvergent für alle Startvektoren $\boldsymbol{x}^0$ aus einer hinreichend kleinen Umgebung von $\boldsymbol{x}^*$, wenn $\varrho(\varphi'(\boldsymbol{x}^*)) < 1$.

Satz 2.2.11

Ist $\boldsymbol{x}^*$ ein Fixpunkt der Funktion φ mit $\varrho(\varphi'(\boldsymbol{x}^*)) < 1$ und ist φ in einer Umgebung von $\boldsymbol{x}^*$ stetig differenzierbar, dann ist die Fixpunktiteration für jeden hinreichend guten Startwert $\boldsymbol{x}^0$ (d. h. aus einer gewissen eventuell aber sehr kleinen Umgebung von $\boldsymbol{x}^*$) durchführbar, und die Folge der Iterierten konvergiert gegen den Fixpunkt $\boldsymbol{x}^*$.

2.3 Das Newton-Verfahren

Wir wollen nun die Nullstellenaufgabe für vektorwertige Funktionen betrachten. Bei gegebener hinreichend glatter Funktion

$$\boldsymbol{f} = \begin{pmatrix} f_1 \\ \vdots \\ f_n \end{pmatrix} : D \subset \mathbb{R}^n \to \mathbb{R}^n, \quad n \in \mathbb{N},$$

ist ein Vektor $\boldsymbol{x}^* = (x_1^*, \ldots, x_n^*)^T \in \mathbb{R}^n$ gesucht, der die Gleichung

$$\boldsymbol{f}(\boldsymbol{x}^*) = \boldsymbol{0}$$

erfüllt, bzw. komponentenweise geschrieben

$$\begin{aligned} f_1(x_1^*, x_2^*, \ldots, x_n^*) &= 0, \\ f_2(x_1^*, x_2^*, \ldots, x_n^*) &= 0, \\ &\vdots \\ f_n(x_1^*, x_2^*, \ldots, x_n^*) &= 0. \end{aligned}$$

2.3.1 Grundidee des Verfahrens

Zur Herleitung des Newton-Verfahrens verwenden wir, ausgehend von der k-ten Iterierten $\boldsymbol{x}^k$, die Taylor-Entwicklung von $\boldsymbol{f}$ an der Stelle $\boldsymbol{x}^k$, vgl. *Lehrtext Analysis*, Satz 4.4.8,

$$\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{f}(\boldsymbol{x}^k) + \boldsymbol{f}'(\boldsymbol{x}^k)(\boldsymbol{x} - \boldsymbol{x}^k) + \cdots,$$

mit der Jacobi-Matrix $\boldsymbol{f}'$, brechen sie nach dem linearen Glied ab

$$\boldsymbol{f}(\boldsymbol{x}) \doteq \boldsymbol{f}(\boldsymbol{x}^k) + \boldsymbol{f}'(\boldsymbol{x}^k)(\boldsymbol{x} - \boldsymbol{x}^k) \tag{2.14}$$

und bestimmen die $(k+1)$-te Iterierte als Lösung der linearen Gleichung

$$\boldsymbol{0} = \boldsymbol{f}(\boldsymbol{x}^k) + \boldsymbol{f}'(\boldsymbol{x}^k)(\boldsymbol{x}^{k+1} - \boldsymbol{x}^k),$$

also, falls $\boldsymbol{f}'(\boldsymbol{x}^k)$ invertierbar ist,

$$\boldsymbol{x}^{k+1} = \boldsymbol{x}^k - \left[\boldsymbol{f}'(\boldsymbol{x}^k)\right]^{-1} \boldsymbol{f}(\boldsymbol{x}^k). \tag{2.15}$$

Bemerkung 2.3.1. Bei einer Implementierung auf einem Computer wird man die Inverse von $\boldsymbol{f}'(\boldsymbol{x}^k)$ nicht berechnen. Vielmehr löst man das lineare Gleichungssystem

$$\boldsymbol{f}'(\boldsymbol{x}^k)\, \boldsymbol{s}^k = -\boldsymbol{f}(\boldsymbol{x}^k)$$

für $\boldsymbol{s}^k$ mit einem geeigneten Verfahren, z. B. der Gauss[7]-Elimination, und setzt anschließend $\boldsymbol{x}^{k+1} := \boldsymbol{x}^k + \boldsymbol{s}^k$.

[7] Johann Carl Friedrich Gauß, *30.4.1777 (Braunschweig, Hztm. Braunschweig und Lüneburg), †23.2.1855 (Göttingen, Königr. Hannover)

Bemerkung 2.3.2. Das NEWTON-Verfahren kann als Fixpunktiteration

$$\boldsymbol{x}^{k+1} = \boldsymbol{\varphi}_N(\boldsymbol{x}^k), \quad k = 0, 1, 2, \ldots,$$

mit

$$\boldsymbol{\varphi}_N(\boldsymbol{x}) = \boldsymbol{x} - [\boldsymbol{f}'(\boldsymbol{x})]^{-1} \boldsymbol{f}(\boldsymbol{x}).$$

aufgefasst werden, wobei jede Nullstelle $\boldsymbol{x}^*$ von $\boldsymbol{f}$ auch ein Fixpunkt von $\boldsymbol{\varphi}_N$ ist.

Wir fassen das NEWTON-Verfahren algorithmisch.

Algorithmus 2.3.3: NEWTON-Verfahren

Gegeben: Eine Funktion $\boldsymbol{f}\colon D \subset \mathbb{R}^n \to D$ mit einer Nullstelle $\boldsymbol{x}^* \in D$ und ein guter Startvektor $\boldsymbol{x}^0 \in D$.

FOR $k = 0, 1, 2, \ldots$ DO
  Berechne die NEWTON-Richtung $\boldsymbol{s}^k$ als Lösung des linearen Gleichungssystems
    $\boldsymbol{f}'(\boldsymbol{x}^k)\,\boldsymbol{s}^k = -\boldsymbol{f}(\boldsymbol{x}^k)$
  Setze
    $\boldsymbol{x}^{k+1} := \boldsymbol{x}^k + \boldsymbol{s}^k$
END FOR

Ergebnis: Eine Folge $\{\boldsymbol{x}^k\}$ von Approximationen, die (hoffentlich) (schnell) gegen $\boldsymbol{x}^*$ konvergiert.

Das Ergebnis des Algorithmus ist noch vage formuliert. Wir müssen noch klären, wann das Verfahren garantiert konvergiert, und wie schnell (im Sinne von Def. 2.2.5) die Konvergenz erfolgt. Diesen Frage werden wir uns Abschnitt 2.3.3 widmen.

2.3.2 Illustrierende Beispiele und geometrische Interpretation

2.3.2.1 Funktionen einer Veränderlicher

Beispiel 2.3.4. Wir kommen nochmal zurück auf Bsp. 2.2.6, wollen diesmal aber das NEWTON-Verfahren einsetzen. Die mittels (2.14) bestimmte Näherung für f ist

$$t(x) := f(x^k) + f'(x^k)(x - x^k),$$

und die $(k+1)$-te Iterierte,

$$x^{k+1} = x^k - f(x^k)/f'(x^k),$$

ist die Nullstelle von t.

Geometrisch gesehen beschreibt t die Tangente an den Graphen von f im Punkt $(x^k, f(x^k))$, und x^{k+1} ist ihr Schnittpunkt mit der x-Achse. siehe Abbildung 2.1.

Wir bestimmen nun eine Näherung für die Lösung $x^* = 0.5671432904097838\ldots$ der Gleichung $f(x) := x - \mathrm{e}^{-x} = 0$. Wir wählen als Startwert $x_0 = 1.0$. Die folgende Tabelle zeigt die berechneten Iterierten und ihre absoluten Fehler als Näherung für x^*.

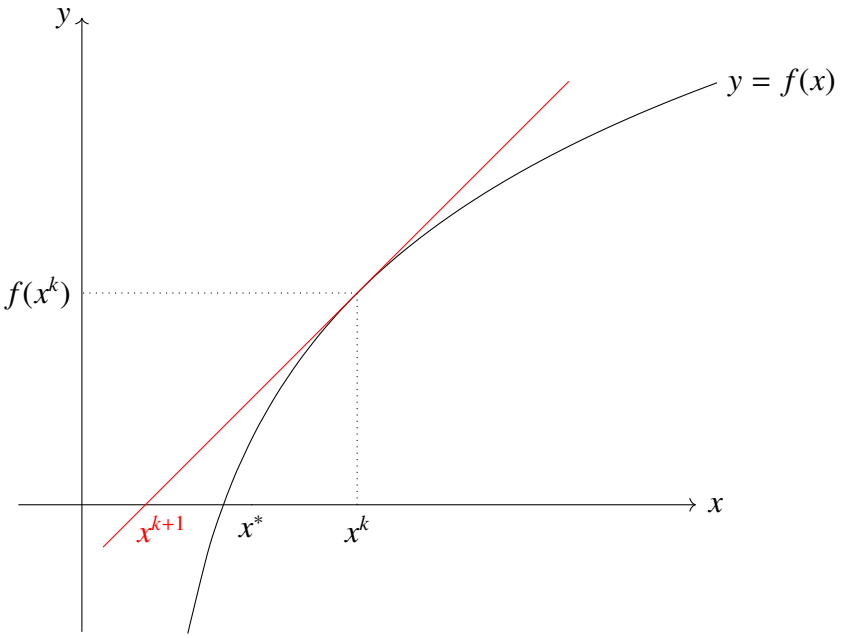


Abbildung 2.1: Ein Schritt des NEWTON-Verfahrens. Rot dargestellt ist die Tangente an den Graphen von f im Punkt $(x^k, f(x^k))$. Ihr Schnittpunkt mit der x-Achse ist die neue Näherung x^{k+1} für die Nullstelle x^*.

k	x_k	$\lvert x_k - x^*\rvert$
1	0.5378828427399902	$2.926 \cdot 10^{-2}$
2	0.5669869914054133	$1.563 \cdot 10^{-4}$
3	0.5671432859891230	$4.421 \cdot 10^{-9}$
4	0.5671432904097838	$1.110 \cdot 10^{-16}$

Bereits nach vier Iterationen ist die Nullstelle bis auf Maschinengenauigkeit exakt berechnet. Das NEWTON-Verfahren konvergiert (zumindest in diesem Beispiel) wesentlich schneller als die Fixpunktiteration in Bsp. 2.2.6. ♠

Warum konvergiert das Verfahren so schnell? Wir hatten festgestellt, dass die lokale Konvergenz der Fixpunktiteration vom Wert der Ableitung im Fixpunkt bestimmt wird, vgl. Satz 2.2.9. Da das NEWTON-Verfahren identisch mit der Fixpunktiteration für die Funktion

$$\varphi_N \colon x \mapsto x - \frac{f(x)}{f'(x)}$$

interpretiert werden kann, berechnen wir φ_N'. Dazu sei f zweimal stetig differenzierbar.

$$\varphi_N'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2} = \frac{f(x)f''(x)}{[f'(x)]^2}\,.$$

Für eine Nullstelle x^* von f mit $f'(x^*) \neq 0$ folgt $\varphi_N'(x^*) = 0$. Die Stetigkeit von f, f' und f'' sichert zudem die Existenz einer Umgebung von x^*, auf der φ_N stetig differenzierbar ist. Somit ist die Kontraktions-„Konstante“ κ umso kleiner – und die Konvergenz umso schneller,

je kleiner die betrachtete Umgebung von x^* ist. Das Verfahren ist somit (mindestens) überlinear gemäß Def. 2.2.5. Im Abschnitt 2.3.3 werden wir uns im Detail mit der Konvergenz des Newton-Verfahrens beschäftigen.

Beispiel 2.3.5. Wir wollen die Nullstellen des Polynoms $p \in \Pi_3$, $p(z) = z^3 - 2z + 2$, bestimmen. Es besitzt eine reelle Nullstelle $z_1 \approx -1.8$ sowie ein Paar konjugiert komplexer Nullstellen $z_{2,3} \approx 0.9 \pm 0.6\mathrm{i}$. Wir setzen $z := x + \mathrm{i}y$, $x, y \in \mathbb{R}$, und erhalten

$$p(x + \mathrm{i}y) = x\left(x^2 - 3y^2 - 2\right) + 2 - \mathrm{i}y\left(y^2 - 3x^2 + 2\right).$$

Eine Nullstelle von p liegt genau dann vor, wenn sowohl Real- als auch Imaginärteil verschwinden. Dies führt uns auf ein nichtlineares Gleichungssystem für die zwei Unbekannten x und y bestehend aus zwei Gleichungen:

$$\boldsymbol{f}(\boldsymbol{x}) = \begin{pmatrix} f_1(x,y) \\ f_2(x,y) \end{pmatrix} = \begin{pmatrix} x(x^2 - 3y^2 - 2) + 2 \\ y(y^2 - 3x^2 + 2) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Die Jacobi-Matrix von $\boldsymbol{f}$ ist

$$\boldsymbol{f}'(\boldsymbol{x}) = \begin{pmatrix} D_1 f_1(x,y) & D_2 f_1(x,y) \\ D_1 f_2(x,y) & D_2 f_2(x,y) \end{pmatrix} = \begin{pmatrix} 3(x^2 - y^2) - 2 & -6xy \\ -6xy & -3(x^2 - y^2) + 2 \end{pmatrix}$$

Ausgehend von einem Startvektor $\boldsymbol{x}^0$ erzeugt das Newton-Verfahren Iterierte $\boldsymbol{x}^k := (x_k, y_k)^T$ gemäß (2.15):

$$\begin{pmatrix} x_{k+1} \\ y_{k+1} \end{pmatrix} = \begin{pmatrix} x_k \\ y_k \end{pmatrix} - \begin{pmatrix} 3(x_k^2 - y_k^2) - 2 & -6x_k y_k \\ -6x_k y_k & -3(x_k^2 - y_k^2) + 2 \end{pmatrix}^{-1} \begin{pmatrix} x_k(x_k^2 - 3y_k^2 - 2) + 2 \\ y_k(y_k^2 - 3x_k^2 + 2) \end{pmatrix}, \quad k = 0, 1, \ldots$$

Die folgende Tabelle listet die Iterierten für verschiedene Startvektoren

k	x_k	y_k	x_k	y_k	x_k	y_k
0	-1.500000	0.000000	1.000000	-0.500000	0.500000	1.000000
1	-1.842105	0.000000	0.868966	-0.572414	0.690531	0.605081
2	-1.772827	0.000000	0.885150	-0.589985	0.881973	0.553404
3	-1.769301	0.000000	0.884646	-0.589743	0.884333	0.591106
4	-1.769292	0.000000	0.884646	-0.589743	0.884645	0.589744
5	-1.769292	0.000000	0.884646	-0.589743	0.884646	0.589743

♠

2.3.3 Konvergenz des Newton-Verfahrens

Satz 2.3.6

Es bezeichne $\|\cdot\|$ eine Vektornorm auf $\mathbb{R}^n$ als auch die ihr zugeordnete Matrixnorm auf $\mathbb{R}^{n,n}$. Die stetig differenzierbare Funktion $\boldsymbol{f} : D \subset \mathbb{R}^n \to \mathbb{R}^n$ besitze eine reguläre Nullstelle $\boldsymbol{x}^* \in D$, das ist eine Stelle mit $\boldsymbol{f}(\boldsymbol{x}^*) = \boldsymbol{0}$ und invertierbarem $\boldsymbol{f}'(\boldsymbol{x}^*)$. Außerdem existiere eine Umgebung $U_\delta(\boldsymbol{x}^*) \subset D$, $\delta > 0$, von $\boldsymbol{x}^*$, auf der die Ableitung von $\boldsymbol{f}$ Lipschitz[8]stetig ist, d. h. es gibt eine Konstante $L > 0$ mit

$$\left\|\boldsymbol{f}'(\boldsymbol{x}) - \boldsymbol{f}'(\boldsymbol{y})\right\| \le L\,\|\boldsymbol{x} - \boldsymbol{y}\| \quad \forall\, \boldsymbol{x}, \boldsymbol{y} \in U_\delta(\boldsymbol{x}^*)\,.$$

Dann ist das Newton-Verfahren für alle Startvektoren $\boldsymbol{x}^0 \in U_\varepsilon(\boldsymbol{x}^*)$,

$$\varepsilon := \min\left\{\delta, \frac{1}{2L\left\|\left[\boldsymbol{f}'(\boldsymbol{x}^*)\right]^{-1}\right\|}\right\},$$

durchführbar und die Folge der Iterierten $(\boldsymbol{x}^k)_{k\in\mathbb{N}_0}$ konvergiert gegen $\boldsymbol{x}^*$. Ferner gilt

$$\left\|\boldsymbol{x}^{k+1} - \boldsymbol{x}^*\right\| \le M\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|^2, \quad k \in \mathbb{N}_0, \quad \text{mit } M := L\left\|\left[\boldsymbol{f}'(\boldsymbol{x}^*)\right]^{-1}\right\|, \tag{2.16}$$

d. h. das Verfahren ist lokal Q-quadratisch konvergent.

Beweis. Wir zeigen induktiv, dass mit $\boldsymbol{x}^0$ alle Iterierten $\boldsymbol{x}^k$, $k \in \mathbb{N}$, in $U_\varepsilon(\boldsymbol{x}^*)$ liegen und dass gilt

$$\left\|\boldsymbol{x}^{k+1} - \boldsymbol{x}^*\right\| \le \frac{1}{2}\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|, \quad k \in \mathbb{N}_0, \tag{2.17}$$

woraus die Konvergenz der Folge $(\boldsymbol{x}^k)_{k\in\mathbb{N}_0}$ gegen $\boldsymbol{x}^*$ folgt. Hierbei werden wir die zwei folgenden beiden Aussagen benutzen, deren Nachweis wir vorerst zurückstellen, da sie eher technischer Natur sind.

1. Für alle $\boldsymbol{x}, \boldsymbol{y} \in U_\delta(\boldsymbol{x}^*)$ – insbesondere also auch für alle $\boldsymbol{x}, \boldsymbol{y} \in U_\varepsilon(\boldsymbol{x}^*)$ – gilt

$$\left\|\boldsymbol{f}(\boldsymbol{x}) - \boldsymbol{f}(\boldsymbol{y}) - \boldsymbol{f}'(\boldsymbol{y})(\boldsymbol{x} - \boldsymbol{y})\right\| \le \frac{L}{2}\left\|\boldsymbol{x} - \boldsymbol{y}\right\|^2. \tag{2.18}$$

2. Für alle $\boldsymbol{x} \in U_\varepsilon(\boldsymbol{x}^*)$ ist $\boldsymbol{f}'(\boldsymbol{x})$ invertierbar und es gilt

$$\left\|\left[\boldsymbol{f}'(\boldsymbol{x})\right]^{-1}\right\| \le 2\left\|\left[\boldsymbol{f}'(\boldsymbol{x}^*)\right]^{-1}\right\|. \tag{2.19}$$

Induktionsanfang: Voraussetzungsgemäß ist $\boldsymbol{x}^0 \in U_\varepsilon(\boldsymbol{x}^*)$.

Induktionsvoraussetzung: Sei $\boldsymbol{x}^k \in U_\varepsilon(\boldsymbol{x}^*)$.

[8]Rudolf Otto Sigismund Lipschitz, *14.5.1832 (Königsberg, Preußen), †7.10.1903 (Bonn, Deutschland)

Induktionsschritt: Für den Fehler der $(k+1)$-ten Iterierten gilt

$$\begin{aligned}
\left\|\boldsymbol{x}^{k+1}-\boldsymbol{x}^*\right\| &= \left\|\boldsymbol{x}^k-\boldsymbol{x}^*-\left[\boldsymbol{f}'(\boldsymbol{x}^k)\right]^{-1}\boldsymbol{f}(\boldsymbol{x}^k)\right\| \\
&= \left\|\left[\boldsymbol{f}'(\boldsymbol{x}^k)\right]^{-1}\left(\boldsymbol{f}'(\boldsymbol{x}^k)(\boldsymbol{x}^k-\boldsymbol{x}^*)-\boldsymbol{f}(\boldsymbol{x}^k)+\boldsymbol{f}(\boldsymbol{x}^*)\right)\right\|, \quad \text{da } \boldsymbol{f}(\boldsymbol{x}^*)=\boldsymbol{0}, \\
&\le \left\|\left[\boldsymbol{f}'(\boldsymbol{x}^k)\right]^{-1}\right\| \left\|\boldsymbol{f}'(\boldsymbol{x}^k)(\boldsymbol{x}^k-\boldsymbol{x}^*)-\boldsymbol{f}(\boldsymbol{x}^k)+\boldsymbol{f}(\boldsymbol{x}^*)\right\| \\
&\le \left\|\left[\boldsymbol{f}'(\boldsymbol{x}^k)\right]^{-1}\right\| \frac{L}{2}\left\|\boldsymbol{x}^k-\boldsymbol{x}^*\right\|^2, \quad \text{wegen (2.18) mit } \boldsymbol{y}=\boldsymbol{x}^k \text{ und } \boldsymbol{x}=\boldsymbol{x}^*, \\
&\le L\left\|\left[\boldsymbol{f}'(\boldsymbol{x}^*)\right]^{-1}\right\| \left\|\boldsymbol{x}^k-\boldsymbol{x}^*\right\|^2, \quad \text{wegen (2.19)}.
\end{aligned}$$

Hieraus folgt sofort die Abschätzung (2.16). Wegen $\boldsymbol{x}^k \in U_\varepsilon(\boldsymbol{x}^*)$, also

$$\left\|\boldsymbol{x}^k-\boldsymbol{x}^*\right\| \le \frac{1}{2L\left\|\boldsymbol{f}'(\boldsymbol{x}^*)^{-1}\right\|},$$

erhalten wir aus (2.16) weiterhin

$$\left\|\boldsymbol{x}^{k+1}-\boldsymbol{x}^*\right\| \le \frac{1}{2}\left\|\boldsymbol{x}^k-\boldsymbol{x}^*\right\|.$$

Somit ist gezeigt, dass $\boldsymbol{x}^{k+1} \in U_\varepsilon(\boldsymbol{x}^*)$. □

Wir komplettieren nun den Beweis von Satz 2.3.6, indem wir die Details zu (2.18) und (2.19) ergänzen.

Beweis von (2.18). Wir starten mit Satz 2.1.23, wonach

$$\boldsymbol{f}(\boldsymbol{x})-\boldsymbol{f}(\boldsymbol{y}) = \int_0^1 \boldsymbol{f}'(\boldsymbol{y}+t(\boldsymbol{x}-\boldsymbol{y}))\,(\boldsymbol{x}-\boldsymbol{y})\;\mathrm{d}t,$$

und subtrahieren auf beiden Seiten $\boldsymbol{f}'(\boldsymbol{y})(\boldsymbol{x}-\boldsymbol{y})$. Wir erhalten so

$$\boldsymbol{f}(\boldsymbol{x})-\boldsymbol{f}(\boldsymbol{y})-\boldsymbol{f}'(\boldsymbol{y})(\boldsymbol{x}-\boldsymbol{y}) = \int_0^1 \left[\boldsymbol{f}'(\boldsymbol{y}+t(\boldsymbol{x}-\boldsymbol{y}))-\boldsymbol{f}'(\boldsymbol{y})\right](\boldsymbol{x}-\boldsymbol{y})\;\mathrm{d}t.$$

Auf beiden Seiten gehen wir zu den Normen über und wenden Satz 2.1.24 an:

$$\begin{aligned}
\left\|\boldsymbol{f}(\boldsymbol{x})-\boldsymbol{f}(\boldsymbol{y})-\boldsymbol{f}'(\boldsymbol{y})(\boldsymbol{x}-\boldsymbol{y})\right\| &\le \int_0^1 \left\|\left[\boldsymbol{f}'(\boldsymbol{y}+t(\boldsymbol{x}-\boldsymbol{y}))-\boldsymbol{f}'(\boldsymbol{y})\right](\boldsymbol{x}-\boldsymbol{y})\right\| \mathrm{d}t \\
&\le \int_0^1 \left\|\boldsymbol{f}'(\boldsymbol{y}+t(\boldsymbol{x}-\boldsymbol{y}))-\boldsymbol{f}'(\boldsymbol{y})\right\| \|\boldsymbol{x}-\boldsymbol{y}\| \;\mathrm{d}t, \qquad (2.20)
\end{aligned}$$

wegen der Verträglichkeit von Vektor- und zugeordneter Matrixnorm.
Aus der vorausgesetzten Lipschitz-Stetigkeit von $\boldsymbol{f}'$ folgt

$$\left\|\boldsymbol{f}'(\boldsymbol{y}+t(\boldsymbol{x}-\boldsymbol{y}))-\boldsymbol{f}'(\boldsymbol{y})\right\| \le Lt\,\|\boldsymbol{x}-\boldsymbol{y}\|,$$

was wir in (2.20) einsetzen:

$$\left\|\boldsymbol{f}(\boldsymbol{x})-\boldsymbol{f}(\boldsymbol{y})-\boldsymbol{f}'(\boldsymbol{y})(\boldsymbol{x}-\boldsymbol{y})\right\| \le \int_0^1 Lt\,\|\boldsymbol{x}-\boldsymbol{y}\|^2\;\mathrm{d}t = \frac{L}{2}\,\|\boldsymbol{x}-\boldsymbol{y}\|^2\;\mathrm{d}t.$$

Das ist (2.18) □

Beweis von (2.19). Wir greifen auf das Störungslemmas (Satz 2.1.20) zurück und wenden es – für beliebige $\boldsymbol{x} \in U_\varepsilon(\boldsymbol{x}^*)$ – an auf die Konstellation

$$\boldsymbol{A} + \boldsymbol{\Delta}_{\boldsymbol{A}} = \boldsymbol{f}'(\boldsymbol{x}), \quad \boldsymbol{A} = \boldsymbol{f}'(\boldsymbol{x}^*), \quad \boldsymbol{\Delta}_{\boldsymbol{A}} = \boldsymbol{f}'(\boldsymbol{x}) - \boldsymbol{f}'(\boldsymbol{x}^*).$$

Der Nachweis wäre erbracht, wenn es uns gelingt zu zeigen, dass

$$\left\| \boldsymbol{f}'(\boldsymbol{x}^*)^{-1} \left(\boldsymbol{f}'(\boldsymbol{x}) - \boldsymbol{f}'(\boldsymbol{x}^*) \right) \right\| \leq \frac{1}{2}, \tag{2.21}$$

da gemäß Störungslemma

$$\left\| (\boldsymbol{A} + \Delta_{\boldsymbol{A}})^{-1} \right\| \leq \frac{\left\| \boldsymbol{A}^{-1} \right\|}{1 - \left\| \boldsymbol{A}^{-1} \Delta_{\boldsymbol{A}} \right\|} \quad \text{wenn} \quad \left\| \boldsymbol{A}^{-1} \Delta_{\boldsymbol{A}} \right\| < 1.$$

Die Submultiplikativität der Matrixnorm impliziert

$$\left\| \boldsymbol{f}'(\boldsymbol{x}^*)^{-1} \left(\boldsymbol{f}'(\boldsymbol{x}) - \boldsymbol{f}'(\boldsymbol{x}^*) \right) \right\| \leq \left\| \boldsymbol{f}'(\boldsymbol{x}^*)^{-1} \right\| \left\| \boldsymbol{f}'(\boldsymbol{x}) - \boldsymbol{f}'(\boldsymbol{x}^*) \right\| \leq \left\| \boldsymbol{f}'(\boldsymbol{x}^*)^{-1} \right\| L \left\| \boldsymbol{x} - \boldsymbol{x}^* \right\|, \tag{2.22}$$

wegen der vorausgesetzten Lipschitz-Stetigkeit von $\boldsymbol{f}'$.

Da $\boldsymbol{x} \in U_\varepsilon(\boldsymbol{x}^*)$ ist

$$\left\| \boldsymbol{x} - \boldsymbol{x}^* \right\| \leq \frac{1}{2L \left\| \left[\boldsymbol{f}'(\boldsymbol{x}^*) \right]^{-1} \right\|}.$$

Wir wenden dies auf die rechte Seite von (2.22) an und erhalten (2.21).

Somit ist der Nachweis von (2.19) erbracht. □

2.3.4 Gedämpfte Newton-Verfahren

Das Newton-Verfahren ist lediglich *lokal* konvergent, d. h. für hinreichend gute Startvektoren $\boldsymbol{x}^0$ aus einer Umgebung von $\boldsymbol{x}^*$. Daher ist eine Abschwächung der Empfindlichkeit bzgl. des Startvektors erstrebenswert.

Sei $\|\cdot\|$ eine beliebige Vektornorm. Ausgehend von der Feststellung, dass $\boldsymbol{x}^*$ genau dann eine Nullstelle von $\boldsymbol{f}$ ist, wenn $\|\boldsymbol{f}(\boldsymbol{x}^*)\| = 0$, zielen gedämpfte Verfahren darauf, eine Folge $(\boldsymbol{x}^k)_{k \in \mathbb{N}_0}$ von Iterierten zu generieren, für die

$$\left\| \boldsymbol{f}(\boldsymbol{x}^{k+1}) \right\| < \left\| \boldsymbol{f}(\boldsymbol{x}^k) \right\|, \quad k \in \mathbb{N}_0, \tag{2.23}$$

ist. Betrachtet man die Niveau- oder Höhenlinien

$$\Gamma_C = \left\{ \boldsymbol{x} \in D : \left\| \boldsymbol{f}(\boldsymbol{x}) \right\| = C \right\}, \quad C \geq 0,$$

dann stellt der Übergang von $\boldsymbol{x}^k$ zu $\boldsymbol{x}^{k+1}$ einen **Abstieg** zu einer niedrigeren Höhenlinie dar.

Definition 2.3.7: Abstiegsrichtung

Einen Vektor $s \in \mathbb{R}^n \setminus \{0\}$ nennen wir eine **Abstiegsrichtung** für $f : \mathbb{R}^n \to \mathbb{R}^n$ im Punkt x bzgl. der Norm $\|\cdot\|$, falls es ein $t^* > 0$ gibt mit

$$\|f(x + ts)\| < \|f(x)\| \quad \forall\, t \in (0, t^*)\,.$$

Satz 2.3.8

Die Ableitung der stetig differenzierbaren Funktion $f : D \subset \mathbb{R}^n \to \mathbb{R}^n$ sei auf ihrem Definitionsbereich D Lipschitzstetig mit einer Konstanten $L > 0$ mit

$$\|f'(x) - f'(y)\|_\infty \le L\,\|x - y\|_\infty \quad \forall\, x, y \in D.$$

Ist $f'(x^k)$ invertierbar, dann ist die Newton-Richtung

$$s^k := -\left[f'(x^k)\right]^{-1} f(x^k)$$

eine Abstiegsrichtung und es gilt

$$\|f(x^k + ts^k)\|_\infty < \|f(x^k)\|_\infty \quad \text{für } 0 < t < t^* := \min\left\{\frac{\|f(x^k)\|_\infty}{L\,\|s^k\|_\infty^2}, 1\right\}$$

Beweis. Für $t \in (0, 1)$ gilt

$$\|f(x^k + ts^k)\|_\infty \le \|f(x^k + ts^k) - f(x^k) - tf'(x^k)s^k\|_\infty + \|f(x^k) + tf'(x^k)s^k\|_\infty\,.$$

Den ersten Term auf der rechten Seite schätzen wir mit Hilfe von (2.18) ab, den zweiten unter Beachtung von $f'(x^k)s^k = -f(x^k)$:

$$\|f(x^k + ts^k)\|_\infty \le Lt^2\,\|s^k\|_\infty^2 + (1 - t)\,\|f(x^k)\|_\infty = \|f(x^k)\|_\infty + t\left(Lt\,\|s^k\|_\infty^2 - \|f(x^k)\|_\infty\right),$$

woraus $\|f(x^k + ts^k)\|_\infty < \|f(x^k)\|_\infty$ für $0 < t < t^*$ folgt. □

Bei der Implementierung der Abstiegsidee wird ein Newton-Schritt $x^{k+1} := x^k + s^k$ verworfen, wenn die Abstiegsbedingung (2.23) nicht erfüllt wird. Stattdessen dämpft man die Schrittweite und macht einen kürzeren Schritt in Newton-Richtung, der zu einem Abstieg führt. Praktisch implementiert wird die Schrittweitendämpfung im k-ten Schritt des Newton-Verfahrens wie folgt

S1. *Bestimmung der* Newton-*Richtung*
Berechne s^k als Lösung von $f'(x^k)s^k = -f(x^k)$

S2. *Dämpfung der Schrittweite*
$\gamma_k := 1$
WHILE $\|f(x^k + \gamma_k s^k)\| \ge \|f(x^k)\|$ DO
$\gamma_k := \gamma_k/2$
END DO

S3. *Festsetzung der neuen Iterierten*
$\boldsymbol{x}^{k+1} := \boldsymbol{x}^k + \gamma_k \boldsymbol{s}^k$

Da $\boldsymbol{s}^k$ Satz 2.3.8 zufolge eine Abstiegsrichtung ist, wird die WHILE-Schleife im Schritt S2 nach endlich vielen Durchläufen verlassen.

2.3.5 Praktische Aspekte des NEWTON-Verfahrens

Unsere Konvergenzuntersuchung für das NEWTON-Verfahren im Abschnitt 2.3.3 hat eine Reihe von idealisierenden Annahmen getroffen, u. a.

- die Existenz einer Lösung,
- die Kenntnis eines guten Startvektors in einer Umgebung der gesuchten Nullstelle,
- die Berechenbarkeit der JACOBI-Matrix und deren Regularität.

Zu diskutieren wären außerdem

- die Lösung des linearen Gleichungssystems zur Bestimmung der NEWTON-Richtung $\boldsymbol{s}^k$, sowie
- geeignete Abbruchkriterien und
- der rechnerische Aufwand.

Dies soll und kann an dieser Stelle nur ansatzweise erfolgen, um etwas die Fallstricke und Herausforderungen in der Praxis aufzuzeigen. Insofern besitzen die nachfolgenden Ausführungen eher informatorischen Charakter.

Bei Betrachtungen des Rechenaufwands ist die Abhängigkeit von der Dimension n des Problems von besonderer Relevanz. Ist $\boldsymbol{f}\colon \mathbb{R}^n \to \mathbb{R}^n$, so interessiert uns das Verhalten für $n \to \infty$.

Existenz von Lösungen und Startwertwahl. Die Existenz ist eine Sache des konkret vorliegenden Problems, oftmals klärt sich diese bei der Modellierung oder ergibt sich aus dem physikalischen Zusammenhang. Unter Umständen gibt es aber mehrere Lösungen, vgl. Bsp. 2.3.5. Welches ist dann die relevante Lösung? Oder werden alle Lösungen benötigt, und wie stellen wir sicher, dass wir alle bestimmt haben?

Für die Wahl der Startvektoren kann es auch keine universelle Empfehlung geben. Dies zeigt ebenfalls Bsp. 2.3.5: Mit einem bestimmten Startvektor können wir – wenn überhaupt – nur eine Lösung finden, aber nicht mehrere.

Berechnung der JACOBI-Matrix. Ist $\boldsymbol{f}$ formelmäßig gegeben, so können wir durch Anwendung der Differentiationsregeln auch $\boldsymbol{f}'$ bestimmen. Da $\boldsymbol{f}\colon \mathbb{R}^n \to \mathbb{R}^n$, ist die JACOBI-Matrix eine $n \times n$-Matrix und besitzt n^2 Einträge. Der Aufwand zu ihrer Berechnung ist also proportional zu n^2. Unter Umständen hat $\boldsymbol{f}'$ eine spezielle Struktur, z. B. viele Nulleinträge, dann sollte diese Struktur auch genutzt werden.

Haben wir $\boldsymbol{f}$ nicht explizit gegeben, sondern bspw. lediglich ein Programm, das uns $\boldsymbol{f}(\boldsymbol{x})$ für ein gegebenes $\boldsymbol{x}$ berechnet, haben wir natürlich auch keinen Zugriff auf die JACOBI-Matrix. In

diesem Fall könnten wir zur numerischen Differentiation greifen, siehe Abschnitt 1.3.1, um eine Näherung für die JACOBI-Matrix zu berechnen. Alternativ kann versucht werden, ausgehend von einer ersten Approximation von $\boldsymbol{f}'$ – im einfachsten Fall der Einheitsmatrix – in jedem Schritt der Iteration aus den berechneten Näherungen $\boldsymbol{x}^k$ Informationen über $\boldsymbol{f}'$ zu extrahieren, und so gleichzeitig Approximationen der JACOBI-Matrix zu bestimmen. Diese Zugänge führen uns zu den NEWTON-ähnlichen Verfahren. Die Literatur zu diesen ist umfangreich. In der Regel geht die schnelle Q-quadratische Konvergenz verloren.

Berechnung der NEWTON-Richtung $\boldsymbol{s}^k$. Entsprechend Bem. 2.3.1 ist in jedem Schritt des Verfahrens ein lineares Gleichungssystem

$$\boldsymbol{f}'(\boldsymbol{x}^k)\,\boldsymbol{s}^k = -\boldsymbol{f}(\boldsymbol{x}^k)$$

für $\boldsymbol{s}^k$ zu lösen. Das Standardverfahren hierfür ist das GAUSSsche Eliminationsverfahren. Der Rechenaufwand (Anzahl an Gleitkommaoperationen) ist proportional zu n^3. Für große n ist dies also der aufwändigste Teilschritt des Verfahrens. Kann hier ggf. gespart werden?

Mit einer detailierten Analyse des Eliminationsverfahren beschäftigt sich u. a. die Lehrveranstaltung *Numerik der Linearen Algebra* (Modul 61522). An dieser Stelle sei vorweggenommen, dass es für eine Matrix $\boldsymbol{A} \in \mathbb{R}^{n,n}$ eine Faktorisierung $\boldsymbol{A} = \boldsymbol{LR}$ bestimmt, wobei $\boldsymbol{L} \in \mathbb{R}^{n,n}$ eine untere Dreiecksmatrix ist, und $\boldsymbol{R} \in \mathbb{R}^{n,n}$ eine obere Dreiecksmatrix. Das Gleichungssystem $\boldsymbol{Ax} = \boldsymbol{LRx} = \boldsymbol{b}$ wird dann in zwei Schritten gelöst: Berechne $\boldsymbol{y}$ aus $\boldsymbol{Ly} = \boldsymbol{b}$ und anschließend $\boldsymbol{x}$ aus $\boldsymbol{Rx} = \boldsymbol{y}$.

Der Aufwand für die Berechnung der Faktorisierung $\boldsymbol{A} = \boldsymbol{LR}$ ist proportional zu n^3, während der zum Lösen der zwei Gleichungssysteme mit $\boldsymbol{L}$ bzw. $\boldsymbol{R}$ proportional zu n^2 ist. Eine Idee ist nun, nicht in jedem Iterationsschritt die JACOBI-Matrix und ihre Faktorisierung neu zu berechnen, sondern über mehrere Iterationen hinweg mit der gleichen Matrix zu arbeiten. Dazu werden die Matrizen $\boldsymbol{L}$ und $\boldsymbol{R}$ abgespeichert, und dann in jeder Iteration lediglich die Gleichungssysteme $\boldsymbol{Ly} = \boldsymbol{b}$ und $\boldsymbol{Rx} = \boldsymbol{y}$ gelöst, was mit geringerem Aufwand möglich ist.

I. Allg. wird so die Q-quadratische Konvergenz verloren gehen. Da aber der Aufwand für einige Iterationen geringer ist (n^2 statt n^3), kann das Verfahren so trotzdem insgesamt effizienter sein und geringere Rechenzeiten erfordern.

2.4 Lösungen der Aufgaben

Lösung 2.1.2. Eigenschaften N_1 und N_2 sind evident. Die Dreiecksungleichung (N_3) folgt aus der für $\mathbb{R}$ bekannten Dreiecksungleichung. Sind $\boldsymbol{x}$ und $\boldsymbol{y}$ zwei Vektoren in $\mathbb{R}^n$, dann gilt

$$\|\boldsymbol{x}+\boldsymbol{y}\|_1 = \sum_{i=1}^{n} |x_i + y_i| \leq \sum_{i=1}^{n} (|x_i| + |y_i|) = \sum_{i=1}^{n} |x_i| + \sum_{i=1}^{n} |y_i| = \|\boldsymbol{x}\|_1 + \|\boldsymbol{y}\|_1 ,$$

also die Dreiecksungleichung für die Summennorm. ♣

Lösung 2.1.3. Gemäß Definition existiert ein $k \in \{1, \ldots, n\}$ mit

$$|x_k| = \|\boldsymbol{x}\|_\infty = \max_{i=1,\ldots,n} |x_i| \ .$$

Es folgt

$$\|\boldsymbol{x}\|_\infty = |x_k| \leq \sum_{i=1}^{n} |x_i| = \|\boldsymbol{x}\|_1 \ .$$

Gleichheit gilt für Vektoren mit genau einer von Null verschiedenen Komponente.

Andererseits gilt

$$\|\boldsymbol{x}\|_1 = \sum_{i=1}^{n} |x_i| \leq n\,|x_k| = n\,\|\boldsymbol{x}\|_\infty .$$

Gleichheit gilt für Vektoren deren sämtliche Komponenten betragsmäßig gleich groß sind.

♣

Lösung 2.1.10. Wir müssen die drei Normeigenschaften nachweisen.

N_1: Zunächst folgt, dass $|||\boldsymbol{A}||| \geq 0$ für alle $\boldsymbol{A} \in \mathbb{R}^{n,n}$. Ist $\boldsymbol{A}$ eine Matrix mit $|||\boldsymbol{A}||| = 0$, dann folgt aus (2.1), dass $\|\boldsymbol{A}\boldsymbol{x}\| = 0$ für alle $\boldsymbol{x} \in \mathbb{R}^n$. Mit anderen Worten: $\boldsymbol{A}$ bildet alle Vektoren aus $\mathbb{R}^n$ auf den Nullvektor ab, und ist somit die Nullmatrix in $\mathbb{R}^{n,n}$, kurz

$$|||\boldsymbol{A}||| > 0 \quad \text{für alle} \quad \boldsymbol{A} \in \mathbb{R}^{n,n} \setminus \{\boldsymbol{0}\},$$

d. h. $|||\cdot|||$ ist positiv definit.

N_2: Wir nutzen die absolute Homogenität der Vektornorm $\|\cdot\|$. Seien $\alpha \in \mathbb{R}$ und $\boldsymbol{A} \in \mathbb{R}^{n,n}$ beliebig, dann gilt

$$|||\alpha\boldsymbol{A}||| = \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} \frac{\|\alpha\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} \frac{|\alpha|\,\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = |\alpha| \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = |\alpha|\,|||\boldsymbol{A}||| .$$

Die Norm $|||\cdot|||$ ist somit absolut homogen.

N_3: Wir nutzen, dass $\|\cdot\|$ die Dreiecksungleichung erfüllt. Seinen $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n,n}$ beliebig, dann gilt

$$\begin{aligned} |||\boldsymbol{A}+\boldsymbol{B}||| &= \max_{\boldsymbol{x}\in\mathbb{R}^{n,n}\setminus\{\boldsymbol{0}\}} \frac{\|(\boldsymbol{A}+\boldsymbol{B})\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\boldsymbol{x}\in\mathbb{R}^{n,n}\setminus\{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \max_{\boldsymbol{x}\in\mathbb{R}^{n,n}\setminus\{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\| + \|\boldsymbol{B}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \\ &\leq \max_{\boldsymbol{x}\in\mathbb{R}^{n,n}\setminus\{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} + \max_{\boldsymbol{x}\in\mathbb{R}^{n,n}\setminus\{\boldsymbol{0}\}} \frac{\|\boldsymbol{B}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = |||\boldsymbol{A}||| + |||\boldsymbol{B}||| . \end{aligned}$$

Für die Norm $|||\cdot|||$ gilt also die Dreiecksungleichung.

Zu verifizieren bleibt also nur noch die Submultiplikativität. Definitionsgemäß ist

$$|||\boldsymbol{AB}||| = \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} \frac{||\boldsymbol{ABx}||}{||\boldsymbol{x}||}.$$

Wegen der bereits gezeigten Verträglichkeit von $|||\cdot|||$ und $||\cdot||$ erhalten wir die Ungleichungskette

$$||\boldsymbol{ABx}|| \le |||\boldsymbol{A}||| \, ||\boldsymbol{Bx}|| \le |||\boldsymbol{A}||| \, |||\boldsymbol{B}||| \, ||\boldsymbol{x}|| \,.$$

Also ist

$$|||\boldsymbol{AB}||| = \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} \frac{||\boldsymbol{ABx}||}{||\boldsymbol{x}||} \le \max_{\boldsymbol{x}\in\mathbb{R}^n\setminus\{\boldsymbol{0}\}} |||\boldsymbol{A}||| \, |||\boldsymbol{B}||| = |||\boldsymbol{A}||| \, |||\boldsymbol{B}||| \,,$$

womit wir auch die Submultiplikativität der zugeordneten Matrixnorm nachgewiesen hätten. ♣

Lösung 2.1.12. Betrachte die Norm

$$||\boldsymbol{A}|| := \max_{i,j=1,2} \left|a_{ij}\right| .$$

Für diese Norm gilt

$$\left\|\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}\right\| = \left\|\begin{pmatrix}2 & 2\\ 2 & 2\end{pmatrix}\right\| = 2 \not\le \left\|\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}\right\|^2 = 1.$$

Sie ist also nicht submultiplikativ und somit keine Matrixnorm. ♣

Lösung 2.1.13. (a) Nachzuweisen ist die Submultiplikativität der Frobenius-Norm. Für beliebige Matrizen $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n,n}$ ist zu zeigen, dass

$$||\boldsymbol{AB}||_F \le ||\boldsymbol{A}||_F \, ||\boldsymbol{B}||_F \,,$$

was äquivalent ist zu

$$||\boldsymbol{AB}||_F^2 = \sum_{i=1}^n \sum_{j=1}^n \left|\sum_{k=1}^n a_{ik} b_{kj}\right|^2 \le \sum_{i=1}^n \sum_{j=1}^n \left|a_{ij}\right|^2 \sum_{i=1}^n \sum_{j=1}^n \left|b_{ij}\right|^2 = ||\boldsymbol{A}||_F^2 \, ||\boldsymbol{B}||_F^2 \,.$$

Aus der Cauchy-Schwarzschen Ungleichung folgt

$$\left|\sum_{k=1}^n a_{ik} b_{kj}\right| \le \left\{\sum_{k=1}^n |a_{ik}|^2\right\}^{1/2} \left\{\sum_{k=1}^n \left|b_{kj}\right|^2\right\}^{1/2} .$$

Somit gilt

$$\begin{aligned} ||\boldsymbol{AB}||_F^2 = \sum_{i=1}^n \sum_{j=1}^n \left|\sum_{k=1}^n a_{ik} b_{kj}\right|^2 &\le \sum_{i=1}^n \sum_{j=1}^n \left\{\sum_{k=1}^n |a_{ik}|^2 \cdot \sum_{k=1}^n \left|b_{kj}\right|^2\right\} \\ &= \left\{\sum_{i=1}^n \sum_{k=1}^n |a_{ik}|^2\right\} \cdot \left\{\sum_{j=1}^n \sum_{k=1}^n \left|b_{kj}\right|^2\right\} = ||\boldsymbol{A}||_F^2 \, ||\boldsymbol{B}||_F^2 \end{aligned}$$

(b) Verträglichkeit der Frobenius-Norm mit der Euklidischen Vektornorm. Zu zeigen ist, dass

$$||\boldsymbol{Ax}||_2 \le ||\boldsymbol{A}||_F \, ||\boldsymbol{x}||_2 \,,$$

was äquivalent ist zu

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_{i=1}^{n} \left| \sum_{k=1}^{n} a_{ik} x_k \right|^2 \leq \left\{ \sum_{i=1}^{n} \sum_{k=1}^{n} |a_{ik}|^2 \right\} \cdot \left\{ \sum_{k=1}^{n} |x_k|^2 \right\} = \|\boldsymbol{A}\|_F^2 \, \|\boldsymbol{x}\|_2^2 \,. \qquad (\star)$$

Wir verwenden wiederum die Cauchy-Schwarzsche Ungleichung:

$$\left| \sum_{k=1}^{n} a_{ik} x_k \right| \leq \left\{ \sum_{k=1}^{n} |a_{ik}|^2 \right\}^{1/2} \left\{ \sum_{k=1}^{n} |x_k|^2 \right\}^{1/2}$$

was nach Quadrierung sofort (⋆) ergibt. ♣

Lösung 2.1.14. Die Matrixnorm $\|\cdot\|_*$ ist mit der Vektornorm $\|\cdot\|$ verträglich. Also gilt definitionsgemäß

$$\|\boldsymbol{A}\boldsymbol{x}\| \leq \|\boldsymbol{A}\|_* \, \|\boldsymbol{x}\| \,, \quad \forall \boldsymbol{A} \in \mathbb{R}^{n,n}, \ \ \boldsymbol{x} \in \mathbb{R}^n,$$

woraus folgt, dass

$$\frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \|\boldsymbol{A}\|_* \,, \quad \forall \boldsymbol{A} \in \mathbb{R}^{n,n}, \ \ \boldsymbol{x} \in \mathbb{R}^n \setminus \{\boldsymbol{0}\}.$$

Wir bilden das Maximum über alle $\boldsymbol{x} \in \mathbb{R}^n \setminus \{\boldsymbol{0}\}$ und erhalten

$$|||\boldsymbol{A}||| = \max_{\boldsymbol{x} \in \mathbb{R}^n \setminus \{\boldsymbol{0}\}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \|\boldsymbol{A}\|_* \quad \forall \boldsymbol{A} \in \mathbb{R}^{n,n} \,.$$

♣

Lösung 2.1.15. Zu zeigen ist, dass für jede Matrix $\boldsymbol{A} \in \mathbb{R}^{n,n}$

$$\|\boldsymbol{A}\|_\infty := \max_{i=1,\ldots,n} \sum_{j=1}^{n} \left| a_{ij} \right| = \max_{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\|_\infty = 1} \|\boldsymbol{A}\boldsymbol{x}\|_\infty \,.$$

Dies ist genau dann der Fall, wenn

(i) $\|\boldsymbol{A}\boldsymbol{x}\|_\infty \leq \|\boldsymbol{A}\|_\infty$ für alle $\boldsymbol{x} \in \mathbb{R}^n$ mit $\|\boldsymbol{x}\|_\infty = 1$, und

(ii) es existiert ein $\boldsymbol{x}^* \in \mathbb{R}^n$ mit $\left\|\boldsymbol{x}^*\right\|_\infty = 1$ und $\left\|\boldsymbol{A}\boldsymbol{x}^*\right\|_\infty = \|\boldsymbol{A}\|_\infty$.

Für $A = \boldsymbol{0}$ ist dies stets gesichert. Sei als im Folgenden $A \neq \boldsymbol{0}$.
(i) Sei $\boldsymbol{x} \in \mathbb{R}^n$ mit $\|\boldsymbol{x}\|_\infty = 1$ beliebig, dann gilt

$$\|\boldsymbol{A}\boldsymbol{x}\|_\infty = \max_{i=1,\ldots,n} |(\boldsymbol{A}\boldsymbol{x})_i| = \max_{i=1,\ldots,n} \left| \sum_{j=1}^{n} a_{ij} x_j \right| \leq \max_{i=1,\ldots,n} \sum_{j=1}^{n} \left| a_{ij} x_j \right| \leq \max_{i=1,\ldots,n} \sum_{j=1}^{n} \left| a_{ij} \right| = \|\boldsymbol{A}\|_\infty \,.$$

(ii) Es existiert ein $k \in \{1, \ldots, n\}$ mit $\|\boldsymbol{A}\|_\infty = \sum_{j=1}^{n} \left| a_{kj} \right|$. Wir definieren den Vektor $\boldsymbol{x}^*$ durch

$$x_j^* = \operatorname{sign} a_{kj}, \quad j = 1, \ldots, n.$$

Für diesen ist einerseits $\|\boldsymbol{x}^*\|_\infty = 1$, und andererseits

$$(\boldsymbol{A}\boldsymbol{x}^*)_k = \sum_{j=1}^{n} a_{kj} x_j^* = \sum_{j=1}^{n} a_{kj} \operatorname{sign} a_{kj} = \sum_{j=1}^{n} \left| a_{kj} \right| = \|\boldsymbol{A}\|_\infty \,.$$

Aus (i) folgt $|(\boldsymbol{A}\boldsymbol{x}^*)_i| \le \|\boldsymbol{A}\|_\infty$, $i = 1, \dots, n$. Also ist $\|\boldsymbol{A}\boldsymbol{x}^*\|_\infty = \|\boldsymbol{A}\|$. ♣

Lösung 2.1.16. Für jede beliebige Matrix $\boldsymbol{A} \in \mathbb{R}^{n,n}$ ist die Matrix $\boldsymbol{A}^T\boldsymbol{A} \in \mathbb{R}^{n,n}$ symmetrisch. Somit sind alle ihre Eigenwerte reell. Sei λ ein beliebiger Eigenwert von $\boldsymbol{A}^T\boldsymbol{A}$ und $\boldsymbol{v} \neq \boldsymbol{0}$ ein Vektor aus dem zugehörigen Eigenraum. Dann gilt

$$\|\boldsymbol{A}\boldsymbol{v}\|_2^2 = \boldsymbol{v}^T\boldsymbol{A}^T\boldsymbol{A}\boldsymbol{v} = \boldsymbol{v}^T\lambda\boldsymbol{v} = \lambda\,\|\boldsymbol{v}\|_2^2$$

Daraus folgt $\lambda = \left(\|\boldsymbol{A}\boldsymbol{v}\|_2 \,/\, \|\boldsymbol{v}\|_2\right)^2 \ge 0$. ♣

Lösung 2.1.17. (a) Die einfachste Form eines Existenzbeweises ist die Angabe des betreffenden Objektes. Was zeichnet Matrixnormen gegenüber anderen Normen aus? Es ist ihre Submultiplikativität. An einer Stelle im Beweis müssen wir also das Produkt zweier Matrizen erzeugen. Wir müssen also versuchen, eine geeignete Vektornorm über die Matrixnorm zu definieren.

Wir versuchen

$$\|\boldsymbol{x}\| := \left\|\big(\underbrace{\boldsymbol{x}\ \ \boldsymbol{x}\ \ \cdots\ \ \boldsymbol{x}}_{n\text{-mal}}\big)\right\|_* . \qquad (\star)$$

Dass $\|\cdot\|$ in der Tat eine Vektornorm auf $\mathbb{R}^n$ ist, lässt sich mit wenigen einfachen Überlegungen aus den Normeigenschaften von $\|\cdot\|_*$ schließen.

Für die so definierte Vektornorm ist nun die Verträglichkeit mit der Matrixnorm zu überprüfen. Es gilt

$$\|\boldsymbol{A}\boldsymbol{x}\| = \left\|\big(\underbrace{\boldsymbol{A}\boldsymbol{x}\ \ \boldsymbol{A}\boldsymbol{x}\ \ \cdots\ \ \boldsymbol{A}\boldsymbol{x}}_{n\text{-mal}}\big)\right\|_* = \left\|\boldsymbol{A}\big(\boldsymbol{x}\ \ \boldsymbol{x}\ \ \cdots\ \ \boldsymbol{x}\big)\right\|_* .$$

Wir nutzen die Submultiplikativität der Matrixnorm und schätzen ab

$$\|\boldsymbol{A}\boldsymbol{x}\| \le \|\boldsymbol{A}\|_* \left\|\big(\boldsymbol{x}\ \ \boldsymbol{x}\ \ \cdots\ \ \boldsymbol{x}\big)\right\|_* = \|\boldsymbol{A}\|_*\,\|\boldsymbol{x}\| .$$

Die gegebene Matrixnorm und die mit ihrer Hilfe gemäß ($\star$) definierte Vektornorm sind verträglich.

(b) Gibt es auch immer eine Norm auf $\mathbb{R}^n$, der $\|\cdot\|_*$ zugeordnet ist? Nein, die Frobenius-Norm ist ein Gegenbeispiel. Für jede zugeordnete Matrixnormen gilt $\|\boldsymbol{I}\| = 1$. (Warum ist das so?) Für die Frobenius-Norm ist aber $\|\boldsymbol{I}\|_F = \sqrt{n}$. ♣

Lösung 2.2.3. Die Funktion φ ist kontrahierend mit Kontraktionskonstante $\kappa \in [0, 1)$.

Zu (2.6):

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| = \left\|\varphi(\boldsymbol{x}^{k-1}) - \varphi(\boldsymbol{x}^*)\right\| \le \kappa \left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^*\right\| ,$$

wegen der Kontraktivität von φ.

Zu (2.8):

$$\boldsymbol{x}^k - \boldsymbol{x}^* = \varphi(\boldsymbol{x}^{k-1}) - \varphi(\boldsymbol{x}^*) = \varphi(\boldsymbol{x}^{k-1}) - \varphi(\boldsymbol{x}^k) + \varphi(\boldsymbol{x}^k) - \varphi(\boldsymbol{x}^*)$$

Dreiecksungleichung:

$$\begin{aligned}\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| &\le \left\|\varphi(\boldsymbol{x}^{k-1}) - \varphi(\boldsymbol{x}^k)\right\| + \left\|\varphi(\boldsymbol{x}^k) - \varphi(\boldsymbol{x}^*)\right\| \\ &\le \kappa \left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^k\right\| + \kappa \left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| ,\end{aligned}$$

wegen der Kontraktivität von φ. Durch Subtraktion des Terms $\kappa \left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\|$ folgt

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \le \frac{\kappa}{1-\kappa} \left\|\boldsymbol{x}^{k-1} - \boldsymbol{x}^k\right\| .$$

Zu (2.7): Aus (2.6) folgt induktiv

$$\left\|\boldsymbol{x}^k - \boldsymbol{x}^*\right\| \le \kappa^{k-1} \left\|\boldsymbol{x}^1 - \boldsymbol{x}^*\right\| \le \kappa^{k-1} \frac{\kappa}{1-\kappa} \left\|\boldsymbol{x}^1 - \boldsymbol{x}^0\right\| , \quad \text{wegen (2.8) mit } k = 1$$

♣

2.5 Programmlistings

Programm 2: Fixpunktiteration(en) für die Gleichung $x - e^{-x} = 0$ im Bsp. 2.2.6

```
% Matlab/Octave
x_star= 0.5671432904097838
x_k= 1  % x_0
% x_k= 0.567  % Iteration gemaess x_kp1= -ln x_k

% Berechung der Iterierten x_k, k= 1,...,20
for k= 0:19
  % Berechnung der neuen Iterierten x_{k+1} aus x_k
  x_kp1= exp(-x_k);
  % x_kp1= -log(x_k);

  % Abstand zur alten Iterierten
  norm_kp1= abs(x_kp1-x_k);

  % Ausgabe
  if k == 0
    fprintf(1, "%2d & %.6f & %.3e & \\\\\n", ...
            k+1, x_kp1, abs(x_kp1-x_star));
  else
    fprintf(1, "%2d & %.6f & %.3e & %.3f \\\\\n", ...
            k+1, x_kp1, abs(x_kp1-x_star), norm_kp1/norm_k);
  end

  % neu --> alt
  norm_k= norm_kp1;
  x_k= x_kp1;
end
```

Kapitel 3

Polynome

Polynome spielen in der Numerischen Mathematik eine wichtige Rolle. Einige Gründe seien exemplarisch hervorgehoben.

- Polynome sind vom Standpunkt der Analysis aus sehr einfache Funktionen. Sie lassen sich elementar differenzieren und integrieren.
- Für viele kompliziertere Funktionen können mit Hilfe approximierender Polynome wesentliche lokale Eigenschaften beschrieben werden (z. B. durch TAYLOR-Entwicklung).
- Polynome und rationale Funktionen, also Quotienten zweier Polynome, sind die einzigen Funktionen, die sich durch die vier Grundrechenarten ($+$, $-$, $\times$, $\div$) mit endlich vielen Operationen exakt berechnen lassen. Alle anderen elementaren Funktionen (sin, cos, tan, $\sqrt{\ }$, exp, ln, etc.) können nur näherungsweise berechnet werden, indem ersatzweise stückweise polynomiale oder rationale Funktionen, sog. Splines, ausgewertet werden.
- In der Linearen Algebra führt das Eigenwertproblem für Matrizen auf die Bestimmung des charakteristischen Polynoms dieser Matrix.

Bereits diese kurze Auflistung zeigt, dass Polynome in der Numerischen Mathematik sowohl Hilfsmittel als auch selber Studiengegenstand sind. Wichtig sind beispielsweise Algorithmen zur schnellen und stabilen Auswertung von Polynomen und zur Bestimmung ihrer Nullstellen.

3.1 Intermezzo: Euklidische Vektorräume

Bevor wir uns den Polynomen konkret zuwenden, wollen wir einige Begriffe aus der Linearen Algebra wiederholen, die für unsere Betrachtungen grundlegend sind.

Definition 3.1.1: Skalarprodukt

Sei $\mathbb{V}$ ein Vektorraum über dem Körper $\mathbb{R}$. Eine Abbildung $\langle\cdot,\cdot\rangle : \mathbb{V}\times\mathbb{V} \to \mathbb{R}$ mit den Eigenschaften

S_1: $\langle\cdot,\cdot\rangle$ ist **linear** im ersten Argument, d. h.

$$\langle \alpha\boldsymbol{x} + \beta\boldsymbol{y}, \boldsymbol{z}\rangle = \alpha\langle \boldsymbol{x}, \boldsymbol{z}\rangle + \beta\langle \boldsymbol{y}, \boldsymbol{z}\rangle \quad \forall\, \boldsymbol{x},\boldsymbol{y},\boldsymbol{z}\in\mathbb{V},\ \alpha,\beta\in\mathbb{R}.$$

S_2: $\langle\cdot,\cdot\rangle$ ist **symmetrisch**, d. h.,

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \langle \boldsymbol{y}, \boldsymbol{x}\rangle \quad \forall\, \boldsymbol{x},\boldsymbol{y}\in\mathbb{V}.$$

S_3: $\langle\cdot,\cdot\rangle$ ist **positiv definit**, d. h.,

$$\langle \boldsymbol{x}, \boldsymbol{x}\rangle > 0 \quad \forall\, \boldsymbol{x}\in\mathbb{V}\setminus\{\boldsymbol{0}\}.$$

heißt **Skalarprodukt**.

Das Paar $(\mathbb{V},\langle\cdot,\cdot\rangle)$ bezeichnen wir als **Euklidischen Vektorraum**, vgl. Definition 7.1.1 im *Kurstext Lineare Algebra*.

Bemerkung 3.1.2. Sofern klar ist, welches Skalarprodukt wir betrachten, schreiben wir kurz $\mathbb{V}$ statt $(\mathbb{V},\langle\cdot,\cdot\rangle)$.

Wir erinnern an die folgenden Aussagen, die Ihnen aus der Linearen Algebra bekannt sind.

Satz 3.1.3: Induzierte Norm

Sei $(\mathbb{V},\langle\cdot,\cdot\rangle)$ ein Euklidischer Vektorraum über $\mathbb{R}$. Dann ist

$$\|\boldsymbol{x}\| := \sqrt{\langle \boldsymbol{x}, \boldsymbol{x}\rangle},\quad \boldsymbol{x}\in\mathbb{V},$$

eine Norm auf $\mathbb{V}$. Sie wird als die **durch das Skalarprodukt** $\langle\cdot,\cdot\rangle$ **induzierte Norm** bezeichnet, vgl. *Lehrtext Lineare Algebra*, 7.1.11 und 7.1.13.

Beispiel 3.1.4. Der $\mathbb{R}^n$, $n\in\mathbb{N}$, versehen mit dem Skalarprodukt

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle := \sum_{i=1}^{n} x_i y_i, \tag{3.1}$$

ist ein Euklidischer Vektorraum über $\mathbb{R}$. ♠

Satz 3.1.5: Cauchy-Schwarzsche Ungleichung

Sei $(\mathbb{V}, \langle\cdot,\cdot\rangle)$ ein Euklidischer Vektorraum über $\mathbb{R}$. Dann gilt

$$|\langle \boldsymbol{x}, \boldsymbol{y}\rangle| \leq \|\boldsymbol{x}\|\,\|\boldsymbol{y}\| \quad \forall\ \boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}.$$

Diese Ungleichung wird als **Cauchy[1]- Schwarz[2]sche Ungleichung** bezeichnet, vgl. *Lehrtext Lineare Algebra*, 7.1.15.

Beispiel 3.1.6. Wir betrachten wieder den $\mathbb{R}^n$, $n \in \mathbb{N}$, versehen mit dem Skalarprodukt (3.1). Die induzierte Norm ist gegeben durch

$$\|\boldsymbol{x}\|_2 := \left(\sum_{i=1}^{n} x_i^2\right)^{1/2},$$

die wir auch als die Euklidische Norm bezeichnen. ♠

Beispiel 3.1.7. Ebenfalls ein Euklidischer Vektorraum ist der Raum $(C[a,b], \langle\cdot,\cdot\rangle)$ der stetigen reellwertigen Funktionen auf dem Intervall $[a,b]$ mit Skalarprodukt bzw. induzierter Norm

$$\langle f, g\rangle := \int_a^b f(t)g(t)\,\mathrm{d}t \qquad \text{und} \qquad \|f\|_2 := \left(\int_a^b f(t)^2\,\mathrm{d}t\right)^{1/2}.$$

♠

Mit Hilfe des Skalarproduktes kann auf $\mathbb{V}$ eine Orthogonalitätsrelation eingeführt werden.

Definition 3.1.8: Orthogonalität

Sei $(\mathbb{V}, \langle\cdot,\cdot\rangle)$ ein Euklidischer Vektorraum über $\mathbb{R}$. Zwei Vektoren $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}$, für die

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = 0$$

gilt, heißen **orthogonal** bezüglich des Skalarproduktes $\langle\cdot,\cdot\rangle$, was wir mit $\boldsymbol{x} \perp_{\langle\cdot,\cdot\rangle} \boldsymbol{y}$ bezeichnen.

Bemerkung 3.1.9. Ist klar, welches Skalarprodukt betrachtet wird, so schreiben wir kurz $\boldsymbol{x} \perp \boldsymbol{y}$. Ist $\mathbb{W} \subset \mathbb{V}$ ein Teilraum von $\mathbb{V}$, und ein Vektor $\boldsymbol{x} \in \mathbb{V}$ ist orthogonal zu allen Vektoren aus $\mathbb{W}$, also $\boldsymbol{x} \perp \boldsymbol{y}$, $\forall \boldsymbol{y} \in \mathbb{W}$, dann verwenden wir hierfür die Notation $\boldsymbol{x} \perp \mathbb{W}$.

Im Folgenden verwenden wir hochgestellte Indizes, um Vektoren zu nummerieren.

Aufgabe 3.1.10. Sei $(\mathbb{V}, \langle\cdot,\cdot\rangle)$ ein Euklidischer Vektorraum und $\mathbb{V}_n \subset \mathbb{V}$ ein n-dimensionaler Unterraum von $\mathbb{V}$ mit Basis $\boldsymbol{v}^1, \ldots, \boldsymbol{v}^n$. Zeigen Sie: Für einen Vektor $\boldsymbol{w} \in \mathbb{V}$ gilt

$$\langle \boldsymbol{w}, \boldsymbol{v}\rangle = 0 \quad \forall\ \boldsymbol{v} \in \mathbb{V}_n \qquad \Longleftrightarrow \qquad \langle \boldsymbol{w}, \boldsymbol{v}^i\rangle = 0, \ \text{ für alle } \ i = 1, \ldots, n.$$

♢

[1] Augustin Louis Cauchy, *21.08.1789 (Paris), †23.05.1857 (Sceaux, bei Paris)
[2] Hermann Amandus Schwarz, *25.1.1843 (Hermsdorf, Schlesien, jetzt Polen), †30.11.1921 (Berlin)

Definition 3.1.11: Lineare Hülle

Seien $\mathbb{V}$ ein Vektorraum über $\mathbb{R}$ und $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k \in \mathbb{V}$. Die Menge

$$\operatorname{span}\{\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k\} := \left\{ \boldsymbol{v} \in \mathbb{V} : \exists\, a_1, \ldots, a_k \in \mathbb{R} \text{ mit } \boldsymbol{v} = \sum_{j=1}^{k} a_j \boldsymbol{x}^j \right\}$$

heißt **lineare Hülle** (englisch: span) der Vektoren $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k$. Sie enthält alle Vektoren aus $\mathbb{V}$, die sich als Linearkombination der Vektoren $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k$ darstellen lassen.

Bemerkung 3.1.12. Für beliebige $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k \in \mathbb{V}$ ist $\operatorname{span}\left\{\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k\right\}$ ein Unterraum von $\mathbb{V}$ der Dimension $\leq k$. Die Dimension ist gleich k genau dann, wenn die Vektoren $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k$ linear unabhängig sind.

Einem wichtigen Resultat von E. Schmidt[3] zufolge, kann in einem Euklidischen Vektorraum jedes System $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k$ linear unabhängiger Vektoren orthonormalisiert werden, d. h. es existiert eine Menge orthonormaler Vektoren $\boldsymbol{v}^1, \ldots, \boldsymbol{v}^k$ mit

$$\operatorname{span}\left\{\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k\right\} = \operatorname{span}\left\{\boldsymbol{v}^1, \ldots, \boldsymbol{v}^k\right\}.$$

Dies wird durch das Gram[4]-Schmidtschen Orthonormalisierungsverfahrens bewerkstelligt. Auch hier ist die Namensgebung, was den Ursprung des Verfahrens betrifft etwas irreführend, wurde diese Technik doch schon von Laplace[5] und Cauchy verwendet.

Algorithmus 3.1.13: Gram-Schmidt-Verfahren

Gegeben: k linear unabhängige Vektoren $\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k$ eines Euklidischen Vektorraums $(\mathbb{V}, \langle \cdot, \cdot \rangle)$ mit induzierter Norm $\|\cdot\|$.

S1. $\boldsymbol{u}^1 := \dfrac{\boldsymbol{x}^1}{\|\boldsymbol{x}^1\|}$

S2. FOR $i = 2, 3, \ldots, k$ DO

$$\tilde{\boldsymbol{u}}^i := \boldsymbol{x}^i - \sum_{j=1}^{i-1} \langle \boldsymbol{x}^i, \boldsymbol{u}^j \rangle \boldsymbol{u}^j$$

$$\boldsymbol{u}^i := \frac{\tilde{\boldsymbol{u}}^i}{\|\tilde{\boldsymbol{u}}^i\|}$$

END DO

Ergebnis: Die Vektoren $\boldsymbol{u}^1, \ldots, \boldsymbol{u}^k$ bilden eine orthonormale Basis in $\operatorname{span}\{\boldsymbol{x}^1, \ldots, \boldsymbol{x}^k\}$.

[3] Erhard Schmidt, *13.01.1876 (Dorpat, Estland), †16.12.1959 (Berlin)
[4] Jørgen Pedersen Gram, *27.06.1850 (Nustrup, Dänemark), †29.04.1916 (Kopenhagen, Dänemark)
[5] Pierre-Simon Laplace, *23.3.1749 (Beaumont-en-Auge, Frankreich), †5.3.1827 (Paris, Frankreich)

3.2 Vektorraum und Ring der Polynome

In diesem Abschnitt führen wir Polynome ein, studieren ihre Struktur und fassen knapp einige ihrer wichtigsten Eigenschaften zusammen. Die meisten Aussagen dürften aus Kursen zur Analysis und Algebra bekannt sein. Im Anschluss lernen Sie das HORNER-Verfahren zur Auswertung von Polynomen kennen.

Definition 3.2.1: Polynome

Sei $\mathbb{K}$ ein Körper.

- Für $n \in \mathbb{N}_0$ bezeichnet $\mu_n \colon \mathbb{K} \to \mathbb{K} \colon x \mapsto x^n$ das **Monom *n*-ten Grades** über $\mathbb{K}$.
- Für beliebige $a_i \in \mathbb{K}$, $i \in \mathbb{N}_0$, nennen wir die Funktion

$$p \colon \mathbb{K} \to \mathbb{K} \colon x \mapsto p(x) \coloneqq a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n \tag{3.2}$$

  ein **Polynom vom Höchstgrad *n*** über $\mathbb{K}$.
- Ist $a_n \neq 0$, so besitzt p den Grad n, und wir schreiben Grad $p = n$. In diesem Fall heißt a_n **Höchstkoeffizient** oder auch **Leitkoeffizient** des Polynoms p.
- Den Grad des Nullpolynoms $p = 0 \cdot \mu_0$ definieren wir als -1.
- Die Gesamtheit der Polynome vom Höchstgrad n über $\mathbb{C}$ bezeichnen wir mit Π_n, die Gesamtheit aller Polynome (beliebigen Grades) über $\mathbb{C}$ mit Π.

Definition 3.2.2: Notation

Die Addition und Multiplikation zweier Funktionen f und g, $f, g \colon D \subset \mathbb{K} \to \mathbb{K}$, sowie die Multiplikation mit Elementen $\alpha \in \mathbb{K}$ notieren wir wie folgt:

$$f + g \colon D \to \mathbb{K} \colon x \mapsto (f+g)(x) \coloneqq f(x) + g(x)\,, \tag{3.3a}$$

$$fg \colon D \to \mathbb{K} \colon x \mapsto (fg)(x) \coloneqq f(x)g(x) \tag{3.3b}$$

und

$$\alpha f \colon D \to \mathbb{K} \colon x \mapsto (\alpha f)(x) \coloneqq \alpha f(x). \tag{3.3c}$$

Weiterhin schreiben wir „$f = g$ auf D“, falls $f(x) = g(x)$ für alle $x \in D$.

Mit diesen Vereinbarungen haben wir für das Polynom p in (3.2) auch die Darstellung

$$p = a_0\mu_0 + a_1\mu_1 + a_2\mu_2 + \cdots + a_n\mu_n = \sum_{i=0}^{n} a_i\mu_i.$$

3.2.1 Der Ring der Polynome

Versehen mit der Addition (3.3a) und der Multiplikation (3.3b) ist Π ein Ring, wobei die Multiplikation lediglich die Struktur einer Halbgruppe mit neutralem Element induziert. Daher ist die Aufgabe, für gegebene $p, q \in \Pi$ eine Lösung $s \in \Pi$ der Gleichung $p = sq$ zu bestimmen, i. Allg. nicht lösbar. Eine Polynomdivision ist lediglich mit Rest im Sinne des folgenden Satzes durchführbar.

Satz 3.2.3: Polynomdivision mit Rest

Sind p, q zwei vom Nullpolynom verschiedene Polynome über $\mathbb{K}$ mit $\operatorname{Grad} q \leq \operatorname{Grad} p$, so existieren eindeutig bestimmte Polynome s und r, so dass $p = sq + r$ und $\operatorname{Grad} r < \operatorname{Grad} q$. Ferner ist $\operatorname{Grad} s = \operatorname{Grad} p - \operatorname{Grad} q$.

Beispiel 3.2.4. $\underbrace{\mu_6 - 1}_{p} = \underbrace{\mu_2}_{s}\underbrace{(\mu_4 - 1)}_{q} + \underbrace{\mu_2 - 1}_{r}$ bzw. $x^6 - 1 = x^2(x^4 - 1) + x^2 - 1$. ♠

Im Folgenden interessieren uns Aussagen über die Nullstellen von Polynomen über $\mathbb{C}$.

Satz 3.2.5: Hauptsatz der Algebra

Ein Polynom p über $\mathbb{C}$ vom Grad $n \geq 0$

$$p = a_0 + a_1\mu_1 + a_2\mu_2 + \cdots + a_n\mu_n,$$

besitzt genau n Nullstellen $z_i \in \mathbb{C}$, $i = 1, \ldots, n$, (mit ihrer Vielfachheit gezählt) und lässt sich als Produkt von n **Linearfaktoren** darstellen:

$$p(x) = a_n(x - z_1)\cdots(x - z_n).$$

Folgerung 3.2.6. *Ein Polynom vom Grad $n \geq 0$ mit reellen Koeffizienten besitzt maximal n reelle Nullstellen.*

Aufgabe 3.2.7. Ein Polynom mit reellen Koeffizienten besitze die Nullstelle $z \in \mathbb{C}$. Zeigen Sie, dass auch die zu z konjugiert komplexe Zahl $\bar{z}$ eine Nullstelle dieses Polynoms ist! ♢

Satz 3.2.8

(i) Ein Polynom $p \in \Pi_n$, $n \geq 0$ ist durch seine Werte in $n + 1$ paarweise verschiedenen Stellen x_i, $i = 0, \ldots, n$, eindeutig bestimmt.

(ii) Zwei Polynome p und q, die auf einem Intervall $(a, b) \subset \mathbb{R}$, $a < b$ übereinstimmen, d. h. $p(x) = q(x)$ für alle $x \in (a, b)$, sind auf $\mathbb{C}$ identisch, d. h., $p(x) = q(x)$ für alle $x \in \mathbb{C}$.

Beweis. (i) Der Beweis erfolgt indirekt. Angenommen es gibt zwei verschiedene Polynome p und $\hat{p}$ vom Höchstgrad n mit $p(x_i) = \hat{p}(x_i)$, $i = 0, \ldots, n$.

Die Differenz $q = p - \hat{p} \neq 0$ ist einerseits ein Polynom mit $0 \leq \operatorname{Grad} q \leq n$, besitzt andererseits wegen $q(x_i) = p(x_i) - \hat{p}(x_i) = 0$, $i = 0, \ldots, n$, aber $n + 1$ Nullstellen. Dies steht im Widerspruch zu Satz 3.2.5. Die Annahme ist somit falsch.

(ii) Sei $s := \text{Grad}(p-q)$. Da p und q auf (a,b) übereinstimmen, existieren $s+1$ paarweise verschiedene Punkte $x_i \in (a,b)$, $i = 0,\dots,s$, mit $(p-q)(x_i) = 0$. Aussage *(i)* impliziert, dass $p - q = 0$ auf $\mathbb{C}$. □

3.2.2 Der Vektorraum der Polynome

Versehen mit der Addition (3.3a) und der Multiplikation (3.3c) bilden sowohl die Polynome Π_n vom Höchstgrad $n \in \mathbb{N}_0$ als auch die Polynome Π beliebigen Grades einen Vektorraum über $\mathbb{K}$. Diese lassen sich wegen (3.2) auch als **lineare Hülle** der Monome beschreiben:

$$\Pi_n = \text{span}\,\{\mu_0, \mu_1, \dots, \mu_n\} \quad \text{bzw.} \quad \Pi = \text{span}\,\{\mu_0, \mu_1, \dots\}\,.$$

Der aus der Linearen Algebra bekannte Begriff der linearen Unabhängigkeit von Vektoren im $\mathbb{R}^n$ bzw. $\mathbb{C}^n$ lässt sich auf Funktionen verallgemeinern.

Definition 3.2.9: Lineare Unabhängigkeit

Sei $\mathbb{K}$ ein Körper. Die n Funktionen $f_k : D \subset \mathbb{K} \to \mathbb{K}$, $k = 1,\dots,n$, heißen **linear unabhängig (über *D*)**, falls aus

$$\sum_{k=1}^{n} a_k f_k = 0 \quad \text{auf } D \quad \text{folgt, dass } a_k = 0 \text{ für } k = 1,\dots,n.$$

Andernfalls werden sie als **linear abhängig** bezeichnet.

Satz 3.2.10

Über $\mathbb{Q}$, $\mathbb{R}$ und $\mathbb{C}$ sind die Monome μ_i, $i = 0, 1, \dots, n$, linear unabhängig.

Beweis. Dies ist eine unmittelbare Folgerung aus Satz 3.2.8.(i). □

Folgerung 3.2.11. *Wegen der Darstellung (3.2) sind die Monome μ_i, $i = 0,\dots,n$, ein Erzeugendensystem in Π_n. Wegen ihrer linearen Unabhängigkeit bilden sie eine Basis des Π_n. Somit gilt* $\dim \Pi_n = n + 1$.

Aus der Linearen Algebra ist bekannt, dass ein Vektorraum verschiedene Basen besitzt. So können wir auch, je nach Problemstellung, andere Basen des Π_n heranziehen, wenn dies geboten ist. Einige wichtige alternative Basen werden wir in den Abschnitten 3.3 und 3.4 sowie im Kapitel 4 kennenlernen.

3.2.3 Das Horner-Verfahren

Das **Horner**[6]**-Verfahren** dient der effizienten Berechnung des Funktionswertes eines in Monom-Darstellung gegebenen Polynoms $p \in \Pi_n$,

$$p(x) = \sum_{i=0}^{n} a_i x^i, \tag{3.4}$$

[6] William George Horner, *1786 (Bristol, England), †22.09.1837 (Bath, England)

an einer Stelle $\alpha \in \mathbb{K}$.

Der Algorithmus lässt sich durch einfaches Ausklammern von Potenzen von x motivieren:

$$p(x) = a_0 + x(a_1 + x(a_2 + \cdots + x(a_{n-2} + x(a_{n-1} + xa_n)) \cdots)).$$

Die Berechnung des Polynoms erfolgt nun von „innen nach außen“ mit der innersten Klammer beginnend.

Algorithmus 3.2.12: HORNER-Verfahren

Gegeben: Ein Polynom p über $\mathbb{K}$ in Monom-Darstellung (3.4) und ein $\alpha \in \mathbb{K}$.

S1. $a_n^{(1)} := a_n$,

S2. FOR $i = n-1, n-2, \ldots, 0$ DO
$a_i^{(1)} := a_{i+1}^{(1)}\alpha + a_i$
END DO

Ergebnis: $p(\alpha) = a_0^{(1)}$.

Eine einfache für die Handrechnung geeignete tabellarische Darstellung dieses Algorithmus ist das sogenannte **HORNER-Schema**:

	a_n	a_{n-1}	a_{n-2}	$\ldots$	a_1	a_0
α	—	$\alpha\, a_n^{(1)}$	$\alpha\, a_{n-1}^{(1)}$	$\ldots$	$\alpha\, a_2^{(1)}$	$\alpha\, a_1^{(1)}$
	$a_n^{(1)}$	$a_{n-1}^{(1)}$	$a_{n-2}^{(1)}$	$\ldots$	$a_1^{(1)}$	$\boxed{a_0^{(1)}}$

Beispiel 3.2.13. Wir wollen das Polynom p,

$$p(x) = 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8,$$

an der Stelle $x = 1/2$ auswerten und stellen dazu das HORNER-Schema für p auf:

	160	32	−216	−44	58	14	−8
1/2	—	80	56	−80	−62	−2	6
	160	112	−160	−124	−4	12	−2

♠

Bemerkung 3.2.14. Man zählt schnell nach, dass zur Berechnung des Funktionswertes mit Hilfe des HORNER-Algorithmus jeweils n Multiplikationen und Additionen erforderlich sind. Eine naive Berechnung nach (3.4) erfordert hingegen $(n+1)n/2$ Multiplikationen und n Additionen. Sie ist also für Polynome hohen Grades signifikant aufwändiger.

Eine alternative Möglichkeit, das HORNER-Verfahren herzuleiten, beruht auf der Polynomdivision mit Rest, also Satz 3.2.3. Für gegebenes α dividieren wir das Polynom p durch $x-\alpha$, ein Polynom ersten Grades in x. Ein Vergleich mit Satz 3.2.3 zeigt, dass die Rechnung identisch zu Alg. 3.2.12 abläuft. Wir erhalten

$$p(x) = \sum_{i=0}^{n} a_i x^i = (x-\alpha) \sum_{i=1}^{n} a_i^{(1)} x^{i-1} + a_0^{(1)}$$

und offensichtlich $p(\alpha) = a_0^{(1)}$.

3.2.3.1 Polynomdivision, Abspaltung von Linearfaktoren

Ist α eine Nullstelle des Polynoms p, so folgt

$$p(x) = \sum_{i=0}^{n} a_i x^i = (x-\alpha) \sum_{i=1}^{n} a_i^{(1)} x^{i-1}. \tag{3.5}$$

Deshalb kann man das Horner-Verfahren auch zum Abspalten eines Linearfaktors eines Polynoms benutzen, wenn eine Nullstelle bekannt ist. Das heißt, zu einem gegebenem Polynom $p \in \Pi_n$ mit der Nullstelle α wird ein Polynom $p_1 \in \Pi_{n-1}$ bestimmt, für das $p(x) = (x-\alpha)p_1(x)$ gilt. Wir vergleichen mit (3.5) und sehen, dass

$$p_1(x) = \sum_{i=1}^{n} a_i^{(1)} x^{i-1}.$$

Sind m Nullstellen z_i, $i = 1, \ldots, m$, von p bekannt, die nicht verschieden sein müssen, so kann man diese durch sukzessive m-fache Anwendung des Horner-Schemas abspalten. Wir erhalten

$$p(x) = (x-z_1)\cdots(x-z_m)p_m(x), \quad p_m \in \Pi_{n-m}.$$

Ist $m = n$, so erhält man die Zerlegung in Linearfaktoren entsprechend Satz 3.2.5. Ferner ist $p_n = a_n$. Die Rechnung im **erweiterten Horner-Schema** (hier exemplarisch für $m = 2$) läuft wie folgt ab.

	a_n	a_{n-1}	a_{n-2}	$\ldots$	a_1	a_0
z_1	$-$	$z_1\, a_n^{(1)}$	$z_1\, a_{n-1}^{(1)}$	$\ldots$	$z_1\, a_2^{(1)}$	$z_1\, a_1^{(1)}$
	$a_n^{(1)}$	$a_{n-1}^{(1)}$	$a_{n-2}^{(1)}$	$\ldots$	$a_1^{(1)}$	0
z_2	$-$	$z_2\, a_n^{(2)}$	$z_2\, a_{n-1}^{(2)}$	$\ldots$	$z_2\, a_2^{(2)}$	
	$a_n^{(2)}$	$a_{n-1}^{(2)}$	$a_{n-2}^{(2)}$	$\ldots$	0	

Für das Polynom p_m erhalten wir die Monom-Darstellung

$$p_m(x) = \sum_{i=m}^{n} a_i^{(m)} x^{i-m}.$$

Aufgabe 3.2.15. Das Polynom q, $q(x) = x^5 - 4x^4 + 4x^3 + 2x^2 - 5x + 2$, hat die beiden Nullstellen 2 und -1. Spalten Sie mit Hilfe des erweiterten Horner-Schemas die Linearfaktoren $(x-2)$ und $(x+1)$ ab. ◊

3.2.3.2 Verschobene Monom-Basis, vollständiges Horner-Schema

Wird das Horner-Schema mit derselben Stelle α sukzessive n-mal angewendet, so erhalten wir eine Entwicklung

$$p(x) = a_0^{(1)} + a_1^{(2)}(x-\alpha) + \ldots + a_{n-1}^{(n)}(x-\alpha)^{n-1} + a_n^{(n+1)}(x-\alpha)^n \tag{3.6}$$

bezüglich der **verschobenen Monom-Basis**

$$\mu_{\alpha,i}\colon x \mapsto (x-\alpha)^i, \quad i \in \mathbb{N}_0.$$

Für beliebiges $\alpha \in \mathbb{C}$ bilden die $\mu_{\alpha,i}$, $i = 0, \ldots, n$, eine Basis des Π_n.

Im **vollständigen Horner-Schema** verläuft die Rechnung folgendermaßen:

	a_n	a_{n-1}	a_{n-2}	$\ldots$	a_1	a_0
α	$-$	$\alpha\, a_n^{(1)}$	$\alpha\, a_{n-1}^{(1)}$	$\ldots$	$\alpha\, a_2^{(1)}$	$\alpha\, a_1^{(1)}$
	$a_n^{(1)}$	$a_{n-1}^{(1)}$	$a_{n-2}^{(1)}$	$\ldots$	$a_1^{(1)}$	$\boxed{a_0^{(1)}}$
α	$-$	$\alpha\, a_n^{(2)}$	$\alpha\, a_{n-1}^{(2)}$	$\ldots$	$\alpha\, a_2^{(2)}$	
	$a_n^{(2)}$	$a_{n-1}^{(2)}$	$a_{n-2}^{(2)}$	$\ldots$	$\boxed{a_1^{(2)}}$	
$\vdots$	$\vdots$	$\vdots$	$\vdots$			
	$a_n^{(n-1)}$	$a_{n-1}^{(n-1)}$	$\boxed{a_{n-2}^{(n-1)}}$			
α	$-$	$\alpha\, a_n^{(n)}$				
	$a_n^{(n)}$	$\boxed{a_{n-1}^{(n)}}$				
α	$-$					
	$\boxed{a_n^{(n+1)}}$					

Ein Vergleich von (3.6) mit der Taylor-Entwicklung

$$p(x) = \sum_{i=0}^{n} \frac{p^{(i)}(\alpha)}{i!}(x-\alpha)^i$$

zeigt, dass

$$a_i^{(i+1)} = \frac{p^{(i)}(\alpha)}{i!}, \quad i = 0, 1, \ldots, n,$$

gilt. Mit Hilfe des Horner-Schemas können also auch die Ableitungswerte eines Polynoms berechnet werden.

Aufgabe 3.2.16. Werten Sie das Polynom p,

$$p(x) = 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8,$$

sowie seine erste und zweite Ableitung mit Hilfe des Horner-Schemas an der Stelle $x = 1/2$ aus! ◊

3.3 Tschebyscheff-Polynome

Eine wichtige Klasse von Basispolynomen sind die Tschebysheff[7]-Polynome, insbesondere jene erster Art. Wir werden im Abschnitt 4.9 auf sie zurückkommen, wenn es gilt, gewisse Eigenschaften von interpolierenden Polynomen zu optimieren.

Definition 3.3.1: Tschebyscheff-Polynome

Die durch die dreigliedrige Rekursion

$$T_{n+1} = 2\mu_1 T_n - T_{n-1}, \quad n = 1, 2, \ldots, \qquad T_0 = \mu_0, \quad T_1 = \mu_1, \tag{3.7}$$

definierten Polynome über $\mathbb{C}$ werden als **Tschebyscheff-Polynome (erster Art)** bezeichnet.

Für $n \geq 1$ ist T_n ein Polynom n-ten Grades mit Höchstkoeffizienten 2^{n-1}.

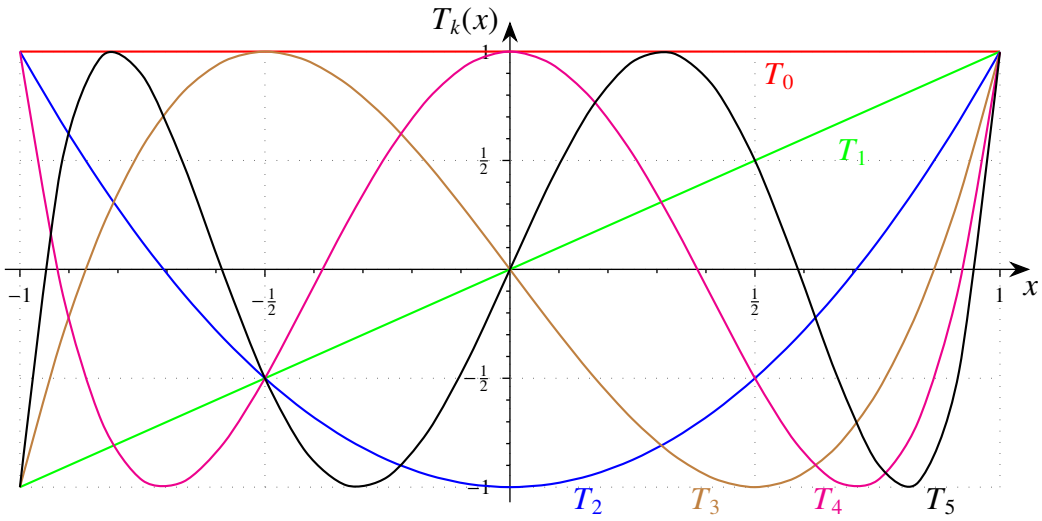


Abbildung 3.1: Die Tschebyscheff-Polynome erster Art $T_0, \ldots, T_5$ auf $[-1, 1]$.

Aufgabe 3.3.2. *(a)* Bestimmen Sie die Monom-Darstellung der Tschebyscheff-Polynome $T_0, \ldots, T_6$!

(b) Stellen Sie das Polynom $p = 160\mu_6 + 32\mu_5 - 216\mu_4 - 44\mu_3 + 58\mu_2 + 14\mu_1 - 8$, als Linearkombination der $T_0, \ldots, T_6$ dar! ◊

[7] Pafnuti Lwowitsch Tschebyscheff, *16.5.1821 (Okatovo, Russland), †8.12.1894 (St. Petersburg, Russland)

Satz 3.3.3

Auf $\mathbb{R}$ besitzen die Tschebyscheff-Polynome die Darstellungen

$$T_n(x) = \begin{cases} \cos(n \arccos x), & x \in [-1,1], \\ \cosh(n \operatorname{arcosh} x), & x \geq 1, \\ (-1)^n \cosh(n \operatorname{arcosh}(-x)), & x \leq -1. \end{cases}$$

Aufgabe 3.3.4. Beweisen Sie Satz 3.3.3 für $x \in (-1,1)$! Hinweis: Substituieren Sie $t = \arccos x$, und wenden Sie die Additionstheoreme für trigonometrische Funktionen auf T_{n+1} und T_{n-1} an. ◊

Der folgende Satz fasst wichtige Eigenschaften der Tschebyscheff-Polynome erster Art zusammen. Im Abschnitt 4.9 werden wir auf sie zurückgreifen.

Satz 3.3.5

Für die Tschebyscheff-Polynome erster Art gilt:

(i) $|T_n(x)| \leq 1$ für $x \in [-1,1]$.

(ii) T_n besitzt im Intervall $[-1,1]$ die Extremalpunkte

$$x_k^{(n)} = \cos \frac{k\pi}{n}, \quad k = 0, \ldots, n, \quad \text{mit} \quad T_n(x_k^{(n)}) = (-1)^k.$$

(iii) T_n hat die n einfachen und im Intervall $(-1,1)$ gelegenen Nullstellen

$$\tilde{x}_k^{(n)} = \cos \frac{(2k-1)\pi}{2n}, \quad k = 1, \ldots, n. \tag{3.8}$$

(iv) Die Nullstellen besitzen die sog. **Trennungseigenschaft**:

$$\tilde{x}_{k+1}^{(n+1)} < \tilde{x}_k^{(n)} < \tilde{x}_k^{(n+1)} \quad k = 1, \ldots, n, \quad n \in \mathbb{N}, \tag{3.9}$$

d. h., zwischen je zwei benachbarten Nullstellen von T_{n+1} liegt eine Nullstelle von T_n.

Beweis. *(i)* Diese Aussage folgt unmittelbar aus Satz 3.3.3, da $|\cos t| \leq 1$ für alle $t \in \mathbb{R}$.

(ii) Wegen *(i)* sind alle $x \in [-1,1]$ mit $|T_n(x)| = 1$ Extremalpunkte. Ferner gilt

$$|\cos y| = 1 \quad \Longleftrightarrow \quad y = k\pi, \quad k \in \mathbb{Z}.$$

Also ist $|T_n(x)| = 1$ genau dann, wenn

$$k\pi = n \arccos x. \tag{3.10}$$

Der Wertebereich der arccos-Funktion ist das Intervall $[0, \pi]$, weshalb alle Extremalstellen x von T_n durch (3.10) mit $k = 0, \ldots, n$ gegeben sind.

(iii) Aus Satz 3.3.3 und (3.8) folgt, dass

$$T_n(\tilde{x}_k^{(n)}) = \cos\frac{(2k-1)\pi}{2} = 0, \quad k = 1, \dots, n.$$

Dies sind alle n Nullstellen von T_n, da jedes Polynom vom Grad n genau n Nullstellen in $\mathbb{C}$ hat, vgl. Satz 3.2.5. Außerdem folgt, dass alle Nullstellen einfach sind.

(iv) Setze

$$t_k^{(n)} := \frac{2k-1}{2n}\pi, \quad k = 1, \dots, n, \quad n \in \mathbb{N}.$$

Es ist leicht nachzurechnen, dass

$$0 < t_k^{(n+1)} < t_k^{(n)} < t_{k+1}^{(n+1)} < \pi, \quad k = 1, \dots, n, \quad n \in \mathbb{N}.$$

Aus der strengen Monotonie der Kosinusfunktion auf $[0, \pi]$ folgt die Trennungseigenschaft. □

Aufgabe 3.3.6. Beweisen Sie:

$$\int_{-1}^{1} \frac{T_i(x)T_j(x)}{\sqrt{1-x^2}}\,\mathrm{d}x = \begin{cases} 0, & i \neq j, \\ \pi, & i = j = 0, \\ \pi/2, & i = j \neq 0. \end{cases}$$

Hinweise: Nutzen Sie die trigonometrische Darstellung der T_k und substituieren Sie geeignet! ◊

3.4 Orthogonale Polynome

In der Numerischen Mathematik spielen orthogonale Polynome – insbesondere ihre Nullstellen – eine herausragende Rolle bei der Approximation von Integralen (Kapitel 5) und von Lösungen von Differentialgleichungen (Numerik II), aber auch bei der Konstruktion iterativer Verfahren zum Lösen linearer Gleichungssysteme.

Unabhängig davon sind orthogonale Polynome ein faszinierendes Studienobjekt der Mathematik! Leider können wir im Rahmen dieses Kurses nur eine Einführung geben. Wir beschränken uns hierbei auf Polynome über $\mathbb{R}$.

3.4.1 Der Orthogonalitätsbegriff für Polynome

Definition 3.4.1: Gewichtsfunktion

Sei $I = (a, b) \subset \mathbb{R}$ ein offenes Intervall. Eine Funktion $\varrho\colon (a, b) \to \mathbb{R}_+$, für die das Integral

$$\int_a^b p(x)\varrho(x)\,\mathrm{d}x$$

für alle $p \in \Pi$ existiert, nennen wir eine **Gewichtsfunktion** über I.

Satz 3.4.2

Bei gegebener Gewichtsfunktion $\varrho\colon (a, b) \to \mathbb{R}_+$ ist

$$\langle v, w\rangle_\varrho := \int_a^b v(x)w(x)\varrho(x)\,\mathrm{d}x \tag{3.11}$$

ein Skalarprodukt auf Π und

$$\|v\|_\varrho := \langle v, v\rangle_\varrho^{1/2}.$$

die durch dieses Skalarprodukt induzierte Norm auf Π.

Bemerkung 3.4.3. Besitzt die Gewichtsfunktion ϱ Singularitäten oder ist das Intervall I unbeschränkt, dann sind die auftretenden Integrale im Sinne von uneigentlichen Integralen zu verstehen.

Aufgabe 3.4.4. Beweisen Sie Satz 3.4.2! ◊

Definition 3.4.5: Orthogonale Polynome

Seien $I \subset \mathbb{R}$ ein offenes Intervall, $\varrho\colon I \to \mathbb{R}_+$ eine Gewichtsfunktion und $\langle\cdot,\cdot\rangle_\varrho$ das zugehörige Skalarprodukt gemäss (3.11). Eine Folge $(u_i)_{i=0}^\infty$ von Polynomen $u_i \in \Pi_i$, $u_i \neq 0$ mit

$$\langle u_i, u_j\rangle_\varrho = 0 \quad \text{für} \quad i \neq j,$$

wird als Folge von **(bezüglich ϱ) orthogonalen Polynomen** bezeichnet.

Bemerkung 3.4.6. Die Mengen $\{u_i\}_{i=0}^n$ und $\{u_i\}_{i=0}^\infty$ bilden orthogonale Basen in Π_n bzw. in Π. Es gilt $\operatorname{Grad} u_i = i$ und somit $u_i \in \Pi_i \backslash \Pi_{i-1}$. Ferner sind – vgl. Aufg. 3.1.10 – die u_i orthogonal zu allen Polynomen $q \in \Pi_{i-1}$, d. h. $\langle u_i, q\rangle_\varrho = 0$ für alle $q \in \Pi_{i-1}$, was wir kurz mit $u_i \perp \Pi_{i-1}$ notieren.

Bemerkung 3.4.7. Die u_i sind durch Vorgabe von ϱ bis auf multiplikative Konstanten eindeutig bestimmt, siehe Aufg. 3.4.8. Es gibt verschiedene Möglichkeiten, die u_i eindeutig zu definieren, z. B.

- Normierung: $\|u_i\|_\varrho = 1$. Die u_i bilden dann eine orthonormale Basis des Π_n bzw. Π und werden daher als (bzgl. ϱ) **orthonormale** Polynome bezeichnet.
- Der Leitkoeffizient von u_i ist 1. In diesem Fall nennt man die Polynome **monisch**.
- Der Funktionswert in einem Randpunkt von I ist 1. (Im Satz 3.7.1 werden wir zeigen, dass die Randpunkte von I keine Nullstellen von u_i sind.)

Aufgabe 3.4.8. Seien ϱ eine Gewichtsfunktion, und $u_i, \tilde{u}_i \in \Pi_i \backslash \Pi_{i-1}$, $i \in \mathbb{N}$, zwei bzgl. ϱ zu Π_{i-1} orthogonale Polynome mit Leitkoeffizienten γ_i bzw. $\tilde{\gamma}_i$. Zeigen Sie, dass $\tilde{\gamma}_i u_i = \gamma_i \tilde{u}_i$. ◊

Ein Beispiel orthogonaler Polynome kennen wir bereits, nämlich die Tschebyscheff-Polynome $T_i \in \Pi_i$ erster Art. In Aufg. 3.3.6 haben Sie bewiesen, dass sie bezüglich der Gewichtsfunktion

$$\varrho_T : (-1,1) \to \mathbb{R}_+ : x \mapsto \varrho_T(x) = \frac{1}{\sqrt{1-x^2}}$$

orthogonal sind. In Anbetracht von Satz 3.3.3 sind sie so normalisiert, dass $T_i(1) = 1$, $i \in \mathbb{N}_0$.

Beispiel 3.4.9. Ausgehend von Def. 3.4.5 wollen wir jetzt exemplarisch ein System orthogonaler Polynome P_i konstruieren, die bzgl. der Gewichtsfunktion

$$\varrho_P : (-1,1) \to \mathbb{R} : x \mapsto \varrho_P(x) = 1$$

orthogonal sind. Für P_i setzen wir an

$$P_i = a_{i0} + a_{i1}\mu_1 + a_{i2}\mu_2 + \cdots + a_{ii}\mu_i, \quad i = 0, 1, \ldots,$$

mit Koeffizienten $a_{ij} \in \mathbb{R}$, die wir aus der Forderung bestimmen, dass P_i, $i = 1, 2, \ldots$, orthogonal zu $\mu_0, \ldots, \mu_{i-1}$ ist. (In Anbetracht von Aufg. 3.1.10 ist dies äquivalent zu Def. 3.4.5.) Zur Vereinfachung schreiben wir $\langle \cdot, \cdot \rangle$ statt $\langle \cdot, \cdot \rangle_{\varrho_P}$.

- $P_0(x) = a_{00}, \ a_{00} \neq 0$
- $P_1(x) = a_{10} + a_{11}x$
  Wir prüfen die Orthogonalität zu Polynomen vom Grad 0:

  $$0 = \langle P_1, \mu_0 \rangle = \int_{-1}^{1} (a_{10} + a_{11}x) \cdot 1 \, \mathrm{d}x = 2a_{10}.$$

  Also: $P_1(x) = a_{11}x, \ a_{11} \neq 0$.

- $P_2(x) = a_{20} + a_{21}x + a_{22}x^2$
  Orthogonalität zu Polynomen vom Grad 0 und 1 impliziert:

$$0 = \langle P_2, \mu_0 \rangle = \int_{-1}^{1} \left(a_{20} + a_{21}x + a_{22}x^2\right) \cdot 1 \, \mathrm{d}x = 2a_{20} + \frac{2}{3}a_{22},$$
$$0 = \langle P_2, \mu_1 \rangle = \int_{-1}^{1} \left(a_{20} + a_{21}x + a_{22}x^2\right) x \, \mathrm{d}x = \frac{2}{3}a_{21}.$$

  Wir erhalten $P_2(x) = a_{22}\left(x^2 - \frac{1}{3}\right)$, $a_{22} \neq 0$.

- $P_3(x) = a_{30} + a_{31}x + a_{32}x^2 + a_{33}x^3$
  Wiederum wird die Orthogonalität, diesmal zu Polynomen vom Grad 0, 1 und 2, eingearbeitet:

$$0 = \langle P_3, \mu_0 \rangle = 2a_{30} + \frac{2}{3}a_{32},$$
$$0 = \langle P_3, \mu_1 \rangle = \frac{2}{3}a_{31} + \frac{2}{5}a_{33},$$
$$0 = \langle P_3, \mu_2 \rangle = \frac{2}{3}a_{30} + \frac{2}{5}a_{32}.$$

  Die erste und die letzte Gleichung liefern $a_{30} = a_{32} = 0$, während aus der zweiten Gleichung $a_{31} = -\frac{3}{5}a_{33}$ folgt. Somit erhalten wir $P_3(x) = a_{33}\left(x^3 - \frac{3}{5}x\right)$, $a_{33} \neq 0$.

- $P_4(x) = a_{44}\left(x^4 - \frac{6}{7}x^2 + \frac{3}{35}\right)$, $a_{44} \neq 0$, etc.

Abschließend bestimmen wir die a_{ii}, $i = 0, \ldots, 4$, so dass $P_i(1) = 1$. Wir erhalten

$$P_0(x) = 1, \quad P_1(x) = x, \quad P_2(x) = \tfrac{1}{2}\left(3x^2 - 1\right), \quad P_3(x) = \tfrac{1}{2}\left(5x^3 - 3x\right)$$

sowie $P_4(x) = \frac{1}{8}\left(35x^4 - 30x^2 + 3\right)$. ♠

Bemerkung 3.4.10. Alternativ lässt sich durch Anwendung des aus der Linearen Algebra bekannten Gram-Schmidtschen Orthogonalisierungsverfahrens (vgl. Alg. 3.1.13) aus den Monomen $\mu_0, \mu_1, \ldots,$ eine bezüglich des Skalarproduktes $\langle \cdot, \cdot \rangle$ orthonormale Basis von Π konstruieren.

Definition 3.4.11: Legendre-Polynome

Die bzgl. der Gewichtsfunktion $\varrho_P \colon (-1, 1) \to \mathbb{R}_+ \colon x \mapsto \varrho_P(x) = 1$ orthogonalen Polynome $P_i \in \Pi_i$, $i = 0, 1, \ldots,$ mit $P_i(1) = 1$ werden als die Legendre-Polynome bezeichnet.

Abbildung 3.2 zeigt die ersten sechs Legendre-Polynome.

Mit den Tschebyscheff- und den Legendre-Polynomen haben wir zwei Systeme orthogonaler Funktionen kennengelernt. Beide sind Spezialfälle der Jacobi[8]-Polynome, die orthogonal bezüglich der Gewichtsfunktion

$$\varrho_{\alpha,\beta} : I = (-1, 1) \to \mathbb{R} : x \mapsto \varrho_{\alpha,\beta}(x) := (1 - x)^{\alpha}(1 + x)^{\beta}, \quad \alpha, \beta > -1,$$

sind. Bis auf einen Normierungsfaktor ergeben sich für $\alpha = \beta = -1/2$ die Tschebyscheff-Polynome, und für $\alpha = \beta = 0$ die Legendre-Polynome.

[8] Carl Gustav Jacob Jacobi, *10.12.1804 (Potsdam, Preussen) †18.2.1851 (Berlin, Deutschland)

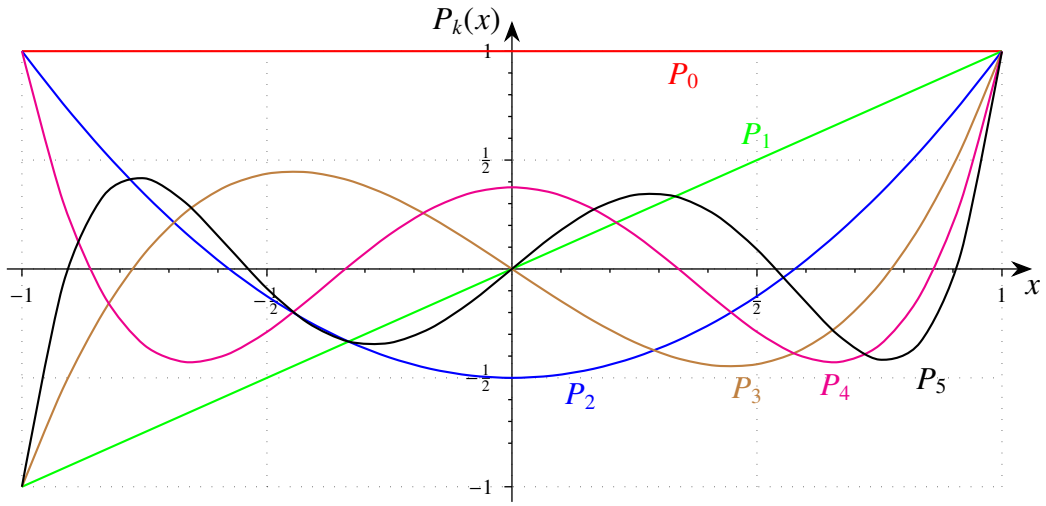


Abbildung 3.2: Die LEGENDRE-Polynome $P_0, \ldots, P_5$

Aufgabe 3.4.12. Seien $\varrho : (-a, a) \to \mathbb{R}_+$, $a > 0$, eine Gewichtsfunktion mit $\varrho(x) = \varrho(-x)$, $x \in (-a, a)$, und $u_i \in \Pi_i \backslash \Pi_{i-1}$, $i \in \mathbb{N}$, ein bzgl. ϱ zu Π_{i-1} orthogonales Polynom. Zeigen Sie, dass $u_i(x) = (-1)^i u_i(-x)$ für alle $x \in \mathbb{R}$. ◊

3.5 Dreigliedrige Rekursionen für orthogonale Polynome

Im Abschnitt 3.3 haben wir die Tschebyscheff-Polynome über die dreigliedrige Rekursion

$$T_{n+1} = 2\mu_1 T_n - T_{n-1}, \quad n = 1, 2, \ldots, \quad T_0 = \mu_0, \quad T_1 = \mu_1,$$

eingeführt und später, nämlich in Aufg. 3.3.6, nachgewiesen, dass sie eine Folge orthogonaler Polynome (bzgl. der Gewichtsfunktion ϱ_T) bilden.

In diesem Abschnitt werden wir für beliebige orthogonale Polynome die Existenz einer dreigliedrigen Rekursion herleiten. Sie bildet u. a. die Grundlage zu einer effizienten Auswertung der Polynome ähnlich zum Horner-Schema. Außerdem gestattet sie, die Frage nach den Nullstellen auf ein Eigenwertproblem für Matrizen zurückzuführen, für das numerische Verfahren verfügbar sind (Numerik II).

Satz 3.5.1

Seien $\varrho\colon I \to \mathbb{R}_+$ eine Gewichtsfunktion, $\langle\cdot,\cdot\rangle_\varrho$ das Skalarprodukt gemäß (3.11), $\|\cdot\|_\varrho$ die zugehörige induzierte Norm, und $(\delta_i)_{i=0}^\infty$ eine Folge positiver reeller Zahlen.

(i) Dann existiert eine eindeutig bestimmte Folge $(u_i)_{i=0}^\infty$ orthogonaler Polynome $u_i \in \Pi_i$ mit Leitkoeffizienten $\gamma_i > 0$ und $\|u_i\|_\varrho = \delta_i$.

(ii) Die Polynome u_i aus (i) genügen der dreigliedrigen Rekursion

$$\beta_{i+1} u_{i+1} = (\mu_1 - \alpha_i)\, u_i - \kappa_i u_{i-1}, \quad i = 1, 2, \ldots, \tag{3.12a}$$

zu den Startwerten

$$u_0 = \gamma_0 \mu_0 \quad \text{und} \quad \beta_1 u_1 = (\mu_1 - \alpha_0)\, u_0, \tag{3.12b}$$

mit $\alpha_i := \dfrac{\langle \mu_1 u_i, u_i\rangle_\varrho}{\delta_i^2}$, $\kappa_i := \dfrac{\beta_i \delta_i^2}{\delta_{i-1}^2}$ und $\beta_{i+1} := \dfrac{\gamma_i}{\gamma_{i+1}} > 0$.

Beweis. *(i)* Zum Nachweis der Existenz wenden wir das Gram-Schmidt-Verfahren (Alg. 3.1.13) auf die Folge $(\mu_i)_{i=0}^\infty$ der Monome an, um eine ONB $(w_i)_{i=0}^\infty$ zu konstruieren mit $w_0 \in \Pi_0$, $w_i \in \Pi_i \backslash \Pi_{i-1}$, $i \in \mathbb{N}$, und $\|w_i\|_\varrho = 1$, $i \in \mathbb{N}_0$. Die lineare Unabhängigkeit der Monome, Satz 3.2.10, sichert die Durchführbarkeit des Verfahrens. Wir setzen

$$u_i := \begin{cases} \delta_i w_i & \text{falls der Leitkoeffizient von } w_i \text{ positiv ist,} \\ -\delta_i w_i & \text{falls er negativ ist.} \end{cases}$$

Die so konstruierte Folge $(u_i)_{i=0}^\infty$ von Polynomen $u_i \in \Pi_i$ ist bzgl. der Gewichtsfunktion ϱ orthogonal, besitzt positive Leitkoeffizienten und es gilt $\|u_i\|_\varrho = \delta_i$.

Die Eindeutigkeit zeigen wir indirekt. Angenommen es existiert neben u_i ein zweites Polynom $\tilde{u}_i \perp \Pi_{i-1}$ mit positivem Leitkoeffizienten und $\|\tilde{u}_i\|_\varrho = \delta_i$. Aus Bem. 3.4.7 folgt $\tilde{u}_i = \zeta u_i$ mit einem $\zeta > 0$. Dann gilt $\delta_i = \|\tilde{u}_i\|_\varrho = \zeta \|u_i\|_\varrho = \zeta\delta_i$, d. h. $\zeta = 1$. Die Polynome u_i und $\tilde{u}_i$ sind also identisch.

(ii) Wichtigstes Hilfsmittel zum Beweis von (3.12) ist Satz 3.2.3 über die Polynomdivision.

Zunächst wenden wir uns aber Aussage (3.12b) über die Startwerte u_0 und u_1 der Rekursion zu.

Der Leitkoffizient von $u_0 \in \Pi_0$ wurde mit γ_0 bezeichnet. Also ist $u_0 = \gamma_0 \mu_0$.

Für das zweite Polynom $u_1 \in \Pi_1 \backslash \Pi_0$ gilt mit gewissen $t_0 \in \mathbb{R} \setminus \{0\}$ und $t_0, s_0 \in \mathbb{R}$

$$\beta_1 u_1 = (t_0 \mu_1 + s_0)\, u_0 \,. \tag{3.13}$$

Koeffizientenvergleich für die Polynome auf der linken und rechten Seite der Gleichung liefert

$$\beta_1 \gamma_1 = t_0 \gamma_0 \,.$$

Da $\beta_1 = \gamma_0/\gamma_1 \neq 0$ ist, folgern wir hieraus, dass $t_0 = 1$. Zur Bestimmung von s_0 multiplizieren wir (3.13) skalar mit u_0 und erhalten (unter Beachtung von $t_0 = 1$)

$$\beta_1 \langle u_1, u_0 \rangle_\varrho = \langle \mu_1 u_0, u_0 \rangle_\varrho + s_0 \langle u_0, u_0 \rangle_\varrho \,.$$

Da $u_1 \perp u_0$ und $\langle u_0, u_0 \rangle = \|u_0\|_\varrho^2 = \delta_0^2$, folgt

$$s_0 = -\frac{\langle \mu_1 u_0, u_0 \rangle_\varrho}{\langle u_0, u_0 \rangle_\varrho} = -\frac{\langle \mu_1 u_0, u_0 \rangle_\varrho}{\delta_0^2} = -\alpha_0.$$

Damit haben wir (3.12b) verifiziert.

Weiterhin folgt aus (3.13) nach skalarer Multiplikation mit u_1

$$\beta_1 \langle u_1, u_1 \rangle_\varrho = \langle \mu_1 u_0, u_1 \rangle_\varrho + s_0 \langle u_0, u_1 \rangle_\varrho \,.$$

Hieraus folgt, da $u_0 \perp u_1$,

$$\beta_1 \delta_1^2 = \langle \mu_1 u_0, u_1 \rangle_\varrho \,, \tag{3.14}$$

eine Gleichung, die wir im weiteren Verlauf noch benötigen werden.

Wir wenden uns nun (3.12a) für beliebiges $i \geq 1$ zu. Da $\beta_{i+1} u_{i+1} \in \Pi_{i+1} \backslash \Pi_i$ ist, existieren gemäß Satz 3.2.3 (Polynomdivision) Zahlen $t_i, s_i \in \mathbb{R}$, $t_i \neq 0$ und ein $q_{i-1} \in \Pi_{i-1}$, so dass

$$\beta_{i+1} u_{i+1} = (t_i \mu_1 + s_i)\, u_i + q_{i-1}. \tag{3.15}$$

Durch Vergleich der Leitkoeffizienten auf der linken ($\beta_{i+1}\gamma_{i+1}$) und der rechten Seite ($t_i \gamma_i$) der Gleichung folgern wir, dass $t_i = 1$. Durch skalare Multiplikation von (3.15) mit u_i, u_{i+1} bzw. u_{i-1} erhalten wir die folgenden drei Gleichungen:

$$\begin{aligned}
\beta_{i+1} \langle u_{i+1}, u_i \rangle_\varrho &= \langle \mu_1 u_i, u_i \rangle_\varrho + s_i \langle u_i, u_i \rangle_\varrho + \langle q_{i-1}, u_i \rangle_\varrho \\
\beta_{i+1} \langle u_{i+1}, u_{i+1} \rangle_\varrho &= \langle \mu_1 u_i, u_{i+1} \rangle_\varrho + s_i \langle u_i, u_{i+1} \rangle_\varrho + \langle q_{i-1}, u_{i+1} \rangle_\varrho \\
\beta_{i+1} \langle u_{i+1}, u_{i-1} \rangle_\varrho &= \langle \mu_1 u_i, u_{i-1} \rangle_\varrho + s_i \langle u_i, u_{i-1} \rangle_\varrho + \langle q_{i-1}, u_{i-1} \rangle_\varrho \,.
\end{aligned}$$

Unter Beachtung der Orthogonalitätseigenschaft $u_{j+1} \perp \Pi_j$ und von $\langle u_j, u_j \rangle_\varrho = \|u_j\|_\varrho^2 = \delta_j^2$, für alle $j \in \mathbb{N}_0$ folgt

$$0 = \langle \mu_1 u_i, u_i \rangle_\varrho + s_i \delta_i^2 \,, \tag{3.16}$$

$$\beta_{i+1} \delta_{i+1}^2 = \langle \mu_1 u_i, u_{i+1} \rangle_\varrho \,, \tag{3.17}$$

$$0 = \langle \mu_1 u_i, u_{i-1} \rangle_\varrho + \langle q_{i-1}, u_{i-1} \rangle_\varrho \,. \tag{3.18}$$

Aus Gleichung (3.16) lesen wir

$$s_i = -\frac{\langle \mu_1 u_i, u_i \rangle_\varrho}{\delta_i^2} = -\alpha_i$$

ab, womit sich (3.15) nun wie folgt liest:

$$\beta_{i+1} u_{i+1} = (\mu_1 - \alpha_i)\, u_i + q_{i-1}. \tag{3.19}$$

Wir müssen noch q_{i-1} bestimmen. Zunächst gilt

$$\langle \mu_1 u_{j-1}, u_j \rangle_\varrho = \langle \mu_1 u_j, u_{j-1} \rangle_\varrho = \beta_j \delta_j^2, \quad \text{für alle } j \in \mathbb{N},$$

was aus (3.14) (für $j = 1$) und (3.17) (für $j > 1$) folgt. Dies wenden wir auf (3.18) an und erhalten

$$0 = \beta_i \delta_i^2 + \langle q_{i-1}, u_{i-1} \rangle_\varrho \ . \tag{3.20}$$

Für $i = 1$ ist $q_{i-1} = q_0 \in \Pi_0$ ein Vielfaches von u_0: $q_0 = r_1 u_0$. Wir setzen in (3.20) ein und erhalten

$$r_1 = -\frac{\beta_1 \delta_1^2}{\langle u_0, u_0 \rangle_\varrho} = -\frac{\beta_1 \delta_1^2}{\delta_0^2} = -\kappa_1 \ .$$

Wir haben somit zunächst die Gültigkeit von (3.12a) für $i = 1$ bewiesen.

Für $i > 1$ ist $q_{i-1} = r_i u_{i-1} + q_{i-2}^*$ mit einem $r_i \in \mathbb{R}$ und einem $q_{i-2}^* \in \Pi_{i-2}$, da $u_{i-1} \in \Pi_{i-1} \backslash \Pi_{i-2}$. Wir setzen wieder in (3.20) ein und beachten, dass $u_{i-1} \perp \Pi_{i-2}$. Es folgt

$$r_i = -\frac{\beta_i \delta_i^2}{\langle u_{i-1}, u_{i-1} \rangle_\varrho} = -\frac{\beta_i \delta_i^2}{\delta_{i-1}^2} = -\kappa_i \ .$$

und somit $q_{i-1} = -\kappa_i u_{i-1} + q_{i-2}^*$, was wir in (3.19) einsetzen:

$$\beta_{i+1} u_{i+1} = (\mu_1 - \alpha_i)\, u_i - \kappa_i u_{i-1} + q_{i-2}^*, \quad i > 1. \tag{3.21}$$

Zur Bestimmung von q_{i-2}^* multiplizieren wir diese Gleichung skalar mit q_{i-2}^* und nutzen die Orthogonalitätseigenschaften der u_j:

$$\beta_{i+1} \underbrace{\langle u_{i+1}, q_{i-2}^* \rangle_\varrho}_{=0} = \underbrace{\langle \mu_1 u_i, q_{i-2}^* \rangle_\varrho}_{= \langle u_i, \mu_1 q_{i-2}^* \rangle_\varrho = 0} - \alpha_i \underbrace{\langle u_i, q_{i-2}^* \rangle_\varrho}_{=0} - \kappa_i \underbrace{\langle u_{i-1}, q_{i-2}^* \rangle_\varrho}_{=0} + \langle q_{i-2}^*, q_{i-2}^* \rangle_\varrho \ .$$

Also ist $\langle q_{i-2}^*, q_{i-2}^* \rangle_\varrho = \left\| q_{i-2}^* \right\|_\varrho^2 = 0$ und folglich $q_{i-2}^* = 0$. Damit folgt aus (3.21) die Gültigkeit von (3.12a) für $i > 1$. □

Bemerkung 3.5.2. Führen wir formal $u_{-1} := 0$ und $\kappa_0 := 0$ ein, so gilt die dreigliedrige Rekursion (3.12a) auch für $i = 0$.

Bemerkung 3.5.3. Für orthonormale Basen, also $\|u_i\|_\varrho = \delta_i = 1$, $i = 0, 1, \ldots$, gilt offensichtlich $\kappa_i = \beta_i$ und $\alpha_i = \langle \mu_1 u_i, u_i \rangle_\varrho$.

Aufgabe 3.5.4. Sei $\varrho : (-a, a) \to \mathbb{R}_+$, eine Gewichtsfunktion mit $\varrho(x) = \varrho(-x)$, $x \in (-a, a)$. Zeigen Sie: Für die zugehörige Folge $(u_i)_{i=0}^\infty$ orthogonaler Polynome gilt $\alpha_i = \langle \mu_1 u_i, u_i \rangle_\varrho / \delta_i^2 = 0$, $i \in \mathbb{N}_0$. ◊

Beispiel 3.5.5. Tschebyscheff-Polynome erster Art. Für die Höchstkoeffizienten gilt

$$\gamma_0 = 1, \quad \text{und} \quad \gamma_i = 2^{i-1}, \ \ i \in \mathbb{N}.$$

Ferner gilt, vgl. Aufg. 3.3.6,

$$\delta_i^2 = \langle T_i, T_i \rangle_{\varrho_T} = \begin{cases} \pi, & i = 0, \\ \pi/2, & i \in \mathbb{N}, \end{cases}$$

und wegen Aufg. 3.5.4 $\alpha_i = 0$, $i \in \mathbb{N}$. Wir erhalten also

	γ_i	β_i	δ_i	κ_i	α_i
$i = 0$	1	–	$\sqrt{\pi}$	0	0
$i = 1$	1	1	$\sqrt{\pi/2}$	1/2	0
$i > 1$	2^{i-1}	1/2	$\sqrt{\pi/2}$	1/2	0

Satz 3.5.1 liefert die Rekursion

$$\tfrac{1}{2} T_{i+1} = \mu_1 T_i - \tfrac{1}{2} T_{i-1}, \ \ i \in \mathbb{N},$$

bzw. $T_{i+1} = 2\mu_1 T_i - T_{i-1}$, die uns schon aus Abschnitt 3.3 bekannt ist. Für $i = 0$ erhalten wir Bem. 3.5.2 folgend $T_1 = \mu_1 T_0$. ♠

Im Fall der Tschebyscheff-Polynome war uns mit Satz 3.3.3 eine explizite Darstellung der Polynome gegeben, die uns gestattet hat, die $\delta_i = \sqrt{\langle T_i, T_i \rangle_{\varrho_T}}$ zu berechnen. Allgemein stellt sich die Frage, wie man einzig aus der Gewichtsfunktion ϱ die dreigliedrige Rekursion herleiten kann. Leider ist diese Frage in ihrer Allgemeinheit nicht ganz einfach zu beantworten.

Wir betrachten exemplarisch die Legendre-Polynome. Bei der Herleitung der dreigliedrigen Rekursion hilft uns die folgende zu zeigende Formel, die auf Rodrigues[9] zurückgeht.

$$P_i(x) = \frac{1}{2^i\, i!} \frac{\mathrm{d}^i}{\mathrm{d}x^i} \left(\left(x^2 - 1 \right)^i \right), \quad i = 0, 1, \ldots \tag{3.22}$$

Satz 3.5.6

Für die durch (3.22) gegebenen Funktionen gelten folgende Aussagen:

(i) Die $(P_i)_{i=0}^{\infty}$ bilden eine Folge von bezüglich der Gewichtsfunktion

$$\varrho_P : (-1, 1) \to \mathbb{R}_+ : x \mapsto \varrho_P(x) := 1$$

orthogonalen Polynomen.

(ii) Sie genügen der dreigliedrigen Rekursion

$$\frac{i+1}{2i+1} P_{i+1} = \mu_1 P_i - \frac{i}{2i+1} P_{i-1}, \ \ i \in \mathbb{N}, \ \ P_1 = \mu_1, \ \ P_0 = \mu_0. \tag{3.23}$$

(iii) $P_i(1) = 1$ für $i \in \mathbb{N}_0$.

[9] Benjamin Olinde Rodrigues, *6.10.1795 (Bordeaux, Frankreich), †17.12.1851 (Paris, Frankreich)

Bemerkung 3.5.7. Wegen (i) und (iii) sind die durch die Rodrigues-Formel (3.22) definierten P_i, $i \in \mathbb{N}_0$, die im Bsp. 3.4.9 eingeführten Legendre-Polynome.

Beweis. (i) Für beliebiges $i \in \mathbb{N}_0$ ist $\psi_i := (\mu_2 - 1)^i$ ein Polynom vom Grad $2i$ und seine i-te Ableitung somit ein Polynom i-ten Grades. Also gilt $P_i \in \Pi_i$, $i \in \mathbb{N}_0$.

Es bleibt für $i > 0$ die Orthogonalität von P_i zu Polynomen aus Π_{i-1} zu prüfen, da hieraus sofort die Orthogonalität von P_i zu allen P_k, $k = 0, 1, \ldots, i-1$, folgt.

Man überlegt sich zunächst, dass ψ_i die i-fachen Nullstellen $x = -1$ und $x = 1$ besitzt. Demzufolge verschwinden auch seine Ableitungen bis zur Ordnung $i - 1$ an diesen Stellen:

$$\psi_i^{(k)}(1) = \psi_i^{(k)}(-1) = 0, \quad k = 0, 1, \ldots, i-1. \tag{3.24}$$

Sei nun $q \in \Pi_{i-1}$ beliebig. Dann gilt aufgrund von (3.22)

$$2^i i! \, \langle P_i, q \rangle_{\varrho_P} = \int_{-1}^{1} \psi_i^{(i)}(x) \, q(x) \, \mathrm{d}x.$$

Wir integrieren partiell und nutzen (3.24):

$$2^i i! \, \langle P_i, q \rangle_{\varrho_P} = \psi_i^{(i-1)}(x) \, q(x) \Big|_{-1}^{1} - \int_{-1}^{1} \psi_i^{(i-1)}(x) \, q'(x) \, \mathrm{d}x = - \int_{-1}^{1} \psi_i^{(i-1)}(x) \, q'(x) \, \mathrm{d}x.$$

Wir integrieren weitere $(i-1)$-mal partiell und erhalten durch wiederholte Anwendung von (3.24):

$$2^i i! \, \langle P_i, q \rangle_{\varrho_P} = (-1)^i \int_{-1}^{1} \psi_i(x) \, q^{(i)}(x) \, \mathrm{d}x = 0,$$

da $q^{(i)} = 0$ für ein Polynom $q \in \Pi_{i-1}$.

(ii) Aus Aufg. 3.5.4 schließen wir zunächst $\alpha_i = \langle \mu_1 P_i, P_i \rangle = 0$, $i \in \mathbb{N}_0$. Die Höchstkoeffizienten der P_i sind

$$\gamma_i = \frac{1}{2^i i!} \frac{(2i)!}{i!}, \quad i \in \mathbb{N}_0.$$

Uns fehlen noch die $\delta_i^2 = \langle P_i, P_i \rangle_{\varrho_P}$. Für sie gilt (Übungsaufgabe)

$$\delta_i^2 = \langle P_i, P_i \rangle_{\varrho_P} = \frac{2}{2i+1}, \quad i \in \mathbb{N}_0.$$

Hieraus berechnen wir unter Bezugnahme auf Satz 3.5.1 die übrigen Faktoren der Rekursion zu

$$\beta_{i+1} = \frac{i+1}{2i+1} \quad \text{und} \quad \kappa_i = \frac{i}{2i+1}.$$

Es folgt unmittelbar (3.23).

(iii) Die Rodrigues-Formel für $i = 0$ und $i = 1$ definiert $P_0(x) = 1$ und $P_1(x) = x$. Also ist $P_0(1) = P_1(1) = 1$. Aus (3.23) folgt nun induktiv $P_i(1) = 1$, für alle $i \in \mathbb{N}_0$. □

Aufgabe 3.5.8. Beweisen Sie: Für die durch die Rodrigues-Formel (3.22) gegebenen Polynome P_i gilt

$$\langle P_i, P_i \rangle_{\varrho_P} = \int_{-1}^{1} P_i(x)^2 \, \mathrm{d}x = \frac{2}{2i+1}, \quad i \in \mathbb{N}_0.$$

◊

Bemerkung 3.5.9. Weitere wichtige Beispiele orthogonaler Polynome sind

- die **Laguerre[10]-Polynome**, welche orthonormal bezüglich der auf $\mathbb{R}^+$ definierten Gewichtsfunktion $\varrho_L(x) = \mathrm{e}^{-x}$ sind, und
- die **Hermite[11]-Polynome**. Sie sind orthonormal bezüglich der auf $\mathbb{R}$ definierten Gewichtsfunktion $\varrho_H(x) = \mathrm{e}^{-x^2}$.

[10] Edmond Nicolas Laguerre, *9.4.1834 (Bar-le-Duc, Frankreich), †14.8.1886 (Bar-le-Duc, Frankreich)
[11] Charles Hermite, *24.12.1822 (Dieuze, Lorraine, Frankreich), †14.01.1901 (Paris, Frankreich)

3.6 Der Clenshaw-Algorithmus zur Polynomauswertung

Im Abschnitt 3.2.3 hatten wir mit dem Horner-Verfahren einen Algorithmus kennengelernt, der es gestattet, die Funktionswerte von in Monom-Darstellung gegebenen Polynomen effizient zu berechnen. Wir wollen jetzt Polynome betrachten, die bezüglich allgemeinerer Basen gegeben sind. Sei

$$p = a_0u_0 + a_1u_1 + a_2u_2 + \cdots + a_nu_n, \tag{3.25}$$

wobei die Basispolynome u_i bei gegebenen $u_0 \in \Pi_0$ und $u_1 \in \Pi_1\backslash\Pi_0$ der dreigliedrigen Rekursion

$$u_i = (\eta_i\mu_1 - \vartheta_i)u_{i-1} - \sigma_iu_{i-2}, \quad i = 2, 3, \ldots \tag{3.26}$$

$\eta_i, \vartheta_i, \sigma_i \in \mathbb{C}$, $\eta_i \neq 0$, genügen mögen. Für alle bislang eingeführten Basen kennen wir eine solche Rekursion:

Basis	η_i	ϑ_i	σ_i	u_1	$u_0(x)$
Monome	1	0	0	μ_1	1
Tschebyscheff 1. Art	2	0	1	μ_1	1
Tschebyscheff 2. Art	2	0	1	$2\mu_1$	1
Legendre	$\frac{2i-1}{i}$	0	$\frac{i-1}{i}$	μ_1	1

Für orthogonale Polynome erhalten wir (3.26) aus (3.12a). Zunächst verschieben wir in (3.12a) die Indizes um eins:

$$\beta_iu_i = (\mu_1 - \alpha_{i-1})\,u_{i-1} - \kappa_{i-1}u_{i-2}$$

und dividieren anschließend durch β_i:

$$\eta_i := \frac{1}{\beta_i}, \quad \vartheta_i := \frac{\alpha_{i-1}}{\beta_i} \quad \text{und} \quad \sigma_i := \frac{\kappa_{i-1}}{\beta_i}.$$

Die Darstellung (3.26) ist für unsere weiteren Ausführungen leichter zu handhaben.

Der im Folgenden vorzustellende Algorithmus geht auf Clenshaw[12] zurück, der ihn zur Auswertung von Polynomen einführte, die bezüglich der Basis der Tschebyscheff-Polynome gegeben sind.

Wir möchten p an der Stelle α auswerten und setzen zur Vereinfachung $\xi_i := \eta_i\alpha - \vartheta_i$. Aus der Rekursion (3.26) folgt dann $u_i(\alpha) = \xi_iu_{i-1}(\alpha) - \sigma_iu_{i-2}(\alpha)$, was wir auf

$$p(\alpha) = a_nu_n(\alpha) + a_{n-1}u_{n-1}(\alpha) + \cdots + a_1u_1(\alpha) + a_0u_0(\alpha)$$

anwenden, um sukzessive $u_n(\alpha)$, $u_{n-1}(\alpha)$, …, zu eliminieren.

Wir setzen $b_n := a_n$ und ersetzen $u_n(\alpha) = \xi_nu_{n-1}(\alpha) - \sigma_nu_{n-2}(\alpha)$:

$$\begin{aligned} p(\alpha) &= b_nu_n(\alpha) + a_{n-1}u_{n-1}(\alpha) + a_{n-2}u_{n-2}(\alpha) + \cdots \\ &= b_n(\xi_nu_{n-1}(\alpha) - \sigma_nu_{n-2}(\alpha)) + a_{n-1}u_{n-1}(\alpha) + a_{n-2}u_{n-2}(\alpha) + \cdots \\ &= \underbrace{(b_n\xi_n + a_{n-1})}_{=:\,b_{n-1}}u_{n-1}(\alpha) + (a_{n-2} - b_n\sigma_n)\,u_{n-2}(\alpha) + a_{n-3}u_{n-3}(\alpha) + \cdots \end{aligned}$$

[12] Charles Williams Clenshaw, *15.3.1926 (Southend-on-Sea, Essex), †23.9.2004

Im nächsten Schritt ersetzen wir $u_{n-1}(\alpha) = \xi_{n-1}u_{n-2}(\alpha) - \sigma_{n-1}u_{n-3}(\alpha)$:

$$\begin{aligned} p(\alpha) &= b_{n-1}(\xi_{n-1}u_{n-2}(\alpha) - \sigma_{n-1}u_{n-3}(\alpha)) + (a_{n-2} - b_n\sigma_n)\,u_{n-2}(\alpha) + a_{n-3}u_{n-3}(\alpha) + \cdots \\ &= \underbrace{(b_{n-1}\xi_{n-1} + a_{n-2} - b_n\sigma_n)}_{=:\,b_{n-2}}\,u_{n-2}(\alpha) + (a_{n-3} - b_{n-1}\sigma_{n-1})\,u_{n-3}(\alpha) + a_{n-4}u_{n-4}(\alpha) + \cdots \end{aligned}$$

Wir fahren fort und eliminieren $u_{n-2}(\alpha)$, $u_{n-3}(\alpha)$ usw. und erhalten

$$p(\alpha) = \underbrace{(b_2\xi_2 - b_3\sigma_3 + a_1)}_{=:\,b_1}\,u_1(\alpha) + (a_0 - b_2\sigma_2)\,u_0(\alpha).$$

Diese Umformungen gießen wir in einen Algorithmus, der in absteigender Reihenfolge die b_i berechnet und zum Schluss das Ergebnis $p(\alpha) = b_1u_1(\alpha) + (a_0 - b_2\sigma_2)\,u_0(\alpha)$.

Algorithmus 3.6.1: CLENSHAW-Algorithmus

Gegeben: Ein Polynom $p \in \Pi_n$ in der Darstellung (3.25) mit dreigliedriger Rekursion (3.26) und ein $\alpha \in \mathbb{K}$.

S1. $b_n := a_n$,
$\xi_n := \eta_n\alpha - \vartheta_n$
$b_{n-1} := b_n\xi_n + a_{n-1}$

S2. FOR $i = n-2, n-3, \ldots, 1$ DO
$\xi_{i+1} := \eta_{i+1}\alpha - \vartheta_{i+1}$
$b_i := b_{i+1}\xi_{i+1} + a_i - b_{i+2}\sigma_{i+2}$
END DO

S3. $b_0 := b_1u_1(\alpha) + (a_0 - b_2\sigma_2)\,u_0(\alpha)$

Ergebnis: $p(\alpha) = b_0$

Bemerkung 3.6.2. Sind, wie bei der Monom-Basis oder der TSCHEBYSCHEFF-Basis die η_i und ϑ_i unabhängig von i, so wird man selbstverständlich die Berechnung der dann ebenfalls von i unabhängigen $\xi_{i+1} =: \xi$ vor die Schleife stellen.

Bei Verwendung der TSCHEBYSCHEFF-Polynome erster Art ($\eta_i = 2$, $\vartheta_i = 0$, $\xi_i = 2\alpha$, $\sigma_i = 1$) lässt sich das Rechenschema des CLENSHAW-Algorithmus folgendermaßen tabellarisch darstellen:

	a_n	a_{n-1}	a_{n-2}	$\cdots$	a_2	a_1	a_0
			$-b_n$	$\cdots$	$-b_4$	$-b_3$	$-b_2$
α		$2\alpha\,b_n$	$2\alpha\,b_{n-1}$	$\cdots$	$2\alpha\,b_3$	$2\alpha\,b_2$	$\alpha\,b_1$
	b_n	b_{n-1}	b_{n-2}	$\cdots$	b_2	b_1	$\boxed{b_0 = p(\alpha)}$

Für die Monom-Darstellung geht Alg. 3.6.1 über in den HORNER-Algorithmus, wobei die dortigen $a_k^{(1)}$ den b_k entsprechen.

Aufgabe 3.6.3. Werten Sie das Polynom

$$p := 5T_6 + 2T_5 + 3T_4 - T_3 - 4T_2 + T_1 - 10T_0$$

mit Hilfe des CLENSHAW-Algorithmus an der Stelle $1/2$ aus! ◊

3.7 Nullstellen orthogonaler Polynome

Die Nullstellen orthogonaler Polynome besitzen eine Reihe interessanter Eigenschaften, die wir in diesem Abschnitt näher untersuchen wollen.

Satz 3.7.1

Seien $I := (a, b) \subset \mathbb{R}$ offen und ϱ eine Gewichtsfunktion über I. Die Nullstellen der bezüglich ϱ orthogonalen Polynome $(u_i)_{i=0}^{\infty}$, liegen in I und sind einfach.

Beweis. Der Beweis erfolgt indirekt und in drei Schritten. Dem Hauptsatz der Algebra, Satz 3.2.5 zufolge besitzt $u_i \in \Pi_i$ genau i komplexe Nullstellen. Wir zeigen, dass u_i weder echt komplexe Nullstellen $z \in \mathbb{C} \setminus \mathbb{R}$ noch reelle Nullstellen in $\mathbb{R} \setminus I$ besitzt. Damit liegen alle Nullstellen in I. Abschließend weisen wir nach, dass diese einfach sind.

(i) Angenommen, u_i besitzt eine Nullstelle z in $\mathbb{C} \setminus \mathbb{R}$. Da u_i ein Polynom mit reellen Koeffizienten ist, ist auch $\bar{z}$ eine Nullstelle von u_i, vgl. Aufg. 3.2.7. Dann ist das Polynom $q : x \mapsto (x - z)(x - \bar{z})$ positiv auf $\mathbb{R}$, da $q(0) = |z|^2 > 0$ und q keine reellen Nullstellen besitzt. Außerdem ist q ein Teilerpolynom von u_i. Das Polynom $p := u_i/q$ besitzt Grad $i - 2$, und ist als solches orthogonal zu u_i:

$$0 = \langle p, u_i \rangle_\varrho = \int_a^b \frac{u_i^2(x)\varrho(x)}{q(x)} \, \mathrm{d}x. \tag{3.27}$$

Der Integrand ist nichtnegativ und nicht identisch Null. Folglich ist das Integral in (3.27) positiv. Dies ist ein Widerspruch. Wir haben gezeigt, dass u_i keine echt komplexen Nullstellen besitzt.

(ii) Angenommen, u_i besitzt eine Nullstelle $z \in \mathbb{R} \setminus I$. Dann ist $p : x \mapsto p(x) = u_i(x)/(x - z)$ ein Polynom vom Grad $i - 1$, und orthogonal zu u_i:

$$0 = \langle p, u_i \rangle_\varrho = \int_a^b \frac{u_i^2(x)\varrho(x)}{x - z} \, \mathrm{d}x. \tag{3.28}$$

Die Funktion $\varrho(x)/(x - z)$ ist entweder positiv oder negativ für alle $x \in I$. Ferner ist $u_i^2 \geq 0$, aber nicht überall null. Folglich ist das Integral in (3.28) nicht Null. Wiederum haben wir die Annahme zu einem Widerspruch geführt. Die u_i besitzen keine Nullstellen in $\mathbb{R} \setminus I$. Insbesondere sind die Randpunkte des Intervalls I keine Nullstellen von u_i.

(iii) Wir haben gezeigt, dass alle Nullstellen in I liegen. Sei nun $z \in I$ eine k-fache Nullstelle von u_i, $k \geq 2$. Dann ist $\tilde{q}$, $\tilde{q}(x) = (x - z)^2$ ein Teilerpolynom von u_i und $\tilde{p} := u_i/\tilde{q} \in \Pi_{i-2}$. Nun verfahren wir analog zu *(i)*: $\tilde{p} \in \Pi_{i-2}$ ist orthogonal zu u_i, d. h.

$$0 = \langle \tilde{p}, u_i \rangle_\varrho = \int_a^b \frac{u_i^2(x)\varrho(x)}{\tilde{q}(x)} \, \mathrm{d}x.$$

Der Integrand ist nichtnegativ und nicht identisch Null. Folglich ist das Integral positiv. Wieder erhalten wir einen Widerspruch. Alle Nullstellen sind einfach. □

Die Nullstellen orthogonaler Polynome besitzen die im folgenden Satz formulierte **Trennungseigenschaft**. Auf einen Beweis wollen wir an dieser Stelle verzichten, der interessierte Leser sei auf die Literatur, z. B. [HB09, Satz 34.5] verwiesen. Für die Tschebyscheff-Polynome haben wir diese Eigenschaft bereits im Abschnitt 3.3 nachgewiesen.

Satz 3.7.2: Trennungseigenschaft der Nullstellen

Sei $(u_i)_{i=0}^{\infty}$ eine Folge orthogonaler Polynome, Grad $u_i = i$. Seien $z_1^{(i)} < z_2^{(i)} < \cdots < z_i^{(i)}$ die i Nullstellen von u_i. Dann gilt

$$z_k^{(i+1)} < z_k^{(i)} < z_{k+1}^{(i+1)}, \quad k = 1, \ldots, i \in \mathbb{N},$$

d. h., zwischen je zwei benachbarten Nullstellen von u_{i+1} liegt eine Nullstelle von u_i.

3.8 Lösungen der Aufgaben

Lösung 3.2.7. Sei

$$p : x \mapsto p(x) = a_n x^n + a_{n-1}x^{n-1} + \cdots + a_1 x + a_0$$

ein beliebiges Polynom mit Koeffizienten $a_0, \ldots, a_n \in \mathbb{R}$. Es besitze die Nullstelle $z \in \mathbb{C}$, d. h. $p(z) = 0$.

$$\begin{aligned} 0 = \overline{p(z)} &= \overline{a_n z^n + a_{n-1}z^{n-1} + \cdots + a_1 z + a_0} \\ &= a_n\overline{z^n} + a_{n-1}\overline{z^{n-1}} + \cdots + a_1\overline{z} + a_0, && \text{da } a_k \in \mathbb{R},\ k = 0, \ldots, n, \\ &= a_n\overline{z}^n + a_{n-1}\overline{z}^{n-1} + \cdots + a_1\overline{z} + a_0 = p(\overline{z}), \end{aligned}$$

da für beliebige $z \in \mathbb{C}$ und $k \in \mathbb{N}$ gilt $\overline{z}^k = \overline{z^k}$. Somit ist mit jedem $z \in \mathbb{C}$ auch $\overline{z}$ eine Nullstelle eines Polynoms mit reellen Koeffizienten. ♣

Lösung 3.2.15. $q(x) = x^5 - 4x^4 + 4x^3 + 2x^2 - 5x + 2$ besitzt die Nullstellen 2 und -1.

Wir stellen das erweiterte Horner-Schema auf:

	1	−4	4	2	−5	2
2		2	−4	0	4	−2
	1	−2	0	2	−1	0
−1		−1	3	−3	1	
	1	−3	3	−1	0	

Somit ist $q(x) = (x-2)(x+1)(x^3 - 3x^2 + 3x - 1) = (x-2)(x+1)(x-1)^3$. ♣

Lösung 3.2.16. Den Funktionswert von $p(x) = 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8$ an der Stelle $x = 1/2$ haben wir bereits im Bsp. 3.2.13 berechnet. Wir vervollständigen das Horner-Schema, um die erste und zweite Ableitung von p zu berechnen:

	160	32	−216	−44	58	14	−8
1/2		80	56	−80	−62	−2	6
	160	112	−160	−124	−4	12	−2
1/2		80	96	−32	−78	−41	
	160	192	−64	−156	−82	−29	
1/2		80	136	36	−60		
	160	272	72	−120	−142		

Wir erhalten $p'(1/2) = -29$ und $p''(1/2) = 2 \cdot (-142) = -284$. ♣

Lösung 3.3.2. *(a)* Wir bestimmen die Monom-Darstellungen der Tschebyscheff-Polynome erster Art über die dreigliedrige Rekursion:

$$\begin{aligned}
T_0(x) &= 1,\\
T_1(x) &= x,\\
T_2(x) &= 2x^2 - 1,\\
T_3(x) &= 4x^3 - 3x,\\
T_4(x) &= 8x^4 - 8x^2 + 1,\\
T_5(x) &= 16x^5 - 20x^3 + 5x,\\
T_6(x) &= 32x^6 - 48x^4 + 18x^2 - 1
\end{aligned}$$

(b_1) Das Polynom p, $p(x) = 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8$, ist als Linearkombination von $T_0, \ldots, T_6$ darzustellen:

$$\begin{aligned}
p(x) &= 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8\\
&= \alpha_6 T_6(x) + r_5(x) && \text{Polynomdivision durch } T_6\\
&= 5(32x^6 - 48x^4 + 18x^2 - 1) + r_5(x)\\
&= 5T_6(x) + 32x^5 + 24x^4 - 44x^3 - 32x^2 + 14x - 3\\
&= 5T_6(x) + \alpha_5 T_5(x) + r_4(x) && \text{Division des Restes } r_5 \text{ durch } T_5\\
&= 5T_6(x) + 2(16x^5 - 20x^3 + 5x) + r_4(x)\\
&= 5T_6(x) + 2T_5(x) + 24x^4 - 4x^3 - 32x^2 + 4x - 3\\
&= 5T_6(x) + 2T_5(x) + \alpha_4 T_4(x) + r_3(x) && \text{Division des Restes } r_4 \text{ durch } T_4\\
&= 5T_6(x) + 2T_5(x) + 3(8x^4 - 8x^2 + 1) + r_3(x)\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - 4x^3 - 8x^2 + 4x - 6\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) + \alpha_3 T_3(x) + r_2(x) && \text{Division des Restes } r_3 \text{ durch } T_3\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - (4x^3 - 3x) + r_2(x)\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - T_3(x) - 8x^2 + x - 6\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - T_3(x) + \alpha_2 T_2(x) + r_1(x) && \text{Division des Restes } r_2 \text{ durch } T_2\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - T_3(x) - 4(2x^2 - 1) + x - 10\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - T_3(x) - 4T_2(x) + x - 10\\
&= 5T_6(x) + 2T_5(x) + 3T_4(x) - T_3(x) - 4T_2(x) + T_1(x) - 10T_0(x)
\end{aligned}$$

Antwort: $p = 5T_6 + 2T_5 + 3T_4 - T_3 - 4T_2 + T_1 - 10T_0$.

(b_2) Alternativ kann man für die Tschebyscheff-Darstellung von p auch ansetzen:

$$p(x) = \sum_{i=0}^{6} \alpha_i T_i(x)$$

Auf der rechten Seite ersetzt man die Tschebyscheff-Polynome durch ihre in *(a)* angegebenen Monom-Darstellung und sortiert nach Potenzen von x^i, $i = 0, \ldots, 6$:

$$\begin{aligned}
p(x) &= 160x^6 + 32x^5 - 216x^4 - 44x^3 + 58x^2 + 14x - 8\\
&= \alpha_0 - \alpha_2 + \alpha_4 - \alpha_6 + (\alpha_1 - 3\alpha_3 + 5\alpha_5)\, x + (2\alpha_2 - 8\alpha_4 + 18\alpha_6)\, x^2\\
&\quad + (4\alpha_3 - 20\alpha_5)\, x^3 + (8\alpha_4 - 48\alpha_6)\, x^4 + 16\alpha_5 x^5 + 32\alpha_6 x^6.
\end{aligned}$$

Durch Koeffizientenvergleich für die Potenzen von x ergibt sich ein gestaffeltes Gleichungssystem:

$$\begin{pmatrix} 1 & 0 & -1 & 0 & 1 & 0 & -1 \\ 0 & 1 & 0 & -3 & 0 & 5 & 0 \\ 0 & 0 & 2 & 0 & -8 & 0 & 18 \\ 0 & 0 & 0 & 4 & 0 & -20 & 0 \\ 0 & 0 & 0 & 0 & 8 & 0 & -48 \\ 0 & 0 & 0 & 0 & 0 & 16 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 32 \end{pmatrix} \begin{pmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{pmatrix} = \begin{pmatrix} -8 \\ 14 \\ 58 \\ -44 \\ -216 \\ 32 \\ 160 \end{pmatrix},$$

das man unten beginnend auflöst. Wir erhalten

$$\alpha_6 = 5, \quad \alpha_5 = 2, \quad \alpha_4 = 3, \quad \alpha_3 = -1, \quad \alpha_2 = -4, \quad \alpha_1 = 1, \quad \alpha_0 = -10.$$

Bem.: Es ist kein Zufall, dass die Spalten der Matrix die Koeffizienten der Monom-Darstellung der Tschebyscheff-Polynome enthalten und die rechte Seite die Koeffizienten der Monom-Darstellung von p. ♣

Lösung 3.3.4. Sei

$$\tilde{T}_n(x) := \cos(n \arccos x), \quad n \geq 0, \quad x \in [-1, 1].$$

Es ist

$$\tilde{T}_0(x) = \cos(0) = 1, \quad \tilde{T}_1(x) = \cos(\arccos x) = x$$

Für $n \geq 1$ folgt mit den Additionstheoremen und der Substitution $t := \arccos x$.

$$\begin{aligned} \tilde{T}_{n+1}(x) &= \cos(n+1)t = \cos nt \ \cos t - \sin nt \ \sin t \\ \tilde{T}_{n-1}(x) &= \cos(n-1)t = \cos nt \ \cos t + \sin nt \ \sin t. \end{aligned}$$

Durch Summation der beiden Gleichungen erhalten wir

$$\tilde{T}_{n+1}(x) + \tilde{T}_{n-1}(x) = 2 \cos nt \ \cos t = 2x\tilde{T}_n(x).$$

Also genügen die $\tilde{T}_n$ auf $[-1, 1]$ der gleichen Rekursion (3.7) wie die Tschebyscheff-Polynome erster Art. Sie sind also dort mit ihnen identisch. ♣

Lösung 3.3.6. Unter Beachtung der Substituationsregel für Integrale erhalten wir mit $t := \arccos x$

$$\begin{aligned} I_{ij} &:= \int_{-1}^{1} T_i(x) T_j(x) \frac{1}{\sqrt{1-x^2}} \, \mathrm{d}x = \int_{-1}^{1} \cos(i \arccos x) \cos(j \arccos x) \, (-\arccos' x) \, \mathrm{d}x \\ &= -\int_{\arccos(-1)}^{\arccos 1} \cos it \cos jt \, \mathrm{d}t = \int_0^{\pi} \cos it \cos jt \, \mathrm{d}t. \end{aligned}$$

$i = j = 0$:

$$I_{00} = \int_0^{\pi} 1 \, \mathrm{d}t = \pi;$$

$i, j \in \mathbb{N}$, $i = j$:

$$\begin{aligned} I_{ii} &= \int_0^{\pi} \cos^2 it \, \mathrm{d}t = \frac{1}{i} \cos it \sin it \Big|_0^{\pi} + \int_0^{\pi} \sin^2 it \, \mathrm{d}t = \int_0^{\pi} \sin^2 it \, \mathrm{d}t \\ &= \int_0^{\pi} (1 - \cos^2 it) \, \mathrm{d}t = \pi - I_{ii} \quad \Rightarrow \quad I_{ii} = \frac{\pi}{2} \end{aligned}$$

$i \in \mathbb{N}_0$, $j \in \mathbb{N}$, $i \neq j$:

$$I_{ij} = \int_0^\pi \cos it \cos jt \,\mathrm{d}t = \frac{1}{j} \cos it \sin jt\Big|_0^\pi + \frac{i}{j} \int_0^\pi \sin it \sin jt \,\mathrm{d}t$$
$$= \frac{i}{j} \int_0^\pi \sin it \sin jt \,\mathrm{d}t = -\frac{i}{j^2} \sin it \cos jt\Big|_0^\pi + \frac{i^2}{j^2} \int_0^\pi \cos it \cos jt \,\mathrm{d}t = \frac{i^2}{j^2} I_{ij} \quad \Rightarrow \quad I_{ij} = 0.$$

♣

Lösung 3.4.4. Aus Satz 3.1.3 wissen wir, dass eine durch ein Skalarprodukt induzierte Norm in der Tat Normeigenschaften besitzt.

Wir beweisen, dass für eine Gewichtsfunktion ϱ

$$\langle v, w \rangle_\varrho := \int_a^b v(x) w(x) \varrho(x) \,\mathrm{d}x$$

ein Skalarprodukt ist.

S_1 – Linearität im ersten Argument: Für beliebiges $\alpha_1, \alpha_2 \in \mathbb{R}$ und beliebige Polynome v_1, v_2, w gilt

$$\langle \alpha_1 v_1 + \alpha_2 v_2, w \rangle_\varrho = \int_a^b \alpha_1 v_1(x) w(x) \varrho(x) \,\mathrm{d}x + \int_a^b \alpha_2 v_2(x) w(x) \varrho(x) \,\mathrm{d}x$$
$$= \alpha_1 \int_a^b v_1(x) w(x) \varrho(x) \,\mathrm{d}x + \alpha_2 \int_a^b v_2(x) w(x) \varrho(x) \,\mathrm{d}x = \alpha_1 \langle v_1, w \rangle_\varrho + \alpha_2 \langle v_2, w \rangle_\varrho .$$

S_2 – Symmetrie: für beliebige Polynome v, w ist

$$\langle v, w \rangle_\varrho = \int_a^b v(x) w(x) \varrho(x) \,\mathrm{d}x = \int_a^b w(x) v(x) \varrho(x) \,\mathrm{d}x = \langle w, v \rangle_\varrho .$$

S_3 – positive Definitheit: Für jedes Polynom v, das nicht identisch verschwindet, existiert ein abgeschlossenes Intervall $[\alpha, \beta] \subset [a, b]$ mit $v(x) \neq 0$, für alle $x \in [\alpha, \beta]$, und es folgt

$$\langle v, v \rangle_\varrho = \int_a^b v(x)^2 \varrho(x) \,\mathrm{d}x \geq \int_\alpha^\beta v(x)^2 \varrho(x) \,\mathrm{d}x > 0.$$

Somit erfüllt $\langle \cdot, \cdot \rangle_\varrho$ alle Eigenschaften eines Skalarproduktes. ♣

Lösung 3.4.8. Wegen der vorausgesetzten Orthogonalität gilt

$$\langle u_i, q \rangle_\varrho = 0 \quad \text{und} \quad \langle \tilde{u}_i, q \rangle_\varrho = 0 \quad \forall\, q \in \Pi_{i-1}. \tag{3.29}$$

Die Polynome $\tilde{\gamma}_i u_i$ und $\gamma_i \tilde{u}_i$ besitzen den selben Leitkoeffizienten, nämlich $\gamma_i \tilde{\gamma}_i$. Also ist die Differenz $d := \tilde{\gamma}_i u_i - \gamma_i \tilde{u}_i$ ein Polynome vom Höchstgrad $i - 1$. Aus (3.29) folgt (mit $q = d \in \Pi_{i-1}$)

$$\|d\|_\varrho^2 = \langle d, d \rangle_\varrho = \langle \tilde{\gamma}_i u_i - \gamma_i \tilde{u}_i, d \rangle_\varrho = \tilde{\gamma}_i \langle u_i, d \rangle_\varrho - \gamma_i \langle \tilde{u}_i, d \rangle_\varrho = 0.$$

Also ist $d = 0$ und somit $\tilde{\gamma}_i u_i = \gamma_i \tilde{u}_i$. ♣

Lösung 3.4.12. Betrachte das Polynome $\tilde{u}_i \in \Pi_i$, $\tilde{u}_i(x) := (-1)^i u_i(-x)$, $x \in \mathbb{R}$. Für ein beliebiges Polynom $q \in \Pi_{i-1}$ gilt

$$\int_{-a}^a \tilde{u}_i(x) q(x) \varrho(x) \,\mathrm{d}x = (-1)^i \int_{-a}^a u_i(-x) q(x) \varrho(x) \,\mathrm{d}x = (-1)^i \int_{-a}^a u_i(x) q(-x) \underbrace{\varrho(-x)}_{=\varrho(x)} \,\mathrm{d}x = 0,$$

da voraussetzungsgemäß $u_i \perp \Pi_{i-1}$. Wir haben somit gezeigt, dass $\tilde{u}_i \perp \Pi_{i-1}$.

Ferner sind die Leitkoeffizienten von u_i und $\tilde{u}_i$ gleich. Mit Aufg. 3.4.8 folgt, dass u_i und $\tilde{u}_i$ identisch sind, d. h. $u_i(x) = (-1)^i u_i(-x)$, $x \in \mathbb{R}$. ♣

Lösung 3.5.4. Wegen Aufg. 3.4.12 gilt $u_i(x)^2 = u_i(-x)^2$, $x \in I$. Folglich gilt

$$\langle u_i, \mu_1 u_i \rangle_\varrho = \int_{-a}^{a} u_i(x)^2 x\varrho(x)\,\mathrm{d}x = \int_0^a u_i(x)^2 x\varrho(x)\,\mathrm{d}x + \int_0^a \underbrace{u_i(-x)^2}_{=u_i(x)^2}(-x)\underbrace{\varrho(-x)}_{=\varrho(x)}\,\mathrm{d}x = 0.$$

♣

Lösung 3.5.8. Wie im Beweis zu Satz 3.5.6 verwenden wir das Hilfspolynom ψ,

$$\psi(x) := (x^2-1)^i = (x-1)^i(x+1)^i.$$

Mit Blick auf die Rodrigues-Formel ist

$$2^{2i}(i!)^2 \langle P_i, P_i \rangle_{\varrho_P} = \int_{-1}^{1} \psi^{(i)}(x)\psi^{(i)}(x)\,\mathrm{d}x.$$

Wir integrieren i-mal partiell und nutzen (3.24):

$$2^{2i}(i!)^2 \langle P_i, P_i \rangle_{\varrho_P} = (-1)^i \int_{-1}^{1} \psi(x)\underbrace{\psi^{(2i)}(x)}_{=(2i)!}\,\mathrm{d}x = (-1)^i(2i)! \int_{-1}^{1} (x-1)^i(x+1)^i\,\mathrm{d}x.$$

Wir integrieren wiederum i-mal partiell:

$$2^{2i}(i!)^2 \langle P_i, P_i \rangle_{\varrho_P} = (2i)!\frac{i(i-1)\cdots 1}{(i+1)(i+2)\cdot(2i)} \int_{-1}^{1} (x+1)^{2i}\,\mathrm{d}x.$$

Hieraus folgt

$$2^{2i}\langle P_i, P_i \rangle_{\varrho_P} = \int_{-1}^{1} (x+1)^{2i}\,\mathrm{d}x = \frac{1}{2i+1}(x+1)^{2i+1}\Big|_{-1}^{1} = \frac{2^{2i+1}}{2i+1} \quad \Longrightarrow \quad \langle P_i, P_i \rangle_{\varrho_P} = \frac{2}{2i+1}.$$

♣

Lösung 3.6.3. Werten Sie das Polynom

$$p = 5T_6 + 2T_5 + 3T_4 - T_3 - 4T_2 + T_1 - 10T_0,$$

mit Hilfe des Clenshaw-Algorithmus an der Stelle $1/2$ aus!

	5	2	3	−1	−4	1	−10
			−5	−7	−5	3	12
1/2		5	7	5	−3	−12	−4
	5	7	5	−3	−12	−8	$\boxed{-2 = p(\alpha)}$

♣

Kapitel 4

Polynominterpolation

Bei der **Interpolation** ist zu einer endlichen Anzahl m von gegebenen Datenpaaren (x_k, f_k), $k = 1, \ldots, m$ eine Funktion g gesucht – eine sog. **Interpolante** oder **Interpolierende** der Daten – die diese Daten exakt abbildet, d. h. $g(x_k) = f_k$, $k = 1, \ldots, m$. Aus der konkreten Gestalt der Aufgabe, insbesondere der Wahl der x_k, kristallisieren sich zwei wesentliche Anwendungen heraus:

Repräsentation: Hinter den Daten f_k verbirgt sich eine Funktion f mit $f_k = f(x_k)$, die sich in ihrem gesamten Definitionsbereich berechnen lässt, unter Umständen jedoch nur mit hohem Aufwand. Die Interpolierende wird als eine einfacher zu handhabende Repräsentation für f bestimmt. Die x_k sind in der Regel frei wählbar und können je nach Anwendung in einem durch den Problemkontext gegebenen Sinne optimiert werden.

In diesen Anwendungsbereich fällt auch die **numerische Integration** oder **Quadratur**. Als Näherung für das bestimmte Integral von f wird das leichter zu berechnende Integral einer Interpolierenden von f verwendet. Auch hier ist eine günstige Wahl der Interpolationsstellen x_k insbesondere für die Genauigkeit des näherungsweise berechneten Integralwertes wichtig.

Rekonstruktion: Die Daten sind zumeist als Ergebnis von Messungen gegeben. Der Einfluss des Anwenders auf die Wahl der x_k ist stark eingeschränkt. Mit der Interpolierenden wird versucht, einen funktionalen Zusammenhang zwischen zwei voneinander abhängigen Größen herzuleiten.

In diesem Zusammenhang können wir die Interpolierende g als ein mathematisches Modell für einen physikalischen Vorgang interpretieren, dessen Parameter über die Bedingungen $g(x_k) = f_k$, $k = 1, \ldots, m$, bestimmt werden.

4.1 Lineare Interpolation

Es gibt eine Vielzahl von Möglichkeiten, systematisch Interpolierende zu konstruieren. Wir werden uns ausschließlich mit dem wichtigsten Spezialfall der **linearen Interpolation** beschäftigen.

Aufgabenstellung: Interpolation (IP)

Gegeben sind

- m paarweise verschiedene **Stützstellen** $\Delta := \{x_k\}_{k=1}^m \subset \mathbb{C}$,
- **Stützwerte** $y_k \in \mathbb{C}$, $k = 1, \ldots, m$, und
- ein ℓ-dimensionaler linearer Raum $\mathbb{V}_\ell$ von Funktionen, die von $\mathbb{C}$ in $\mathbb{C}$ abbilden.

Gesucht ist eine Funktion $g \in \mathbb{V}_\ell$, die die m **Interpolationsbedingungen**

$$g(x_k) = y_k, \quad k = 1, \ldots, m, \tag{4.1}$$

erfüllt.

Bemerkung 4.1.1. Durch die Vorgabe der Stützstellen und -werte wird eine Abbildung

$$y\colon \Delta \to \mathbb{C}\colon x_k \mapsto y(x_k) = y_k$$

definiert, die z. B. tabellarisch erfasst werden kann. Man spricht daher auch davon, dass die interpolierende Funktion g die Daten einer gegebenen Wertetabelle interpoliert.

Da $\mathbb{V}_\ell$ ein linearer Raum ist, können wir die gesuchte Interpolierende als Linearkombination einer Basis $\{u_j\}_{j=1}^\ell$ von $\mathbb{V}_\ell$ suchen:

$$g = \sum_{j=1}^{\ell} c_j u_j.$$

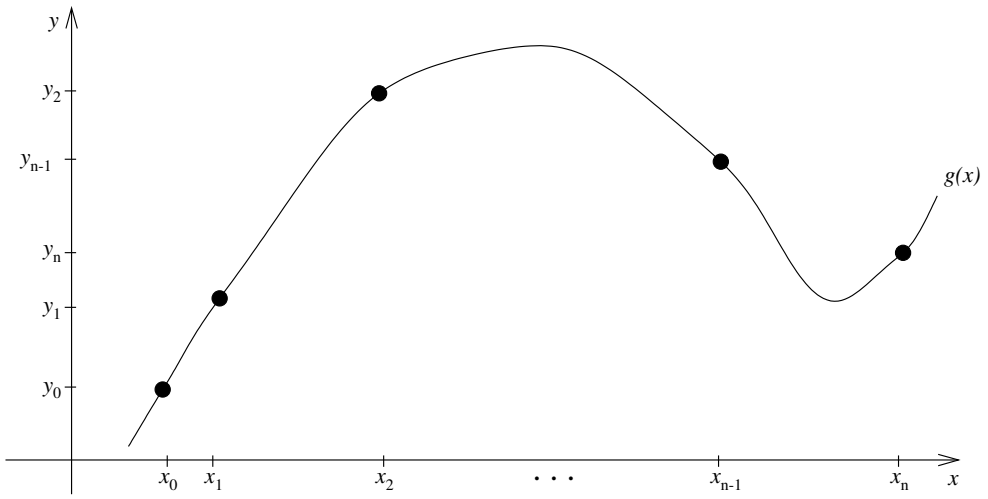


Abbildung 4.1: Interpolante g zu den Stützstellen $x_0, \ldots, x_n$ und Stützwerten $y_0, \ldots, y_n$

Diesen Ansatz setzen wir in (4.1) ein, was auf ein lineares Gleichungssystem für die c_j führt:

$$\begin{aligned} u_1(x_1)\,c_1 + u_2(x_1)\,c_2 + \cdots + u_\ell(x_1)\,c_\ell &= y_1,\\ u_1(x_2)\,c_1 + u_2(x_2)\,c_2 + \cdots + u_\ell(x_2)\,c_\ell &= y_2,\\ &\vdots\\ u_1(x_m)\,c_1 + u_2(x_m)\,c_2 + \cdots + u_\ell(x_m)\,c_\ell &= y_m, \end{aligned}$$

oder kurz

$$\boldsymbol{A}\boldsymbol{c} = \boldsymbol{y} \tag{4.2}$$

mit der Matrix $\boldsymbol{A} \in \mathbb{C}^{m,\ell}$,

$$a_{kj} = u_j(x_k), \quad k = 1,\dots,m, \quad j = 1,\dots,\ell,$$

der rechten Seite $\boldsymbol{y} = (y_1,\dots,y_m)^T \in \mathbb{C}^m$ und dem Vektor $\boldsymbol{c} = (c_1,\dots,c_\ell)^T \in \mathbb{C}^\ell$ der zu bestimmenden Koeffizienten.

Aufgrund der Äquivalenz von (IP) und (4.2) können die Aussagen zur Lösbarkeit linearer Gleichungssysteme auf (IP) übertragen werden.

In diesem Kapitel werden wir uns ausschließlich mit dem Fall $\ell = m$ beschäftigen, für den die Interpolationsaufgabe genau dann eine eindeutige Lösung besitzt, wenn die Matrix $\boldsymbol{A}$ regulär ist.

Bemerkung 4.1.2. Von praktischem Interesse ist aber auch die Konstellation $\ell < m$, insbesondere $\ell \ll m$. Dies ist z. B. der Fall, wenn einige wenige Parameter eines Modells mittels einer großen Anzahl von Messungen bestimmt werden sollen. In diesem Fall ist das Gleichungssystem (4.2) überbestimmt und besitzt i. Allg. keine Lösung. Man wird dann eine Ersatzlösung suchen, die beispielsweise $\|\boldsymbol{A}\boldsymbol{c} - \boldsymbol{y}\|_2$ minimiert. Man beachte aber, dass die so erhaltene Funktion g i. Allg. die Interpolationsbedingungen nicht exakt, sondern lediglich näherungsweise erfüllen wird.

Entsprechend der Wahl von $\mathbb{V}_\ell$ wird die Art der Interpolation klassifiziert. Als Basisfunktionen werden wir in diesem Kapitel Polynome einsetzen, weswegen wir auch von **Polynominterpolation** sprechen. Im Kapitel 6 wenden wir uns der **Spline-Interpolation** zu, bei der geeignet zusammengesetzten Polynome, sog. Splines, Verwendung finden.

Wie bereits angedeutet ist die Polynominterpolation durch die Wahl $\mathbb{V}_\ell = \Pi_n$, $n = \ell - 1$, charakterisiert. Da $\dim \Pi_n = n + 1$, definieren wir das Interpolationspolynom durch die Vorgabe von Stützwerten in $m = n + 1$ Stützstellen. Üblicher Praxis folgend nummerieren wir diese von $k = 0$ bis $k = n$ durch.

Wir formalisieren die Aufgabenstellung der Polynominterpolation wie folgt.

Aufgabenstellung: Polynominterpolation (Π-IP)

Gegeben ist ein System $\Delta := \{x_k\}_{k=0}^n \subset \mathbb{C}$ paarweise verschiedener **Stützstellen** sowie zugehörige **Stützwerte** $y_k \in \mathbb{C}$, $k = 0,\dots,n$.
Gesucht ist ein Polynom $p_n \in \Pi_n$, das den Interpolationsbedingungen

$$p_n(x_k) = y_k, \quad k = 0,\dots,n, \tag{4.3}$$

genügt.

Beispiel 4.1.3. Gegeben seien die folgenden Stützstellen und -werte.

k	0	1	2	3
x_k	-2	0	1	2
y_k	-5	1	4	15

Wir wollen das zugehörige Interpolationspolynom $p_3 \in \Pi_3$ bestimmen und anschließend an der Stelle $x = \mathrm{i}$ auswerten.

In Π_3 wählen wir die Monom-Basis und setzen für das Interpolationspolynom an:

$$p_3(x) = \sum_{j=0}^{3} c_j \mu_j(x)\,.$$

Aus den Interpolationsbedingungen (4.3) erhalten wir vier Gleichungen für die c_j:

$$y_k = c_0 + c_1 x_k + c_2 x_k^2 + c_3 x_k^3, \quad k = 0, 1, 2, 3,$$

bzw.

$$\begin{aligned} -5 &= c_0 - 2c_1 + 4c_2 - 8\,c_3 \\ 1 &= c_0 \\ 4 &= c_0 + c_1 + c_2 + c_3 \\ 15 &= c_0 + 2c_1 + 4c_2 + 8\,c_3 \end{aligned}$$

Durch Lösen dieses linearen Gleichungssystems, z. B. mit dem Eliminationsverfahren, ermitteln wir $c_0 = c_1 = c_2 = c_3 = 1$. Also

$$p_3(x) = x^3 + x^2 + x + 1.$$

Zur Berechnung von $p_3(\mathrm{i})$ bemühen wir natürlich das Horner-Schema:

	1	1	1	1
i	–	i	$-1+\mathrm{i}$	-1
	1	$1+\mathrm{i}$	i	0

$p_3(\mathrm{i}) = 0.$

♠

4.2 Die Lagrangesche Form des Interpolationspolynoms

Wir betrachten jetzt eine einfache Möglichkeit, ein Interpolationspolynom zu konstruieren, das die Aufgabe (Π-IP) löst. Damit wird auch die Existenz einer Lösung gezeigt. Die Eindeutigkeit der Lösung folgt aus Satz 3.2.8.(i), wonach ein Polynom n-ten Grades durch seine Funktionswerte in $n+1$ Punkten eindeutig bestimmt ist.

Definition 4.2.1: Lagrange[1]-Polynome

Sei $\Delta := \{x_k\}_{k=0}^n$ ein System paarweise verschiedener Stützstellen.

(i) Die Polynome L_k,

$$L_k(x) := \prod_{j=0,\, j\neq k}^{n} \frac{x - x_j}{x_k - x_j}, \quad k = 0, \ldots, n,$$

werden als die zu diesen Stützstellen gehörenden **Lagrangeschen Grundpolynome** bezeichnet.

(ii) Das Polynom ω_{n+1},

$$\omega_{n+1}(x) := (x - x_0)(x - x_1) \cdots (x - x_n)$$

wird als das zu diesen Stützstellen gehörende **Knotenpolynom** bezeichnet.

Offensichtlich sind die L_k Polynome vom Grad n. Ferner gilt

$$L_k(x_j) = \delta_{kj}, \quad 0 \le k, j \le n, \tag{4.4}$$

mit dem Kronecker[2]-Symbol

$$\delta_{kj} := \begin{cases} 1 & \text{für } j = k, \\ 0 & \text{für } j \neq k. \end{cases}$$

Die Lagrangeschen Grundpolynome sind also so konstruiert, dass sie in allen Stützstellen verschwinden mit Ausnahme einer, in der sie den Wert 1 annehmen; siehe auch Abbildung 4.2.

Bemerkung 4.2.2. Die L_k, $k = 0, \ldots, n$, bilden eine Basis des Π_n, weshalb wir sie auch als **Lagrangesche Basispolynome** bezeichnen. Zwischen ihnen und dem Knotenpolynom besteht der nachfolgende Zusammenhang:

$$L_k(x) = \frac{\omega_{n+1}(x)}{\omega'_{n+1}(x_k)(x - x_k)}, \quad \text{für } x \neq x_k, \;\; k = 0, 1, \ldots, n. \tag{4.5}$$

Mit Hilfe der Lagrangeschen Basispolynome kann die Lösbarkeit von (Π-IP) einfach durch Angabe der Lösung gezeigt werden:

$$p_n(x) = \sum_{k=0}^{n} y_k L_k(x) = \sum_{k=0}^{n} y_k \prod_{\substack{j=0 \\ j\neq k}}^{n} \frac{x - x_j}{x_k - x_j}. \tag{4.6}$$

[1] Joseph-Louis Lagrange, *25.1.1736 (Turin, Sardinien-Piemont), †10.4.1813 (Paris, Frankreich)

[2] Leopold Kronecker, *7.12.1823 (Liegnitz, Preußen, jetzt Legnica, Polen), †29.12.1891 (Berlin, Deutschland)

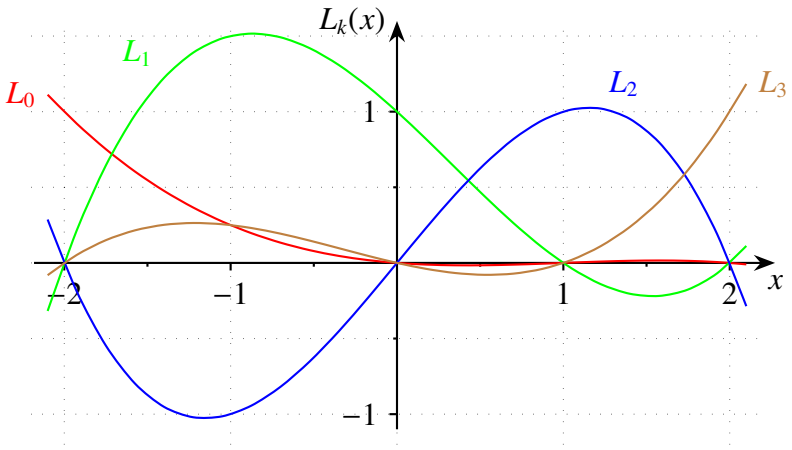


Abbildung 4.2: Die Lagrangeschen Grundpolynome zu den Stützstellen $x_0 = -2$, $x_1 = 0$, $x_2 = 1$ und $x_3 = 2$

Diese Darstellung bezeichnen wir als **Lagrangesche Form des Interpolationspolynoms**.

Das durch (4.6) definierte Polynom p_n ist als eine Linearkombination der $L_k \in \Pi_n$ ein Polynom vom Höchstgrad n. Wegen (4.4) gilt

$$p_n(x_k) = \sum_{i=0}^{n} y_i L_i(x_k) = y_k L_k(x_k) = y_k, \quad k = 0, \ldots, n.$$

Somit löst p_n die Interpolationsaufgabe (Π-IP). Die Eindeutigkeit der Lösung von (Π-IP) folgt – wie bereits diskutiert – aus Satz 3.2.8.(i). Wir fassen zusammen.

Satz 4.2.3

Die Interpolationsaufgabe (Π-IP) besitzt eine eindeutige Lösung.

Beispiel 4.2.4. Wir betrachten wieder die Wertetabelle aus Bsp. 4.1.3, wollen diesmal aber die Lagrangesche Darstellungform zur Ermittlung des Interpolationspolynoms verwenden.

k	0	1	2	3
x_k	−2	0	1	2
y_k	−5	1	4	15

Wir bestimmen zunächst die Lagrangeschen Basispolynome zu den gegebenen Stützstellen:

$$\begin{aligned}
L_0(x) &= \frac{x-x_1}{x_0-x_1}\cdot\frac{x-x_2}{x_0-x_2}\cdot\frac{x-x_3}{x_0-x_3} = \frac{x}{-2}\cdot\frac{x-1}{-3}\cdot\frac{x-2}{-4},\\
L_1(x) &= \frac{x-x_0}{x_1-x_0}\cdot\frac{x-x_2}{x_1-x_2}\cdot\frac{x-x_3}{x_1-x_3} = \frac{x+2}{2}\cdot\frac{x-1}{-1}\cdot\frac{x-2}{-2},\\
L_2(x) &= \frac{x-x_0}{x_2-x_0}\cdot\frac{x-x_1}{x_2-x_1}\cdot\frac{x-x_3}{x_2-x_3} = \frac{x+2}{3}\cdot\frac{x}{1}\cdot\frac{x-2}{-1},\\
L_3(x) &= \frac{x-x_0}{x_3-x_0}\cdot\frac{x-x_1}{x_3-x_1}\cdot\frac{x-x_2}{x_3-x_2} = \frac{x+2}{4}\cdot\frac{x}{2}\cdot\frac{x-1}{1}.
\end{aligned}$$

Anschließend setzen wir in (4.6) ein

$$p_3(x) = -5\frac{x(x-1)(x-2)}{-24} + \frac{(x+2)(x-1)(x-2)}{4} + 4\frac{(x+2)x(x-2)}{-3} + 15\frac{(x+2)x(x-1)}{8}.$$

Aufgrund der Konstruktion der LAGRANGEschen Basispolynome ist – im Gegensatz zur Verwendung der Monom-Basis – kein Gleichungssystem zu lösen. Um aber beispielsweise die Monomdarstellung $p_3(x) = x^3 + x^2 + x + 1$ herzuleiten, ist einiger Rechenaufwand erforderlich. Die Basispolynome müssen ausmultipliziert und nach Potenzen von x sortiert werden. ♠

Aufgabe 4.2.5. Sei $\Delta = \{x_k\}_{k=0}^n$ ein System paarweise verschiedener Stützstellen. Beweisen Sie: Es gilt $\sum_{k=0}^n L_k = \mu_0$. ♢

Bemerkung 4.2.6. Bei festem Stützstellensystem $\Delta = \{x_k\}_{k=0}^n \subset \mathbb{C}$ ist die Abbildung

$$I\colon \mathbb{C}^{n+1} \to \Pi_n\colon \boldsymbol{y} = (y_0, \ldots, y_n)^T \mapsto I(\boldsymbol{y}) \coloneqq \sum_{k=0}^n y_k\, L_k,$$

linear, denn es gilt

$$I(\alpha \boldsymbol{y}) = \alpha I(\boldsymbol{y}) \quad \text{und} \quad I(\boldsymbol{y} + \boldsymbol{z}) = I(\boldsymbol{y}) + I(\boldsymbol{z}), \quad \text{für alle } \alpha \in \mathbb{C},\ \boldsymbol{y}, \boldsymbol{z} \in \mathbb{C}^{n+1}.$$

Somit ist I ein Vektorraumhomomorphismus zwischen $\mathbb{C}^{n+1}$ und Π_n und wegen der Eindeutigkeit des Interpolationspolynoms sogar ein Vektorraumisomorphismus.

4.3 Die Newtonsche Form des Interpolationspolynoms

Nachdem in Π_n eine Basis $\{u_k\}_{k=0}^n$ ausgezeichnet ist, läuft die Bestimmung des Interpolationspolynoms auf das Lösen eines linearen Gleichungssystems hinaus; vergleiche Abschnitt 4.1.

Im Fall der Lagrange-Basis $\{L_k\}_{k=0}^n$ ist die Koeffizientenmatrix in (4.2) die Einheitsmatrix, also trivial zu invertieren. Wird allerdings nur eine einzige Stützstelle geändert, so ändert sich die gesamte Basis, wie man der Definition der L_k, unmittelbar ansieht. Diese Basis ist überwiegend aus theoretischer Sicht interessant.

Wird hingegen die Monom-Basis verwendet, so ist ein Gleichungssystem mit vollbesetzter Koeffizientenmatrix zu lösen, was recht aufwendig ist, und bei numerischer Rechnung wegen schlechter Kondition Probleme bereiten kann.

Die Idee der Newton[3]schen Darstellung ist die Verwendung einer Basis, die zu einem gestaffelten Gleichungssystem führt. Die zugehörige Koeffizientenmatrix in (4.2) ist eine reguläre untere Dreiecksmatrix.

Definition 4.3.1: Newtonsche Grundpolynome

Seien $n+1$ paarweise verschiedene Punkte $x_k \in \mathbb{C}$, $k = 0, \dots, n$, gegeben. Die Polynome N_k mit

$$N_0(x) := 1, \quad N_k(x) := (x - x_0)(x - x_1) \cdots (x - x_{k-1}), \quad k = 1, \dots, n, \quad x \in \mathbb{C},$$

werden als die zu diesen Stützstellen gehörenden **Newtonschen Grund- oder Basispolynome** bezeichnet.

Aufgabe 4.3.2. Skizzieren Sie die Newtonschen Grundpolynome N_k, $k = 0, \dots, 3$, zu den Stützstellen $x_0 = -2$, $x_1 = 0$, $x_2 = 1$ und $x_3 = 2$! ◊

Da N_k ein Polynom vom Grad k ist, bilden die N_k, $k = 0, \dots, n$, eine Basis des Π_n und wir können für das Interpolationspolynom

$$p_n = \sum_{k=0}^{n} c_k N_k \tag{4.7}$$

ansetzen. Anschließend arbeiten wir die Interpolationsbedingung (4.3) für $k = 0, \dots, n$ ein. Dies führt auf das gestaffelte Gleichungssystem

$$\begin{aligned}
y_0 &= c_0, \\
y_1 &= c_0 + c_1(x_1 - x_0), \\
y_2 &= c_0 + c_1(x_2 - x_0) + c_2(x_2 - x_0)(x_2 - x_1), \\
&\vdots \\
y_n &= c_0 + c_1(x_n - x_0) + c_2(x_n - x_0)(x_n - x_1) + \cdots \\
&\qquad + c_n(x_n - x_0)(x_n - x_1) \cdots (x_n - x_{n-1}),
\end{aligned}$$

[3] Isaac Newton, *4.1.1643 (Woolsthorpe, Lincolnshire, England), †31.3.1727 (London, England)

welches sich durch Umstellen nach c_k, $k = 0, \dots, n$, auflösen lässt. Dies ist stets möglich, da die Stützstellen paarweise verschieden sind, und somit $(x_k - x_0)(x_k - x_1) \cdots (x_k - x_{k-1}) \neq 0$, $k = 1, \dots, n$.

Beispiel 4.3.3. Wir betrachten wieder die Wertetabelle

k	0	1	2	3
x_k	-2	0	1	2
y_k	-5	1	4	15

aus Bsp. 4.1.3, wollen diesmal aber die Newtonsche Form des Interpolationspolynoms ermitteln. Wir bestimmen zunächst die Newtonschen Basispolynome zu den gegebenen Stützstellen:

$$\begin{aligned} N_0(x) &= 1, \\ N_1(x) &= x - x_0 && = x + 2, \\ N_2(x) &= (x - x_0)(x - x_1) && = (x + 2)x, \\ N_3(x) &= (x - x_0)(x - x_1)(x - x_2) && = (x + 2)x(x - 1). \end{aligned}$$

Als Ansatz für das Interpolationspolynom ergibt sich aus (4.7)

$$p_3(x) = c_0 + c_1(x + 2) + c_2(x + 2)x + c_3(x + 2)x(x - 1).$$

Wir lösen das gestaffelte Gleichungssystem

$$\begin{aligned} y_0 = -5 &= c_0 && \Longrightarrow && c_0 = -5, \\ y_1 = 1 &= -5 + c_1(0 + 2) && \Longrightarrow && c_1 = 3, \\ y_2 = 4 &= -5 + 3(1 + 2) + c_2(1 + 2)1 && \Longrightarrow && c_2 = 0, \\ y_3 = 15 &= -5 + 3(2 + 2) + 0(2 + 2)2 + c_3(2 + 2)2(2 - 1) && \Longrightarrow && c_3 = 1, \end{aligned}$$

und erhalten $p_3(x) = -5 + 3(x + 2) + (x + 2)x(x - 1)$. ♠

Nachdem wir die Idee des Newtonschen Ansatzes (4.7) illustriert haben, kommen wir jetzt zur systematischen Berechnung der Koeffizienten c_k.

Definition 4.3.4

Seien $\Delta := \{\xi_j\}_{j=0}^k \subset \mathbb{C}$, $k \in \mathbb{N}_0$, ein System paarweise verschiedener Stützstellen und $\eta\colon \Delta \to \mathbb{C}\colon \xi_j \mapsto \eta_j$. Mit $\eta[\xi_0, \xi_1, \dots, \xi_k]$ bezeichnen wir den Koeffizienten von μ_k in der Monomdarstellung des eindeutig bestimmten Polynoms $p \in \Pi_k$, das die Stützpunkte (ξ_j, η_j), $j = 0, \dots, k$, interpoliert.

Bemerkung 4.3.5. Besitzt das Interpolationspolynoms p den Grad k, so ist $\eta[\xi_0, \xi_1, \dots, \xi_k]$ der Leitkoeffizient von p andernfalls ist $\eta[\xi_0, \xi_1, \dots, \xi_k] = 0$.

Wir möchten die Koeffizienten c_k, $k = 0, \dots, n$, des Polynoms bestimmen, das die Wertetabelle (x_k, y_k), $k = 0, \dots, n$, interpoliert. Wir setzen an

$$p_n = c_0 N_0 + c_1 N_1 + c_2 N_2 + \cdots + c_n N_n \tag{4.8}$$

und bestimmen im Folgenden die c_k.

Sei $k \in \{0, \dots, n\}$ beliebig. Da $N_j \in \Pi_j$, $j = 0, \dots, n$, folgt

$$p_k := \sum_{j=0}^{k} c_j N_j \in \Pi_k.$$

Weiterhin ist c_k der Koeffizient von μ_k in der Monomdarstellung von p_k, da N_k den Leitkoeffizienten 1 besitzt und $p_j \in \Pi_{k-1}$, für $j < k$. Andererseits ist wegen (4.8)

$$p_k = p_n - \sum_{j=k+1}^{n} c_j N_j$$

und somit

$$p_k(x_\nu) = p_n(x_\nu) - \sum_{j=k+1}^{n} c_j N_j(x_\nu) = p_n(x_\nu) = y_\nu \quad \text{für } \nu = 0, \dots, k,$$

da definitionsgemäß N_ν die Nullstellen x_j, $j = 0, \dots, \nu - 1$, besitzt. Also ist p_k jenes eindeutig bestimmte Polynom vom Höchstgrad k, das die Wertetabelle (x_j, y_j), $j = 0, \dots, k$, interpoliert. Gemäß Def. 4.3.4 ist also $c_k = y[x_0, \dots, x_k]$.

Wir fassen unsere Überlegungen zusammen.

Satz 4.3.6

Seien $\Delta := \{x_k\}_{k=0}^n \subset \mathbb{C}$, $n \in \mathbb{N}_0$, ein System paarweise verschiedener Stützstellen und $y\colon \Delta \to \mathbb{C}\colon x_k \mapsto y_k$ eine Funktion auf Δ. Dann besitzt das Polynom $p_n \in \Pi_n$, das die Wertetabelle (x_k, y_k), $k = 0, \dots, n$, interpoliert, die Darstellung

$$p_n = y[x_0]N_0 + y[x_0, x_1]N_1 + y[x_0, x_1, x_2]N_2 + \cdots + y[x_0, \dots, x_n]N_n\,,$$

die wir als **Newtonsche Form des Interpolationspolynoms** bezeichnen.

Nach diesen Vorüberlegungen fehlt uns noch ein Verfahren zur Berechnung der $y[x_0, \dots, x_k]$. Der Schlüssel hierzu ist der folgende Satz.

Satz 4.3.7

Seien $\Delta := \{x_k\}_{k=0}^n$ ein System paarweise verschiedener Stützstellen und $y\colon \Delta \to \mathbb{C}\colon x_j \mapsto y_j$. Dann gilt

$$y[x_k] = y_k, \quad k = 0, \dots, n, \tag{4.9a}$$

$$y[x_k, \dots, x_{k+j}] = \frac{y[x_{k+1}, \dots, x_{k+j}] - y[x_k, \dots, x_{k+j-1}]}{x_{k+j} - x_k}, \quad k = 0, \dots, n-j, \quad j = 1, \dots, n. \tag{4.9b}$$

Bemerkung 4.3.8. Wegen ihrer Struktur werden die $y[x_k, \dots, x_{k+j}]$ auch als **dividierte Differenzen (der Ordnung j der Funktion y zum Stützstellensystem Δ)** bezeichnet.

Aufgabe 4.3.9. Beweisen Sie Satz 4.3.7! ♢

Bemerkung 4.3.10. Der Wert einer dividierten Differenz $y[x_0, x_1, \ldots, x_j]$ ist invariant gegenüber einer Umordnung der Stützstellen. Ist π, $i \mapsto \pi_i$, eine beliebige Permutation der Indizes $0, 1, \ldots, j$, dann gilt $y[x_0, x_1, \ldots, x_j] = y[x_{\pi_0}, x_{\pi_1}, \ldots, x_{\pi_j}]$.

Bemerkung 4.3.11. Die Rollen von Def. 4.3.4 und Satz 4.3.7 können auch vertauscht werden. So können die $y[x_i, \ldots, x_\ell]$ alternativ über die Rekursion (4.9) eingeführt werden. Im Anschluss wäre dann zu zeigen, dass die Charakterisierung in der Def. 4.3.4 gilt.

Die Berechnung der dividierten Differenzen erfolgt im **Steigungsschema**:

k	x_k	y_k	$y[x_k]$	$y[x_{k-1}, x_k]$	$y[x_{k-2}, x_{k-1}, x_k]$	$\cdots$	
0	x_0	y_0	$y[x_0]$				
1	x_1	y_1	$y[x_1]$	$\searrow$ $y[x_0, x_1]$			
2	x_2	y_2	$y[x_2]$	$\searrow$ $y[x_1, x_2]$	$\searrow$ $y[x_0, x_1, x_2]$		
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	
$n-1$	x_{n-1}	y_{n-1}	$y[x_{n-1}]$	$\searrow$ $y[x_{n-2}, x_{n-1}]$	$\searrow$ $y[x_{n-3}, x_{n-2}, x_{n-1}]$	$\cdots$	
n	x_n	y_n	$y[x_n]$	$\searrow$ $y[x_{n-1}, x_n]$	$\searrow$ $y[x_{n-2}, x_{n-1}, x_n]$	$\cdots$	$\searrow$ $y[x_0, \ldots, x_n]$

Beispiel 4.3.12. Wir wollen das Steigungsschema für die durch die Wertetabelle aus Bsp. 4.3.3 definierte Funktion $y : \Delta \to \mathbb{R}$ aufstellen.

k	x_k	y_k	$y[x_k]$	$y[x_{k-1}, x_k]$	$y[x_{k-2}, x_{k-1}, x_k]$	$y[x_{k-3}, \ldots, x_k]$
0	-2	-5	$\boxed{-5}$			
1	0	1	1	$\searrow \frac{1-(-5)}{0-(-2)} = \boxed{3}$		
2	1	4	4	$\searrow \frac{4-1}{1-0} = 3$	$\searrow \frac{3-3}{1-(-2)} = \boxed{0}$	
3	2	15	15	$\searrow \frac{15-4}{2-1} = 11$	$\searrow \frac{11-3}{2-0} = 4$	$\searrow \frac{4-0}{2-(-2)} = \boxed{1}$

Auf der Diagonale des Schemas finden sich die Koeffizienten für die NEWTONsche Form des Interpolationspolynoms. ♠

Wir fassen die Berechnung der c_k, $k = 0, 1, \ldots, n$, als Algorithmus.

Algorithmus 4.3.13: Berechnung der Koeffizienten in der NEWTON-Darstellung

Gegeben: Ein System von Stützstellen und -werten $(x_k, y_k) \in \mathbb{C}^2$, $k = 0, 1, \ldots, n$.

S1. FOR $k = 0, 1, \ldots, n$ DO
$c_k := y_k$
END DO

S2. FOR $j = 1, \ldots, n$ DO
FOR $k = n, n-1, \ldots, j$ DO
$$c_k := \frac{c_k - c_{k-1}}{x_k - x_{k-j}}$$
END DO
END DO

Ergebnis: Die Koeffizienten c_k, $k = 0, 1, \ldots, n$, in der NEWTONschen Darstellung (4.7) jenes Interpolationspolynoms, welches die Wertetabelle (x_k, y_k), $k = 0, 1, \ldots, n$, interpoliert.

Ein Vorteil der NEWTONschen Form des Interpolationspolynoms gegenüber der LAGRANGE- und der Monom-Darstellung ist, dass weitere Stützstellen und -werte einfach ergänzt werden können. Genügt $p_n \in \Pi_n$ den Interpolationsbedingungen (4.3) und wird ein Polynom $p_{n+1} \in \Pi_{n+1}$ gesucht, das neben (4.3) auch $p_{n+1}(x_{n+1}) = y_{n+1}$ erfüllt, dann gilt

$$p_{n+1}(x) = p_n(x) + c_{n+1}(x - x_0)(x - x_1)\cdots(x - x_n) = p_n(x) + c_{n+1}N_{n+1}(x),$$

wobei $c_{n+1} = y[x_0, \ldots, x_{n+1}]$ gemäß Satz 4.3.6 bestimmt wird. Zur Berechnung von c_{n+1} wird das Steigungsschema einfach um eine weitere Zeile für x_{n+1} ergänzt.

4.4 Auswertung des Interpolationspolynoms

Wir widmen uns jetzt der Frage, wie das Interpolationspolynom an einer vorgegebenen Stelle effizient ausgewertet werden kann. Eine naive Auswertung des Interpolationspolynoms in LAGRANGE-Form (Satz 4.2.3) erfordert im Wesentlichen $4n^2$ Operationen. Bei der manuellen Durchführung der Berechnung beobachtet man allerdings, dass eine Vielzahl von Operationen mehrfach ausgeführt werden.

4.4.1 Das Verfahren von AITKEN und NEVILLE

Gemäß Satz 3.2.8.(i) ist ein Polynom $p_n \in \Pi_n$ durch seine Werte in $n+1$ verschiedenen Stellen eindeutig bestimmt. Für die Berechnung von $p_n(\alpha)$ für ein vorgegebenes $\alpha \in \mathbb{C}$ ergeben sich somit zwei Möglichkeiten:

- Direkte Berechnung von $p_n(\alpha)$ aus den Stützstellen und -werten;
- Bestimmung des Interpolationspolynoms als Linearkombination geeigneter Basispolynome und anschließende Berechnung des Funktionswertes aus dieser Darstellung mit einem angepassten Verfahren, z. B. dem HORNER- oder CLENSHAW-Algorithmus.

Das Verfahren von AITKEN[4] und NEVILLE[5], dem wir uns jetzt widmen, wählt den ersten Zugang. Mit der zweiten Möglichkeit beschäftigen wir uns im Abschnitt 4.4.2, wo wir eine modifizierte Version des HORNER-Verfahrens herleiten, das eine effiziente Auswertung des Interpolationspolynoms in NEWTON-Form gestattet.

Satz 4.4.1

Sei $p_{m,k} \in \Pi_m$, $0 \le m \le k \le n$, das (eindeutig bestimmte) Polynom mit

$$p_{m,k}(x_j) = y_j, \quad j = k-m, \dots, k.$$

Dann gilt die rekursive Darstellung

$$\begin{aligned} p_{0,k}(x) &= y_k, && 0 \le k \le n, \\ p_{m,k}(x) &= \frac{(x - x_{k-m})p_{m-1,k}(x) - (x - x_k)p_{m-1,k-1}(x)}{x_k - x_{k-m}}, && 1 \le m \le k \le n. \end{aligned}$$

Aufgabe 4.4.2. Beweisen Sie Satz 4.4.1! ◊

Offensichtlich ist $p_n = p_{n,n}$ die Lösung der Interpolationsaufgabe (Π-IP), und die Rekursion von Satz 4.4.1 kann zur Auswertung des Interpolationspolynoms verwendet werden.

[4] Alexander Craig Aitken, *1.4.1895 (Dunedin, New Zealand), †3.11.1967 (Edinburgh, Schottland)
[5] Eric Harold Neville, *1.1.1889 (London, England), †22.8.1961 (Reading, Berkshire, England)

Algorithmus 4.4.3: Verfahren von AITKEN und NEVILLE

Gegeben: Ein System von Stützstellen und -werten $(x_k, y_k) \in \mathbb{C}^2$, $k = 0, \ldots, n$, und ein $\alpha \in \mathbb{C}$.

S1. FOR $k = 0, \ldots, n$ DO
$p_{0,k} := y_k$
$t_k := \alpha - x_k$
END DO

S2. FOR $m = 1, \ldots, n$ DO
FOR $k = m, \ldots, n$ DO
$$p_{m,k} := p_{m-1,k} + \frac{t_k}{t_{k-m} - t_k}(p_{m-1,k} - p_{m-1,k-1})$$
END DO
END DO

Ergebnis: $p_n(\alpha) = p_{n,n}$.

Die Berechung der $p_{m,k}$ erfolgt ähnlich dem Steigungsschema in Dreiecksform, dem sog. NEVILLE-Schema:

k	x_k	t_k	y_k	$p_{0,k}$	$p_{1,k}$	$p_{2,k}$	$\ldots$		
0	x_0	t_0	y_0	$p_{0,0}$					
1	x_1	t_1	y_1	$p_{0,1}$	$\searrow\rightarrow p_{1,1}$				
2	x_2	t_2	y_2	$p_{0,2}$	$\searrow\rightarrow p_{1,2}$	$\searrow\rightarrow p_{2,2}$			
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\ddots$		
$n-1$	x_{n-1}	t_{n-1}	y_{n-1}	$p_{0,n-1}$	$\searrow\rightarrow p_{1,n-1}$	$\searrow\rightarrow p_{2,n-1}$	$\ldots$	$\searrow\rightarrow p_{n-1,n-1}$	
n	x_n	t_n	y_n	$p_{0,n}$	$\searrow\rightarrow p_{1,n}$	$\searrow\rightarrow p_{2,n}$	$\ldots$	$\searrow\rightarrow p_{n-1,n}$	$\searrow\rightarrow p_{n,n}$

Beispiel 4.4.4. Wir betrachten wieder die Wertetabelle aus Bsp. 4.1.3:

k	0	1	2	3
x_k	-2	0	1	2
y_k	-5	1	4	15

Wir wollen den Funktionswert des durch die Tabelle definierten Polynoms $p_3 \in \Pi_3$ in $\alpha = \mathrm{i}$ mit dem NEVILLE-Schema berechnen.

k	x_k	t_k	y_k	$p_{0,k}$	$p_{1,k}$	$p_{2,k}$	$p_{3,k}$
0	-2	$\mathrm{i}+2$	-5	-5			
1	0	i	1	1	$\searrow\rightarrow 1+3\mathrm{i}$		
2	1	$\mathrm{i}-1$	4	4	$\searrow\rightarrow 1+3\mathrm{i}$	$\searrow\rightarrow 1+3\mathrm{i}$	
3	2	$\mathrm{i}-2$	15	15	$\searrow\rightarrow 11\mathrm{i}-7$	$\searrow\rightarrow -3-\mathrm{i}$	$\searrow\rightarrow 0$

Wir erhalten als Ergebnis $p_3(\mathrm{i}) = 0$, was uns in Anbetracht von Bsp. 4.1.3 nicht überrascht. ♠

Bemerkung 4.4.5. Im Alg. 4.4.3 werden nach Berechnung der $p_{m,k}$, $k = m, \ldots, n$, die $p_{m-1,k}$, $k = m-1, \ldots, n$, nicht mehr benötigt. Daher kann der Speicherbedarf für die $p_{m,k}$ durch geeignetes Überspeichern von $(n+2)(n+1)/2$ auf $n+1$ reduziert werden. Der Algorithmus wird dazu wie folgt umorganisiert. Beachten Sie, dass zur Wahrung der Datenabhängigkeiten die innere Schleife im Schritt 2 heruntergezählt wird.

Algorithmus 4.4.6: Verfahren von AITKEN und NEVILLE (modifiziert)

Gegeben: Ein System von Stützstellen und -werten $(x_k, y_k) \in \mathbb{C}^2$, $k = 0, \ldots, n$, und ein $\alpha \in \mathbb{C}$.

S1. FOR $i = 0, \ldots, n$ DO
$q_i := y_i$
$t_i := \alpha - x_i$
END DO

S2. FOR $m = 1, \ldots, n$ DO
FOR $i = n, n-1, \ldots, m$ DO
$$q_i := q_i + \frac{t_i}{t_{i-m} - t_i}(q_i - q_{i-1})$$
END DO
END DO

Ergebnis: $p_n(\alpha) = q_n$.

4.4.2 Das modifizierte HORNER-Schema

Ist das Interpolationspolynom in NEWTONscher Darstellung gegeben, so lässt sich das HORNER-Schema aus Abschnitt 3.2.3 leicht modifizieren, um das Interpolationspolynom auszuwerten. Wir verwenden die spezielle Gestalt der NEWTONschen Basispolynome (Def. 4.3.1), um (4.7) umzuformen:

$$p_n(x) = c_0 + (x - x_0)(c_1 + (x - x_1)(c_2 + \cdots + (x - x_{n-2})(c_{n-1} + (x - x_{n-1})c_n)\cdots)).$$

Wie beim HORNER-Verfahren erfolgt die Berechnung von „innen nach außen“ mit der innersten Klammer beginnend.

Algorithmus 4.4.7: Modifiziertes HORNER-Verfahren

Gegeben: Das Interpolationspolynom p_n in NEWTON-Darstellung (4.7) mit Koeffizienten c_k und Stützstellen x_k, $k = 0, 1, \ldots, n$, und ein $\alpha \in \mathbb{C}$.

S1. $b_n := c_n$,

S2. FOR $k = n-1, n-2, \ldots, 0$ DO
$b_k := c_k + b_{k+1}(\alpha - x_k)$
END DO

Ergebnis: $p_n(\alpha) = b_0$.

Eine einfache tabellarische Darstellung für diesen Algorithmus ist das **modifizierte Horner-Schema**:

		x_{n-1}	x_{n-2}	$\dots$	x_1	x_0
	c_n	c_{n-1}	c_{n-2}	$\dots$	c_1	c_0
α	$-$	$(\alpha - x_{n-1})b_n$	$(\alpha - x_{n-2})b_{n-1}$	$\dots$	$(\alpha - x_1)b_2$	$(\alpha - x_0)b_1$
	b_n	b_{n-1}	b_{n-2}	$\dots$	b_1	$\boxed{b_0 = p_n(\alpha)}$

Aufgabe 4.4.8. Berechnen Sie den Wert des Polynoms p_3, $p_3(x) = -5 + 3(x+2) + (x+2)x(x-1)$, aus Bsp. 4.3.3 an der Stelle $\alpha = \mathrm{i}$. ◊

Bemerkung 4.4.9. Um die Newton-Darstellung des Interpolationspolynoms p_n mit Hilfe des Steigungsschemas zu bestimmen, sind $(n+1)n/2$ Divisionen und $(n+1)n$ Additionen erforderlich. Die Auswertung des Interpolationspolynoms an einer Stelle $\alpha \in \mathbb{C}$ mit dem modifizierten Hornerschema benötigt lediglich $2n$ Additionen und n Multiplikationen. Mit Blick auf den Rechenaufwand ist daher dieses Vorgehen dem Verfahren von Aitken und Neville vorzuziehen, wenn das Interpolationspolynom an mehreren Stellen auszuwerten ist.

4.5 Der Interpolationsfehler

Auch wenn eine Funktion f und ihr Interpolationspolynom p in den Stützstellen übereinstimmen, weichen i. Allg. $f(x)$ und $p(x)$ voneinander ab, wenn x keine Interpolationsstelle ist. Der Frage nach der Größe des **Interpolationsfehlers** kommt daher zentrale Bedeutung zu. Ihr wollen wir uns jetzt zuwenden. Wir beschränken uns im Folgenden auf stetige reelle Funktionen über einem Intervall $[a, b]$, d. h. Funktionen aus dem Raum $C[a, b]$. Diesen versehen wir mit der Maximumnorm

$$\|v\|_{[a,b]} := \max_{x\in[a,b]} |v(x)|\,, \qquad v \in C[a, b].$$

Satz 4.5.1: Interpolationsfehler

Sei $f \in C^{n+1}[a, b]$ und $p_n \in \Pi_n$ das Interpolationspolynom von f zu einem System $\Delta = \{x_i\}_{i=0}^n \subset [a, b]$ paarweise verschiedener Stützstellen. Dann existiert zu jedem $x \in [a, b]$ ein $\xi = \xi(x) \in (a, b)$ mit

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n + 1)!}\omega_{n+1}(x),$$

mit dem **Knotenpolynom** $\omega_{n+1}(x) := (x - x_0)(x - x_1)\cdots(x - x_n)$.

Beweis. Die Aussage ist offensichtlich für $x \in \Delta$ wahr, da sowohl $f - p_n$ als auch ω_{n+1} in den Stützstellen verschwinden. Sei also $x \in [a, b] \setminus \Delta$ beliebig, aber fest. Setze

$$K := \frac{f(x) - p_n(x)}{\omega_{n+1}(x)}, \tag{4.10}$$

K ist wohldefiniert, da $\omega_{n+1}(x) \neq 0$. Um eine explizite Darstellung für K herzuleiten, führen wir die Hilfsfunktion

$$\varphi : [a, b] \to \mathbb{R} : t \mapsto \varphi(t) = f(t) - p_n(t) - K\omega_{n+1}(t) \tag{4.11}$$

ein. Sie besitzt $(n + 2)$ verschiedene Nullstellen $a \leq \eta_{0,0} < \eta_{0,1} < \cdots < \eta_{0,n+1} \leq b$, nämlich die Interpolationsstellen $x_0, \ldots, x_n$ sowie die Stelle $t = x$, letztere wegen (4.10).

Mit dem Satz von Rolle[6] folgt, dass die Ableitung φ' in jedem Intervall $(\eta_{0,i}, \eta_{0,i+1})$ eine Nullstelle besitzt. Das heißt, φ' besitzt $n + 1$ Nullstellen $a < \eta_{1,0} < \eta_{1,1} < \cdots < \eta_{1,n} < b$.

Wir wiederholen die Argumentation induktiv. Es folgt: Die k-te Ableitung $\varphi^{(k)}$ von φ besitzt $(n + 2 - k)$ Nullstellen $a < \eta_{k,0} < \eta_{k,1} < \cdots < \eta_{k,n+1-k} < b$. Insbesondere existiert eine Nullstelle $\eta_{n+1,0} =: \xi \in (a, b)$ der $(n + 1)$-ten Ableitung von φ. Durch $(n + 1)$-malige Differentiation erhalten wir aus (4.11)

$$0 = \varphi^{(n+1)}(\xi) = f^{(n+1)}(\xi) - \underbrace{p_n^{(n+1)}(\xi)}_{=0,\ \text{da } p_n\in\Pi_n} - K\,\underbrace{\omega_{n+1}^{(n+1)}(\xi)}_{=(n+1)!} \quad\Longrightarrow\quad K = \frac{f^{(n+1)}(\xi)}{(n + 1)!}.$$

Die Aussage des Satzes folgt unmittelbar. □

[6] Michel Rolle, *21.4.1652 (Ambert, Basse-Auvergne, Frankreich), †8.11.1719 (Paris, Frankreich)

Beispiel 4.5.2. Wir untersuchen den Interpolationsfehler r_n, der bei der Interpolation der Exponentialfunktion mit einem Polynom $p_n \in \Pi_n$ auftritt:

$$r_n(x) := \exp(x) - p_n(x) = \frac{\exp(\xi)}{(n+1)!}\,\omega_{n+1}(x). \tag{4.12}$$

Liegen sowohl die Stützstellen $x_0 < x_1 < \cdots < x_n$ als auch x im Intervall $[0,1]$, dann auch $\xi = \xi(x)$. Somit gilt $1 \le \exp(\xi) \le \mathrm{e}$. Außerdem kann ω_{n+1} abgeschätzt werden gemäß

$$|\omega_{n+1}(x)| = \prod_{k=0}^{n} |x - x_k| \le 1.$$

Es folgt

$$\left\|\exp - p_n\right\|_{[0,1]} \le \frac{\mathrm{e}}{(n+1)!}.$$

Der Interpolationsfehler wird für wachsendes n schnell klein:

$$\begin{aligned} \|r_0\|_{[0,1]} &\le 2.72, \\ \|r_5\|_{[0,1]} &\le 3.78 \cdot 10^{-3}, \\ \|r_{10}\|_{[0,1]} &\le 6.81 \cdot 10^{-8}, \\ \|r_{20}\|_{[0,1]} &\le 5.33 \cdot 10^{-20}. \end{aligned} \tag{4.13}$$

Die Fehlerfunktion r_n hat einen typisch oszillierenden Verlauf, siehe Abbildung 4.3. Sie wechselt an jeder Stützstelle das Vorzeichen. Dass dies die einzigen Vorzeichenwechsel sind, liegt daran, dass der Exponentialfaktor in der Fehlerdarstellung (4.12) positiv ist.

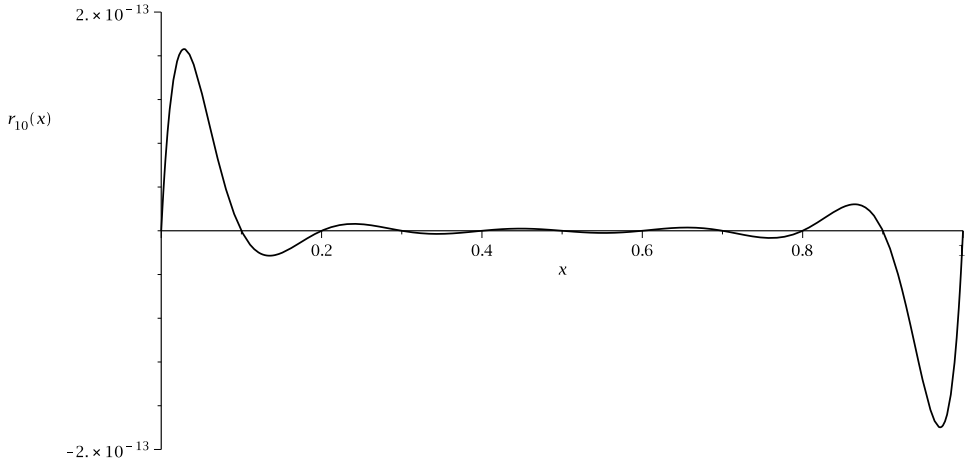


Abbildung 4.3: Fehlerfunktion $r_{10} = \exp - p_{10}$ bei 11 gleichabständigen Stützstellen

Abbildung 4.3 entnehmen wir, dass der Fehler r_{10} bei gleichabständigen Stützstellen etwa $2 \cdot 10^{-13}$ ist. Im Vergleich dazu ist die Abschätzung (4.13) sehr pessimistisch. Das liegt daran, dass bei der Herleitung von (4.13) die spezielle Lage der Stützstellen nicht berücksichtigt wurde. So könnte man die Ungleichung

$$\left|\left(x - \frac{k}{n}\right)\left(x - \frac{n-k}{n}\right)\right| \le \frac{1}{4}, \quad x \in [0,1], \quad 0 \le k \le n,$$

benutzen, um eine schärfere Abschätzung des Fehlers anzugeben. ♠

Satz 4.5.3

Sei $f \in C^n[a,b]$. Die Stellen $x_0, \ldots, x_n \in [a,b]$ seien paarweise verschieden. Dann existiert ein ξ, $\min\{x_0, \ldots, x_n\} < \xi < \max\{x_0, \ldots, x_n\}$, mit

$$f[x_0, \ldots, x_n] = \frac{f^{(n)}(\xi)}{n!}.$$

Beweis. Seien $p_i \in \Pi_i$, $i \in \{n-1, n\}$ jene Polynome, die f in den Stellen $x_0, \ldots, x_i$ interpolieren. Einerseits impliziert Satz 4.3.6, dass

$$p_n(x_n) - p_{n-1}(x_n) = f[x_0, \ldots, x_n](x_n - x_0)(x_n - x_1)\cdots(x_n - x_{n-1}). \tag{4.14}$$

Andererseits existiert wegen Satz 4.5.1 ein ξ, $\min\{x_0, \ldots, x_n\} < \xi < \max\{x_0, \ldots, x_n\}$, mit

$$p_n(x_n) - p_{n-1}(x_n) = f(x_n) - p_{n-1}(x_n) = \frac{f^{(n)}(\xi)}{n!}(x_n - x_0)(x_n - x_1)\cdots(x_n - x_{n-1}).$$

Vergleich mit (4.14) liefert unmittelbar die Behauptung des Satzes. □

Folgerung 4.5.4. *Durch simultanen Grenzübergang in den Argumenten $x_1, \ldots, x_n$ gegen x_0 folgt*

$$\lim_{x_1 \to x_0} \cdots \lim_{x_n \to x_0} f[x_0, x_1, \ldots, x_n] = \frac{f^{(n)}(x_0)}{n!}.$$

Wir definieren daher

$$f[\underbrace{x_0, x_0, \ldots, x_0}_{(n+1)\text{-mal}}] := \frac{f^{(n)}(x_0)}{n!}. \tag{4.15}$$

4.6 Hermite-Interpolation

Bei der Hermite-Interpolation werden neben Funktionswerten auch Ableitungen zur Festlegung des Interpolationspolynoms vorgegeben. An dieser Stelle wollen wir nicht sonderlich tief in die Materie einsteigen. Als wichtig wird sich allerdings Satz 4.6.1 im Zusammenhang mit der Analyse des Fehlers von Quadraturformeln im Kapitel 5 herausstellen.

Aufgabenstellung: Hermite-Interpolation (Π_H-IP)

Gegeben sei ein System $\Delta := \{x_i\}_{i=0}^n \subset [a,b]$ paarweise verschiedener Stützstellen, maximale Ableitungsordnungen $r_i \in \mathbb{N}_0$, $i = 0,\dots,n$, und zugehörige Stützwerte $y_{k,i} \in \mathbb{C}$, $k = 0,\dots,r_i$, $i = 0,\dots,n$.

Gesucht ist ein Polynom $p_{n^*} \in \Pi_{n^*}$, $n^* := n + r_0 + \cdots + r_n$, das den $n^* + 1$ Interpolationsbedingungen

$$p_{n^*}^{(k)}(x_i) = y_{k,i}, \quad k = 0,\dots,r_i, \quad i = 0,\dots,n,$$

genügt.

Diese Aufgabe besitzt eine eindeutige Lösung und in Analogie zu Satz 4.5.1 gilt folgende Abschätzung für den Interpolationsfehler.

Satz 4.6.1

Sei $f \in C^{n^*+1}[a,b]$ und $p_{n^*} \in \Pi_{n^*}$ das Interpolationspolynom entsprechend (Π_H-IP) mit $y_{k,i} = f^{(k)}(x_i)$ für $k = 0,\dots,r_i$, $i = 0,\dots,n$. Dann existiert für beliebiges $x \in [a,b]$ ein $\xi = \xi(x) \in (a,b)$ mit

$$f(x) - p_{n^*}(x) = \frac{f^{(n^*+1)}(\xi)}{(n^*+1)!} \prod_{i=0}^{n} (x - x_i)^{1+r_i}.$$

Algorithmische Aspekte wollen wir nur an einem Beispiel diskutieren. Dies betrifft insbesondere die Verallgemeinerung des Steigungsschemas und der dividierten Differenzen (vgl. Def. 4.3.4 und Satz 4.3.7) für mehrfach auftretende Stützstellen. Auftretende dividierte Differenzen der Form $y[x_i,\dots,x_i]$ werden gemäß Folg. 4.5.4 durch die vorgegebenen Ableitungswerte ersetzt:

$$y[\underbrace{x_i,\dots,x_i}_{(\nu+1)\text{-mal}}] := \frac{y_{\nu,i}}{\nu!}. \tag{4.16}$$

Beispiel 4.6.2. Wir betrachten die Aufgabenstellung (Π_H-IP) für $x_0 \neq x_1$, $r_0 = 2$ und $r_1 = 1$. D. h., in x_0 werden der Funktionswert sowie die erste und zweite Ableitung vorgegeben, in x_1 hingegen nur der Funktionswert und die erste Ableitung.

Für das Interpolationspolynom $p_4 \in \Pi_4$ setzen wir in modifizierter Newtonscher Form an:

$$p_4(x) = c_0 + c_1\,(x - x_0) + c_2\,(x - x_0)^2 + c_3\,(x - x_0)^3 + c_4\,(x - x_0)^3\,(x - x_1)\ ,$$

dabei findet jeweils die in den Stützstellen vorgegebene höchste Ableitungsordnung Berücksichtigung.

Für die Ableitungen von p_4 gilt

$$p_4'(x) = c_1 + 2c_2\,(x - x_0) + 3c_3\,(x - x_0)^2 + c_4\left(3\,(x - x_0)^2\,(x - x_1) + (x - x_0)^3\right)$$

bzw.

$$p_4''(x) = 2c_2 + 6c_3\,(x - x_0) + 6c_4\left((x - x_0)\,(x - x_1) + (x - x_0)^2\right).$$

Wir arbeiten die Interpolationsbedingungen ein. In x_0 sind $p_4(x_0) = y_{0,0}$, $p_4'(x_0) = y_{1,0}$ und $p_4''(x_0) = y_{2,0}$ vorgegeben. Unter Berücksichtigung von (4.16) erhalten wir

$$p_4(x_0) = c_0 = y_{0,0} = y[x_0]\,, \qquad p_4'(x_0) = c_1 = y_{1,0} = y[x_0, x_0]$$

sowie

$$p_4''(x_0) = 2c_2 = y_{2,0} = 2y[x_0, x_0, x_0]\,,$$

Die Vorgabe des Funktionswertes $y_{0,1}$ in x_1 impliziert

$$p_4(x_1) = c_0 + c_1\,(x_1 - x_0) + c_2\,(x_1 - x_0)^2 + c_3\,(x_1 - x_0)^3 = y_{0,1} = y[x_1]\,.$$

Wir ersetzen c_0, c_1 und c_2, die wir bereits bestimmt haben:

$$c_1 + c_2\,(x_1 - x_0) + c_3\,(x_1 - x_0)^2 = \frac{y[x_1] - y[x_0]}{x_1 - x_0} = y[x_0, x_1]\,, \tag{4.17a}$$

$$c_2 + c_3\,(x_1 - x_0) = \frac{y[x_0, x_1] - y[x_0, x_0]}{x_1 - x_0} =: y[x_0, x_0, x_1]\,, \tag{4.17b}$$

$$c_3 = \frac{y[x_0, x_0, x_1] - y[x_0, x_0, x_0]}{x_1 - x_0} =: y[x_0, x_0, x_0, x_1]\,. \tag{4.17c}$$

Abschließend arbeiten wir die vorgegebene Ableitung an der Stelle x_1 ein:

$$p_4'(x_1) = c_1 + 2c_2\,(x_1 - x_0) + 3c_3\,(x_1 - x_0)^2 + c_4\,(x_1 - x_0)^3 = y_{1,1} = y[x_1, x_1]$$

(4.17a) $\Longrightarrow$

$$c_2 + 2c_3\,(x_1 - x_0) + c_4\,(x_1 - x_0)^2 = \frac{y[x_1, x_1] - y[x_0, x_1]}{x_1 - x_0} =: y[x_0, x_1, x_1]$$

(4.17b) $\Longrightarrow$

$$c_3 + c_4\,(x_1 - x_0) = \frac{y[x_0, x_1, x_1] - y[x_0, x_0, x_1]}{x_1 - x_0} =: y[x_0, x_0, x_1, x_1]$$

(4.17c) $\Longrightarrow$

$$c_4 = \frac{y[x_0, x_0, x_1, x_1] - y[x_0, x_0, x_0, x_1]}{x_1 - x_0} =: y[x_0, x_0, x_0, x_1, x_1]$$

Zusammenfassend erhalten wir für das Interpolationspolynom p_4 die Darstellung

$$p(x) = y[x_0] + y[x_0, x_0]\,(x - x_0) + y[x_0, x_0, x_0]\,(x - x_0)^2 \\ + y[x_0, x_0, x_0, x_1]\,(x - x_0)^3 + y[x_0, x_0, x_0, x_1, x_1]\,(x - x_0)^3\,(x - x_1)\ .$$

♠

Die Rechnung im Steigungsschema lässt sich weiter formalisieren, worauf wir an dieser Stelle aber nicht im Detail eingehen wollen. Für Bsp. 4.6.2 sieht die Rechnung im Steigungsschema wie folgt aus:

$$\begin{array}{c|cccccc}
x_0 & y_{0,0} = y[x_0] & & & & & \\
x_0 & y_{0,0} = y[x_0] & y[x_0, x_0] = y_{1,0} & & & & \\
x_0 & y_{0,0} = y[x_0] & y[x_0, x_0] = y_{1,0} & y[x_0, x_0, x_0] = \tfrac{1}{2} y_{2,0} & & & \\
x_1 & y_{0,1} = y[x_1] & \searrow\!\!\rightarrow\ y[x_0, x_1] & \searrow\!\!\rightarrow\ y[x_0, x_0, x_1] & \ldots & & \\
x_1 & y_{0,1} = y[x_1] & y[x_1, x_1] = y_{1,1} & \searrow\!\!\rightarrow\ y[x_0, x_1, x_1] & \ldots & \searrow\!\!\rightarrow\ & y[x_0, x_0, x_0, x_1, x_1]
\end{array}$$

Aufgabe 4.6.3. Bestimmen Sie die Newtonsche Form des Polynoms $p_4 \in \Pi_4$ mit

$$p_4(-1) = 1, \quad p_4(0) = p_4'(0) = -1, \quad p_4''(0) = -2, \quad p_4(2) = 1,$$

und berechnen Sie $p_4(1)$ mit dem modifizierten Horner-Schema. ♢

4.7 Rundungsfehlereinfluss

Zum eigentlichen Interpolationsfehler, den wir im vorigen Abschnitt untersucht haben, gesellen sich Fehler, die aus gestörten Daten resultieren, z. B. Stützwerte y_k, die mit Messfehlern behaftet sind oder aus einer Rechnung mit Maschinenzahlen stammen, und damit mit Rundungsfehlern behaftet sind. Ihren Einfluss wollen wir jetzt analysieren.

Seien $\Delta := \{x_k\}_{k=0}^n \subset [a,b]$ ein System paarweise verschiedener Stützstellen, y_k, $k = 0,\dots,n$, die zugehörigen exakten Stützwerte sowie $\tilde{y}_k$, $k = 0,\dots,n$, die gestörten. Für die Fehler gelte

$$\tilde{y}_k = y_k + \delta_k, \quad |\delta_k| \le \delta, \quad k = 0,\dots,n.$$

Die Interpolationspolynome vom Höchstgrad n zu den (x_k, y_k) und $(x_k, \tilde{y}_k)$ bezeichen wir mit p_n bzw. mit $\tilde{p}_n$. Mit Hilfe der Lagrangeschen Basispolynome L_k kann die Differenz $\tilde{p}_n - p_n$ wie folgt dargestellt werden:

$$\tilde{p}_n - p_n = \sum_{k=0}^n (\tilde{y}_k - y_k)\, L_k = \sum_{k=0}^n \delta_k L_k.$$

Ausgehend von dieser Darstellung können wir wie folgt abschätzen

$$\left|(\tilde{p}_n - p_n)(x)\right| = \left|\sum_{k=0}^n \delta_k L_k(x)\right| \le \sum_{k=0}^n |\delta_k|\, |L_k(x)| \le \sum_{k=0}^n \delta\, |L_k(x)| = \delta \sum_{k=0}^n |L_k(x)| =: \delta\lambda_\Delta(x). \quad (4.18)$$

Nach Übergang zum Maximum über $x \in [a,b]$ erhalten wir

$$\|\tilde{p}_n - p_n\|_{[a,b]} \le \delta\, \|\lambda_\Delta\|_{[a,b]} =: \delta\Lambda_\Delta.$$

Sowohl λ_Δ als auch Λ_Δ sind nur von der Lage der Stützstellen abhängig. Die Fehlerschranken $\delta\lambda_\Delta$ bzw. $\delta\Lambda_\Delta$ sind somit aufgespalten in eine nur von den Daten abhängige Fehlerkomponente δ und einen nur von der Lage der Interpolationsstellen abhängigen Teil λ_Δ bzw. Λ_Δ. Letztere stellen Schranken für die Fehlerverstärkung dar.

Definition 4.7.1: Lebesgue-Konstante

Seien $\Delta := \{x_k\}_{k=0}^n \subset [a,b]$ ein System paarweise verschiedener Stützstellen und L_k, $k = 0,\dots,n$, die zugehörigen Lagrangeschen Basispolynome. Die Funktion

$$\lambda_\Delta : x \mapsto \lambda_\Delta(x) := \sum_{k=0}^n |L_k(x)|$$

wird als **Lebesgue[7]-Funktion** bezeichnet und $\Lambda_\Delta := \|\lambda_\Delta\|_{[a,b]}$ als **Lebesgue-Konstante**.

[7]Henri Léon Lebesgue, *28.6.1875 (Beauvais, Oise, Picardie, Frankreich), †26.7.1941 (Paris, Frankreich)

In der Abbildung 4.4 sind für äquidistante Stützstellen

$$x_k = -1 + \frac{2k}{n}, \quad k = 0, 1, \ldots, n,$$

die LEBESGUE-Funktionen dargestellt. Tabelle 4.1 enthält die zugehörigen LEBESGUE-Konstanten über dem Intervall $[-1, 1]$. Wir beobachten, dass sie sehr schnell mit dem Polynomgrad wachsen.

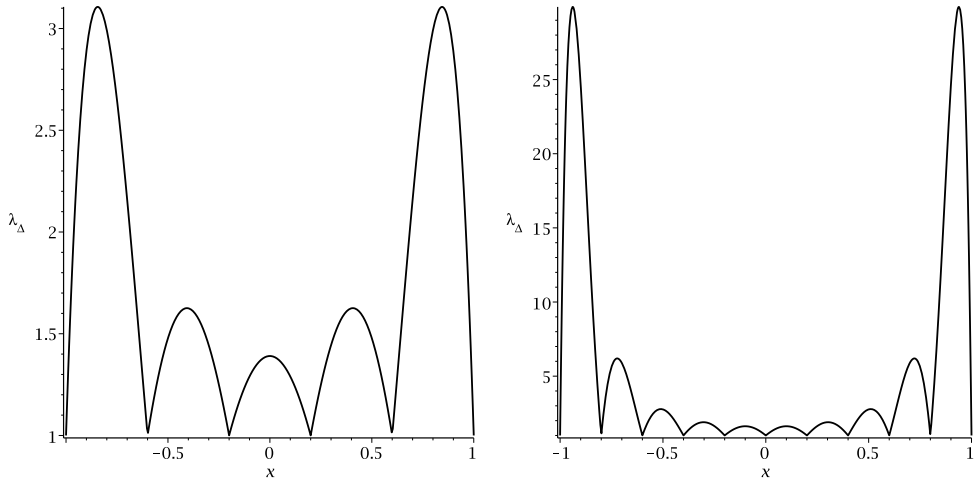


Abbildung 4.4: LEBESGUE-Funktion zu gleichabständigen Stützstellen; links: $n = 5$, rechts: $n = 10$

n	Λ_Δ	n	Λ_Δ
1	1.000	10	$2.990 \cdot 10^1$
2	1.250	15	$5.124 \cdot 10^2$
3	1.631	20	$1.099 \cdot 10^4$
4	2.208	25	$2.613 \cdot 10^5$
5	3.106	30	$6.601 \cdot 10^6$

Tabelle 4.1: Die LEBESGUE-Konstante bei äquidistanten Stützstellen

Unsere Überlegungen bei der Herleitung von (4.18) können wir geringfügig modifizieren, um den folgenden Satz zu beweisen.

Satz 4.7.2

Sei $\Delta := \{x_k\}_{k=0}^n \subset [a, b]$ ein System paarweise verschiedener Stützstellen. Dann gelten für alle Polynome $q \in \Pi_n$ die Abschätzungen

$$|q(x)| \le \lambda_\Delta(x) \max_{k=0,\ldots,n} |q(x_k)| \le \Lambda_\Delta \max_{k=0,\ldots,n} |q(x_k)|, \quad \forall\, x \in [a, b].$$

4.8 Das Runge-Phänomen

Die Vermutung liegt nahe, dass sich die Approximationsgüte des Interpolationspolynoms verbessert, wenn mehr Stützstellen verwendet werden. Dass dem nicht so sein muss, zeigt das folgende instruktive Beispiel von Runge[8]: Betrachte die Funktion

$$f_R\colon [-1,1] \to \mathbb{R} : t \mapsto f_R(t) = \frac{1}{1+25t^2}$$

und Systeme gleichabständiger Stützstellen $-1 + 2k/n$, $k = 0, \ldots, n$. Abbildung 4.5 zeigt die Funktion f_R und ihre Interpolierende für $n = 4, 8, 16$ und 32. Wir beobachten, dass auf dem Intervall $[-1/2, 1/2]$ die Folge der Interpolierenden mit zunehmender Stützstellenzahl gegen f_R zu konvergieren scheint, auf dem gesamten Intervall $[-1, 1]$ aber nicht. In der Nähe der Endpunkte scheint die Folge sogar zu divergieren.

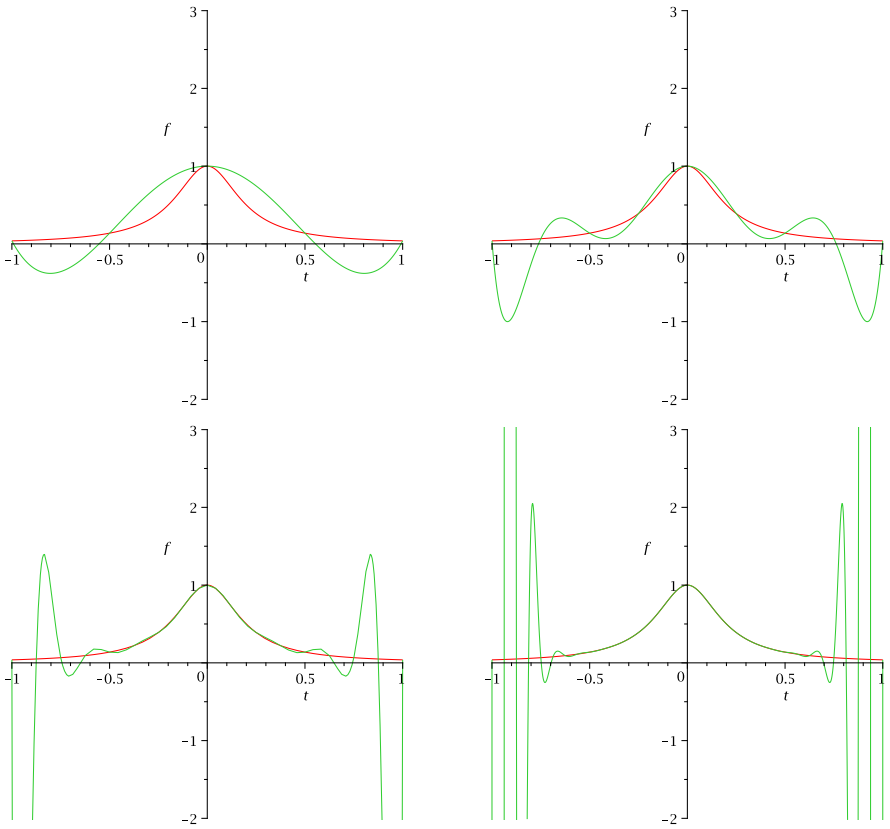


Abbildung 4.5: Die Runge-Funktion und ihre Interpolierenden bei Verwendung gleichabständiger Stützstellen; $n = 4, 8, 16$ und 32

Wir beschließen diesen Abschnitt mit zwei auf den ersten Blick negativen Aussagen zur Polynominterpolation. Dazu definieren wir für beliebige Stützstellensysteme $\Delta = \{x_k\}_{k=0}^n \in [a, b]$ den sogenannten **Interpolationsoperator**

$$I_\Delta\colon C[a,b] \to \Pi_n\colon f \mapsto I_\Delta f := p_n\,,$$

[8]Carl David Tolmé Runge, *30.8.1856 (Bremen), †3.1.1927 (Göttingen)

der jeder stetigen Funktion f das durch $p_n(x_k) = f(x_k)$, $k = 0, \ldots, n$, eindeutig bestimmte Interpolationspolynom vom Höchstgrad n zuordnet.

Sei also $\{\Delta_n\}_{n=0}^{\infty}$ eine beliebige Folge von Stützstellensystemen $\Delta_n = \{x_{n,k}\}_{k=0}^{n} \subset [a, b]$. Dann existiert ein $f \in C[a, b]$ mit:

- $\left\| I_{\Delta_n} f - f \right\|_{[a,b]} \not\to 0$ für $n \to \infty$ (Faber[9] 1914);
- Die Folge $\{I_{\Delta_n} f\}_{n=1}^{\infty}$ divergiert fast überall auf $[a, b]$ (Erdős[10] und Vértesi[11] 1980).

Erfreulicherweise greifen diese negativen Aussagen zur Polynominterpolation nicht, wenn die zu interpolierende Funktion f nicht nur stetig, sondern geringfügig „glatter“ ist, z. B. stetig und stückweise stetig differenzierbar.

[9] Georg Faber, *5.4.1877 (Kaiserslautern), †7.3.1966 (München)
[10] Pál Erdős, *26.3.1913 (Budapest, Ungarn), †20.9.1996 (Warschau, Polen)
[11] Péter Vértesi, *12.7.1941 (Ungarn)

4.9 Optimierung der Stützstellen

In Anbetracht manch ernüchternder Aussage des vorangegangenen Abschnitts drängt sich natürlich die Frage auf, ob und wie in günstigen Situationen der Interpolationsfehler signifikant reduziert werden kann.

Ist $f \in C^{n+1}[a,b]$, dann ergibt sich aus Satz 4.5.1 für den Interpolationsfehler

$$\|f - p_n\|_{[a,b]} \leq \frac{\left\|f^{(n+1)}\right\|_{[a,b]}}{(n+1)!} \|\omega_{n+1}\|_{[a,b]}$$

mit dem Knotenpolynom

$$\omega_{n+1}(x) := (x - x_0)(x - x_1) \cdots (x - x_n).$$

Da die Funktion f vorgegeben ist, ist $\left\|f^{(n+1)}\right\|_{[a,b]}$ nicht zu beeinflussen. Wir können allerdings die Stützstellen x_i so wählen, dass die Norm des Knotenpolynoms, also $\|\omega_{n+1}\|_{[a,b]}$, minimal wird.

Einfachheitshalber beschränken wir uns auf $\{x_k\}_{k=0}^n \subset [-1,1]$. Mittels einer affinen Transformation lassen sich die Ergebnisse auf beliebige Intervalle $[a,b]$ übertragen. Schlüssel zur Minimierung von ω_{n+1} ist T_{n+1}, das Tschebyscheff-Polynom erster Art vom Grad $n+1$, das im Abschnitt 3.3 eingeführt wurde.

Satz 4.9.1

Für jedes Polynom q mit Grad $n+1$ und Höchstkoeffizient 1 gilt

$$\|q\|_{[-1,1]} \geq 2^{-n} \|T_{n+1}\|_{[-1,1]} = 2^{-n}.$$

Beweis. Der Beweis erfolgt indirekt. Wir nehmen an, es existiert ein Polynom q vom Grad $n+1$ mit Höchstkoeffizient 1 und $\|q\|_{[-1,1]} < 2^{-n}$.

Laut Satz 3.3.5 besitzt T_{n+1} im Intervall $[-1,1]$ die Extremalpunkte

$$s_k = \cos \frac{k\pi}{n+1}, \quad k = 0, \ldots, n+1, \quad \text{mit} \quad T_{n+1}(s_k) = (-1)^k, \tag{4.19}$$

also $\|T_{n+1}\|_{[-1,1]} = 1$.

Betrachte die Differenz $\varphi := T_{n+1} - 2^n q$. Wegen $2^n \|q\|_{[-1,1]} < 1$ folgt aus (4.19)

$$\begin{aligned} \varphi(s_k) &> 0 \quad \text{für gerades } k \text{ sowie} \\ \varphi(s_k) &< 0 \quad \text{für ungerades } k, \quad k = 0, \ldots, n+1. \end{aligned}$$

Das heißt, φ wechselt $(n+1)$mal das Vorzeichen in $[-1,1]$, und besitzt somit $n+1$ Nullstellen. Andererseits ist $\varphi \in \Pi_n$, da $2^n q$ und T_{n+1} Polynome vom Grad $n+1$ mit gleichen Höchstkoeffizienten, nämlich 2^n, sind. Dies ist ein Widerspruch zum Fundamentalsatz der Algebra, Satz 3.2.5. □

Folgerung 4.9.2. *Für jedes Stützstellensystem* $\{x_k\}_{k=0}^n \subset [-1,1]$, $n \in \mathbb{N}$, *ist*

$$\max_{t\in[-1,1]} \left|(t-x_0)(t-x_1)\cdots(t-x_n)\right| \geq \max_{t\in[-1,1]} \left|(t-x_{n,0}^*)(t-x_{n,1}^*)\cdots(t-x_{n,n}^*)\right| = 2^{-n}.$$

Dabei sind

$$x_{n,k}^* := \cos\frac{(2k+1)\pi}{2(n+1)}, \quad k = 0,\ldots,n,$$

die Nullstellen des Tschebyscheff*-Polynoms* T_{n+1}. *Dessen Nullstellen sind somit die optimalen Stützstellen für die Interpolation in* $[-1,1]$ *mit Polynomen aus* Π_n. *Dieses System von Stützstellen bezeichnen wir kurz mit* $\Delta_n^T := \{x_{n,k}^*\}_{k=0}^n$, $n \in \mathbb{N}$.

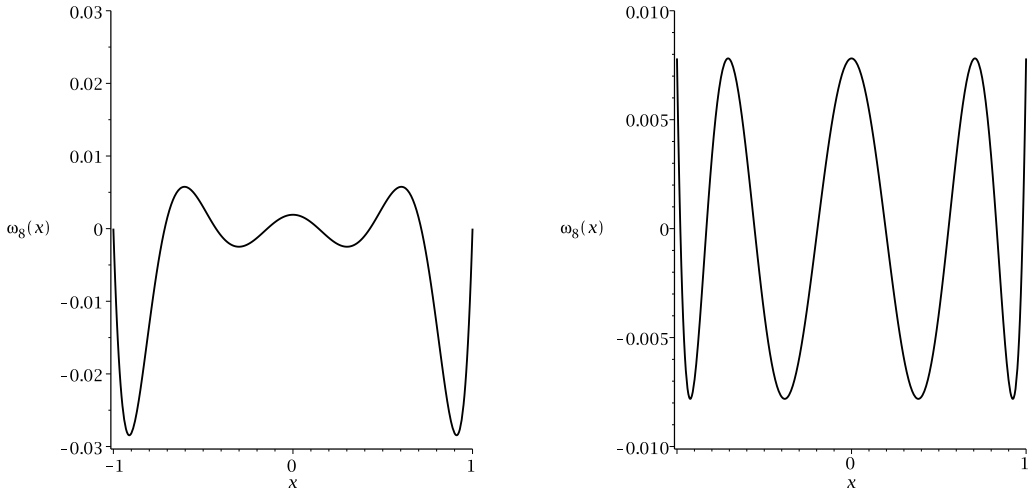


Abbildung 4.6: Das Knotenpolynom ω_{n+1} bei gleichabständigen Stützstellen (links) und Tschebyscheff-Stützstellen (rechts), $n = 7$. Beachten Sie die unterschiedlichen Skalierungen!

Abbildung 4.6 zeigt zum Vergleich graphische Darstellungen des Knotenpolynoms für gleichabständige und Tschebyscheff-Stützstellen. Zu erkennen ist, dass bei gleichabständigen Stützstellen die Norm des Knotenpolynoms größer als bei Tschebyscheff-Stützstellen ist. Der Unterschied wird mit zunehmender Zahl der Stützstellen größer.

Bemerkung 4.9.3. *(i)* Für $f \in C^{n+1}[-1,1]$ erhalten wir aus dem Satz 4.5.1 und der Folg. 4.9.2 für den Interpolationsfehler bei der Tschebyscheff-Interpolation die Abschätzung

$$\left\|f - I_{\Delta_n^T} f\right\|_{[-1,1]} \leq \frac{\left\|f^{(n+1)}\right\|_{[-1,1]}}{2^n(n+1)!}.$$

Darüber hinaus kann gezeigt werden, dass gilt

$$\left\|f - I_{\Delta_n^T} f\right\|_{[-1,1]} \leq \|f-q\|_{[-1,1]} \quad \text{für alle } \ q \in \Pi_n,$$

d. h. die Tschebyscheff-Interpolierende ist – gemessen in der Maximumnorm $\|\cdot\|_{[-1,1]}$ – die bestmögliche Approximation von f durch Polynome in Π_n.

(ii) Ist $f \in C[a,b]$ stückweise stetig differenzierbar, dann gilt für den Interpolationsfehler

$$\left\| f - I_{\Delta_n^T} f \right\|_{[a,b]} \leq C \frac{\ln(n+1)}{n}, \quad n \in \mathbb{N},$$

mit einer lediglich von f abhängigen Konstanten C. Somit konvergiert die Folge der Tscheby-scheff-Interpolierenden für $n \to \infty$ gleichmäßig gegen f.

Wir kommen zurück zur Runge-Funktion $f_R : t \mapsto 1/(1+25t^2)$, und vergleichen die Qualität der Interpolation bei Verwendung von Tschebyscheff-Stützstellen mit den Ergebnissen aus Abschnitt 4.8, wo gleichabständige Stützstellen verwendet wurden. Ein Vergleich von Abbildung 4.5 mit Abbildung 4.7 zeigt eine signifikante Verbesserung der Approximationsqualität bei Verwendung Tschebyscheffscher Stützstellen. Für $n = 32$ ist optisch kein Unterschied zwischen f_R und der Interpolierenden zu erkennen, was durch die schnelle Konvergenz der Folge der Interpolierenden gegen f_R bedingt ist.

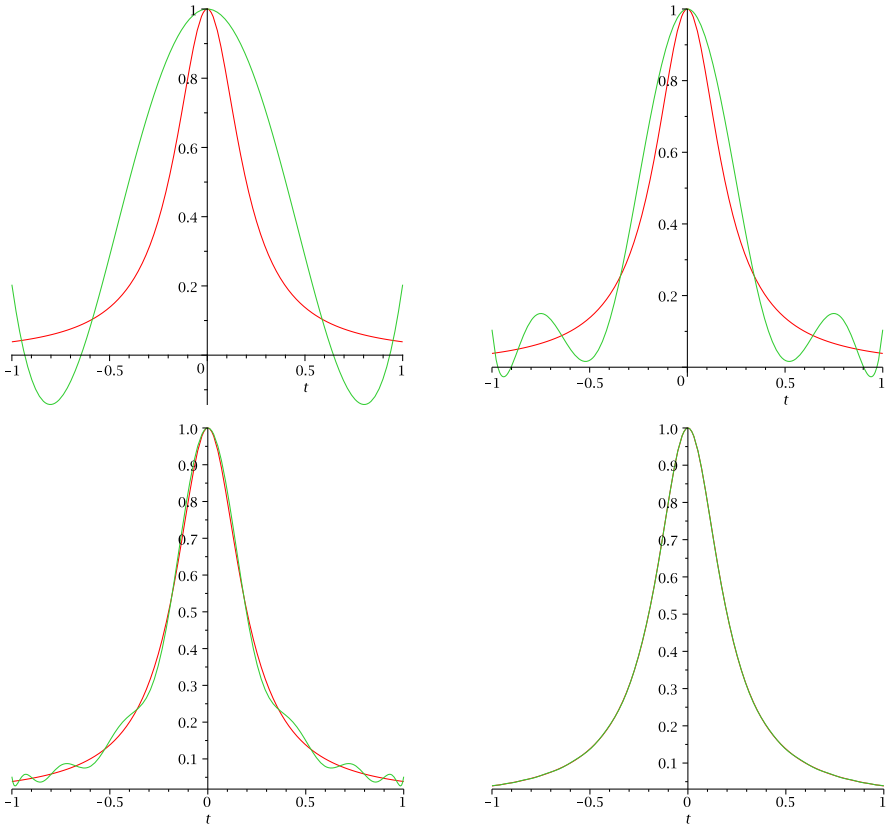


Abbildung 4.7: Die Runge-Funktion und ihre Interpolierenden bei Verwendung von $n+1$ Tschebyscheff-Stützstellen; $n = 4, 8, 16$ und 32

4.10 Lösungen der Aufgaben

Lösung 4.2.5. Zu zeigen ist

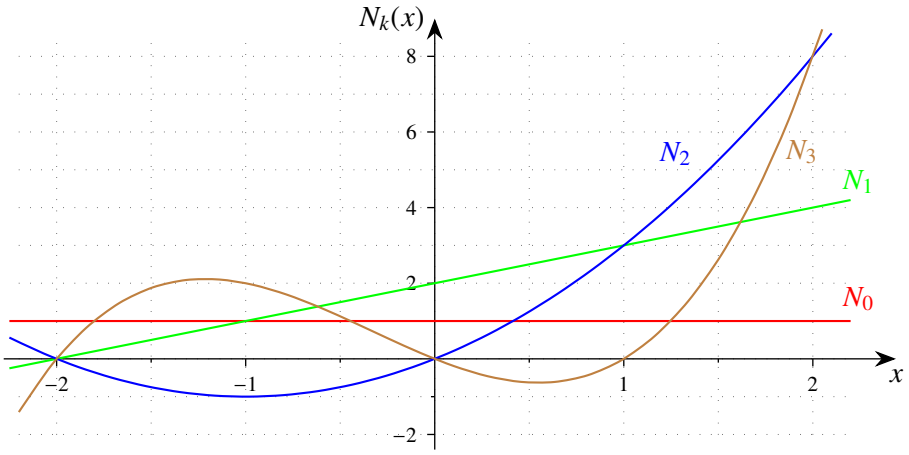
$$q := \sum_{k=0}^{n} L_k = \mu_0.$$

Offensichtlich ist $\mu_0 \in \Pi_n$ und $q \in \Pi_n$, da $L_k \in \Pi_n$, $k = 0, \ldots, n$. Wegen (4.4) gilt

$$q(x_k) = L_k(x_k) = 1 = \mu_0(x_k), \quad k = 0, \ldots, n.$$

Damit stimmen q und μ_0 in $n+1$ Punkten überein. Somit sind sie wegen Satz 3.2.8.(i) identisch. ♣

Lösung 4.3.2.



Die Newtonschen Grundpolynome zu den Stützstellen $x_0 = -2$, $x_1 = 0$, $x_2 = 1$ und $x_3 = 2$ ♣

Lösung 4.3.9. Wir argumentieren induktiv über den Grad j der zu betrachtenden Polynome.

Induktionsanfang, $j = 0$: Sei $k \in \{0, \ldots, n\}$ beliebig. Das Polynom $p \in \Pi_0$, das (x_k, y_k) interpoliert, ist durch $p(x) = y_k$, $x \in \mathbb{C}$, gegeben. Also ist $y[x_k] = y_k$.

Induktionsschritt, $j \geq 1$: Sei $k \in \{0, 1, \ldots, n-j\}$ beliebig. Die Rekursionsvorschrift des Satzes berechnet $y[x_k, \ldots, x_{k+j}]$ aus $y[x_k, \ldots, x_{k+j-1}]$ und $y[x_{k+1}, \ldots, x_{k+j}]$. Sie sind die Koeffizienten von μ_{j-1} in der Monomdarstellung von $q, r \in \Pi_{j-1}$, welche die Wertetabellen (x_ν, y_ν), $\nu = k \ldots, k+j-1$, bzw. (x_ν, y_ν), $\nu = k+1 \ldots, k+j$, interpolieren.

Aus diesen konstruieren wir ein Polynom $p \in \Pi_j$, das die Wertetabelle (x_ν, y_ν), $\nu = k \ldots, k+j$, interpoliert wie folgt:

$$p(x) := q(x)\frac{x_{k+j} - x}{x_{k+j} - x_k} + r(x)\frac{x - x_k}{x_{k+j} - x_k}. \tag{4.20}$$

Wir überprüfen, dass p die Interpolationsbedingungen erfüllt:

$$p(x_k) = q(x_k)\frac{x_{k+j} - x_k}{x_{k+j} - x_k} + r(x_k)\frac{0}{x_{k+j} - x_k} = q(x_k) = y_k\,,$$

für $\nu = 1, \ldots, j-1$ gilt

$$p(x_{k+\nu}) = q(x_{k+\nu})\frac{x_{k+j} - x_{k+\nu}}{x_{k+j} - x_k} + r(x_{k+\nu})\frac{x_{k+\nu} - x_k}{x_{k+j} - x_k} = y_{k+\nu}\frac{x_{k+j} - x_{k+\nu}}{x_{k+j} - x_k} + y_{k+\nu}\frac{x_{k+\nu} - x_k}{x_{k+j} - x_k} = y_{k+\nu}\,.$$

Ferner ist

$$p(x_{k+j}) = q(x_{k+j})\frac{x_{k+j} - x_{k+j}}{x_{k+j} - x_k} + r(x_{k+j})\frac{x_{k+j} - x_k}{x_{k+j} - x_k} = r(x_{k+j}) = y_{k+j}\,.$$

Also interpoliert p die Wertetabelle (x_ν, y_ν), $\nu = k \ldots, k+j$. Gemäß Def. 4.3.4 ist $y[x_k, \ldots, x_{k+j}]$ der Koeffizient von μ_j in der Monomdarstellung von p.

Koeffizientenvergleich für die Koeffizienten von μ_j in (4.20) liefert die behauptete Rekursion

$$y[x_k, \ldots, x_{k+j}] = \frac{y[x_{k+1}, \ldots, x_{k+j}] - y[x_k, \ldots, x_{k+j-1}]}{x_{k+j} - x_k}.$$

♣

Lösung 4.4.2. $m = 0$: Sei $k \in \{0, \ldots, n\}$ beliebig. Offensichtlich ist $p_{0,k} \in \Pi_0$ und $p_{0,k}(x) = y_k$, $x \in \mathbb{C}$.

$m \geq 1$: Sei $k \in \{m, m+1, \ldots, n\}$ beliebig. Da $p_{m-1,k}, p_{m-1,k-1} \in \Pi_{m-1}$ folgt

$$p_{m,k} = \frac{(\mu_1 - x_{k-m})p_{m-1,k} - (\mu_1 - x_k)p_{m-1,k-1}}{x_k - x_{k-m}} \in \Pi_m.$$

In Analogie zur Lösung 4.3.9 verifiziert man, dass

$$p_{m,k}(x_\nu) = y_\nu, \quad \nu = k - m, \ldots, k.$$

♣

Lösung 4.4.8. Wir stellen das modifizierte Horner-Schema zur Berechnung von $p_3(\mathrm{i})$ auf:

x_k		1	0	-2
c_k	1	0	3	-5
$\alpha = \mathrm{i}$	–	$\mathrm{i}-1$	$-1-\mathrm{i}$	5
	1	$\mathrm{i}-1$	$2-\mathrm{i}$	$\boxed{0 = p_3(\mathrm{i})}$

♣

Lösung 4.6.3.

Steigungsschema:

$$\begin{array}{l|l}
x_0 = -1 & y_{0,0} = 1 \\
x_1 = 0 & y_{0,1} = -1 \searrow -2 \\
x_1 = 0 & y_{0,1} = -1 \searrow y_{1,1} = -1 \searrow 1 \\
x_1 = 0 & y_{0,1} = -1 \searrow y_{1,1} = -1 \searrow \tfrac{1}{2}y_{2,1} = -1 \searrow -2 \\
x_2 = 2 & y_{0,2} = 1 \searrow 1 \qquad \searrow 1 \qquad \searrow 1 \qquad \searrow 1
\end{array}$$

Hieraus ergibt sich die Newtonsche Form des Interpolationspolynom:

$$p_4(x) = 1 - 2(x+1) + (x+1)x - 2(x+1)x^2 + (x+1)x^3 \qquad \left[= x^4 - x^3 - x^2 - x - 1 \right]$$

Modifizierte Horner-Schema zur Berechnung von $p_4(1)$:

x_k		0	0	0	-1
c_k	1	-2	1	-2	1
$\alpha = 1$	–	1	-1	0	-4
	1	-1	0	-2	$\boxed{-3 = p_4(1)}$

♣

Kapitel 5

Quadratur

Bei der **Quadratur** – also der **numerischen Integration** – geht es darum, Näherungswerte für bestimmte Integrale zu ermitteln. Diese Integrale können i. Allg. nicht exakt berechnet werden, da für die meisten Funktionen die Stammfunktion nicht explizit angebbar ist. In anderen Fällen ist der Integrand nicht formelmäßig gegeben, sondern lediglich durch ein Computerprogramm, das seinen Wert an jeder beliebigen Stelle berechnen kann. Oder es liegt gar nur eine Wertetabelle für den Integranden vor.

Aufgabenstellung: Quadratur

Gegeben ist eine integrierbare Funktion $f : [a, b] \to \mathbb{R}$, $a, b \in \mathbb{R}$, $a < b$. Gesucht ist der Wert des bestimmten Integrals

$$I_a^b[f] := \int_a^b f(x)\,\mathrm{d}x\,.$$

Die prinzipielle Idee zur Approximation des Intergrals ist dabei, den Integranden durch ein interpolierendes Polynom zu ersetzen und dieses zu integrieren, was ja mit elementaren Mitteln möglich ist. Bei der Analyse der resultierenden Verfahren werden wir auf die Ergebnisse aus Kapitel 4 zur Polynominterpolation zurückgreifen.

5.1 RIEMANN-Summen

Ein einfachstes Näherungsverfahren ergibt sich unmittelbar aus der Definition des Integral als Grenzwert der RIEMANN[1]-Summen. Ist eine Zerlegung

$$\Delta\colon a = x_0 < x_1 < \cdots < x_m = b \tag{5.1}$$

des Intervalls $[a, b]$ gewählt, erhalten wir einen Näherungswert des gesuchten Integrals in Form einer RIEMANNschen Summe

$$\sum_{i=1}^{m} (x_i - x_{i-1}) f(\xi_i), \quad \xi_i \in [x_{i-1}, x_i]\,.$$

Wird die Zerlegung immer weiter verfeinert, d. h. für

$$\max_{i=1,\ldots,m} |x_i - x_{i-1}| \to 0,$$

dann konvergiert die RIEMANN-Summe definitionsgemäß gegen das RIEMANN-Integral $I_a^b[f]$. Für diesen Grenzprozess ist die konkrete Wahl der Zerlegung und der Zwischenpunkte ξ_i ohne Belang. Ein numerisches Verfahren zur Approximation des Integrals muss hingegen explizite Vorschriften zur Wahl der Zerlegung Δ und der Zwischenpunkte ξ_i enthalten.

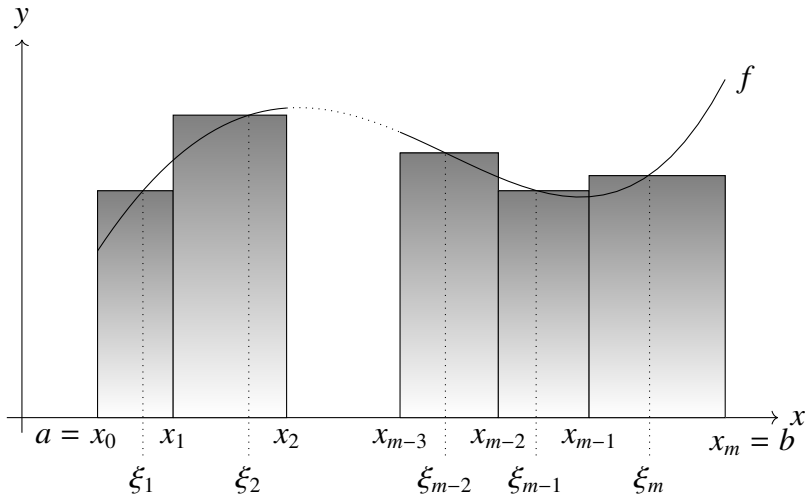


Abbildung 5.1: Riemannsche Summe als numerische Näherung für ein Integral

Beispiel 5.1.1. Zur Illustration wollen wir das Integral

$$I_0^1[\exp] = \int_0^1 \mathrm{e}^x \,\mathrm{d}x = \mathrm{e} - 1 \approx 1.718281828459046$$

numerisch berechnen. Wir haben uns ein Integral gewählt, dessen Wert wir kennen, um den Fehler und die Effizienz unseres Verfahrens beurteilen zu können.

[1] Georg Friedrich Bernhard Riemann, *17.9.1826 (Breselenz, Kgr. Hannover) †20.07.1866 (Selasca, Italien)

Wir zerlegen das Interval $[0,1]$ gleichabständig in m Teilintervalle $[x_{i-1}, x_i]$, $i = 1, \ldots, m$, der Länge $h = x_i - x_{i-1} = 1/m$, $i = 1, \ldots, m$. Als Zwischenstellen zur Funktionsauswertung wählen wir die linken Intervallenden, d. h. $\xi_i = x_{i-1} \in [x_{i-1}, x_i]$. Wir erhalten so die Näherung

$$I_0^1[\exp] \approx \sum_{i=1}^{m} \mathrm{e}^{x_{i-1}}(x_i - x_{i-1}) = h \sum_{i=1}^{m} \mathrm{e}^{x_{i-1}} =: L_{0,m}^1[\exp].$$

Der Aufwand dieses Verfahrens ist durch die Anzahl der Funktionsauswertungen bestimmt und somit proportional zu m.

Auf jedem Teilintervall approximieren wir das Integral wie folgt

$$\int_{x_{i-1}}^{x_i} \mathrm{e}^x \,\mathrm{d}x \approx \mathrm{e}^{x_{i-1}}(x_i - x_{i-1}).$$

Geometrisch interpretiert ist dies der Flächeninhalt eines Rechteckes mit Breite h und Höhe $\mathrm{e}^{x_{i-1}}$, dem Funktionswert des Integranden im linken Ende des Teilintervalls. Die Quadraturformel $L_{0,m}^1$ wird daher auch als **summierte** (oder zusammengesetzte) **linksseitige Rechteckregel** bezeichnet.

Die folgende Tabelle enthält die so erhaltenen Approximationen sowie ihre absoluten Fehler.

m	$L_{0,m}^1[\exp]$	abs. Fehler
2^5	1.691573506747	2.67e-02
2^6	1.704892710065	1.34e-02
2^7	1.711578529691	6.70e-03
2^8	1.714927994171	3.35e-03
2^9	1.716604365088	1.68e-03
2^{10}	1.717442960217	8.39e-04

m	$L_{0,m}^1[\exp]$	abs. Fehler
2^{11}	1.717862360199	4.19e-04
2^{12}	1.718072085794	2.10e-04
2^{13}	1.718176954993	1.05e-04
2^{14}	1.718229391193	5.24e-05
2^{15}	1.718255609692	2.62e-05
2^{16}	1.718268719042	1.31e-05

Mit Blick auf zwei benachbarte Zeilen der Tabelle, z. B. für $m = 2^{15}$ und $m = 2^{16}$, sehen wir, dass bei einer Verdoppelung der Teilintervalle – und somit einer Verdoppelung des Aufwandes – der Fehler halbiert wird. Daher vermuten wir, dass sich der Fehler in etwa proportional zu $h = 1/m$ verhält. Möchte man den Quadraturfehler in den Bereich der Maschinengenauigkeit bringen, wären bei doppelter Genauigkeit ca. 10^{16} Funktionsauswertungen erforderlich. Das ist praktisch nicht durchführbar. ♠

Beispiel 5.1.2. Alternativ können als Zwischenstellen zur Funktionsauswertung die Mittelpunkte der Intervalle $[x_{i-1}, x_i]$ gewählt werden, also

$$\xi_i = x_{i-1/2} := \frac{x_{i-1} + x_i}{2}.$$

Wir erhalten so die Näherung

$$I_0^1[\exp] \approx \sum_{i=1}^{m} \mathrm{e}^{x_{i-1/2}}(x_i - x_{i-1}) = h \sum_{i=1}^{m} \mathrm{e}^{x_{i-1/2}} =: M_{0,m}^1[\exp].$$

Wiederum ist der Aufwand des Verfahrens proportional zu m. Da die Funktionsauswertung in den Mittelpunkten der Teilintervalle erfolgt, sprechen wir von der **summierten Mittelpunktregel**. Die nächste Tabelle enthält die mit ihr berechneten Näherungen und deren absolute Fehler.

m	$M^1_{0,m}$[exp]	abs. Fehler
2^5	1.718211913384	6.99e-05
2^6	1.718264349317	1.75e-05
2^7	1.718277458650	4.37e-06
2^8	1.718280736005	1.09e-06
2^9	1.718281555346	2.73e-07
2^{10}	1.718281760181	6.83e-08

m	$M^1_{0,m}$[exp]	abs. Fehler
2^{11}	1.718281811389	1.71e-08
2^{12}	1.718281824192	4.27e-09
2^{13}	1.718281827392	1.07e-09
2^{14}	1.718281828192	2.67e-10
2^{15}	1.718281828392	6.67e-11
2^{16}	1.718281828442	1.67e-11

Diesmal beobachten wir, dass eine Verdoppelung der Teilintervalle (und des Aufwandes) zu einer Reduktion des Fehlers auf ein Viertel führt. Wir vermuten, dass der Fehler proportional zu $h^2 = 1/m^2$ ist. Möchte man den Quadraturfehler in den Bereich der Maschinengenauigkeit 10^{-16} bringen, wären diesmal lediglich ca. 10^8 Funktionsauswertungen erforderlich, was eine signifikante Verbesserung gegenüber der linksseitigen Rechteckregel darstellt. ♠

In den nächsten Abschnitten werden wir uns mit der systematischen Konstruktion und der theoretischen Fundierung von Quadraturverfahren beschäftigen. Unter anderem werden wir sehen, warum die Mittelpunktregel bei vergleichbarem Aufwand und ähnlicher Konstruktion bessere Näherungswerte liefert als die linksseitige Rechteckregel.

5.2 Elementare Quadraturformeln

Die Definition der RIEMANN-Summen gestattet eine alternative Interpretation. Nach Wahl der Zerlegung $\Delta : a = x_0 < x_1 < \cdots < x_m = b$ und der Zwischenstellen $\xi_i \in [x_{i-1}, x_i]$, $i = 1, \ldots, m$, wird der Integrand f auf dem Intervall $[x_{i-1}, x_i]$ durch ein Polynom $p_{0,i} \in \Pi_0$ angenähert, das f in ξ_i interpoliert. Anschließend wird $p_{0,i}$ statt f integriert. So erhalten wir die Näherung

$$\int_{x_{i-1}}^{x_i} f(x)\,\mathrm{d}x \approx \int_{x_{i-1}}^{x_i} p_{0,i}(x)\,\mathrm{d}x \quad \text{bzw.} \quad \int_a^b f(x)\,\mathrm{d}x \approx \sum_{i=1}^{m} \int_{x_{i-1}}^{x_i} p_{0,i}(x)\,\mathrm{d}x.$$

Diese Idee wollen wir im Folgenden verallgemeinern, indem wir auf jedem Teilintervall den Integranden f durch ein Polynom $p_{n,i} \in \Pi_n$ ersetzen, das f in $n+1$ Stützstellen interpoliert. Dabei werden wir auf die Ergebnisse aus Kapitel 4 zur Polynominterpolation zurückgreifen.

5.2.1 Konstruktion mittels Interpolation

Für ein typisches Teilintervall $[x_{i-1}, x_i]$ in (5.1) stehe der Einfachheit halber im Folgenden $[\alpha, \beta]$. Seien $\eta_0, \ldots, \eta_n \in [\alpha, \beta]$ paarweise verschiedene Stützstellen und $p_n \in \Pi_n$ das eindeutig bestimmte Polynom, das den Integranden f an den Stützstellen η_j, $j = 0, \ldots, n$, interpoliert. Es gilt, vgl. Abschnitt 4.2,

$$p_n(x) = \sum_{j=0}^{n} L_j(x) f(\eta_j),$$

mit den LAGRANGEschen Grundpolynomen L_j, $j = 0, \ldots, n$, zu den Stützstellen η_j. Integration bzgl. $x \in [\alpha, \beta]$ liefert

$$\int_\alpha^\beta f(x)\,\mathrm{d}x \approx \int_\alpha^\beta p_n(x)\,\mathrm{d}x = \sum_{j=0}^{n} \int_\alpha^\beta L_j(x)\,\mathrm{d}x\, f(\eta_j).$$

Definition 5.2.1: Interpolatorische Quadraturformel

Seien $\eta_0, \ldots, \eta_n \in [\alpha, \beta]$ paarweise verschiedene Stützstellen und $L_0, \ldots, L_n \in \Pi_n$ die zugehörigen LAGRANGEschen Basispolynome. Dann nennen wir $Q_\alpha^\beta \colon C[\alpha, \beta] \to \mathbb{R}$,

$$f \mapsto Q_\alpha^\beta[f] := (\beta - \alpha) \sum_{j=0}^{n} \gamma_j f(\eta_j) \quad \text{mit} \quad \gamma_j := \frac{1}{\beta - \alpha} \int_\alpha^\beta L_j(x)\,\mathrm{d}x. \tag{5.2}$$

eine **interpolatorische Quadraturformel**. Die γ_j bezeichnen wir als die **Gewichte** der Quadraturformel.

Aufgabe 5.2.2. Beweisen Sie: Für die Gewichte γ_i einer interpolatorischen Quadraturformel Q_α^β gilt $\sum_{j=0}^{n} \gamma_j = 1$. ◊

Bemerkung 5.2.3. Es gilt die einfache Merkregel:

$$\text{Intervalllänge} \times \text{Gewichte} \times \text{Funktionswerte},$$

deretwegen wir in (5.2) nicht einfach $\beta - \alpha$ herauskürzen.

Wir wollen exemplarisch einige interpolatorische Quadraturformeln bestimmen.

Beispiel 5.2.4. Quadratur mittels Π_0-Interpolation, $n = 0$, hatten wir bereits im einführenden Beispiel betrachtet.

(i) Die **linksseitige Rechteckregel** ergibt sich durch Wahl der Interpolationsstelle $\eta_0 = \alpha$. Das zugehörige γ_0 ergibt sich aus

$$\gamma_0 = \frac{1}{\beta - \alpha} \int_\alpha^\beta L_0(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha} \int_\alpha^\beta 1\,\mathrm{d}x = 1,$$

was die Quadraturformel

$$I_\alpha^\beta[f] \approx L_\alpha^\beta[f] := (\beta - \alpha) f(\alpha)$$

liefert. In ähnlicher Weise lässt sich natürlich auch eine **rechtsseitige Rechteckregel** durch die Wahl $\eta_0 = \beta$ herleiten: $I_\alpha^\beta[f] \approx R_\alpha^\beta[f] := (\beta - \alpha) f(\beta)$.

(ii) Die **Mittelpunktregel** ergibt sich durch Wahl des Intervallmittelpunktes als Interpolationsstelle: $\eta_0 = (\alpha + \beta)/2$ sowie $(\beta - \alpha)\,\gamma_0 = \int_\alpha^\beta L_0(x)\,\mathrm{d}x = \int_\alpha^\beta 1\,\mathrm{d}x = \beta - \alpha$. Wir erhalten

$$I_\alpha^\beta[f] \approx M_\alpha^\beta[f] := (\beta - \alpha) f\left(\frac{\alpha + \beta}{2}\right).$$

Bei obigen Rechteckregeln wird der Integralwert $I_\alpha^\beta[f]$ approximiert durch den Flächeninhalt eines Rechteckes mit einer Grundseite der Länge $\beta - \alpha$ und der Höhe $f(\alpha)$, $f(\beta)$ bzw. $f((\alpha + \beta)/2)$, siehe Abbildung 5.2. ♠

Beispiel 5.2.5. Interpolation mit Polynomen ersten Grades, also $n = 1$. Als Interpolationsstellen wählen wir die beiden Intervallenden $\eta_0 = \alpha$ und $\eta_1 = \beta$. Die Gewichte ergeben sich wie folgt:

$$\gamma_0 = \frac{1}{\beta - \alpha} \int_\alpha^\beta L_0(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha} \int_\alpha^\beta \frac{\beta - x}{\beta - \alpha}\,\mathrm{d}x = \frac{1}{2},$$
$$\gamma_1 = \frac{1}{\beta - \alpha} \int_\alpha^\beta L_1(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha} \int_\alpha^\beta \frac{x - \alpha}{\beta - \alpha}\,\mathrm{d}x = \frac{1}{2}.$$

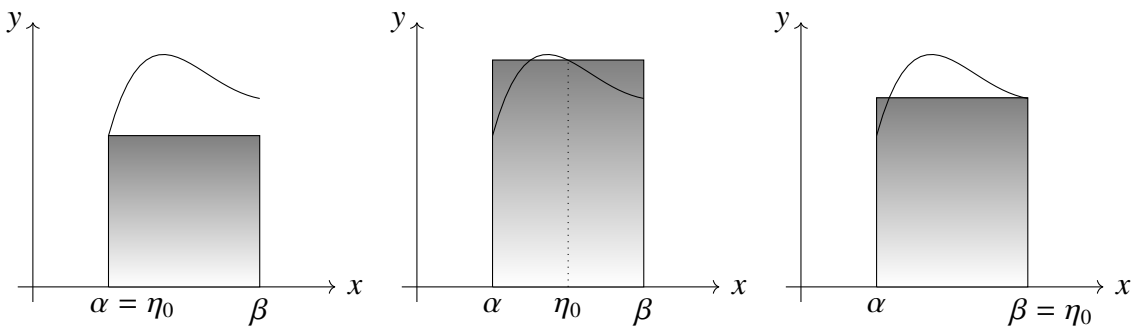


Abbildung 5.2: Rechteckregeln (linksseitige, Mittelpunktregel und rechtsseitige)

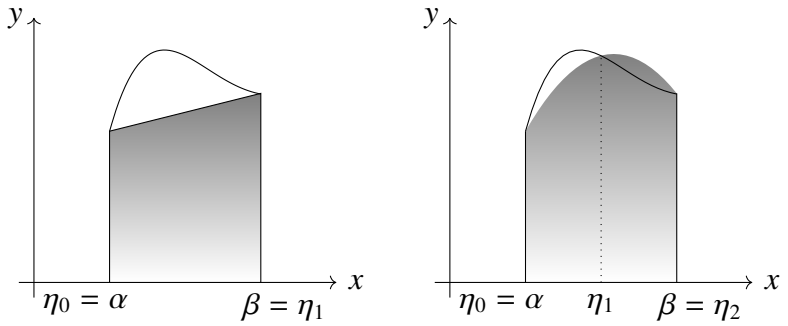


Abbildung 5.3: Trapezregel (links) und Simpsonregel (rechts)

Wir erhalten die Integralnäherung

$$I_\alpha^\beta[f] \approx T_\alpha^\beta[f] := (\beta - \alpha)\frac{f(\alpha) + f(\beta)}{2}$$

Geometrisch interpretiert ist $T_\alpha^\beta[f]$ der Flächeninhalt jenes rechtwinkligen Trapezes mit Grundseiten der Länge $f(\alpha)$ und $f(\beta)$ sowie Höhe $\beta - \alpha$, siehe Abbildung 5.3. Hieraus leitet sich der Name der Quadraturformel ab: **Trapezregel**. ♠

Beispiel 5.2.6. Wir approximieren den Integranden f durch ein quadratisches Polynom, das f in den beiden Intervallenden und im Mittelpunkt des Intervalls interpoliert, also $n = 2$, $\eta_0 = \alpha$, $\eta_1 = (\alpha + \beta)/2$ und $\eta_2 = \beta$. Für die Gewichte erhalten wir

$$\gamma_0 = \frac{1}{\beta - \alpha}\int_\alpha^\beta L_0(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha}\int_\alpha^\beta \frac{\eta_1 - x}{\eta_1 - \alpha}\frac{x - \beta}{\alpha - \beta}\,\mathrm{d}x = \frac{1}{6},$$
$$\gamma_1 = \frac{1}{\beta - \alpha}\int_\alpha^\beta L_1(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha}\int_\alpha^\beta \frac{x - \alpha}{\eta_1 - \alpha}\frac{x - \beta}{\eta_1 - \beta}\,\mathrm{d}x = \frac{2}{3},$$

sowie

$$\gamma_2 = \frac{1}{\beta - \alpha}\int_\alpha^\beta L_2(x)\,\mathrm{d}x = \frac{1}{\beta - \alpha}\int_\alpha^\beta \frac{x - \alpha}{\beta - \alpha}\frac{x - \eta_1}{\beta - \eta_1}\,\mathrm{d}x = \frac{1}{6}.$$

Dies liefert die Quadraturformel

$$I_\alpha^\beta[f] \approx S_\alpha^\beta[f] := \frac{\beta - \alpha}{6}\left(f(\alpha) + 4f\left(\frac{\alpha + \beta}{2}\right) + f(\beta)\right),$$

welche als **Simpson[2]-Regel** oder **Kepler[3]sche Fassregel** bezeichnet wird. ♠

[2]Thomas Simpson, *20.8.1710 (Market Bosworth, Leicestershire, England), †14.5.1761 (Market Bosworth, Leicestershire, England)

[3]Johannes Kepler, *27.12.1571 (Weil der Stadt, Württemberg), †15.11.1630 (Regensburg, Bayern)

5.2.2 Der Quadraturfehler

In diesem Abschnitt soll uns die Frage nach der Genauigkeit interpolatorischer Quadraturformeln beschäftigen. Wie kann der **Quadraturfehler**

$$\left|I_\alpha^\beta[f] - Q_\alpha^\beta[f]\right|$$

analysiert werden? Wie hängt er vom verwendeten Polynomgrad n ab? Bei unseren Untersuchungen werden wir den Quadraturfehler auf den Interpolationsfehler zurückführen und die Ergebnisse aus Abschnitt 4.5 zur Anwendung bringen.

Satz 5.2.7

Seien $f \in C^{n+1}[\alpha,\beta]$, $n \in \mathbb{N}_0$, und $\Delta := \{\eta_j\}_{j=0}^n \subset [\alpha,\beta]$ ein System paarweise verschiedener Stützstellen.

Für den Fehler der interpolatorischen Quadraturformel (5.2) gilt

$$\left|I_\alpha^\beta[f] - Q_\alpha^\beta[f]\right| \le C_\Delta\,(\beta-\alpha)^{n+2}\left\|f^{(n+1)}\right\|_{[\alpha,\beta]}$$

mit der Konstanten

$$C_\Delta := \frac{1}{(n+1)!}\cdot\frac{1}{(\beta-\alpha)^{n+2}}\int_\alpha^\beta |\omega_{n+1}(x)|\,\mathrm{d}x$$

und $\omega_{n+1}(x) := (x-\eta_0)\cdots(x-\eta_n)$.

Beweis. Es bezeichne $p_n \in \Pi_n$ jenes eindeutig bestimmte Polynom, das die Funktion f in den Stützstellen η_j, $j = 0,\dots,n$, interpoliert. Dann gilt für den Quadraturfehler

$$I_\alpha^\beta[f] - Q_\alpha^\beta[f] = \int_\alpha^\beta f(x)\,\mathrm{d}x - \int_\alpha^\beta p_n(x)\,\mathrm{d}x = \int_\alpha^\beta (f(x)-p_n(x))\,\mathrm{d}x,$$

woraus wir unmittelbar folgern, dass

$$\left|I_\alpha^\beta[f] - Q_\alpha^\beta[f]\right| \le \int_\alpha^\beta \left|f(x)-p_n(x)\right|\mathrm{d}x. \tag{5.3}$$

Den Interpolationsfehler $f - p_n$ schätzen wir mit Hilfe von Satz 4.5.1 ab. Für alle $x \in [\alpha,\beta]$ gilt

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi(x))}{(n+1)!}\omega_{n+1}(x)$$

mit einem $\xi(x) \in [\alpha,\beta]$.

Es folgt

$$|f(x)-p_n(x)| \le \left\|f^{(n+1)}\right\|_{[\alpha,\beta]}\frac{|\omega_{n+1}(x)|}{(n+1)!},$$

womit wir die rechte Seite von (5.3) abschätzen können:

$$\left|I_\alpha^\beta[f] - Q_\alpha^\beta[f]\right| \le \int_\alpha^\beta \left\|f^{(n+1)}\right\|_{[\alpha,\beta]}\frac{|\omega_{n+1}(x)|}{(n+1)!}\,\mathrm{d}x = \left\|f^{(n+1)}\right\|_{[\alpha,\beta]}\frac{1}{(n+1)!}\int_\alpha^\beta |\omega_{n+1}(x)|\,\mathrm{d}x\,.$$

Die Aussage des Satzes folgt nach Erweitern mit $(\beta-\alpha)^{n+2}$. □

Bemerkung 5.2.8. Die Konstante C_Δ ist nicht abhängig vom Intervall $[\alpha,\beta]$, sondern lediglich von der relativen Lage der Stützstellen innerhalb des Intervalls. Wir wollen dies kurz verifizieren und betrachten dazu ein zweites Intervall $[\tilde\alpha,\tilde\beta] \subset \mathbb{R}$. Die affine Transformation

$$\chi\colon [\alpha,\beta] \to [\tilde\alpha,\tilde\beta]\colon x \mapsto \chi(x) := \frac{\tilde\beta-\tilde\alpha}{\beta-\alpha}(x-\alpha)+\tilde\alpha$$

bildet das Intervall $[\alpha,\beta]$ bijektiv auf $[\tilde\alpha,\tilde\beta] \subset \mathbb{R}$ ab und überführt das Stützstellensystem auf $[\alpha,\beta]$ gemäß $\tilde\eta_j := \chi(\eta_j)$, $j = 0,\dots,n$, in ein Stützstellensystem auf $[\tilde\alpha,\tilde\beta]$.

Aus der Kettenregel für Integrale folgt nun

$$\begin{aligned}\frac{1}{(\tilde\beta-\tilde\alpha)^{n+2}}\int_{\tilde\alpha}^{\tilde\beta}\prod_{j=0}^{n}\left|\tilde x-\tilde\eta_j\right|\,\mathrm{d}\tilde x &= \frac{1}{(\beta-\alpha)\,(\tilde\beta-\tilde\alpha)^{n+1}}\int_\alpha^\beta\prod_{j=0}^{n}\left|\chi(x)-\chi(\eta_j)\right|\,\mathrm{d}x\\ &= \frac{1}{(\beta-\alpha)\,(\tilde\beta-\tilde\alpha)^{n+1}}\int_\alpha^\beta\prod_{j=0}^{n}\left|\frac{\tilde\beta-\tilde\alpha}{\beta-\alpha}(x-\eta_j)\right|\,\mathrm{d}x = \frac{1}{(\beta-\alpha)^{n+2}}\int_\alpha^\beta\prod_{j=0}^{n}\left|x-\eta_j\right|\,\mathrm{d}x\,.\end{aligned}$$

Diese Feststellung wird später bei der Untersuchung summierter Quadraturformeln eine wichtige Rolle spielen.

Eine besondere Situation liegt vor, wenn die Stützstellen symmetrisch bezüglich des Mittelpunktes η_* des Intervalls $[\alpha,\beta]$ sind, und dieser selbst eine Stützstelle ist. Dies ist bspw. sowohl bei der Mittelpunkt- als auch bei der Simpsonregel der Fall.

In diesem Fall können wir unsere Abschätzung u. U. verschärfen.

Satz 5.2.9

Seien $f \in C^{n+2}[\alpha,\beta]$, $n \in \mathbb{N}_0$, n gerade, und $\Delta := \{\eta_0 < \eta_1 < \cdots < \eta_n\} \subset [\alpha,\beta]$ ein System von Stützstellen, die symmetrisch zum Mittelpunkt des Intervalls $[\alpha,\beta]$ sind, d. h.

$$\frac{\eta_j+\eta_{n-j}}{2} = \eta_{n/2} = \frac{\alpha+\beta}{2},\quad j = 0,\dots,\frac{n}{2}.$$

Dann gilt für den Fehler der zugehörigen interpolatorischen Quadraturformel (5.2)

$$\left|I_\alpha^\beta[f]-Q_\alpha^\beta[f]\right| \le \tilde C_\Delta\,(\beta-\alpha)^{n+3}\left\|f^{(n+2)}\right\|_{[\alpha,\beta]}$$

mit der Konstanten

$$\tilde C_\Delta := \frac{1}{(n+2)!}\cdot\frac{1}{(\beta-\alpha)^{n+3}}\int_\alpha^\beta\left|x-\eta_{n/2}\right|\left|\omega_{n+1}(x)\right|\,\mathrm{d}x.$$

Beweis. Es bezeichne wieder $p_n \in \Pi_n$ jenes Polynom, das die Funktion f in den Stützstellen η_j, $j = 0,\dots,n$, interpoliert. Definitionsgemäß gilt für die Quadraturformel

$$Q_\alpha^\beta[f] = \int_\alpha^\beta p_n(x)\,\mathrm{d}x.$$

Sei $\tilde{p}_{n+1} \in \Pi_{n+1}$ jenes eindeutig definierte Polynom mit

$$\tilde{p}_{n+1}(\eta_j) = f(\eta_j), \quad j = 0, \dots, n, \quad \text{und} \quad \tilde{p}'_{n+1}(\eta_{n/2}) = f'(\eta_{n/2}).$$

Es gilt (Übungsaufgabe)

$$\int_\alpha^\beta p_n(x)\,\mathrm{d}x = \int_\alpha^\beta \tilde{p}_{n+1}(x)\,\mathrm{d}x. \tag{5.4}$$

Somit gilt für den Quadraturfehler

$$I_\alpha^\beta[f] - Q_\alpha^\beta[f] = \int_\alpha^\beta (f(x) - \tilde{p}_{n+1}(x))\,\mathrm{d}x.$$

Der Interpolationsfehler $f - \tilde{p}_{n+1}$ kann wie folgt dargestellt werden (siehe Einsendeaufgaben zu Kapitel 4). Für alle $x \in [\alpha,\beta]$ existiert ein $\xi = \xi(x) \in [\alpha,\beta]$ mit

$$f(x) - \tilde{p}_{n+1}(x) = \frac{f^{(n+2)}(\xi)}{(n+2)!}(x - \eta_{n/2})\,\omega_{n+1}(x)\,\mathrm{d}x.$$

Der Rest des Beweises verläuft analog zu dem von Satz 5.2.7. □

Aufgabe 5.2.10. Beweisen Sie Gleichung (5.4)! Skizzieren Sie $p_n - \tilde{p}_{n+1}$, z. B. für die Simpsonregel, um eine Beweisidee zu entwickeln. ♢

Beispiel 5.2.11. Wir wollen die Sätze 5.2.7 und 5.2.9 anwenden.

Rechteckregeln: Wir benutzen Satz 5.2.7 mit $n = 0$ und $\eta_0 = \alpha$ und erhalten für die linksseitige Rechteckregel

$$C_\Delta = \frac{1}{(\beta-\alpha)^2}\int_\alpha^\beta |x-\alpha|\,\mathrm{d}x = \frac{1}{(\beta-\alpha)^2}\int_\alpha^\beta (x-\alpha)\,\mathrm{d}x = \frac{1}{2},$$

sowie

$$\left|I_\alpha^\beta[f] - L_\alpha^\beta[f]\right| \le \frac{(\beta-\alpha)^2}{2}\,\|f'\|_{[\alpha,\beta]}$$

Dieselbe Abschätzung erhalten wir für die rechtsseitige Rechteckregel.

Für die *Trapezregel* sind $n = 1$, $\eta_0 = \alpha$ und $\eta_1 = \beta$. Wir berechnen die Konstante

$$C_\Delta = \frac{1}{2\,(\beta-\alpha)^3}\int_\alpha^\beta |x-\alpha|\,|x-\beta|\,\mathrm{d}x = \frac{1}{2\,(\beta-\alpha)^3}\int_\alpha^\beta (\beta-x)\,(x-\alpha)\,\mathrm{d}x = \frac{1}{12}.$$

Satz 5.2.7 impliziert nun

$$\left|I_\alpha^\beta[f] - T_\alpha^\beta[f]\right| \le \frac{(\beta-\alpha)^3}{12}\,\|f''\|_{[\alpha,\beta]}\,.$$

Mittelpunktregel: $n = 0$, $\eta_0 = (\alpha+\beta)/2$. Satz 5.2.9 kann zur Anwendung gebracht werden.

$$\left|I_\alpha^\beta[f] - M_\alpha^\beta[f]\right| \le \frac{\|f''\|_{[\alpha,\beta]}}{2}\int_\alpha^\beta (x-\eta_0)^2\,\mathrm{d}x = \frac{(\beta-\alpha)^3}{24}\,\|f''\|_{[\alpha,\beta]}\,.$$

Simpson*regel:* $n = 2$, $\eta_0 = \alpha$, $\eta_1 = (\alpha+\beta)/2$, $\eta_2 = \beta$. Die Voraussetzungen von Satz 5.2.9 sind erfüllt. Folglich gilt

$$\left|I_\alpha^\beta[f] - S_\alpha^\beta[f]\right| \le \frac{\left\|f^{(4)}\right\|_{[\alpha,\beta]}}{24}\int_\alpha^\beta (x-\alpha)(x-\eta_1)^2(\beta-x)\,\mathrm{d}x = \frac{(\beta-\alpha)^5}{2880}\left\|f^{(4)}\right\|_{[\alpha,\beta]}\,.$$

♠

5.3 Summierte Quadraturformeln

Um eine höhere Genauigkeit bei der Berechung eines Integralwertes

$$I_a^b[f] \coloneqq \int_a^b f(x)\,\mathrm{d}x$$

zu erreichen, zerlegen wir das Intervall $[a,b]$ in $m \in \mathbb{N}$ Teilintervalle $[x_{i-1}, x_i]$, $i = 1,\dots,m$,

$$a = x_0 < x_1 < \cdots < x_{m-1} < x_m = b,$$

und wenden auf jedem Teilintervall eine elementare Quadraturformel an. Eine so erhaltene Approximation des Integralwertes $I_a^b[f]$ bezeichnen wir als **summierte Quadraturformel** oder auch als **zusammengesetzte Quadraturformel**.

5.3.1 Konstruktion

Sei eine elementare Quadraturformel

$$Q_\alpha^\beta[f] \coloneqq (\beta-\alpha)\sum_{j=0}^{n}\gamma_j f(\eta_j)$$

zur Approximation des Integrals $I_\alpha^\beta[f]$ gegeben. Durch die affine Transformation

$$\chi_i\colon [\alpha,\beta] \to [x_{i-1},x_i]\colon \eta \mapsto \chi_i(\eta) \coloneqq \frac{x_i - x_{i-1}}{\beta-\alpha}(\eta-\alpha) + x_{i-1}, \quad i = 1,\dots,m,$$

wird das Intervall $[\alpha,\beta]$ eineindeutig auf das Intervall $[x_{i-1}, x_i]$ abgebildet. Durch Anwendung der elementaren Quadraturformel auf jedem Teilintervall $[x_{i-1}, x_i]$ unserer Zerlegung von $[a,b]$ erhalten wir die **summierte Quadraturformel**

$$Q_{a,m}^b[f] \coloneqq \sum_{i=1}^{m} Q_{x_{i-1}}^{x_i}[f] = \sum_{i=1}^{m}(x_i - x_{i-1})\sum_{j=0}^{n}\gamma_j f\big(\chi_i(\eta_j)\big) \approx I_a^b[f]. \tag{5.5}$$

Bemerkung 5.3.1. In diesem Zusammenhang wird das Intervall $[\alpha,\beta]$ als **Referenzintervall** bezeichnet. Zur Normierung es ist oft üblich, die Intervalle $[-1,1]$ oder $[0,1]$ als Referenzintervalle zu verwenden.

Der Einfachheit halber beschränken wir uns im Folgenden auf den Fall einer gleichabständigen Zerlegung des Intervalls $[a,b]$, d. h.

$$x_i - x_{i-1} = \frac{b-a}{m} =: h, \quad i = 1,\dots,m.$$

Wir bezeichnen h als **Schrittweite** unserer Zerlegung. Die Darstellung der summierten Quadraturformel vereinfacht sich so zu

$$Q_{\alpha,m}^\beta[f] = h\sum_{i=1}^{m}\sum_{j=0}^{n}\gamma_j f\big(\chi_i(\eta_j)\big).$$

Beispiel 5.3.2. Summierte Mittelpunktregel, Abbildung 5.4,

$$I_a^b[f] = \sum_{i=1}^{m} I_{x_{i-1}}^{x_i}[f] \approx \sum_{i=1}^{m} M_{x_{i-1}}^{x_i}[f] = \sum_{i=1}^{m} (x_i - x_{i-1}) f\left(\frac{x_{i-1} + x_i}{2}\right)$$
$$= h \sum_{i=1}^{m} f\left(\frac{x_{i-1} + x_i}{2}\right) =: M_{a,m}^b[f]$$

Ihr waren wir bereits im einleitenden Bsp. 5.1.2 begegnet. ♠

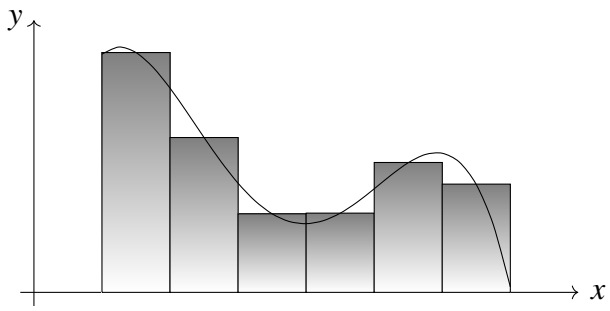


Abbildung 5.4: Summierte Mittelpunktregel

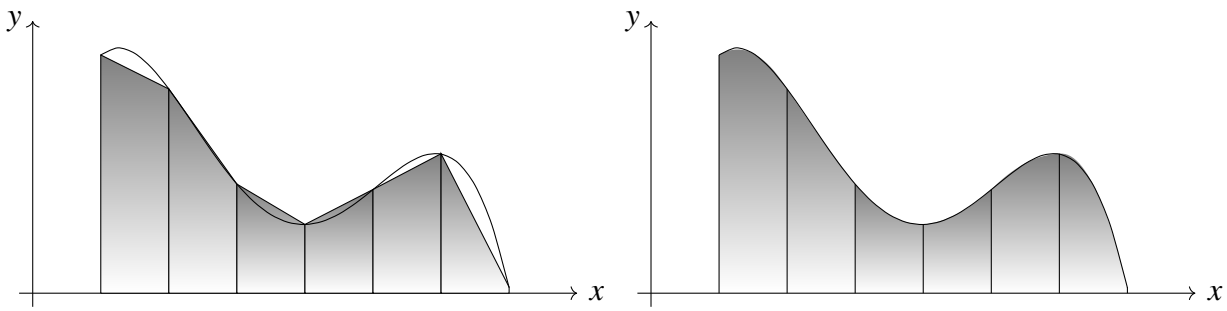
Beispiel 5.3.3. Summierte Trapezregel, vgl. Abbildung 5.5a,

$$I_a^b[f] = \sum_{i=1}^{m} I_{x_{i-1}}^{x_i}[f] \approx \sum_{i=1}^{m} T_{x_{i-1}}^{x_i}[f] = \sum_{i=1}^{m} (x_i - x_{i-1}) \frac{f(x_{i-1}) + f(x_i)}{2}$$
$$= \frac{h}{2} \sum_{i=1}^{m} (f(x_{i-1}) + f(x_i)) = \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{m-1} f(x_i) + f(x_m) \right) =: T_{a,m}^b[f]$$

♠

Beispiel 5.3.4. Summierte Simpsonregel

$$I_a^b[f] \approx \sum_{i=1}^{m} S_{x_{i-1}}^{x_i}[f] = \frac{h}{6} \sum_{i=1}^{m} \left(f(x_{i-1}) + 4 f(x_{i-1/2}) + f(x_i) \right), \quad x_{i-1/2} := \frac{x_{i-1} + x_i}{2},$$
$$= \frac{h}{6} \left(f(x_0) + 2 \sum_{i=1}^{m-1} f(x_i) + 4 \sum_{i=1}^{m} f(x_{i-1/2}) + f(x_m) \right) =: S_{a,m}^b[f],$$



(a) Trapezregel (b) Simpsonregel

Abbildung 5.5: Summierte Quadraturformeln

Abbildung 5.5b illustriert dieses Quadraturverfahren. Optisch ist kaum ein Unterschied zwischen dem Integranden und die ihn auf den einzelnen Teilintervallen interpolierenden quadratischen Polynome auszumachen. ♠

5.3.2 Numerische Illustration

Wir wollen diese Herleitungen mit zwei numerischen Experimenten für die summierte Trapez- und die Simpsonregel ergänzen. Wie in den Beispielen 5.1.1 und 5.1.2 betrachten wir das Integral

$$I_0^1[\exp] = \int_0^1 \mathrm{e}^x \,\mathrm{d}x = \mathrm{e} - 1 \approx 1.718281828459046.$$

Die folgende Tabelle zeigt unsere Ergebnisse für die summierte Trapezregel.

m	$T^1_{0,m}[\exp]$	abs. Fehler
2^5	1.718421660316	1.40e-04
2^6	1.718316786850	3.50e-05
2^7	1.718290568083	8.74e-06
2^8	1.718284013367	2.18e-06
2^9	1.718282374686	5.46e-07
2^{10}	1.718281965016	1.37e-07

m	$T^1_{0,m}[\exp]$	abs. Fehler
2^{11}	1.718281862598	3.41e-08
2^{12}	1.718281836994	8.53e-09
2^{13}	1.718281830593	2.13e-09
2^{14}	1.718281828992	5.33e-10
2^{15}	1.718281828592	1.33e-10
2^{16}	1.718281828492	3.33e-11

Wie bei der Mittelpunktregel beobachten wir, dass eine Verdoppelung der Anzahl der Teilintervalle (und des Aufwandes) zu einer Reduktion des Fehlers auf ein Viertel führt, d. h. der Fehler ist proportional zu $h^2 = 1/m^2$. Ein Vergleich der Fehler mit jenen aus Bsp. 5.1.2 zeigt, dass für große m der Fehler der Trapezregel in etwa doppelt so groß ist wie jener der Mittelpunktregel.

Wir kommen zur summierten Simpsonregel:

m	$S^1_{0,m}[\exp]$	abs. Fehler
2	1.718318841922	3.70e-05
2^2	1.718284154700	2.33e-06
2^3	1.718281974052	1.46e-07
2^4	1.718281837562	9.10e-09
2^5	1.718281829028	5.69e-10

m	$S^1_{0,m}[\exp]$	abs. Fehler
2^6	1.718281828495	3.56e-11
2^7	1.718281828461	2.22e-12
2^8	1.718281828459	1.38e-13
2^9	1.718281828459	9.55e-15
2^{10}	1.718281828459	2.22e-16

Diese Quadraturformel ist wesentlich genauer als Trapez- und Mittelpunktregel. Bereits für $m = 1024$ liegt der Fehler im Bereich der Maschinengenauigkeit. Durch Division der Fehler für $m = 2^7$ und $m = 2^8$ erkennen wir, dass eine Verdoppelung der Zahl der Intervalle zu einer Reduktion des Fehlers um den Faktor 16 führt. Der Fehler ist somit proportional zu $h^4 = 1/m^4$ bei lediglich doppeltem Aufwand im Vergleich zur Trapez- und Mittelpunktregel.

Bemerkung 5.3.5. Statt einer gleichmäßigen Zerlegung des Integrationsbereiches $[a, b]$ kann in besonderen Fällen eine andere günstiger sein. Wenn sich in einem Teilgebiet der Integrand stark ändert, ist es u. U. günstiger, dort eine feinere Zerlegung (kleinere Intervalle) als im übrigen Gebiet zu verwenden. Auch kann auf jedem Teilintervall eine andere Quadraturformel zum Einsatz gebracht werden. Auf Details einer solchen angepassten – oder adaptiven – Quadratur können wir an dieser Stelle nicht eingehen.

5.3.3 Der Quadraturfehler

Wir wenden uns nun der Fehleranalysis summierter Quadraturformeln,

$$\left|I_\alpha^\beta[f] - Q_\alpha^\beta[f]\right| \quad \text{bzw.} \quad \left|I_a^b[f] - Q_{a,m}^b[f]\right|,$$

zu. Dabei interessiert uns insbesondere seine Abhängigkeit vom verwendeten Polynomgrad n sowie der Anzahl m der Teilintervalle bzw. der Schrittweite $h := (b-a)/m$. Wir werden dabei auf die Ergebnisse aus Abschnitt 5.2.2 zurückgreifen.

Satz 5.3.6

Sei Q_α^β eine elementare, auf dem Referenzintervall $[\alpha,\beta]$ definierte, interpolatorische Quadraturformel, mit $n+1$, $n \in \mathbb{N}_0$, paarweise verschiedenen Stützstellen $\eta_j \in [\alpha,\beta]$, $j = 0,\dots,n$. Dann gelten für den Quadraturfehler der zugehörigen, gleichabständigen, gemäß (5.5) konstruierten, summierten Quadraturregel $Q_{a,m}^b$ mit $m \in \mathbb{N}$ Teilintervallen der Länge $h := (b-a)/m$ die folgenden Aussagen.

(i) Ist $f \in C^{n+1}[a,b]$, dann gilt

$$\left|I_a^b[f] - Q_{a,m}^b[f]\right| \le C_\Delta\,(b-a)\,h^{n+1}\left\|f^{(n+1)}\right\|_{[a,b]},$$

mit der Konstanten C_Δ aus Satz 5.2.7.

(ii) Ist $f \in C^{n+2}[a,b]$, $n \in \mathbb{N}_0$ gerade, und liegen die Stützstellen symmetrisch zum Mittelpunkt des Referenzintervalls $[\alpha,\beta]$, dann gilt

$$\left|I_a^b[f] - Q_{a,m}^b[f]\right| \le \tilde{C}_\Delta\,(b-a)\,h^{n+2}\left\|f^{(n+2)}\right\|_{[a,b]},$$

mit $\tilde{C}_\Delta$ aus Satz 5.2.9.

Beweis. (i) Bei einer summierten Quadraturformel wird das Intervall $[a,b]$ gleichabständig in Teilintervalle $[x_{i-1},x_i]$, $i = 1,\dots,m$, zerlegt, auf denen jeweils die elementare Quadraturformel Anwendung findet. Mit der Dreiecksungleichung erhalten wir zunächst

$$\left|I_a^b[f] - Q_{a,m}^b[f]\right| \le \sum_{i=1}^m \left|I_{x_{i-1}}^{x_i}[f] - Q_{x_{i-1}}^{x_i}[f]\right| \le \sum_{i=1}^m C_\Delta h^{n+2}\left\|f^{(n+1)}\right\|_{[x_{i-1},x_i]},$$

wegen Satz 5.2.7, Bem. 5.2.8 und da $x_i - x_{i-1} = h$, $i = 1,\dots,m$. Es ist

$$\left\|f^{(n+1)}\right\|_{[x_{i-1},x_i]} \le \left\|f^{(n+1)}\right\|_{[a,b]}, \quad \text{da } [x_{i-1},x_i] \subset [a,b],\ i = 1,\dots,m.$$

Die erste Fehlerabschätzung des Satzes folgt nun unmittelbar:

$$\left|I_a^b[f] - Q_{a,m}^b[f]\right| \le C_\Delta m h^{n+2}\left\|f^{(n+1)}\right\|_{[a,b]} = C_\Delta(b-a)h^{n+1}\left\|f^{(n+1)}\right\|_{[a,b]}.$$

(ii) Der Beweis der zweiten Quadraturfehlerabschätzung erfolgt analog unter Benutzung von Satz 5.2.9. □

Beispiel 5.3.7. Aus Satz 5.3.6 können wir die folgenden Fehlerabschätzungen für konkrete Quadraturformeln ableiten.

Trapezregel:

$$\left|I_a^b[f] - T_{a,m}^b[f]\right| \leq \frac{b-a}{12} h^2 \left\|f''\right\|_{[a,b]} \tag{5.6}$$

Mittelpunktregel:

$$\left|I_a^b[f] - M_{a,m}^b[f]\right| \leq \frac{b-a}{24} h^2 \left\|f''\right\|_{[a,b]}$$

Ein Vergleich mit (5.6) bestätigt – wenngleich nur heuristisch, denn wir vergleichen lediglich zwei *obere* Schranken – unsere frühere Beobachtung im Abschnitt 5.3.2, wonach der Fehler der Trapezregel etwa doppelt so groß wie jener der Mittelpunktregel ist. Auf der rechten Seite in (5.6) tritt der Faktor $1/12$ auf, während dieser bei der Mittelpunktregel $1/24$ ist.

Simpson*regel:*

$$\left|I_a^b[f] - S_{a,m}^b[f]\right| \leq \frac{b-a}{2880} h^4 \left\|f^{(4)}\right\|_{[a,b]}$$

Diese theoretischen Resultate sind im Einklang mit unseren Experimenten im Abschnitt 5.3.2. ♠

5.4 Ordnung und Exaktheit von Quadraturformeln

Abschließend wollen wir zwei Begriffe einführen, die im Zusammenhang mit Quadraturverfahren Verwendung finden.

Definition 5.4.1: Exaktheitsgrad von Quadraturformeln

Unabhängig von der Konstruktion nennen wir

$$Q_\alpha^\beta[f] := (\beta - \alpha) \sum_{j=0}^{n} \gamma_j f(\eta_j), \quad \eta_j \in [\alpha, \beta],$$

zur Approximation von $I_\alpha^\beta[f]$ eine **elementare Quadraturformel**.

Wir sagen, sie besitzt den **Exaktheitsgrad** $r \in \mathbb{N}_0$, falls

$$Q_\alpha^\beta[q] = I_\alpha^\beta[q] \quad \forall\, q \in \Pi_r\,, \tag{5.7}$$

d. h. wenn sie alle Polynome vom Höchstgrad r exakt integriert, und

$$Q_\alpha^\beta[q^*] \neq I_\alpha^\beta[q^*] \quad \text{für ein } q^* \in \Pi_{r+1}\,.$$

Bemerkung 5.4.2. Sowohl I_α^β als auch Q_α^β sind lineare Abbildungen. Deshalb ist es zur Überprüfung der Exaktheit ausreichend, eine beliebige Basis von Π_q hinsichtlich ihrer Exaktheit zu untersuchen, z. B. die Monom-Basis $\mu_0, \mu_1, \ldots, \mu_r$.

Beispiel 5.4.3. Die einseitigen Rechteckregeln sind exakt für Polynome vom Grad 0, die Mittelpunkt- und die Trapezregel für Polynome vom Grad 1. Die Simpsonregel besitzt Exaktheitsgrad 3. ♠

Bemerkung 5.4.4. Aufgrund ihrer Konstruktion sind interpolatorische Quadraturformeln mit $n+1$ Stützstellen exakt für alle Polynome $q \in \Pi_n$. Sie besitzen also Exaktheitsgrad $r \geq n$. Insbesondere gilt $r > n$ für die Mittelpunkt- und die Simpsonregel.

Umgekehrt gilt: Besitzt eine elementare Quadraturformel mit $n+1$ Stützstellen, $n \in \mathbb{N}_0$, Exaktheitsgrad $r \geq n$, dann ist sie eine interpolatorische Quadraturformel. (Übungsaufgabe)

Definition 5.4.5: Ordnung zusammengesetzer Quadraturformeln

Eine **zusammengesetzte Quadraturformel** $Q_{a,m}^b$ besitzt die **Ordnung** $p \in \mathbb{N}$, falls eine Konstante C existiert mit

$$\left| I_a^b[f] - Q_{a,m}^b[f] \right| \leq C(b-a)h^p \left\| f^{(p)} \right\|_{[a,b]}, \quad h := (b-a)/m\,,$$

für alle Funktionen $f \in C^p[a,b]$.

Beispiel 5.4.6. Trapez- und Mittelpunktregel besitzen die Ordnung 2, während die Simpson-Regel Ordnung 4 besitzt; vgl. Bsp. 5.3.7. ♠

Aufgabe 5.4.7. Verifizieren Sie die Aussagen von Bsp. 5.4.3! ♢

Zwischen Exaktheitsgrad einer elementaren Quadraturformel und der Ordnung der zugehörigen summierten Quadraturformel besteht ein grundlegender Zusammenhang, auf dessen Beweis an dieser Stelle zunächst verzichtet sei.

Satz 5.4.8

Ist Q_α^β eine elementare Quadraturformel mit Exaktheitsgrad $r \in \mathbb{N}_0$, dann besitzt die zugehörige summierte Quadraturregel $Q_{a,m}^b$ die Ordnung $r+1$.

Bemerkung 5.4.9. Satz 5.4.8 illustriert sehr schön die Bedeutung eines hohen Exaktheitsgrades für die Effizienz des Verfahrens. Bei hinreichender Differenzierbarkeit des Integranden f konvergiert die Folge der Integralnäherungen $Q_{a,m}^b[f]$ wie h^{r+1} bzw. $m^{-(r+1)}$ gegen den Integralwert $I_a^b[f]$. Um das Integral mit Maschinengenauigkeit `eps` zu approximieren ist $m \approx \texttt{eps}^{-1/(r+1)}$ zu wählen.

Zur Berechnung der Integralnäherung sind $(r+1)m$ Funktionsauswertungen erforderlich (jeweils $r+1$ Funktionsauswertungen auf jedem der m Teilintervalle). Der Gesamtaufwand ist also proportional zu

$$(r+1)\,\texttt{eps}^{-1/(r+1)}\,.$$

Er reduziert sich geringfügig um $m-1$ Funktionsauswertungen, wenn die Menge der Stützstellen der elementaren Quadraturformel beide Intervallenden des Referenzintervalls enthält.

In Anbetracht dieser Feststellung könnte man versuchen, interpolatorischer Quadraturformeln beliebig hoher Ordnung durch die Wahl gleichabständiger Stützstellen $\eta_j = \alpha + j\,(\beta-\alpha)\,/n$, $j = 0,\ldots,n$, $n \in \mathbb{N}$, zu konstruieren. Dies ist jedoch aus zwei Gründen nicht empfehlenswert:

- Rundungsfehler werden bei der Berechung der Funktionswerte an den Stützstellen verstärkt, da die Lebesgue-Konstanten sehr groß sind, vgl. Abschnitt 4.7.
- Es treten negative Gewichte auf. Dies hat zur Folge, dass die Quadraturformel die Monotonieeigenschaft des Integrals

  $$f \geq g \;\text{ auf }\; (\alpha,\beta) \quad\Longrightarrow\quad I_\alpha^\beta[f] \geq I_\alpha^\beta[g],$$

  nicht widerspiegelt.

Einer gangbaren Alternative wenden wir uns im nächsten Abschnitt zu.

5.5 Gauss-Legendre-Formeln

Im vorangegangenen Abschnitt haben wir die Stützstellen für die interpolatorischen Quadraturformeln nach Gutdünken, z. B. gleichabständig, gewählt. Natürlich können wir auch versuchen, die Stützstellen so zu optimieren, dass die resultierende Quadraturformel möglichst genau ist.

Die Gewichte und Stützstellen einer optimierten Quadraturformel können aus der Forderung bestimmt werden, dass selbige exakt ist für Polynome möglichst hohen Grades. Dies ist in Anbetracht unserer Überlegungen im vorherigen Abschnitt wünschenswert, vgl. Bem. 5.4.9.

Beispiel 5.5.1. Zum Einstieg wollen wir eine optimierte Quadraturformel Q^1_{-1} mit zwei Stützstellen zur Approximation von I^1_{-1} konstruieren. Dazu setzen wir an

$$Q^1_{-1}[f] = \vartheta_0 f(\eta_0) + \vartheta_1 f(\eta_1), \quad \eta_0 < \eta_1.$$

Bem. 5.4.2 folgend, brauchen wir die Exaktheit nur für die Elemente der Monom-Basis, also μ_i, $i = 0, 1, \dots$, zu untersuchen. Die Quadraturformel besitzt vier Parameter, wir benötigen ebensoviele Gleichungen, um ein konsistentes Gleichungssystem zu erhalten. Wir fordern also Exaktheit der Quadraturformel für die ersten vier Monome und erhalten das Gleichungssystem

$$\begin{aligned}
2 &= I^1_{-1}[\mu_0] = Q^1_{-1}[\mu_0] = \vartheta_0 + \vartheta_1,\\
0 &= I^1_{-1}[\mu_1] = Q^1_{-1}[\mu_1] = \vartheta_0\eta_0 + \vartheta_1\eta_1,\\
\tfrac{2}{3} &= I^1_{-1}[\mu_2] = Q^1_{-1}[\mu_2] = \vartheta_0\eta_0^2 + \vartheta_1\eta_1^2,\\
0 &= I^1_{-1}[\mu_3] = Q^1_{-1}[\mu_3] = \vartheta_0\eta_0^3 + \vartheta_1\eta_1^3.
\end{aligned}$$

Dieses Gleichungssystem besitzt die eindeutige Lösung

$$\eta_0 = -\frac{1}{\sqrt{3}}, \quad \eta_1 = \frac{1}{\sqrt{3}}, \quad \vartheta_0 = \vartheta_1 = 1,$$

Dies sind nicht zufällig Nullstellen des Legendre-Polynoms P_2, vgl. Abschnitt 3.4.1!

Wir erhalten die Quadraturformel

$$I^1_{-1}[f] \approx Q^1_{-1}[f] = f\left(\frac{-1}{\sqrt{3}}\right) + f\left(\frac{1}{\sqrt{3}}\right).$$

Wegen obiger Konstruktion ist sie exakt für Polynome vom Grad 3. Das Monom $\mu_4 \in \Pi_4$ wird jedoch nicht exakt integriert, sodass die Quadraturformel Exaktheitsgrad 3 besitzt. ♠

Im Folgenden beschränken wir uns auf das Referenzintervall $[-1, 1]$. Unsere Quadraturformel besitze $n+1$ paarweise verschiedenen Stützstellen $\eta_j \subset [-1, 1]$, $j = 0, \dots, n$, $n \in \mathbb{N}_0$. Das zugehörige Knotenpolynom ist

$$\omega_{n+1} \in \Pi_{n+1} : x \mapsto \omega_{n+1}(x) = (x - \eta_0)(x - \eta_1)\cdots(x - \eta_n).$$

5.5.1 Maximaler Exaktheitsgrad und optimale Wahl der Stützstellen

Welchen Exaktheitsgrad kann eine interpolatorische Quadraturformel mit $n+1$ Stützstellen besitzen? Nach Festlegung der Stützstellen sind die Gewichte durch (5.2) als Mittelwerte der zugehörigen LAGRANGE-Polynome bestimmt:

$$Q^1_{-1}[f] := 2\sum_{j=0}^{n} \gamma_j f(\eta_j) \quad \text{mit} \quad \gamma_j := \frac{1}{2}\int_{-1}^{1} L_j(x)\,\mathrm{d}x.$$

Der erreichte Exaktheitsgrad ist n. Durch verbesserte Wahl der $n+1$ Stützstellen η_j können wir hoffen, ihn pro verbessert gewählter Stützstelle um eins zu erhöhen. Ein Exaktheitsgrad von $2n+1$ scheint so — wie im Bsp. 5.5.1 beobachtet — möglich. Wir werden im Folgenden sehen, dass dieser in der Tat erreicht, aber nicht überboten werden kann.

Satz 5.5.2

Jede Quadraturformel mit $n+1$ Stützstellen besitzt Exaktheitsgrad $r < 2(n+1)$.

Beweis. Sei ω_{n+1} das zu den Stützstellen der Quadraturformel gehörige Knotenpolynom. Dann existiert mit ω^2_{n+1} ein Polynom vom Grad $2(n+1)$, für das die Quadraturformel nicht exakt ist. Einerseits ist $\omega_{n+1}(\eta_j) = 0$, $j = 0, \ldots, n$, und somit

$$Q^1_{-1}[\omega^2_{n+1}] = 2\sum_{j=0}^{n} \gamma_j \left[\omega_{n+1}(\eta_j)\right]^2 = 0.$$

Andererseits ist $\omega^2_{n+1} \geq 0$ auf $[-1,1]$, aber nicht identisch null. Folglich ist

$$I^1_{-1}[\omega^2_{n+1}] = \int_{-1}^{1} \left[\omega_{n+1}(x)\right]^2 \mathrm{d}x > 0.$$

Das heißt, $Q^1_{-1}[\omega^2_{n+1}] \neq I^1_{-1}[\omega^2_{n+1}]$, und der Exaktheitsgrad der Quadraturformel ist kleiner als $2(n+1)$. □

Satz 5.5.3

Sei Q^1_{-1} eine interpolatorische Quadraturformel mit $n+1$ Stützstellen und zugehörigem Knotenpolynom ω_{n+1}.

(i) Ist Q^1_{-1} exakt für Polynome vom Höchstgrad $n+1+s$, $0 \leq s \leq n$, dann ist ω_{n+1} orthogonal zu Π_s, d. h. $I^1_{-1}[\omega_{n+1} q] = 0$ für alle $q \in \Pi_s$.

(ii) Ist ω_{n+1} orthogonal zu Π_s, $0 \leq s \leq n$, dann besitzt Q^1_{-1} Exaktheitsgrad $r \geq n+1+s$.

Beweis. *(i)* Die Quadraturformel Q^1_{-1} sei exakt für Polynome vom Grad $n+1+s$. Für jedes Polynom $q \in \Pi_s$ ist $\omega_{n+1} q \in \Pi_{n+1+s}$. Also gilt

$$\langle \omega_{n+1}, q\rangle = I^1_{-1}[\omega_{n+1} q] = Q^1_{-1}[\omega_{n+1} q] = 2\sum_{j=0}^{n} \gamma_j\, \omega_{n+1}(\eta_j)\, q(\eta_j) = 0,$$

da das Knotenpolynom ω_{n+1} in den Stützstellen η_j verschwindet. Somit ist gezeigt, dass ω_{n+1} orthogonal zu allen $q \in \Pi_s$ ist.

(ii) Sei ω_{n+1} orthogonal zu Π_s. Für jedes beliebige Polynom $p \in \Pi_{n+1+s}$, existieren gemäß Satz 3.2.3 über die Polynomdivision zwei Polynome $\tilde{p} \in \Pi_s$ und $\mathring{p} \in \Pi_n$ mit

$$p = \omega_{n+1}\tilde{p} + \mathring{p}.$$

Wir integrieren p:

$$I_{-1}^1[p] = I_{-1}^1\left[\omega_{n+1}\tilde{p} + \mathring{p}\right] = I_{-1}^1\left[\omega_{n+1}\tilde{p}\right] + I_{-1}^1\left[\mathring{p}\right] = I_{-1}^1\left[\mathring{p}\right], \tag{5.8}$$

da $I_{-1}^1\left[\omega_{n+1}q\right] = 0$ für alle $q \in \Pi_s$.

Andererseits gilt, da $\omega_{n+1}(\eta_j) = 0$, $j = 0, \ldots, n$,

$$Q_{-1}^1[p] = Q_{-1}^1[\omega_{n+1}\tilde{p}] + Q_{-1}^1[\mathring{p}] = Q_{-1}^1[\mathring{p}]. \tag{5.9}$$

Die Quadraturformel Q_{-1}^1 ist exakt für alle Polynome in Π_n, vgl. Bem. 5.4.4. Insbesondere ist

$$Q_{-1}^1[\mathring{p}] = I_{-1}^1\left[\mathring{p}\right],$$

woraus wir mit Hilfe von (5.8) und (5.9) ableiten, dass

$$Q_{-1}^1[p] = I_{-1}^1\left[p\right].$$

Somit ist Q_{-1}^1 exakt für alle $p \in \Pi_{n+1+s}$, und sie besitzt daher Exaktheitsgrad $r \geq n + 1 + s$. □

Aus den Sätzen 5.5.2 und 5.5.3 schließen wir, dass die resultierende Quadraturformel den maximal möglichen Exaktheitsgrad $2n + 1$ genau dann besitzt, wenn als Stützstellen der Quadraturformel die Nullstellen des Legendre-Polynoms P_{n+1} gewählt werden. In diesem Fall ist das Knotenpolynom ω_{n+1} ein reellzahliges Vielfaches von P_{n+1} und somit orthogonal zu Π_n, vgl. Abschnitt 3.4. Diese Art der Quadratur geht auf Gauss zurück, und wird als **Gauss-Legendre-Quadratur** bezeichnet.

Definition 5.5.4: Gauss-Legendre-Formel

Seien $n \in \mathbb{N}_0$ und $\eta_0, \ldots, \eta_n \in [\alpha, \beta]$ die Nullstellen des Legendre-Polynoms P_{n+1}
Dann wird die zugehörige interpolatorische Quadraturformel $G_{-1}^{n,1}$ zur Approximation von I_{-1}^1 als **Gauss-Legendre-Formel** bezeichnet.

5.5.2 Gewichte der Gauss-Legendre-Formeln

Unseren Ausführungen im Abschnitt 5.2.1, insbesondere (5.2), folgend lässt sich die Gauss-Legendre-Formel schreiben als

$$G_{-1}^{n,1}[f] := 2\sum_{j=0}^{n} \gamma_j f(\eta_j) \quad \text{mit den Gewichten} \quad \gamma_j := \frac{1}{2}\int_{-1}^{1} L_j(x)\,\mathrm{d}x.$$

Um eine handliche Formel für die Gewichte herzuleiten, stellen wir die Lagrangeschen Grundpolynome L_j mittels (4.5) über das Knotenpolynom ω_{n+1} dar:

$$\gamma_j = \frac{1}{2}\int_{-1}^{1} \frac{\omega_{n+1}(x)}{\omega'_{n+1}(\eta_j)(x-\eta_j)}\,\mathrm{d}x, \quad j = 0,\dots,n.$$

Da ω_{n+1} ein reellzahliges Vielfaches des Legendre-Polynoms P_{n+1} ist, folgt

$$\gamma_j = \frac{1}{2\,P'_{n+1}(\eta_j)}\int_{-1}^{1} \frac{P_{n+1}(x)}{x-\eta_j}\,\mathrm{d}x, \quad j = 0,\dots,n.$$

Zwei Beobachtungen helfen uns, dieses Integral zu bestimmen. Zunächst ist

$$x \mapsto \frac{P_n(x) - P_n(\eta_j)}{x-\eta_j}$$

ein Polynom vom Höchstgrad $n-1$. Als solches ist es orthogonal zu P_{n+1}. Es folgt

$$P_n(\eta_j)\int_{-1}^{1} \frac{P_{n+1}(x)}{x-\eta_j}\,\mathrm{d}x = \int_{-1}^{1} \frac{P_n(x)P_{n+1}(x)}{x-\eta_j}\,\mathrm{d}x \tag{5.10}$$

und hieraus für die Gewichte γ_j

$$\gamma_j = \frac{1}{2\,P_n(\eta_j)P'_{n+1}(\eta_j)}\int_{-1}^{1} \frac{P_n(x)P_{n+1}(x)}{x-\eta_j}\,\mathrm{d}x, \quad j = 0,\dots,n.$$

(Aufgrund der im Satz 3.7.2 formulierten Trennungseigenschaft ist $P_n(\eta_j) \neq 0$.)
Da η_j eine Nullstelle von P_{n+1} ist, ist

$$x \mapsto \frac{P_{n+1}(x)}{x-\eta_j}$$

ein Polynom n-ten Grades. Folglich existieren ein $\alpha \in \mathbb{R}$ sowie ein Polynom $\pi_{n-1} \in \Pi_{n-1}$, so dass

$$\frac{P_{n+1}(x)}{x-\eta_j} = \alpha\,(P_n(x) + \pi_{n-1}(x))\,.$$

Vergleich der Leitkoeffizienten liefert $\alpha = (2n+1)/(n+1)$. Da P_n und π_{n-1} zueinander orthogonal sind, erhalten wir für die Gewichte

$$\gamma_j = \frac{2n+1}{2(n+1)\,P_n(\eta_j)P'_{n+1}(\eta_j)}\int_{-1}^{1} P_n(x)^2\,\mathrm{d}x = \frac{1}{(n+1)\,P_n(\eta_j)P'_{n+1}(\eta_j)}, \quad j = 0,\dots,n,$$

vgl. Aufg. 3.5.8.
Wir fassen unsere Erkenntnisse zusammen.

Satz 5.5.5

Die Gewichte γ_j, $j = 0,\dots,n$, der Gauss-Legendre-Formel $G^{n,1}_{-1}$, $n \in \mathbb{N}_0$ sind

$$\gamma_j = \frac{1}{(n+1)\,P_n(\eta_j)P'_{n+1}(\eta_j)}, \quad j = 0,\dots,n,$$

wobei η_j, $j = 0,\dots,n$, die Nullstellen des Legendre-Polynoms P_{n+1} sind.

Bemerkung 5.5.6. Aus der Rodrigues-Formel (3.22) für die Legendre-Polynome lässt sich ableiten, dass

$$\left(1-x^2\right)P_i'(x) = i\left(P_{i-1}(x) - xP_i(x)\right), \quad x \in \mathbb{R},\ i \in \mathbb{N}, \tag{5.11}$$

(Übungsaufgabe). Hieraus folgt mit $i = n+1$ und da η_j eine Nullstelle von P_{n+1} ist, dass

$$(n+1)P_n(\eta_j) = (n+1)\left(P_n(\eta_j) - \eta_j P_{n+1}(\eta_j)\right) = \left(1-\eta_j^2\right)P_{n+1}'(\eta_j).$$

Damit erhalten wir ein alternative Darstellung für die Gewichte der Quadraturformel:

$$\gamma_j = \frac{1}{\left(1-\eta_j^2\right)P_{n+1}'(\eta_j)^2}, \quad j = 0,\dots,n, \tag{5.12}$$

wie sie auch häufig in der Literatur zu finden ist.

Bemerkung 5.5.7. Die Ableitungen P_{n+1}' können durch Differentiation der dreigliedrigen Rekursion (3.23) berechnet werden:

$$(i+1)P_{i+1}' = (2i+1)(\mu_1 P_i' + P_i) - iP_{i-1}', \quad i \in \mathbb{N},\ P_0' = 0,\ P_1' = 1.$$

Bemerkung 5.5.8. Die Quadraturformel $G_{-1}^{n,1}$ ist exakt für $L_j^2 \in \Pi_{2n}$, $j = 0,\dots,n$. Es folgt

$$0 < \int_{-1}^{1} L_j(x)^2\,\mathrm{d}x = G_{-1}^{n,1}[L_j^2] = 2\gamma_j,$$

da $L_j(\eta_k) = \delta_j^k$. Die Gewichte sind also positiv. Das lässt sich natürlich auch an (5.12) ablesen.

5.5.3 Fehler der Gauss-Legendre-Formeln

Zur Abschätzung des Quadraturfehlers verfahren wir ähnlich wie bei der Mittelpunkt- und der Simpsonregel, indem wir ein Hilfspolynom konstruieren, das neben Funktionswerten des Integranden f auch Ableitungswerte in den Stützstellen verwendet.

Satz 5.5.9

Sei $f \in C^{2(n+1)}[-1,1]$, $n \in \mathbb{N}_0$. Dann gilt für den Quadraturfehler der Gauss-Legendre-Formel

$$\left|I_{-1}^1[f] - G_{-1}^{n,1}[f]\right| \le \frac{2}{(2n+3)!}\left(\frac{2^{n+1}\left((n+1)!\right)^2}{(2n+2)!}\right)^2 \left\|f^{(2n+2)}\right\|_{[-1,1]}. \tag{5.13}$$

Beweis. Sei zunächst $p_n \in \Pi_n$ jenes eindeutig bestimmte Polynom, das f an den Nullstellen η_j, $j = 0,\dots,n$, des Legendre-Polynoms P_{n+1} interpoliert. Dann gilt definitionsgemäß

$$G_{-1}^{n,1}[f] = \int_{-1}^{1} p_n(x)\,\mathrm{d}x.$$

Wir definieren ein Hilfspolynom $\tilde{p}_{2n+1} \in \Pi_{2n+1}$:

$$\tilde{p}_{2n+1}(\eta_j) = f(\eta_j), \quad \tilde{p}'_{2n+1}(\eta_j) = f'(\eta_j), \quad j = 0, \dots, n.$$

Es gilt

$$\begin{aligned} G_{-1}^{n,1}[f] &= \int_{-1}^{1} p_n(x)\,\mathrm{d}x = G_{-1}^{n,1}[p_n] = G_{-1}^{n,1}[\tilde{p}_{2n+1}], && \text{da } p_n(\eta_j) = \tilde{p}_{2n+1}(\eta_j),\ j = 0, \dots, n, \\ &= \int_{-1}^{1} \tilde{p}_{2n+1}(x)\,\mathrm{d}x, && \text{da } G_{-1}^{n,1}[q] \text{ exakt ist für alle } q \in \Pi_{2n+1}. \end{aligned}$$

Für den Quadraturfehler erhalten wir somit

$$I_{-1}^{1}[f] - G_{-1}^{n,1}[f] = \int_{-1}^{1} (f - \tilde{p}_{2n+1})(x)\,\mathrm{d}x.$$

Wiederum haben wir den Quadraturfehler auf den Interpolationsfehler zurückgeführt. Da wir neben den Funktionswerten von f auch die Ableitungswerte in den Stützstellen verwenden, handelt es sich um eine Hermite-Interpolation, siehe Abschnitt 4.6. Wir greifen auf Satz 4.6.1 mit $r_0 = r_1 = \cdots = r_n = 1$ zurück. Dieser Satz sichert, dass für jedes $x \in [-1, 1]$ ein $\xi(x) \in [-1, 1]$ existiert mit

$$(f - \tilde{p}_{2n+1})(x) = \frac{f^{(2n+2)}(\xi(x))}{(2n+2)!}\Big[\omega_{n+1}(x)\Big]^2.$$

Wir fahren fort wie im Beweis zu Satz 5.2.7 und erhalten

$$\left|I_{-1}^{1}[f] - G_{-1}^{n,1}[f]\right| \le \frac{\left\|f^{(2n+2)}\right\|_{[-1,1]}}{(2n+2)!} \int_{-1}^{1} \Big[\omega_{n+1}(x)\Big]^2\,\mathrm{d}x. \tag{5.14}$$

Durch Vergleich der Höchstkoeffizienten von ω_{n+1} und von P_{n+1}, siehe (3.22), verifizieren wir die Identität

$$\omega_{n+1} = \frac{2^{n+1}\,((n+1)!)^2}{(2n+2)!} P_{n+1}.$$

Außerdem haben wir in Aufg. 3.5.8 nachgewiesen, dass

$$\int_{-1}^{1} P_{n+1}(x)^2\,\mathrm{d}x = \frac{2}{2n+3}.$$

Somit gilt

$$\int_{-1}^{1} \omega_{n+1}(x)^2\,\mathrm{d}x = \left(\frac{2^{n+1}\,((n+1)!)^2}{(2n+2)!}\right)^2 \int_{-1}^{1} P_{n+1}(x)^2\,\mathrm{d}x = \frac{2}{2n+3}\left(\frac{2^{n+1}\,((n+1)!)^2}{(2n+2)!}\right)^2.$$

Wir setzen in (5.14) ein und erhalten die gesuchte Fehlerabschätzung. □

Bemerkung 5.5.10. Die Abschätzung (5.13) ist scharf und kann nicht verbessert werden, weil mit $f^* := \omega_{n+1}^2$ eine Funktion $f^* \in C^{(2n+2)}[-1, 1]$ existiert, für die in (5.13) Gleichheit gilt. Dies ist schnell verifiziert, da $G_{-1}^{n,1}[\omega_{n+1}^2] = 0$.

5.6 Extrapolation und Romberg-Verfahren

In diesem Abschnitt wollen wir mit der **Romberg[4]-Quadratur** eine Technik kennenlernen, die basierend auf der summierten Trapezregel Integralapproximationen beliebig hoher Ordnung gestattet. Dazu werden Näherungen verschiedener Schrittweiten geeignet kombiniert.

Diesem Verfahren zu Grunde liegt das Prinzip der **Richardson[5]-Extrapolation**, einer wichtigen Methode zur Genauigkeitsverbesserung, das universell in vielen Bereichen der Numerik eingesetzt werden kann.

Die Grundidee der Extrapolation wollen wir im nächsten Abschnitt kennenlernen und anschließend auf die Approximation von Integralen anwenden.

5.6.1 Richardson-Extrapolation

Wir betrachten ein numerisches Verfahren, das in Abhängigkeit von einem Diskretisierungsparameter $h > 0$ Näherungen $T_0(h)$ für eine Größe $\mathcal{T}$ berechnet: $\mathcal{T} = \lim_{h\to 0} T_0(h)$. Beispiele sind die numerische Differentiation (siehe Abschnitt 1.3.1) und die Approximation von Integration mit summierten Quadraturformeln.

Voraussetzung für die Durchführbarkeit der Richardson-Extrapolation ist die Existenz einer **asymptotischen Entwicklung** des Fehlers in Potenzen von h für $h \to 0$:

$$T_0(h) = \mathcal{T} + \tau_1 h^\kappa + \tau_2 h^{2\kappa} + \cdots + \tau_\ell h^{\ell\kappa} + R_{0,\ell}(h) \tag{5.15a}$$

mit einem Restglied

$$\left|R_{0,\ell}(h)\right| \le C_R h^{(\ell+1)\kappa}, \tag{5.15b}$$

gewissen Koeffizienten $\tau_j \in \mathbb{R}$, $j = 1, \ldots, \ell$, sowie Zahlen $\kappa > 0$ und $C_R \ge 0$.

Beispiel 5.6.1. Im Abschnitt 1.3.1 hatten wir über den Differenzenquotienten

$$(\delta_h f)(x) := \frac{f(x+h) - f(x)}{h}$$

Näherungen für $f'(x)$ berechnet und hinsichtlich Genauigkeit untersucht. Ist $f \in C^{\ell+2}[a,b]$, $\ell \in \mathbb{N}_0$, dann liefert eine Taylor-Entwicklung an der Stelle x für $a \le x < x + h \le b$:

$$(\delta_h f)(x) = f'(x) + \frac{f''(x)}{2}h + \frac{f'''(x)}{3!}h^2 + \cdots + \frac{f^{(\ell+1)}(x)}{(\ell+1)!}h^\ell + R_{0,\ell}(h)$$

mit dem Restglied $R_{0,\ell}(h)$

$$\left|R_{0,\ell}(h)\right| \le \frac{\left\|f^{(\ell+2)}\right\|_{[a,b]}}{(\ell+2)!}h^{\ell+1}.$$

Dies ist eine asymptotische Entwicklung der Art (5.15a) für $T_0(h) = (\delta_h f)(x)$ und $\mathcal{T} = f'(x)$ mit $\kappa = 1$. ♠

[4] Werner Romberg, *16.5.1909 (Berlin) †5.2.2003 (Heidelberg)

[5] Lewis Fry Richardson, 11.10.1881 (Newcastle upon Tyne, England), †30.9.1953 (Kilmun, Scotland)

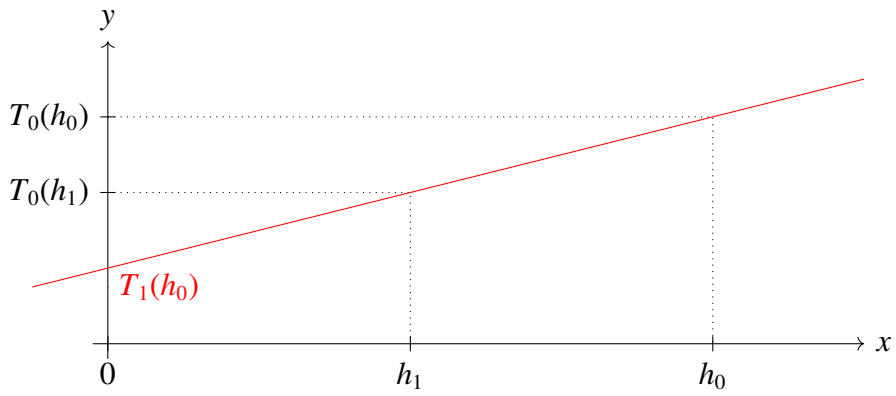


Abbildung 5.6: Geometrische Interpretation der Extrapolation

5.6.1.1 Die Idee der Extrapolation

Wir wollen zunächst die Idee der RICHARDSON-Extrapolation an einem kleinen Beispiel darstellen. Dazu betrachten wir (5.15) für $\ell = 1$ und $\kappa = 1$:

$$T_0(h) = \mathcal{T} + \tau_1 h + R_{0,1}(h) \tag{5.16a}$$

mit dem Restglied

$$\left|R_{0,1}(h)\right| \leq C_R h^2 \,. \tag{5.16b}$$

Als erstes berechnen wir für zwei verschiedene Schrittweiten h_0 und $h_1 = h_0/2$ die Näherungen $T_0(h_0)$ und $T_0(h_1)$. Gemäß (5.16a) gilt für diese

$$T_0(h_0) = \mathcal{T} + \tau_1 h_0 + R_{0,1}(h_0), \tag{5.17a}$$

$$T_0\left(\frac{h_0}{2}\right) = \mathcal{T} + \tau_1 \frac{h_0}{2} + R_{0,1}\left(\frac{h_0}{2}\right). \tag{5.17b}$$

Wir eliminieren nun die Terme, die τ_1 enthalten. Dazu multiplizieren wir (5.17b) mit zwei und subtrahieren (5.17a):

$$T_1(h_0) := 2T_0\left(\frac{h_0}{2}\right) - T_0(h_0) = \mathcal{T} + 2R_{0,1}\left(\frac{h_0}{2}\right) - R_{0,1}(h_0) \,. \tag{5.18}$$

Wir haben so eine neue Näherung $T_1(h_0)$ für die gesuchte Größe $\mathcal{T}$ erhalten. Für deren Fehler können wir aus (5.18) unmittelbar eine Fehlerabschätzung ableiten:

$$|T_1(h_0) - \mathcal{T}| \leq \left|2R_{0,1}\left(\frac{h_0}{2}\right)\right| + \left|R_{0,1}(h_0)\right| \leq \frac{3}{2} C_R h_0^2 \,, \quad \text{wegen (5.16b).}$$

Die Extrapolationsidee kann geometrisch interpretiert werden. In der (x, y)-Ebene verbinden wir die Punkte $(h_0, T_0(h_0))$ und $(h_1, T_0(h_1))$ durch eine Gerade. Deren Schnittpunkt mit der y-Achse liefert die verbesserte Näherung: $(0, T_1(h_0))$, siehe Abbildung 5.6.

Aber auch eine Interpretation im Rahmen der Interpolation ist möglich: $T_1(h_0) = q_1(0)$, wobei $q_1 \in \Pi_1$ jenes Polynom ist, das den Interpolationsbedingungen $q_1(h_0) = T_0(h_0)$ und $q_1(h_1) = T_0(h_1)$ genügt.

Durch geschickte Kombination zweier Näherungen erster Ordnung haben wir eine Näherung zweiter Ordnung erhalten. Die Extrapolationsidee kann aber noch weiter getrieben werden, indem Näherungswerte für weitere Schrittweiten einbezogen werden. Zur Illustration nehmen wir an, dass (5.15) für $\ell = 2$ und wiederum $\kappa = 1$ gilt, also

$$T_0(h) = \mathcal{T} + \tau_1 h + \tau_2 h^2 + R_{0,2}(h) \tag{5.19a}$$

und

$$\left|R_{0,2}(h)\right| \leq C_R h^3 \,. \tag{5.19b}$$

Wie bisher verwenden wir Schrittweiten h_0 und $h_1 = h_0/2$ sowie als weitere Schrittweite $h_2 = h_0/4$. Wir berechnen $T_1(h_0)$ und $T_1(h_1) = T_1(h_0/2)$ gemäß (5.18) und erhalten unter Beachtung von (5.19a)

$$T_1(h_0) = 2T_0\left(\frac{h_0}{2}\right) - T_0(h_0) = \mathcal{T} - \tau_2 \frac{h_0^2}{2} + 2R_{0,2}\left(\frac{h_0}{2}\right) - R_{0,2}(h_0) \tag{5.20a}$$

sowie

$$T_1\left(\frac{h_0}{2}\right) = 2T_0\left(\frac{h_0}{4}\right) - T_0\left(\frac{h_0}{2}\right) = \mathcal{T} - \tau_2 \frac{h_0^2}{8} + 2R_{0,2}\left(\frac{h_0}{4}\right) - R_{0,2}\left(\frac{h_0}{2}\right) \tag{5.20b}$$

Nun eliminieren wir τ_2 indem wir (5.20b) mit vier multiplizieren und (5.20a) subtrahieren:

$$4T_1\left(\frac{h_0}{2}\right) - T_1\left(h_0\right) = 3\mathcal{T} + 8R_{0,2}\left(\frac{h_0}{4}\right) - 6R_{0,2}\left(\frac{h_0}{2}\right) + R_{0,2}\left(h_0\right) \,. \tag{5.21}$$

Wir dividieren durch drei und erhalten

$$T_2(h_0) := \frac{4T_1\left(h_0/2\right) - T_1\left(h_0\right)}{3} = \mathcal{T} + R_{2,2}(h_0)$$

mit dem Restglied

$$R_{2,2}(h_0) := \frac{1}{3}\left\{8R_{0,2}\left(\frac{h_0}{4}\right) - 6R_{0,2}\left(\frac{h_0}{2}\right) + R_{0,2}\left(h_0\right)\right\} \,,$$

den wir betragsmäßig mit Hilfe von (5.19b) wie folgt abschätzen

$$\left|R_{2,2}(h_0)\right| \leq \frac{C_R}{3}\left\{8\left(\frac{h_0}{4}\right)^3 + 6\left(\frac{h_0}{2}\right)^3 + h_0^3\right\} = \frac{5C_R}{8}h_0^3 \,.$$

Die Größe $T_2(h_0)$ ist also eine Näherung dritter Ordnung für $\mathcal{T}$.

Auch diese Vorgehensweise zur Bestimmung von $T_2(h_0)$ kann auf Interpolation zurückgeführt werden, da $T_2(h_0) := q_2(0)$, wobei q_2 jenes Polynom aus Π_2 ist, das die Interpolationsbedingungen

$$q_2(h_i) = T_0(h_i), \quad i = 0, 1, 2,$$

erfüllt; siehe Abbildung 5.7

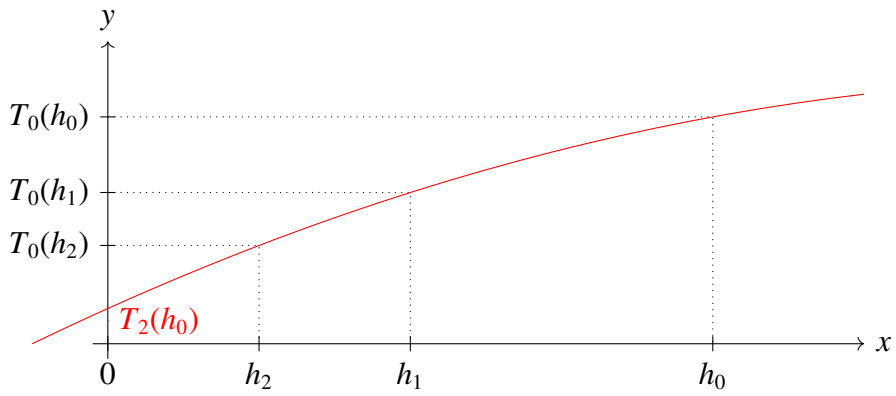


Abbildung 5.7: Geometrische Interpretation der Extrapolation II

5.6.1.2 Extrapolation durch Polynominterpolation

Wir wollen nun unsere Überlegungen aus dem vorangegangen Abschnitt abstrakter fassen und dabei gleichzeitig verallgemeinern. Die asymptotische Fehlerentwicklung (5.15a) können wir schreiben als

$$T_0(h) = p_\ell(h^\kappa) + R_{0,\ell}(h) \tag{5.22}$$

mit dem Polynom $p_\ell := \mathcal{T} + \tau_1\mu_1 + \tau_2\mu_2 + \cdots + \tau_\ell\mu_\ell \in \Pi_\ell$, dessen Koeffizienten uns jedoch unbekannt sind. Insbesondere wollen wir ja gerade für $\mathcal{T} = p(0)$ eine Näherung berechnen.

Die Idee der Richardson-Extrapolation ist nun, unter Vernachlässigung des Restgliedes $R_{0,\ell}$, ein Polynom $q_\ell \in \Pi_\ell$ zu bestimmen, das p_ℓ approximiert. Dessen Wert an der Stelle Null verwenden wir, um eine verbesserte Näherung für $\mathcal{T}$ zu gewinnen: $\mathcal{T} = p_\ell(0) \approx q_\ell(0)$.

Wir wählen verschiedene Schrittweiten $\hbar := h_0 > h_1 > \cdots > h_\ell > 0$, berechnen für diese $T_0(h_i)$ und definieren $q_\ell \in \Pi_\ell$ durch die Interpolationsbedingungen

$$q_\ell\left(h_i^\kappa\right) = T_0(h_i), \quad i = 0, \ldots, \ell. \tag{5.23}$$

Als neuer Näherungswert für $\mathcal{T}$ ergibt sich

$$T_\ell(\hbar) := q_\ell(0).$$

Da das Polynom q_ℓ lediglich an einer Stelle auszuwerten ist, werden wir den Algorithmus von Aitken und Neville zum Einsatz bringen, den wir im Abschnitt 4.4.1 kennengelernt haben.

Die Bezeichnung **Extrapolation** leitet sich daraus ab, dass das Interpolationspolynom außerhalb des durch die Stützstellen abgegrenzten Intervalls ausgewertet wird.

5.6.1.3 Fehlerabschätzung

Bevor wir uns den algorithmischen Aspekten widmen und uns ein kleines illustrierendes Beispiel ansehen, wollen wir den Fehler des Verfahrens untersuchen. Wir gehen von der Existenz einer asymptotischen Entwicklung (5.15) mit einem $\kappa > 0$ aus, fixieren das Verhältnis der Schrittweiten

und setzen $h_i := \hbar\nu_i$, $i = 0, \dots, \ell$, mit $\nu_0 = 1 > \nu_1 > \cdots > \nu_\ell > 0$, die unabhängig von der größten Schrittweite $\hbar \in \mathbb{R}_+$ sind.

Wir benutzen die Lagrangeschen Basispolynome L_i zu den Stützstellen h_i^κ, $i = 0, \dots, \ell$, um den Fehler wie folgt darzustellen.

$$R_{\ell,\ell}(\hbar) := T_\ell(\hbar) - \mathcal{T} = q_\ell(0) - p_\ell(0) = \sum_{i=0}^{\ell} L_i(0)\left(q_\ell(h_i^\kappa) - p_\ell(h_i^\kappa)\right).$$

Für die Summanden auf der rechten Seite gewinnen wir aus der Fehlerentwicklung (5.22) und der Interpolationsbedingung (5.23) die Darstellung

$$q_\ell(h_i^\kappa) - p_\ell(h_i^\kappa) = R_{0,\ell}(h_i).$$

Es folgt

$$R_{\ell,\ell}(\hbar) = \sum_{i=0}^{\ell} L_i(0) R_{0,\ell}(h_i).$$

Wir verifizieren durch Ausklammern von $\hbar$ und Kürzen, dass

$$L_i(0) = \prod_{m=0,\ m\neq i}^{\ell} \frac{h_m^\kappa}{h_m^\kappa - h_i^\kappa} = \prod_{m=0,\ m\neq i}^{\ell} \frac{\nu_m^\kappa}{\nu_m^\kappa - \nu_i^\kappa}.$$

Um die $R_{0,\ell}(h_i)$ abzuschätzen benutzen wir (5.15b):

$$\left|R_{0,\ell}(h_i)\right| \le C_R\,(\nu_i\hbar)^{(\ell+1)\kappa}$$

Wir erhalten so für den Fehler des Extrapolationsverfahrens

$$|T_\ell(\hbar) - \mathcal{T}| = \left|R_{\ell,\ell}(\hbar)\right| \le C_R C_\ell \hbar^{(\ell+1)\kappa}. \tag{5.24}$$

mit der Konstante

$$C_\ell := \left| \sum_{i=0}^{\ell} \nu_i^{(\ell+1)\kappa} \prod_{m=0,\ m\neq i}^{\ell} \frac{\nu_m^\kappa}{\nu_m^\kappa - \nu_i^\kappa} \right|.$$

5.6.1.4 Praktische Durchführung der Extrapolation

Zunächst werden die Approximationen $T_0(h_i)$ berechnet und anschließend das durch die Wertepaare $(h_i^\kappa, T_0(h_i))$, $i = 0, \dots, \ell$, definierte Polynom, wie schon erwähnt, mit Alg. 4.4.3, dem Verfahren von Aitken und Neville, an der Stelle 0 ausgewertet.

Algorithmus 5.6.2: RICHARDSON-Extrapolation

Gegeben: Ein Verfahren zur Berechnung von Näherungen $T_0(h)$ für eine Größe $\mathcal{T}$ mit asymptotischer Entwicklung (5.15), $\hbar > 0$ sowie $\nu_0 = 1 > \nu_1 > \cdots > \nu_\ell > 0$.

S1. Berechnung der Anfangsnäherungen mit dem Grundverfahren

FOR $m = 0, \ldots, \ell$ DO

$T_{0,m} := T_0(\nu_m \hbar)$

END DO

S2. Extrapolation der Näherungen mit dem Algorithmus von AITKEN und NEVILLE

FOR $i = 1, \ldots, \ell$ DO

FOR $m = i, \ldots, \ell$ DO

$$T_{i,m} := T_{i-1,m} + \frac{T_{i-1,m} - T_{i-1,m-1}}{(\nu_{m-i}/\nu_m)^\kappa - 1}$$

END DO

END DO

Ergebnis: Eine Näherung $T_{\ell,\ell}$ der Ordnung $\hbar^{(\ell+1)\kappa}$ für $\mathcal{T}$.

Beispiel 5.6.3. Wir kommen zurück auf die im Abschnitt 1.3.1 untersuchte Approximation der Ableitung der Exponentialfunktion durch den Differenzenquotienten δ_h. Im Bsp. 5.6.1 haben wir gesehen, dass für δ_h eine asymptotische Entwicklung (5.15a) mit $\kappa = 1$ existiert. Folglich ist die RICHARDSON-Extrapolation anwendbar.

			extrapolierte Näherungen $T_{i,k}$			
k	h_k	$T_{0,k}$	$i = 1$	$i = 2$	$i = 3$	$i = 4$
0	1	1.952				
1	2^{-1}	$8.085 \cdot 10^{-1}$	$3.354 \cdot 10^{-1}$			
2	2^{-2}	$3.700 \cdot 10^{-1}$	$6.861 \cdot 10^{-2}$	$2.033 \cdot 10^{-2}$		
3	2^{-3}	$1.772 \cdot 10^{-1}$	$1.557 \cdot 10^{-2}$	$2.114 \cdot 10^{-3}$	$4.882 \cdot 10^{-4}$	
4	2^{-4}	$8.674 \cdot 10^{-2}$	$3.710 \cdot 10^{-3}$	$2.416 \cdot 10^{-4}$	$2.592 \cdot 10^{-5}$	$4.898 \cdot 10^{-6}$
5	2^{-5}	$4.292 \cdot 10^{-2}$	$9.059 \cdot 10^{-4}$	$2.889 \cdot 10^{-5}$	$1.496 \cdot 10^{-6}$	$1.326 \cdot 10^{-7}$
6	2^{-6}	$2.135 \cdot 10^{-2}$	$2.238 \cdot 10^{-4}$	$3.533 \cdot 10^{-6}$	$8.987 \cdot 10^{-8}$	$3.860 \cdot 10^{-9}$
7	2^{-7}	$1.065 \cdot 10^{-2}$	$5.563 \cdot 10^{-5}$	$4.368 \cdot 10^{-7}$	$5.507 \cdot 10^{-9}$	$1.165 \cdot 10^{-10}$
8	2^{-8}	$5.316 \cdot 10^{-3}$	$1.387 \cdot 10^{-5}$	$5.430 \cdot 10^{-8}$	$3.409 \cdot 10^{-10}$	$3.554 \cdot 10^{-12}$
9	2^{-9}	$2.656 \cdot 10^{-3}$	$3.462 \cdot 10^{-6}$	$6.769 \cdot 10^{-9}$	$2.117 \cdot 10^{-11}$	$1.390 \cdot 10^{-13}$
10	2^{-10}	$1.328 \cdot 10^{-3}$	$8.648 \cdot 10^{-7}$	$8.452 \cdot 10^{-10}$	$1.145 \cdot 10^{-12}$	$1.901 \cdot 10^{-13}$
11	2^{-11}	$6.638 \cdot 10^{-4}$	$2.161 \cdot 10^{-7}$	$1.051 \cdot 10^{-10}$	$6.097 \cdot 10^{-13}$	$5.742 \cdot 10^{-13}$
12	2^{-12}	$3.318 \cdot 10^{-4}$	$5.401 \cdot 10^{-8}$	$1.659 \cdot 10^{-11}$	$3.943 \cdot 10^{-12}$	$4.246 \cdot 10^{-12}$

Tabelle 5.1: Fehler der Approximation von $\exp'(1)$ durch $T_{0,k} := (\delta_h \exp)(1)$ und Verbesserung durch i Extrapolationsschritte, $i = 1, \ldots, 4$, $\nu_k = (1/2)^k$.

Mit Blick auf die Fehlerabschätzung (5.24) rechnen wir in diesem Beispiel bei einer Halbierung der Schrittweite mit einer Verringerung des Fehlers um den Faktor 2^{i+1}, da $\kappa = 1$. Dies ist in der Tabelle auch zu sehen. In der vierten Spalte ($i = 1$) ist der Quotient aus aufeinanderfolgenden Einträgen ca. 4, in der fünften Spalte ($i = 2$) ist er ca. 8. In den beiden letzten Spalten machen wir zunächst vergleichbare Beobachtungen, wenn wir die Spalten nach unten gehen. Allerdings

reißt die Konvergenz für $i = 3$ bei $\hbar = 2^{-7}$ (bzw. $\hbar = 2^{-5}$ für $i = 4$) ab. Hier macht sich wieder bemerkbar, dass unser Rechner mit Gleitkommazahlen (mit eps = 10^{-16}) arbeitet und nicht mit reellen Zahlen. Mit einem Fehler von ca. 10^{-13} sind die so berechneten Näherungen aber wesentlich genauer als unter Verzicht auf die Extrapolation in Abschnitt 1.3.1, wo die beste erreichbare Approximation einen Fehler von 10^{-8} aufwies. ♠

5.6.2 Das Romberg-Verfahren

Wir wollen jetzt die Extrapolationsidee auf die Berechnung von Integralen anwenden. Voraussetzung für den Erfolg der Extrapolation ist eine asymptotische Entwicklung des Fehlers entsprechend (5.15a). Eine solche ist für die summierte Trapezregel mit der sog. Euler[6]-Maclaurin[7]sche Summenformel des folgenden Satzes gegeben. Auf einen Beweis wollen wir an dieser Stelle verzichten.

Satz 5.6.4

Seien $f \in C^{2\ell+2}[a,b]$, $\ell \in \mathbb{N}$, und $h = (b-a)/m$, $m \in \mathbb{N}$. Dann gilt für die summierte Trapezregel

$$T^b_{a,m}[f] = I^b_a[f] + \sum_{k=1}^{\ell} \tau_k h^{2k} + R_\ell(h),$$

mit gewissen Konstanten $\tau_k \in \mathbb{R}$, $k = 1, \ldots, \ell$, und einem Restglied $|R_\ell(h)| \le Ch^{2\ell+2}$.

Bei der praktischen Durchführung starten wir von der summierten Trapezregel $T^b_{a,m_0}[f]$, $m_0 \in \mathbb{N}$, auf einem groben Gitter mit Gitterweite $\hbar := (b-a)/m_0$, berechnen weitere Näherungen $T^b_{a,m_i}[f]$, mit der Trapezregel auf feineren Gittern mit $m_0 < m_1 < \cdots < m_\ell$, $m_i \in \mathbb{N}$, $i = 0, \ldots, \ell$, und führen mit diesen Näherungswerten die Extrapolation gemäß Alg. 5.6.2 durch. Wir fassen dieses Vorgehen formal wie folgt.

Algorithmus 5.6.5: Romberg-Verfahren

Gegeben: $f \in C^{2\ell+2}[a,b]$, $\ell \in \mathbb{N}$, eine Folge natürlicher Zahlen $m_0 < m_1 < \cdots < m_\ell$.

S1. Berechnung der Trapezsummen
FOR $k = 0, \ldots, \ell$ DO
$T_{0,k} := T^b_{a,m_k}[f]$
END DO

S2. Extrapolation der Trapezsummen
FOR $i = 1, \ldots, \ell$ DO
FOR $k = i, \ldots, \ell$ DO
$$T_{i,k} := T_{i-1,k} + \frac{T_{i-1,k} - T_{i-1,k-1}}{(m_k/m_{k-i})^2 - 1}$$
END DO
END DO

Ergebnis: Eine Näherung $T_{\ell,\ell}$ für $I^b_a[f]$ mit einem Fehler $\left|R_{\ell,\ell}(\hbar)\right| \le C\hbar^{2(\ell+1)}$, $\hbar = (b-a)/m_0$.

Zwei gängige Verfeinerungsfolgen $\{m_k\}_{k=0}^{\ell}$ für die Trapezsummen sind, bei gegebenem $m_0 \in \mathbb{N}$, die

[6]Leonhard Euler, *15.4.1707 (Basel, Schweiz), †18.9.1783 (St. Petersburg, Russland)
[7]Colin Maclaurin, 2/1698 (Kilmodan, Argyllshire, Schottland) †14.6.1746 (Edinburgh, Schottland)

ROMBERG-Folge:

$$m_k = 2^k m_0, \quad k = 1, 2, \ldots$$

BULIRSCH[8]-Folge:

$$m_{2k-1} = 2^k m_0, \quad m_{2k} = 3 \cdot 2^{k-1} m_0, \quad k = 1, 2, \ldots$$

Die klassische ROMBERG-Folge führt zu einem einfacheren Rechenschema, während bei Verwendung der BULIRSCH-Folge weniger Funktionsauswertungen erforderlich sind. Für $\ell = 8$ sind dies $32m_0 + 1$ unter Verwendung der BULIRSCH-Folge, aber $256m_0 + 1$ bei der ROMBERG-Folge.

Wir wollen diesen Abschnitt mit einem numerischen Experiment beschließen und betrachten wieder das Integral

$$I_0^1[\exp] = \int_0^1 \mathrm{e}^x \, \mathrm{d}x = \mathrm{e} - 1 \approx 1.718281828459046.$$

Tabelle 5.2 enthält neben den Fehlern der Trapezregel (dritte Spalte) auch jene der aus ihr extrapolierten Näherungen für bis zu vier Extrapolationsschritte (Spalten 4-7). Man überzeugt sich (z. B. durch Multiplikation der Fehler mit $m_k^{2(i+1)}$), dass für festes i die Fehler proportional zu $m_k^{-2(i+1)}$ kleiner werden bis in etwa die Maschinengenauigkeit erreicht wird. Die entsprechenden Werte hierfür sind in der Tabelle unterstrichen.

		Trapezs. $T_{0,k}$	extrapolierte Näherungen $T_{i,k}$			
k	m_k	$T^1_{0,m_k}[\exp]$	$i=1$	$i=2$	$i=3$	$i=4$
0	1	$1.41 \cdot 10^{-1}$				
1	2	$3.56 \cdot 10^{-2}$	$5.79 \cdot 10^{-4}$			
2	2^2	$8.94 \cdot 10^{-3}$	$3.70 \cdot 10^{-5}$	$8.59 \cdot 10^{-7}$		
3	2^3	$2.24 \cdot 10^{-3}$	$2.33 \cdot 10^{-6}$	$1.38 \cdot 10^{-8}$	$3.35 \cdot 10^{-10}$	
4	2^4	$5.59 \cdot 10^{-4}$	$1.46 \cdot 10^{-7}$	$2.16 \cdot 10^{-10}$	$1.34 \cdot 10^{-12}$	$3.29 \cdot 10^{-14}$
5	2^5	$1.40 \cdot 10^{-4}$	$9.10 \cdot 10^{-9}$	$3.38 \cdot 10^{-12}$	$\underline{4.88 \cdot 10^{-15}}$	$\underline{4.44 \cdot 10^{-16}}$
6	2^6	$3.50 \cdot 10^{-5}$	$5.69 \cdot 10^{-10}$	$5.40 \cdot 10^{-14}$	$1.11 \cdot 10^{-15}$	$1.11 \cdot 10^{-15}$
7	2^7	$8.74 \cdot 10^{-6}$	$3.56 \cdot 10^{-11}$	$\underline{4.44 \cdot 10^{-16}}$	$1.33 \cdot 10^{-15}$	$1.33 \cdot 10^{-15}$
8	2^8	$2.18 \cdot 10^{-6}$	$2.22 \cdot 10^{-12}$	$8.88 \cdot 10^{-16}$	$8.88 \cdot 10^{-16}$	$8.88 \cdot 10^{-16}$
9	2^9	$5.46 \cdot 10^{-7}$	$1.40 \cdot 10^{-13}$	$1.11 \cdot 10^{-15}$	$1.11 \cdot 10^{-15}$	$1.11 \cdot 10^{-15}$
10	2^{10}	$1.37 \cdot 10^{-7}$	$7.11 \cdot 10^{-15}$	$1.78 \cdot 10^{-15}$	$1.78 \cdot 10^{-15}$	$1.78 \cdot 10^{-15}$

Tabelle 5.2: Fehler der extrapolierten Trapezsumme zur Berechnung von $I_0^1[\exp]$ mit i Extrapolationsschritten, $i = 1, \ldots, 4$, ROMBERG-Folge.

Dieses Beispiel illustriert sehr gut die Effizienz von Extrapolationsverfahren. Mit lediglich 33 Funktionsauswertungen für $T_{4,5}$ erhalten wir bereits eine Näherung im Bereich der Maschinengenauigkeit. Voraussetzung dafür ist allerdings die Stetigkeit entsprechend hoher Ableitungen des Integranden.

[8] Roland Zdeněk Bulirsch, *10.11.1932 (Liberec, Tschechoslowakei) †21.9.2022 (Gauting)

5.7 Lösungen der Aufgaben

Lösung 5.2.2.

$$\sum_{j=0}^{n} \gamma_j = \sum_{j=0}^{n} \frac{1}{\beta-\alpha} \int_\alpha^\beta L_j(x)\,\mathrm{d}x = \frac{1}{\beta-\alpha} \int_\alpha^\beta \sum_{j=0}^{n} L_j(x)\,\mathrm{d}x = \frac{1}{\beta-\alpha} \int_\alpha^\beta 1\,\mathrm{d}x, \quad \text{vgl. Aufg. 4.2.5,}$$
$$= 1. \qquad \clubsuit$$

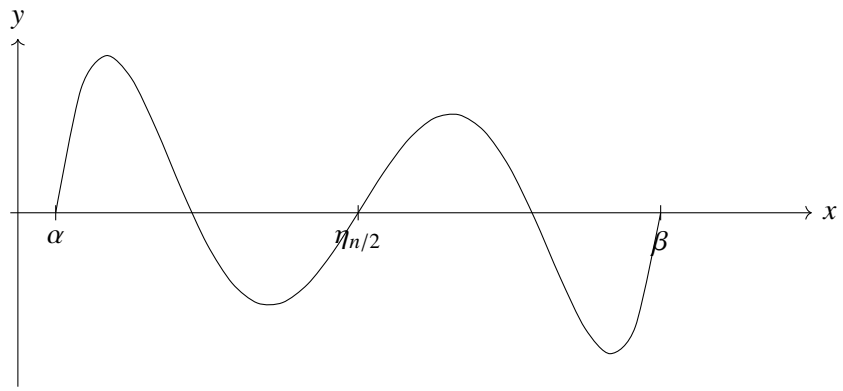
Lösung 5.2.10. Die Polynome $p_n \in \Pi_n$ und $\tilde{p}_{n+1} \in \Pi_{n+1}$ sind definiert durch

$$p_n(\eta_j) = \tilde{p}_{n+1}(\eta_j) = f(\eta_j), \quad j = 0, \dots, n, \quad \text{sowie} \quad \tilde{p}'_{n+1}(\eta_{n/2}) = f'(\eta_{n/2}).$$

Somit ist ihre Differenz $q := \tilde{p}_{n+1} - p_n \in \Pi_{n+1}$ durch die Interpolationsbedingungen

$$q(\eta_j) = 0, \quad j = 0, \dots, n, \quad \text{sowie} \quad q'(\eta_{n/2}) = (f' - p'_n)(\eta_{n/2}).$$

eindeutig definiert.



$p_n - \tilde{p}_{n+1}$

Das Polynom q ist ungerade bzgl. des Mittelpunktes $\eta_{n/2}$ des Intervalls $[\alpha,\beta]$, d. h.

$$q(\eta_{n/2} + x) = -q(\eta_{n/2} - x), \quad x \in \mathbb{R}. \tag{5.25}$$

Die Integrale auf dem linken Teilintervall $[\alpha, \eta_{n/2}]$ und dem rechten $[\eta_{n/2}, \beta]$ addieren sich dann zu Null.

Zum Nachweis von (5.25) überlegt man sich, dass das Polynom $\pi \in \Pi_{n+1}$, $\pi(x) := q(\eta_{n/2} + x) + q(\eta_{n/2} - x)$ die $n+1$ Nullstellen $\eta_j - \eta_{n/2}$, $j = 0, \dots, n$, hat, da $\pi(\eta_j - \eta_{n/2}) = q(\eta_j) + q(2\eta_{n/2} - \eta_j) = q(\eta_j) + q(\eta_{n-j}) = 0$. Ferner besitzt die Nullstelle 0 die Vielfachheit zwei, da $\pi'(x) = q'(\eta_{n/2} + x) - q'(\eta_{n/2} - x)$, also $\pi'(0) = 0$. Satz 3.2.5 impliziert dann, dass $\pi = 0$ auf $\mathbb{R}$.

$$\begin{aligned}
\int_\alpha^\beta (p_n - \tilde{p}_{n+1})(x)\,\mathrm{d}x = \int_\alpha^\beta q(x)\,\mathrm{d}x &= \int_\alpha^{\eta_{n/2}} q(x)\,\mathrm{d}x + \int_{\eta_{n/2}}^\beta q(x)\,\mathrm{d}x \\
&= -\int_{(\beta-\alpha)/2}^{0} q(\eta_{n/2} - t)\,\mathrm{d}t + \int_0^{(\beta-\alpha)/2} q(\eta_{n/2} + t)\,\mathrm{d}t \\
&= \int_0^{(\beta-\alpha)/2} \Big[\underbrace{q(\eta_{n/2} - t) + q(\eta_{n/2} + t)}_{=\pi(t)=0}\Big]\,\mathrm{d}t = 0
\end{aligned}$$

♣

Lösung 5.4.7. Es genügt, die Quadraturformeln auf dem Intervall $[0, 1]$ zu betrachten. Es gilt

$$I_0^1[\mu_k] = \int_0^1 x^k \, \mathrm{d}x = \frac{1}{k+1}, \quad k \in \mathbb{N}_0.$$

Linksseitige Rechteckregel:

$$L_0^1[\mu_0] = (1-0) \cdot 1 = 1 = I_0^1[\mu_0],$$
$$L_0^1[\mu_1] = (1-0) \cdot 0 \neq \frac{1}{2} = I_0^1[\mu_1].$$

Die Quadraturformel ist exakt auf Π_0, aber nicht auf Π_1. Gleiches gilt für die rechtsseitige Rechteckregel.

Mittelpunktregel:

$$M_0^1[\mu_0] = (1-0) \cdot 1 = 1 = I_0^1[\mu_0],$$
$$M_0^1[\mu_1] = (1-0) \cdot \frac{1}{2} = \frac{1}{2} = I_0^1[\mu_1],$$
$$M_0^1[\mu_2] = (1-0) \cdot \frac{1}{4} \neq \frac{1}{3} = I_0^1[\mu_2].$$

Die Mittelpunktregel ist exakt auf Π_1, aber nicht auf Π_2.

Trapezregel:

$$T_0^1[\mu_0] = \frac{1-0}{2} \cdot (1+1) = 1 = I_0^1[\mu_0],$$
$$T_0^1[\mu_1] = \frac{1-0}{2} \cdot (0+1) = \frac{1}{2} = I_0^1[\mu_1],$$
$$T_0^1[\mu_2] = \frac{1-0}{2} \cdot (0+1) = \frac{1}{2} \neq \frac{1}{3} = I_0^1[\mu_2].$$

Die Trapezregel ist ebenfalls exakt auf Π_1, aber nicht auf Π_2.

Simpson*regel:*

$$S_0^1[\mu_0] = \frac{1-0}{6} \cdot (1+4+1) = 1 = I_0^1[\mu_0],$$
$$S_0^1[\mu_1] = \frac{1-0}{6} \cdot \left(0 + 4\frac{1}{2} + 1\right) = \frac{1}{2} = I_0^1[\mu_1],$$
$$S_0^1[\mu_2] = \frac{1-0}{6} \cdot \left(0 + 4\frac{1}{4} + 1\right) = \frac{1}{3} = I_0^1[\mu_2],$$
$$S_0^1[\mu_3] = \frac{1-0}{6} \cdot \left(0 + 4\frac{1}{8} + 1\right) = \frac{1}{4} = I_0^1[\mu_3],$$
$$S_0^1[\mu_4] = \frac{1-0}{6} \cdot \left(0 + 4\frac{1}{16} + 1\right) = \frac{5}{24} \neq \frac{1}{5} = I_0^1[\mu_4].$$

Die Simpsonregel ist exakt auf Π_3, aber nicht auf Π_4. ♣

Kapitel 6

Spline-Interpolation

Im Abschnitt 4.8 hatten wir gesehen, dass die Erhöhung des Polynomgrades nicht immer zu einer Verbesserung der Approximationsgüte des Interpolationspolynoms führt. Dies gilt insbesondere, wenn die zu interpolierende Funktion nur geringe Regularität aufweist. In diesem Fall stellt die Verwendung zusammengesetzter Polynome niedrigen Grades eine Alternative dar. Dazu wird das Intervall, auf dem die Funktion zu approximieren ist, in Teilintervalle zerlegt, auf denen mit unterschiedlichen Polynomen gearbeitet wird. Der Übergang zwischen den Teilintervallen kann unterschiedlich glatt gewählt werden.

Splines finden außerdem Anwendung in numerischen Verfahren zur näherungsweisen Lösung von Differentialgleichungen. Bei Konvergenzuntersuchungen für diese Verfahren wird häufig auf Aussagen zum Fehler von interpolierenden Splines zurückgegriffen.

Darüber hinaus sind Spline-Kurven und Spline-Flächen klassische Werkzeuge im Computer Aided Geometric Design.

6.1 Polynomiale Splines

Definition 6.1.1

Seien $\Delta\colon a = \xi_0 < \xi_1 < \cdots < \xi_n = b$ eine **Zerlegung** (oder auch **Partitionierung**) von $[a, b]$, $I_j := (\xi_{j-1}, \xi_j)$, $h_j := \xi_j - \xi_{j-1}$, $i = 1, \ldots, n$, und $h := \max\limits_{j=1,\ldots,n} h_j$.

Für $\ell, m \in \mathbb{N}_0$, $\ell < m$, definieren wir

$$\mathcal{S}_m^\ell(\Delta) := \left\{ s \in C^\ell[a, b] : s|_{I_j} \in \Pi_m,\ j = 1, \ldots, n \right\}.$$

Eine Funktion $s \in \mathcal{S}_m^\ell(\Delta)$ wird als **(polynomialer) Spline vom Grad m und der Glattheit ℓ zur Zerlegung Δ** bezeichnet. Die ξ_i heißen die **Knoten** des Splines.

Bemerkung 6.1.2. Der Begriff „Spline“ stammt aus dem Schiffsbau. Splines (deutsch „Straklatte“) sind dünne elastische Stäbe zumeist aus Holz und werden verwendet, um Linien zu zeichnen, die keine abrupten Änderungen des Krümmungsradius aufweisen. Sie werden in einigen wenigen Punkten fixiert und richten sich dann so aus, dass die Biegeenergie minimal wird.

Satz 6.1.3

Der $\mathcal{S}_m^\ell(\Delta)$ ist ein linearer Raum über $\mathbb{R}$ mit $\dim \mathcal{S}_m^\ell(\Delta) = n(m+1) - (\ell+1)(n-1)$.

Aufgabe 6.1.4. Beweisen Sie Satz 6.1.3! ◊

Aufgabenstellung: Interpolation mit polynomialen Splines

Gegeben seien $\ell, m \in \mathbb{N}_0$, $n \in \mathbb{N}$, eine Partitionierung $\Delta := \{\xi_j\}_{j=0}^n$, des Intervalls $[a, b]$ sowie Stützstellen $a \le x_1 < x_2 < \cdots < x_N \le b$ mit zugehörigen Stützwerten $y_1, \ldots, y_N$, $N \in \mathbb{N}$, $N \le \dim \mathcal{S}_m^\ell(\Delta)$.

Gesucht ist ein Spline $s \in \mathcal{S}_m^\ell(\Delta)$, der den Interpolationsbedingungen

$$s(x_j) = y_j, \quad j = 1, \ldots, N,$$

genügt.

Bemerkung 6.1.5. Die Aufgabe der Spline-Interpolation ist nicht in jedem Fall ad hoc wohlgestellt, wie wir später bei der Behandlung der Interpolation mit kubischen C^2-Splines, $\mathcal{S}_3^2(\Delta)$, sehen werden.

Schon vorab können wir festhalten, dass auf jedem Teilintervall $\bar{I}_j$, wobei $\bar{I}_j$ den Abschluss des Intervalls I_j beschreibt, der Partitionierung Δ maximal $m+1$ Interpolationsbedingungen vorgegeben werden können. Dies ergibt sich daraus, dass ein Polynom m-ten Grades durch die Vorgabe von Werten in $m+1$ Punkten eindeutig bestimmt ist.

6.2 Lineare C^0-Splines

Wir beginnen mit einem einfachen Beispiel: stetige Splines mit Polynomgrad 1, betrachten also $\mathcal{S}_1^0(\Delta)$. Die Dimension dieses Raumes ist $n+1$. Die Anzahl der Knoten ist ebenfalls $n+1$. Es erscheint also sinnvoll, die Knoten auch als Interpolationsstellen zu benutzen.

Aufgabenstellung: Interpolation mit linearen C^0-Splines

Gegeben sind $n+1$ Stützstellen $\Delta := \{x_j\}_{j=0}^n$, $a = x_0 < x_1 < \cdots < x_n = b$ sowie Stützwerte $y_0, y_1, \ldots, y_n \in \mathbb{R}$.

Gesucht ist ein Spline $s \in \mathcal{S}_1^0(\Delta)$, der den Interpolationsbedingungen

$$s(x_j) = y_j, \quad j = 0, \ldots, n,$$

genügt.

Geometrisch gesehen verbinden wir einfach benachbarte Punkte (x_j, y_j) und (x_{j+1}, y_{j+1}) durch gerade Linien. Es ergibt sich die Darstellung

$$s(x) = \frac{x_j - x}{h_j} y_{j-1} + \frac{x - x_{j-1}}{h_j} y_j, \quad x \in \bar{I}_j, \quad j = 1, \ldots, n.$$

Abbildung 6.1 illustriert das Vorgehen anhand der RUNGE-Funktion. Im Gegensatz zur Polynominterpolation mit gleichabständigen Stützstellen entstehen keine Oszillationen, vgl. Abbildung 4.5. Ähnlich waren wir de facto im vorhergenden Kapitel bei der Konstruktion der summierten Trapezregel vorgegangen.

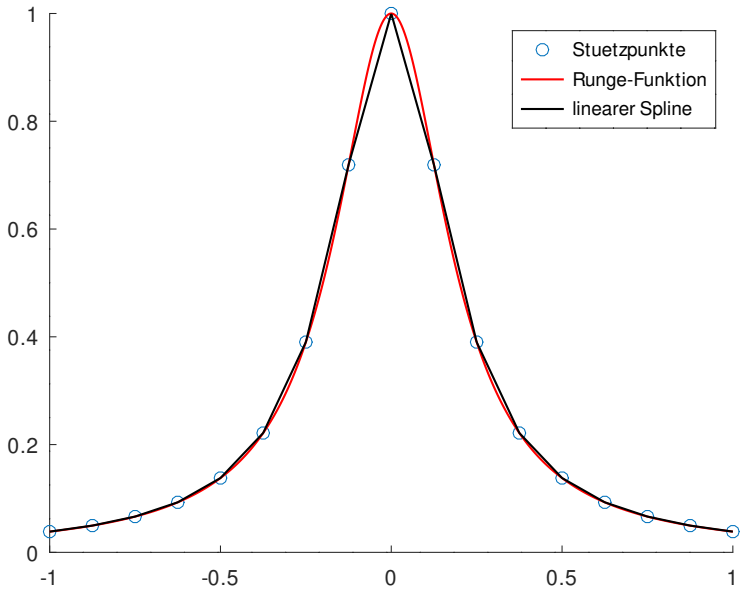


Abbildung 6.1: Interpolation mit linearen C^0-Splines für die RUNGE-Funktion, $n = 16$.

Zur Abschätzung des Interpolationsfehlers können wir auf Satz 4.5.1 zurückgreifen, da auf jedem Intervall I_j der interpolierende Spline mit einem Polynom ersten Grades übereinstimmt, das f in x_j und x_{j+1} interpoliert:

$$f(x) - s(x) = \frac{f''(\xi)}{2}\left(x - x_j\right)\left(x - x_{j+1}\right), \quad x \in \bar{I}_j,\ j = 1, \ldots, n.$$

Es ergibt sich die Abschätzung

$$\|f - s\|_{[x_{j-1}, x_j]} \leq \frac{h_j^2}{8} \|f''\|_{[x_{j-1}, x_j]}, \quad j = 1, \ldots, n.$$

Durch Bildung des Maximums über alle Intervalle erhalten wir die Aussage des folgenden Satzes.

Satz 6.2.1: Fehler der $\mathcal{S}_1^0$-Interpolation

Sei $f \in C^2[a, b]$.

Dann gilt für den Fehler der Interpolation mit linearen C^0-Splines

$$\|f - s\|_{[a,b]} \leq \frac{h^2}{8} \|f''\|_{[a,b]}.$$

Bemerkung 6.2.2. Wie bei den summierten Quadraturformeln ist bei der Spline-Interpolation von Interesse, wie sich der Fehler für $h \to 0$ verhält. Hier geht die Schrittweite h in der zweiten Potenz in die Fehlerabschätzung ein.

Aus dem Satz wird auch klar, dass uns im Gegensatz zur Polynom-Interpolation keine bösen Überraschungen erwarten, wenn wir die Partitionierung Δ verfeinern.

6.3 Kubische C^2-Splines

Die $\mathcal{S}_3^2$-Interpolation ist gewissermaßen das „klassische“ Beispiel für die Spline-Interpolation und kommt der Straklatte am nächsten. Die Knoten des Splines und die Interpolationsstellen fallen zusammen.

Aufgabenstellung: Interpolation mit kubischen C^2 Splines

Gegeben sind $n+1$ Stützstellen $\Delta := \{x_j\}_{j=0}^n$, $a = x_0 < x_1 < \cdots < x_n = b$ sowie Stützwerte $y_0, y_1, \ldots, y_n \in \mathbb{R}$.

Gesucht ist ein Spline $s \in \mathcal{S}_3^2(\Delta)$, der den Interpolationsbedingungen

$$s(x_j) = y_j, \quad j = 0, \ldots, n, \tag{6.1}$$

genügt.

Gemäß Satz 6.1.3 ist $\dim \mathcal{S}_3^2(\Delta) = 4n - (2+1)(n-1) = n+3$, wir haben aber lediglich $n+1$ Interpolationsbedingungen. Das Gleichungssystem ist also unterbestimmt und nicht eindeutig lösbar. Wir benötigen zwei weitere (sinnvolle) Bedingungen. Diese werden üblicherweise als sogenannte Randbedingungen formuliert.

Vollständige Randbedingungen: An den beiden Endpunkten werden zusätzliche die Werte y_0' bzw. y_n' für die Ableitung vorgegeben: $s'(x_0) = y_0'$ und $s'(x_n) = y_n'$.

Natürliche Randbedingungen: $s''(x_0) = s''(x_n) = 0$. Dies bedeutet, dass der Spline an den beiden Endpunkten verschwindende Biegung besitzt. Dies stellt sich bei der Straklatte physikalisch bedingt automatisch ein.

Zyklische Randbedingungen: $s'(x_0) = s'(x_n)$ und $s''(x_0) = s''(x_n)$.

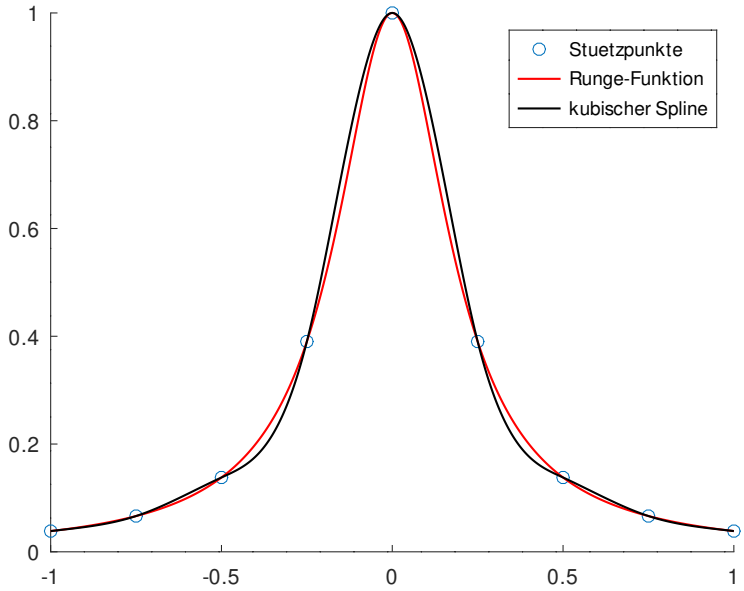


Abbildung 6.2: Interpolation mit kubischen C^2-Splines für die RUNGE-Funktion, vollständige Randbedingungen, $n = 8$.

Not-a-knot-Randbedingungen: $s|_{[x_0,x_2]} \in \Pi_3$ bzw. $s|_{[x_{n-2},x_n]} \in \Pi_3$. Auf den beiden Intervallen I_1 und I_2 wird das gleiche Polynom verwendet, d. h. x_1 ist eigentlich kein Knoten der Partitionierung Δ. Daher rührt auch der Name der Randbedingung.

Abbildung 6.2 zeigt beispielhaft einen kubischen C^2-Spline, der die Runge-Funktion auf einer gleichabständigen Partitionierung interpoliert.

6.3.1 Konstruktion und Berechnung

Auf jedem Teilintervall I_j ist der Spline ein Polynom 3. Grades, wir bezeichnen dieses mit s_j:

$$s|_{[x_{j-1},x_j]} = s_j \in \Pi_3, \quad j = 1, \dots, n.$$

Aus den Interpolationsbedingungen folgt unmittelbar

$$s_j(x_{j-1}) = y_{j-1} \quad \text{und} \quad s_j(x_j) = y_j, \quad j = 1, \dots, n.$$

Damit sind auf jedem Teilintervall der Partitionierung zwei der vier Freiheitsgrade zur Beschreibung eines kubischen Polynoms fixiert. Desweiteren verwenden wir die Werte der zweiten Ableitung in den Knoten:

$$s''(x_j) = m_j, \quad j = 0, \dots, n. \tag{6.2}$$

Die m_j werden auch als die **Momente des Splines** bezeichnet. Für die Beschreibung des Polynoms s_j bedeutet dies

$$s_j''(x_{j-1}) = m_{j-1} \quad \text{und} \quad s_j''(x_j) = m_j, \quad j = 1, \dots, n.$$

Durch die Gleichungen (6.1) und (6.2) ist sichergestellt, dass der Spline die Interpolationsbedingungen erfüllt, stetig ist und auch seine zweite Ableitung stetig ist. Dabei sind die m_j noch nicht bekannt und müssen erst noch berechnet werden. Die bestimmenden Gleichungen hierfür erhalten wir im Folgenden aus der Forderung, dass die erste Ableitung von C^2-Splines ebenfalls stetig ist.

Wir arbeiten uns durch die Details. Aus (6.2) und $s_j'' \in \Pi_1$ folgt

$$s_j''(x) = \frac{x_j - x}{h_j} m_{j-1} + \frac{x - x_{j-1}}{h_j} m_j, \quad x \in \bar{I}_j, \quad j = 1, \dots, n.$$

Wir integrieren zweimal:

$$s_j'(x) = -\frac{(x_j - x)^2}{2h_j} m_{j-1} + \frac{(x - x_{j-1})^2}{2h_j} m_j + \gamma_j, \quad x \in \bar{I}_j, \quad j = 1, \dots, n,$$

und

$$s_j(x) = \frac{(x_j - x)^3}{6h_j} m_{j-1} + \frac{(x - x_{j-1})^3}{6h_j} m_j + \alpha_j(x_j - x) + \beta_j(x - x_{j-1}), \quad x \in \bar{I}_j, \quad j = 1, \dots, n.$$

Die α_j, β_j und γ_j werden unter Berücksichtigung der Interpolationsbedingungen ermittelt:

$$s_j(x_{j-1}) = \frac{h_j^2 m_{j-1}}{6} + \alpha_j h_j = y_{j-1}$$

bzw.

$$s_j(x_j) = \frac{h_j^2 m_j}{6} + \beta_j h_j = y_j, \quad j = 1, \ldots, n.$$

Es folgt

$$\alpha_j = \frac{y_{j-1}}{h_j} - \frac{h_j m_{j-1}}{6}, \quad \beta_j = \frac{y_j}{h_j} - \frac{h_j m_j}{6} \text{ und } \gamma_j = \frac{y_j - y_{j-1}}{h_j} - \frac{h_j(m_j - m_{j-1})}{6}, \quad j = 1, \ldots, n.$$

Für die Ableitungswerte in den Knoten folgt

$$s_j'(x_{j-1}) = -\frac{h_j}{2} m_{j-1} + \gamma_j \quad \text{sowie} \quad s_j'(x_j) = \frac{h_j}{2} m_j + \gamma_j, \quad j = 1, \ldots, n. \tag{6.3}$$

Die Ableitung s' des Splines ist nun genau dann stetig wenn

$$s_j'(x_j) = s_{j+1}'(x_j), \quad j = 1, \ldots, n-1,$$

Was uns auf die Gleichungen

$$\frac{h_j}{6} m_{j-1} + \frac{h_j + h_{j+1}}{3} m_j + \frac{h_{j+1}}{6} m_{j+1} = \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{y_j - y_{j-1}}{h_j}, \quad j = 1, \ldots, n-1,$$

führt. Wir erinnern uns an die Definition der dividierten Differenzen (vgl. Satz 4.3.7) und schreiben die letzten Gleichungen als

$$\frac{h_j}{6} m_{j-1} + \frac{h_j + h_{j+1}}{3} m_j + \frac{h_{j+1}}{6} m_{j+1} = (h_j + h_{j+1})\, y[x_{j-1}, x_j, x_{j+1}], \quad j = 1, \ldots, n-1. \tag{6.4}$$

Natürliche Randbedingungen. Die Vorgabe $s''(x_0) = s''(x_n) = 0$ impliziert $m_0 = m_n = 0$, und wir können beide Größen aus dem Gleichungssystem eliminieren. Wir erhalten ein lineares Gleichungssystem $\boldsymbol{A}\boldsymbol{m} = \boldsymbol{b}$ für die Unbekannten $\boldsymbol{m} := (m_1, m_2, \ldots, m_{n-1})^T \in \mathbb{R}^{n-1}$ mit Matrix

$$\boldsymbol{A} := \begin{pmatrix} \frac{h_1 + h_2}{3} & \frac{h_2}{6} & & & 0 \\ \frac{h_2}{6} & \frac{h_2 + h_3}{3} & \frac{h_3}{6} & & \\ & \ddots & \ddots & \ddots & \\ & & \frac{h_{n-2}}{6} & \frac{h_{n-2} + h_{n-1}}{3} & \frac{h_{n-1}}{6} \\ 0 & & & \frac{h_{n-1}}{6} & \frac{h_{n-1} + h_n}{3} \end{pmatrix} \in \mathbb{R}^{n-1,n-1}$$

und rechter Seite

$$\boldsymbol{b} := \begin{pmatrix} (h_1 + h_2)\, y[x_0, x_1, x_2] \\ (h_2 + h_3)\, y[x_1, x_2, x_3] \\ \vdots \\ (h_{n-2} + h_{n-1})\, y[x_{n-3}, x_{n-2}, x_{n-1}] \\ (h_{n-1} + h_n)\, y[x_{n-2}, x_{n-1}, x_n] \end{pmatrix} \in \mathbb{R}^{n-1}$$

Die Matrix $\boldsymbol{A}$ besitzt drei schöne Eigenschaften: Sie ist symmetrisch, tridiagonal und **diagonaldominant**. Warum dies nützlich ist, werden wir gleich sehen.

Vollständige Randbedingungen. Die Vorgabe der Ableitungswerte $s'(x_0) = y'_0$ bzw. $s'(x_n) = y'_n$, sowie (6.3) ergeben die beiden Gleichungen (Beachten Sie Abschnitt 4.6 für die Definition der dividierten Differenzen!)

$$\frac{h_1}{3} m_0 + \frac{h_1}{6} m_1 = \frac{y_1 - y_0}{h_1} - y'_0 = y[x_0, x_1] - y[x_0, x_0] = h_1\, y[x_0, x_0, x_1]$$

und

$$\frac{h_n}{6} m_{n-1} + \frac{h_n}{3} m_n = y'_n - \frac{y_n - y_{n-1}}{h_n} = y[x_n, x_n] - y[x_{n-1}, x_n] = h_n\, y[x_{n-1}, x_n, x_n]\,.$$

Zusammen mit den Gleichungen (6.4) für die inneren Knoten erhalten wir wiederum ein lineares Gleichungssystem $\boldsymbol{A}\boldsymbol{m} = \boldsymbol{b}$, diesmal für $\boldsymbol{m} := (m_0, m_1, \ldots, m_n)^T \in \mathbb{R}^{n+1}$ mit der Matrix

$$\boldsymbol{A} := \begin{pmatrix} \frac{h_1}{3} & \frac{h_1}{6} & & & & 0 \\ \frac{h_1}{6} & \frac{h_1 + h_2}{3} & \frac{h_2}{6} & & & \\ & \frac{h_2}{6} & \frac{h_2 + h_3}{3} & \frac{h_3}{6} & & \\ & & \ddots & \ddots & \ddots & \\ & & & \frac{h_{n-1}}{6} & \frac{h_{n-1} + h_n}{3} & \frac{h_n}{6} \\ 0 & & & & \frac{h_n}{6} & \frac{h_n}{3} \end{pmatrix} \in \mathbb{R}^{n+1,n+1}$$

und der rechten Seite

$$\boldsymbol{b} := \begin{pmatrix} h_1\, y[x_0, x_0, x_1] \\ (h_1 + h_2)\, y[x_0, x_1, x_2] \\ (h_2 + h_3)\, y[x_1, x_2, x_3] \\ \vdots \\ (h_{n-1} + h_n)\, y[x_{n-2}, x_{n-1}, x_n] \\ h_n\, y[x_{n-1}, x_n, x_n] \end{pmatrix} \in \mathbb{R}^{n+1}$$

Wiederum ist die Matrix $\boldsymbol{A}$ symmetrisch, tridiagonal und **diagonaldominant**.

6.3.2 Lösung tridiagonaler Gleichungssysteme

Die bei der obigen Konstruktion kubischer Splines zu lösenden Gleichungssysteme haben eine Systemmatrix, die Tridiagonalgestalt besitzt und diagonaldominant ist.

Definition 6.3.1: Diagonaldominanz

Eine Matrix $\boldsymbol{A} = (a_{i,j}) \in \mathbb{C}^{m,m}$ wird als **diagonaldominant** bezeichnet, falls

$$|a_{i,i}| > \sum_{j=1,\, j\neq i}^{m} |a_{i,j}| \quad \forall\, i = 1, \ldots, m,$$

Satz 6.3.2

Jede diagonaldominante Matrix ist invertierbar.

Aufgabe 6.3.3. Beweisen Sie Satz 6.3.2!

Hinweis: $\boldsymbol{A} \in \mathbb{C}^{m,m}$ ist genau dann invertierbar, wenn $\boldsymbol{Ax} = \boldsymbol{0}$ nur die triviale Lösung besitzt. ◊

Definition 6.3.4: Tridiagonalmatrix

Eine Matrix $\boldsymbol{A} = (a_{i,j}) \in \mathbb{C}^{n,n}$ heißt **Tridiagonalmatrix** genau dann wenn

$$a_{i,j} = 0, \quad \forall\, |i-j| > 1,\ i, j = 1, \ldots, n.$$

Seien $\boldsymbol{e}, \boldsymbol{d}, \boldsymbol{f} \in \mathbb{C}^n$, dann setzen wir

$$\operatorname{tridiag}(\boldsymbol{e}, \boldsymbol{d}, \boldsymbol{f}) := \begin{pmatrix} d_1 & f_1 & & & 0 \\ e_2 & d_2 & f_2 & & \\ & \ddots & \ddots & \ddots & \\ & & e_{n-1} & d_{n-1} & f_{n-1} \\ 0 & & & e_n & d_n \end{pmatrix}$$

Für tridiagonale Gleichungssysteme kann das Gausssche Eliminationsverfahren unter Beachtung der vielen Nullen vereinfacht werden. Zunächst wird die erste Gleichung nach x_1 umgestellt und in die zweite eingesetzt und somit aus ihr eliminiert. Die übrigen Gleichungen müssen nicht modifiziert werden, da x_1 nicht in ihnen vorkommt. Anschließend wird die zweite Gleichung nach x_2 umgestellt und in die dritte eingesetzt, etc. In der Folge erhalten wir ein lineares Gleichungssystem, bei dem nur die Hauptdiagonale und die erste obere Nebendiagonale besetzt ist, d. h. die von Null verschiedene Einträge haben. Dies können wird mit x_n beginnend einfach auflösen. Dies ist die sog. Rücksubstitution.

Algorithmus 6.3.5: THOMAS[1]-Algorithmus

Gegeben: Eine Matrix $\boldsymbol{A} = \text{tridiag}\,(\boldsymbol{e}, \boldsymbol{d}, \boldsymbol{f}) \in \mathbb{C}^{n,n}$ und ein Vektor $\boldsymbol{b} \in \mathbb{C}^n$.

S1. **Elimination**

FOR $i = 2, \ldots, n$ DO
$\ell := e_i / d_{i-1}$
$d_i := d_i - \ell \cdot f_{i-1}$
$b_i := b_i - \ell \cdot b_{i-1}$
END DO

S2. **Rückwärtsersetzung**

$x_n := b_n / d_n$
FOR $i = n-1, n-2, \ldots, 1$ DO
$x_i := (b_i - f_i \cdot x_{i+1}) / d_i$
END DO

Ergebnis: Der Vektor $\boldsymbol{x} = (x_1, \ldots, x_n)^T$ löst das Gleichungssystem $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$.

Bemerkung 6.3.6. Es ist leicht nachzuzählen, dass der Aufwand des THOMAS-Algorithmus proportional zur Anzahl n der Unbekannten x_i ist. In solchen Fällen sprechen wir davon, dass der Algorithmus **optimal** ist, oder optimale Komplexität besitzt: Bis auf eine multiplikative Konstante ist er so aufwändig wie das reine Aufschreiben/Abspeichern der Lösung.

Bemerkung 6.3.7. Die Diagonaldominanz der Matrix $\boldsymbol{A}$ sichert zunächst nur die Existenz einer eindeutigen Lösung des Gleichungssystems, aber nicht ohne weitere Überlegungen auch die Durchführbarkeit des THOMAS-Algorithmus. So muss gezeigt werden, dass bei der Bestimmung der Eliminationsfaktoren ℓ nicht durch Null diviert wird.

Dass dies aus der Diagonaldominanz folgt, kann bewiesen werden, z. B. in der Lehrveranstaltung *Numerik der Linearen Algebra* (Modul 61522).

6.3.3 Interpolationsfehler

Wie bei der Polynominterpolation sind wir an Aussagen über den Fehler der Splineinterpolation interessiert. Exemplarisch betrachten wir den Fall vollständiger Randbedingungen und gehen davon aus, dass die Stützwerte als Funktionswerte einer viermal stetig differenzierbaren Funktion f an den Stützstellen vorliegen, d. h.

$$y_j = f(x_j), \quad j = 0, \ldots, n, \quad y'_0 = f'(x_0), \quad y'_n = f'(x_n).$$

Die wesentliche Schwierigkeit ist dabei, den Fehler für die zweite Ableitung abzuschätzen. Insbesondere interessiert die Frage, wie gut m_i die Ableitung f'' im Knoten x_i approximiert – also eine Aussage über $|m_i - f''(x_i)|$.

Haben wir erst einmal eine Abschätzung für $\|s'' - f''\|_{[a,b]}$, dann können $s' - f'$ und $s - f$ relativ einfach untersucht werden:

[1] Llewellyn Hilleth Thomas, *21.10.1903 (London, England), †20.4.1992 (Raleigh, North Carolina, USA)

- Der Spline s interpoliert f an den Knoten, insbesondere ist $(f-s)(x_j) = (f-s)(x_{j+1}) = 0$, $j = 1, \dots, n$. Der Satz von Rolle impliziert für jedes Teilintervall die Existenz eines $\eta_j \in (x_j, x_{j+1})$ mit $(f-s)'(\eta_j) = 0$. Also gilt für alle $x \in [x_j, x_{j+1}]$

$$(f-s)'(x) = \int_{\eta_j}^{x} (f-s)''(\sigma)\,\mathrm{d}\sigma.$$

  Wir schätzen ab:

$$\left|(f-s)'(x)\right| \le \left|\eta_j - x\right| \|(f-s)''\|_{[x_j,x_{j+1}]} \le h\,\|(f-s)''\|_{[a,b]}\,.$$

- Da $(f-s)(x_j) = 0$, gilt für alle $x \in [x_j, (x_j + x_{j+1})/2]$

$$(f-s)(x) = \int_{x_j}^{x} (f-s)'(\sigma)\,\mathrm{d}\sigma, \quad \text{für } x \in [x_j, (x_j + x_{j+1})/2].$$

  (Ist $x \in [(x_j + x_{j+1})/2, x_{j+1}]$, dann integrieren wir stattdessen von x_{j+1} bis x.) Es folgt wie oben

$$\left|(f-s)(x)\right| \le \left|x_j - x\right| \left\|(f-s)'\right\|_{[x_j,x_{j+1}]} \le \frac{h}{2}\,\|(f-s)'\|_{[a,b]} \le \frac{h^2}{2}\,\|(f-s)''\|_{[a,b]}\,.$$

Unsere Ergebnisse fassen wir im folgenden Satz zusammenfassen. Wobei wir die Abschätzung für $k = 2$ erst noch erbringen müssen.

Satz 6.3.8

Sei $f \in C^4[a,b]$. Dann gelten für den Fehler der Interpolation mit kubischen C^2-Splines die Abschätzungen

$$\left\|s^{(k)} - f^{(k)}\right\|_{[a,b]} \le C_k\, h^{4-k} \left\|f^{(4)}\right\|_{[a,b]}\,, \quad k = 0, 1, 2, \tag{6.5}$$

mit den Konstanten $C_1 = C_2 = 13/8$ und $C_0 = C_2/2$.

Der Approximationsfehler für die zweite Ableitung

Sei zunächst $q \in \mathcal{S}_1^0(\Delta)$ jener eindeutig definierte Spline, der f'' in den Knoten interpoliert, d. h.

$$q(x_j) = f''(x_j), \quad j = 0, \dots, n, \qquad \text{vgl. Abschnitt 6.2.}$$

Dann folgt mit der Dreiecksungleichung

$$\|(f-s)''\|_{[a,b]} \le \|f'' - q\|_{[a,b]} + \|q - s''\|_{[a,b]}\,.$$

Den ersten Term auf der rechten Seite können wir mit Satz 6.2.1 abschätzen. Bei dem zweiten machen wir uns zunutze, dass $q - s''$ als stückweise lineare Funktion ihre Extrema in den Knoten annimmt. Wir erhalten

$$\|(f-s)''\|_{[a,b]} \le \frac{h^2}{8} \left\|f^{(4)}\right\|_{[a,b]} + \max_{j=0,\dots,n} \left|f''(x_j) - s''(x_j)\right|\,. \tag{6.6}$$

Wir schreiben das im Abschnitt 6.3.1 hergeleitete Gleichungssystem geringfügig um, indem wir durch $(h_j + h_{j+1})$ dividieren. Ferner setzen wir

$$\alpha_j := \begin{cases} 0, & \text{für } j = 0, \\ \dfrac{h_j}{h_j + h_{j+1}}, & \text{für } j = 1, \dots, n-1, \text{ und} \\ 1, & \text{für } j = n, \end{cases}$$

und definieren zwei lineare Abbildungen $M\colon \mathbb{R}^{n+1} \to \mathbb{R}^{n+1}$ (das ist de facto eine Matrix) und $\Phi\colon C^1[a,b] \to \mathbb{R}^{n+1}$ gemäß

$$(Mv)_j := \begin{cases} \dfrac{v_0}{3} + \dfrac{(1-\alpha_0)\, v_1}{6}, & j = 0, \\ \dfrac{\alpha_j\, v_{j-1}}{6} + \dfrac{v_j}{3} + \dfrac{(1-\alpha_j)\, v_{j+1}}{6}, & j = 1, \dots, n-1, \\ \dfrac{\alpha_n\, v_{n-1}}{6} + \dfrac{v_n}{3}, & j = n. \end{cases}$$

bzw.

$$(\Phi g)_j := \begin{cases} g[x_0, x_0, x_1], & j = 0, \\ g[x_{j-1}, x_j, x_{j+1}], & j = 1, \dots, n-1, \\ g[x_{n-1}, x_n, x_n], & j = n. \end{cases}$$

Mit dieser Notation erhalten wir für die Interpolation mit kubischen C^2-Splines mit vollständigen Randbedingungen das Gleichungssystem

$$(Mm)_j = (\Phi f)_j, \quad j = 0, 1, \dots, n.$$

Für den Approximationsfehler der zweiten Ableitung ergibt sich

$$(M(m - f''))_j = (\Phi f)_j - (Mf'')_j, \quad j = 0, 1, \dots, n. \tag{6.7}$$

Die rechte Seite können wir mittels Taylor-Entwicklungen abschätzen, während mit Hilfe der folgenden Aussage dann von $|M(m - f'')|$ auf $|m - f''|$ geschlossen wird.

Aussage 6.3.9

Für alle $v \in \mathbb{R}^{n+1}$ gilt:

$$\max_{j=0,1\dots,n} |v_j| \le 6 \max_{j=0,1,\dots,n} |(Mv)_j| .$$

Aufgabe 6.3.10. Beweisen Sie Auss. 6.3.9 mit Hilfe des Störungslemmas, Satz 2.1.20! ◊

Angewandt auf (6.7) ergibt sich die Abschätzung

$$\max_{j=0,\dots,n} |m_j - f_j''| \le 6 \max_{j=0,\dots,n} |(\Phi f)_j - (Mf'')_j| . \tag{6.8}$$

Für die rechte Seite können mit Hilfe der Taylor-Entwicklung die folgenden Schranken hergeleitet werden.

Aussage 6.3.11

Sei $f \in C^4[a,b]$. Dann gilt

$$\left|(\Phi f)_j - (Mf'')_j\right| \le \frac{h_j^2 + h_{j+1}^2}{8} \left\|f^{(4)}\right\|_{[x_{j-1},x_{j+1}]}, \quad j = 0,\dots,n,$$

wobei wir formal $x_{-1} := x_0$, $x_{n+1} := x_n$ und $h_0 := h_{n+1} := 0$ setzen.

Zusammen mit (6.8) erhalten wir hieraus

$$\max_{j=0,\dots,n} \left|m_j - f_j''\right| \le \frac{3}{2} h^2 \left\|f^{(4)}\right\|_{[a,b]}.$$

Unter Beachtung von $m_j = s''(x_j)$ und (6.6) erhalten wir die Aussage von Satz 6.3.8 für die zweite Ableitung.

Aufgabe 6.3.12. Beweisen Sie Auss. 6.3.11! Zeigen Sie zunächst: Für alle $j \in \{0,1,\dots,n\}$ existieren $\xi^-, \eta^- \in [x_{j-1}, x_j]$ und $\xi^+, \eta^+ \in [x_j, x_{j+1}]$ derart, dass

$$(\Phi f)_j = \frac{f_j''}{2} + \frac{h_{j+1} - h_j}{6} f_j''' + \frac{1}{24(h_j + h_{j+1})} \left(h_{j+1}^3 f^{(4)}(\xi^+) + h_j^3 f^{(4)}(\xi^-)\right)$$

und

$$(Mf'')_j = \frac{f_j''}{2} + \frac{h_{j+1} - h_j}{6} f_j''' + \frac{1}{12(h_j + h_{j+1})} \left(h_{j+1}^3 f^{(4)}(\eta^+) + h_j^3 f^{(4)}(\eta^-)\right),$$

Folgern Sie anschließend Auss. 6.3.11. ◊

6.3.4 Minimaleigenschaft von $\mathcal{S}_3^2$-Splines

Unter vereinfachenden Annahmen beschreibt das sog. Holladay[2]-Funktional,

$$g \in C^2[a,b] \mapsto H[g] := \int_a^b g''(x)^2 \,\mathrm{d}x,$$

die in einem geraden dünnen Stab gespeicherte Energie, wenn er in die durch die Kurve $(x, g(x))$, $x \in [a,b]$, vorgegebene Lage gebracht wird.

Seien $a = x_0 < x_1 < \cdots < x_n = b$ eine Knotenfolge und $y_j \in \mathbb{R}$, $j = 0,\dots,n$ fest. Wir definieren

$$C_\Delta^2[a,b] := \left\{g \in C^2[a,b] \colon g(x_j) = y_j, \quad j = 0,1,\dots,n\right\}.$$

Sind $f \in C_\Delta^2[a,b]$ und $s \in C_\Delta^2[a,b] \cap \mathcal{S}_3^2(\Delta)$ beliebig, dann gilt (Übungsaufgabe)

$$H[f] = H[s] + H[f-s] + 2\,(f' - s')s''\Big|_a^b \tag{6.9}$$

[2] John C. Holladay, *1928 (Cleveland, Ohio, USA), †22.12.1986 (Irvine, California, USA)

Da $H[v] \geq 0$ für alle $v \in C^2[a,b]$, ist

$$H\left[f\right] \geq H\left[s\right] + 2\left(f' - s'\right)s''\Big|_a^b,$$

wobei Gleichheit für $f \equiv s$ gilt.

Hieraus lassen sich die folgenden drei Minimierungseigenschaften ableiten.

- Für den Spline $\hat{s}$ mit natürlichen Randbedingungen $\hat{s}''(a) = \hat{s}''(b) = 0$ gilt

$$H[\hat{s}] \leq H[f], \quad \forall\, f \in C^2_\Delta[a,b].$$

- Sind $y'_0, y'_n \in \mathbb{R}$ gebeben, dann gilt für den Spline $\bar{s}$ mit vollständigen Randbedingungen $\bar{s}'(a) = y'_0$ und $\bar{s}'(b) = y'_n$

$$H[\bar{s}] \leq H[f], \quad \forall\, f \in \left\{v \in C^2_\Delta[a,b] \colon v(a) = y'_0,\ v(b) = y'_n\right\}$$

- Für den Spline $\tilde{s}$ mit periodischen Randbedingungen $\tilde{s}'(a) = \tilde{s}'(b)$ und $\tilde{s}''(a) = \tilde{s}''(b)$ gilt

$$H[\tilde{s}] \leq H[f], \quad \forall\, f \in \left\{v \in C^2_\Delta[a,b] \colon v'(a) = v'(b)\right\}$$

Aufgabe 6.3.13. Beweisen Sie (6.9)! ◊

6.4 Lösungen der Aufgaben

Lösung 6.1.4. Auf jedem der n Teilintervalle ist der Spline ein Polynom vom Grad m. Es ergeben sich $n(m+1)$ Freiheitsgrade zum Beschreiben des Splines.

In den $n-1$ inneren Knoten $\xi_1, \dots, \xi_{n-1}$ sind die Funktion sowie ihre ersten ℓ Ableitungen stetig. Dies ergibt $(\ell+1)(n-1)$ Bedingungen, die vom Spline erfüllt werden müssen. Also ergibt sich $\dim \mathcal{S}_m^\ell(\Delta) = n(m+1) - (\ell+1)(n-1)$. ♣

Lösung 6.3.3. Sei $\boldsymbol{A} \in \mathbb{C}^{m,m}$ diagonaldominant. Angenommen, es gibt eine nichttriviale Lösung $\boldsymbol{x} \neq \boldsymbol{0}$ von $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$. Dann existiert ein $k \in \{1, \dots, m\}$ mit $|x_k| = \|\boldsymbol{x}\|_\infty > 0$. Es folgt aus der k-ten Gleichung des Gleichungssystems:

$$a_{k,k} x_k = - \sum_{i=1,\, i\neq k}^{m} a_{k,j} x_j .$$

Die Dreiecksungleichung impliziert, dass

$$\left|a_{k,k}\right| |x_k| \leq \sum_{i=1,\, i\neq k} \left|a_{k,j}\right| \left|x_j\right| \leq \sum_{i=1,\, i\neq k} \left|a_{k,j}\right| |x_k| .$$

Hieraus folgt, da $|x_k| > 0$,

$$\left|a_{k,k}\right| \leq \sum_{i=1,\, i\neq k} \left|a_{k,j}\right| ,$$

was im Widerspruch zur Diagonaldominanz von $\boldsymbol{A}$ steht. ♣

Lösung 6.3.10. Es gilt $\boldsymbol{v} = \boldsymbol{M}^{-1}\boldsymbol{M}\boldsymbol{v}$ und somit

$$\|\boldsymbol{v}\|_\infty \leq \left\|\boldsymbol{M}^{-1}\right\|_\infty \|\boldsymbol{M}\boldsymbol{v}\|_\infty .$$

Die Matrix $\boldsymbol{M}$ stellen wir als Summe zweier Matrizen dar:

$$\boldsymbol{M} = \boldsymbol{D} + \boldsymbol{\Delta}_{\boldsymbol{D}}, \quad \text{wobei} \quad \boldsymbol{D} = \tfrac{1}{3}\boldsymbol{I} .$$

Es ist $\|\boldsymbol{D}\|_\infty = 1/3$, $\|\boldsymbol{\Delta}_{\boldsymbol{D}}\|_\infty = 1/6$ und $\left\|\boldsymbol{D}^{-1}\right\|_\infty = 3$.
Das Störungslemmas, Satz 2.1.20 impliziert die Abschätzung

$$\left\|\boldsymbol{M}^{-1}\right\|_\infty = \left\|(\boldsymbol{D} + \boldsymbol{\Delta}_{\boldsymbol{D}})^{-1}\right\|_\infty \leq \frac{\left\|\boldsymbol{D}^{-1}\right\|_\infty}{1 - \left\|\boldsymbol{D}^{-1}\right\|_\infty \|\boldsymbol{\Delta}_{\boldsymbol{D}}\|_\infty} = \frac{3}{1 - 3\frac{1}{6}} = 6 .$$

♣

Lösung 6.3.12. Dies ist eine Einsendeaufgabe. ♣

Lösung 6.3.13. Es gilt $(f'')^2 = (s'')^2 + (f'' - s'')^2 + 2\,(f-s)''\,s''$. Den letzen Term behandeln wir mit partieller Integration:

$$\begin{aligned}
&\int_a^b (f-s)''(x) s''(x)\,\mathrm{d}x \\
&\quad = (f-s)'(x) s''(x)\Big|_{x=a}^b - \int_a^b (f-s)'(x) s'''(x)\,\mathrm{d}x \\
&\quad = (f-s)'(x) s''(x)\Big|_{x=a}^b - \sum_{j=1}^n \int_{x_{j-1}}^{x_j} (f-s)'(x) s'''(x)\,\mathrm{d}x \\
&\quad = (f-s)'(x) s''(x)\Big|_{x=a}^b - \sum_{j=1}^n \left\{ (f-s)(x) s'''(x)\Big|_{x_{j-1}}^{x_j} - \int_{x_{j-1}}^{x_j} (f-s)(x) s^{(4)}(x)\,\mathrm{d}x \right\} \\
&\quad = (f-s)'(x) s''(x)\Big|_{x=a}^b ,
\end{aligned}$$

da $f - s = 0$ in den Knoten, und $s^{(4)} \equiv 0$ auf jedem Teilintervall. Es folgt (6.9). ♣

Literaturverzeichnis

[AG11] U. M. Ascher and Ch. Greif. *A first course in numerical methods*. SIAM, Society for Industial and Applied Mathematics, Philadelphia, PA, 2011.

[FH07] R. W. Freund and R. H. W. Hoppe. *Stoer/Bulirsch: Numerische Mathematik 1, 10. überarb. Aufl.* Springer, Berlin, 2007.

[HB09] M. Hanke-Bourgeois. *Grundlagen der numerischen Mathematik und des wissenschaftlichen Rechnens, 3. überarb. Aufl.* Vieweg+Teubner, Wiesbaden, 2009.

[Her26] . Hermann. *Numerische Mathematik, 5. Aufl., Bd. 1+2.* De Gruyter Studium, 2026.

[Pla06] R. Plato. *Numerische Mathematik kompakt. Grundlagenwissen für Studium und Praxis, 3. überarb. Aufl.* Vieweg, Wiesbaden, 2006.

[SK11] H.-R. Schwarz and N. Köckler. *Numerische Mathematik, 8. Aufl.* Vieweg+Teubner, Wiesbaden, 2011.

[SW05] R. Schaback and H. Wendland. *Numerische Mathematik, 5. Aufl.* Springer-Lehrbuch. Springer-Verlag, Berlin, 2005.